


9 Probabilità Condizionata e Alberi	18
9.1 Rappresentazione ad Albero	18
10 Probabilità Totale e Teorema di Bayes	19
10.1 Sistema di Alternativi e Probabilità Totale	19
10.2 Teorema di Bayes	20
11 Eventi Indipendenti	21
11.1 Indipendenza per più di due eventi	21
11.2 Schema di Bernoulli	22
12 Variabili Aleatorie: Definizioni Fondamentali	23
13 Variabili Aleatorie Discrete e Funzioni di Massa	24
13.1 Interpretazione Frequentista	24
14 Variabili Aleatorie Discrete Notevoli	25
14.1 Schema di Bernoulli e V.A. Binomiale	25
14.2 V.A. Geometrica	26
14.3 V.A. di Poisson	26
15 Variabili Aleatorie con Densità (Continue)	27
16 V.A. con Densità Notevoli	27
16.1 Variabile Uniforme	27
16.2 Variabile Esponenziale	28
17 Funzione di Ripartizione (F.d.R.) e Quantili	29
17.1 Quantili e Formula di Cambio Variabile	29
18 Variabili Gaussiane (Normali)	30
18.1 Gaussiana Generale	30

1 Introduzione: Le tre parti del corso

Il corso si divide concettualmente in tre rami fondamentali, che rispondono a domande diverse:

- 1. Statistica Descrittiva:** Analisi dei dati del campione, senza trarne conclusioni sull'intera popolazione. *Esempio:* Calcolare l'altezza media sul campione di 10 italiani.
- 2. Probabilità:** Data la distribuzione teorica della popolazione, si calcola la probabilità di ottenere un certo campione. *Esempio:* Data una moneta con probabilità di testa p , su 10 lanci qual è la probabilità di ottenere 3 teste?
- 3. Statistica Inferenziale:** Dato un campione, si ricavano informazioni (inferenze) sulla popolazione. *Esempio:* Se otteniamo 3 teste su 10 lanci, che cosa possiamo dire della probabilità reale p della moneta?



- **Unimodale / Bimodale:** Si concentra attorno a una o due colonne più alte. Nel caso simmetrico bimodale, $Media = Mediana$, ma differiscono dalle due mode.

- **Asimmetrica (Skewed)** a destra/sinistra:

- **Asimmetrica a destra (caso standard):** I dati si allungano verso destra. Generalmente si ha $Moda < Mediana < Media$. Ad esempio, con frequenze $1(2/20), 2(7/20), 3(4/20), 4(3/20), 5(2/20), 6(2/20)$, abbiamo $Moda=2, Mediana=3, Media=3.3$.
- **Attenzione - Esempio controintuitivo:** Non vale per tutti i casi unimodali asimmetrici a destra. Se i dati sono $1(20/100), 2(25/100), 3(40/100), 4(11/100), 5(1/100), 6(1/100)$ la forma ha coda a destra, ma si ottiene $Moda=3, Mediana=3, Media=2.74$ ($Media < Moda$).

3 Indici Statistici

3.1 Indici di Centralità

Indicano il "centro" della distribuzione.

- **Media campionaria ($\bar{x}$):** Media aritmetica dei dati.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \sum_{j=1}^M a_j p(a_j) \quad \begin{matrix} Q_j = \text{FREQ. MODALITÀ} \\ P(a_j) = \text{FREQ. REL.} (3) \\ (\text{QUANTE VOLTE APPARE}) \end{matrix}$$

Esempio redditi (in migliaia di): 25, 32, 41, 19, 47, 35, 51, 32, 29, 500. La media è $\bar{x} = 81.1$. Nota del prof: La media è molto sensibile ai valori estremi (outliers).

- **Mediana campionaria:** Ordinando i dati in senso crescente, è il valore centrale.
 - Se n dispari: dato in posizione $\frac{n+1}{2}$. QUINDI $x(\frac{n+1}{2})$, ESISTE IL VALORE CENTRALE (UNICO).
 - Se n pari: media dei due dati centrali $\frac{1}{2}(x(\frac{n}{2}) + x(\frac{n}{2}+1))$.

Esempio redditi ordinati: 19, 25, 29, 32, 32, 35, 41, 47, 51, 500. Mediana = $(32 + 35)/2 = 33.5$. Nota del prof: La mediana "non vede le modalità del gruppo più grande", è molto più robusta.

- **Media sfrondata (Trimmed mean):** Ottenuta togliendo una frazione q dei dati più grandi e più piccoli, calcolando la media sui rimanenti. *Esempio del prof:* La "media olimpica" (si tolgono i voti più alti e più bassi) o il "prezzo giusto in appalti".

3.2 Indici di Dispersione

Indicano quanto i dati sono dispersi attorno al valore centrale. *Esempio del prof:* I dati $X = (1, 2, 3)$ e i dati $Y = (-10, 2, 14)$ hanno entrambi media 2, ma Y è visibilmente molto più disperso.

- **Varianza campionaria ($Var(x)$):**

USATA PER UN CAMPIONE INVECE CHE PER UNA POPOLAZIONE, IL "..."

$$Var(x) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (4)$$

$$4 \quad Var(x) = 0 \quad \text{se } x_i \text{ TUTTI UGUALI } (= \bar{x})$$




Figura 1: Diagramma a barre per i dati del dado: 6, 2, 3, 1, 2, 5, 6, 5, 5, 1. L'etichetta sopra le barre indica la frazione (frequenza relativa).

2.2 Caratteri Continui e Istogramma

Per un **carattere continuo** (es. altezza, temperatura in Kelvin), che può assumere un grande numero di modalità in un intervallo, la **frequenza relativa della singola modalità è troppo bassa**. Si **raggruppano i dati in intervalli** e si usa l'**istogramma**.

Nell'istogramma, è l'**area** (non l'altezza) a rappresentare la **frequenza relativa**. L'altezza rappresenta la **densità di frequenza**:

USIAMO L'AREA PER POTER TENERE CONTO DELLA GRANDEZZA DELL'INTERVALLO

$$\text{Densità di freq.} = \frac{\text{Frequenza relativa}}{\text{Ampiezza dell'intervallo}} \quad (2)$$

L'utilizzo dell'area è fondamentale quando gli intervalli hanno **ampiezza diversa**. Il professore fa notare che bisogna fare attenzione a "come scegliere gli intervalli dell'istogramma (non troppi e non troppo pochi)".

		(AREA)	(ALTEZZA)
Altezza	Freq. Assoluta	Freq. Relativa	Densità di frequenza
1.55 - 1.58	10	10/200	$(10/200) \cdot (1/0.03)$
1.58 - 1.61	25	25/200	$(25/200) \cdot (1/0.03)$
1.61 - 1.64	35	35/200	$(35/200) \cdot (1/0.03)$


Tabella 1: Esempio di calcolo della densità per l'istogramma (200 individui).

2.3 Forme delle Distribuzioni e Relazione tra Indici

Osservando l'istogramma o il diagramma a barre, si possono identificare diverse forme tipiche:

- **Normale:** Simile a una campana simmetrica. In questo caso **Media = Mediana =**

Moda
NEL CASO
DI SIMMETRIA
PERFETTA



INTEGRAZIONE 1/4

Il **vettore unidimensionale** e la **distribuzione delle frequenze** sono due facce della stessa medaglia. Sono solo due modi diversi di organizzare e leggere la stessa identica informazione.

- Il **vettore unidimensionale** $x = (x_1, x_2, \dots, x_n)$ rappresenta i **dati grezzi** (raw data). È l'elenco esatto di tutte le misurazioni che hai preso, una per una, nell'ordine in cui le hai registrate.
- La **distribuzione** (il grafico con le modalità sull'asse x e le frequenze sull'asse y) rappresenta i **dati raggruppati**. Invece di guardare ogni singola misurazione nel vettore, raggruppi i valori identici (le modalità a_j) e conti quante volte compaiono (le frequenze relative $p(a_j)$).

Il collegamento matematico

Prendiamo l'esempio del lancio di 10 dadi che trovi nei tuoi appunti. I dati grezzi formano il tuo vettore unidimensionale x di taglia $n=10$:

$$x = (6, 2, 3, 1, 2, 5, 6, 5, 5, 1)$$

Se vuoi calcolare la **media campionaria** usando il vettore unidimensionale (la formula classica), sommi tutti gli elementi e dividi per n :

$$\text{media di } x = (1/10) \cdot (6 + 2 + 3 + 1 + 2 + 5 + 6 + 5 + 5 + 1) = 3.6$$

Ma nota bene cosa succede in quella lunga somma: il numero 1 compare 2 volte, il 2 compare 2 volte, il 5 compare 3 volte, ecc. Invece di fare una somma lunghissima, possiamo raggruppare i termini uguali usando la moltiplicazione:

$$\text{media di } x = (1/10) \cdot (1 \cdot 2 + 2 \cdot 2 + \dots)$$

Se ora "distribuiamo" quel fratto 10 (cioè la divisione per n) a ogni addendo, quei numeri diventano magicamente le **frequenze relative** di ciascuna **modalità** che metti sull'asse y del tuo grafico:

$$\bar{x} = 1 \cdot \left(\frac{2}{10}\right) + 2 \cdot \left(\frac{2}{10}\right) + 3 \cdot \left(\frac{1}{10}\right) + 4 \cdot \left(\frac{0}{10}\right) + 5 \cdot \left(\frac{3}{10}\right) + 6 \cdot \left(\frac{2}{10}\right) = 3.6$$

Ed ecco il collegamento! La formula matematica che unisce le due visioni (vettore e distribuzione) è proprio questa:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \sum_{j=1}^M a_j p(a_j)$$

(dove gli x_i sono i **dati grezzi** del vettore, a_j sono le **modalità** uniche sull'asse x del grafico, e $p(a_j)$ sono le loro **frequenze relative** sull'asse y del grafico).

E per gli altri indici?

Vale esattamente lo stesso principio. Anche la **varianza empirica**, che col vettore grezzo si calcola come la media degli scarti al quadrato, si può tradurre perfettamente usando le frequenze relative della distribuzione:

$$\text{Var}_e(x) = \left(\sum_{j=1}^M a_j^2 p(a_j) \right) - \bar{x}^2$$

In sintesi: usi il vettore unidimensionale x quando devi definire le formule in modo generale e matematicamente rigoroso o quando un software deve analizzare i dati riga per riga. Usi invece la distribuzione (modalità e frequenze) per visualizzare i dati sui grafici o per calcolare gli indici a mano molto più velocemente.

cambia solo il modo in cui lo "disegni" e lo calcoli geometricamente. Vediamo i due scenari.

1. Il vettore unidimensionale (Dati grezzi)

Immagina una semplice linea retta orizzontale (l'asse dei numeri).

- **I dati:** Per ogni singola misurazione del tuo vettore, disegni un puntino (o appoggi un pesetto) su questa linea. Se un numero si ripete, disegni un altro puntino esattamente nello stesso punto, sovrapponendoli.
- **La media:** Graficamente, la media campionaria è il **baricentro** (o centro di massa) di tutti questi puntini. Se questa linea fosse l'asse di un'altalena, la media è il punto esatto in cui devi mettere il fulcro per farla stare in perfetto equilibrio.
- **La varianza:** Misura quanto i dati sono sparsi. Graficamente, è la media delle distanze al quadrato di ogni singolo puntino da quel fulcro centrale.

2. La distribuzione (Modalità e Frequenze)

Ora passiamo al grafico in due dimensioni (diagramma a barre o istogramma).

- **I dati:** Invece di avere tanti puntini ammucchiati, "fondiamo" i puntini che si trovano nello stesso punto in un'unica colonna verticale. L'asse orizzontale rappresenta sempre i valori (le modalità), ma l'asse verticale ora ci mostra direttamente il "peso" di quella colonna, ovvero la sua frequenza relativa.
- **La media:** Il baricentro è sempre lì. L'altalena non si è mossa. Solo che ora, invece di bilanciare tanti pesetti singoli tutti uguali, stai bilanciando poche colonne compatte, ma di peso diverso. Il calcolo con le frequenze relative ti fa trovare lo stesso identico punto di equilibrio.
- **La varianza:** Invece di misurare la distanza di ogni singolo pesetto dal centro, misuri la distanza della singola colonna dal fulcro, e poi moltiplichi questa

distanza per quanto è alta e "pesante" quella colonna (la sua frequenza relativa).

In pratica, il grafico della distribuzione non è altro che una vista in 2D del vettore 1D: la seconda dimensione (l'altezza sull'asse y) serve solo a rimpiazzare l'ammucchiamento dei dati identici, facendo ordine. I concetti geometrici di "centro" (media) e "dispersione" (varianza) restano fisicamente e graficamente identici.

Hai fatto benissimo a sollevare questo dubbio, perché è l'equivoco visivo per eccellenza quando si inizia a studiare statistica! Ti spiego subito dove sta l'inghippo e perché la tua intuizione sulla "linea perpendicolare" non è sbagliata, ma va solo ricalibrata.

Media e varianza si calcolano **sempre e solo sui valori dell'asse orizzontale (asse x)**, ovvero sulle modalità (es. 170 cm, 180 cm, ecc.).

Il trucco per non confondersi è capire esattamente che ruolo giocano i due assi:

- **L'asse x stabilisce le posizioni e le distanze fisiche:** Le colonne del grafico non vengono posizionate a caso, ma esattamente in corrispondenza del loro valore numerico. Se hai una colonna a 160 cm e una a 170 cm, la distanza matematica tra loro è 10. È su questa precisa distanza orizzontale che si calcolano gli scarti per la varianza.
- **L'asse y (la frequenza) stabilisce solo il "peso":** Disegnare una colonna più alta non sposta il dato sull'asse x . Significa semplicemente che su quel preciso punto (es. 170 cm) ci sono "impilate" più persone. L'asse verticale non entra mai nel calcolo come unità di misura del carattere, ma funziona solo come un **moltiplicatore**.

Come si traduce questo nelle formule?

Prendiamo la formula della media ricavata dalle frequenze relative che il tuo professore ha scritto negli appunti:

$$\bar{x} = \sum_{j=1}^M a_j p(a_j)$$

- a_j (es. 170 cm) è la modalità che leggi sull'asse x .
- $p(a_j)$ (es. 20%) è la frequenza relativa che leggi sull'asse y .

Come vedi, la formula sta sommando le altezze (l'asse x), ma usa la frequenza (l'asse y) per dire alla matematica: "Guarda che questo 170 cm vale il 20% del totale, quindi quando calcoli il centro di equilibrio, fagli tirare la media verso di sé con una forza proporzionale a quel 20%".

4/4

Lo stesso identico discorso vale per la **varianza**. Negli appunti si calcola prendendo lo scarto al quadrato, ovvero la distanza fisica sull'asse x tra il dato e la media, e lo si moltiplica per la frequenza relativa. Anche in questo caso, stai calcolando distanze orizzontali e le stai "pesando" con l'altezza della colonna.

Ti è più chiaro ora come le formule "leggono" il grafico prendendo le vere e proprie misure dall'asse orizzontale e usano l'asse verticale solo come indicatore di gravità?

• **Varianza empirica ($Var_e(x)$)**: Media esatta degli scarti quadratici. (DELLA MEDIA)

$$Var_e(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2 \quad (5)$$

Relazione fondamentale: $Var(x) = \frac{n}{n-1} Var_e(x)$. La varianza è zero se e solo se tutti i dati x_i sono uguali.

Esempio di calcolo varianza (dati dato di prima):

$$Var_e(x) = \frac{1}{10} (1^2 \cdot 2 + 2^2 \cdot 2 + 3^2 \cdot 1 + 4^2 \cdot 0 + 5^2 \cdot 3 + 6^2 \cdot 2) - 3.6^2 \approx 3.64.$$

$$\text{Quindi } Var(x) = \frac{10}{9} \cdot 3.64 \approx 4.04.$$

• **Scarto quadratico medio (Deviazione standard): $\sigma(x) = \sqrt{Var(x)}$** . Ha il vantaggio di mantenere la stessa unità di misura dei dati originali.

SE È ALTO $\Rightarrow$ ELEVATA VARIABILITÀ RISPETTO ALLA MEDIA

4 Funzione di Ripartizione Empirica e Quantili

4.1 Funzione di Ripartizione Empirica (ECDF)

La funzione di ripartizione empirica $F_e(t)$ è definita come la **frequenza relativa dei dati** che sono $\leq t$. Per disegnarla o calcolarla:

1. Si ordinano i dati $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$.
2. Per $t < x_{(1)}$, $F_e(t) = 0$.
3. La funzione fa un salto verso l'alto pari a $1/n$ in corrispondenza di ogni dato (o $2/n$, $3/n$ se ci sono più dati uguali).
4. Per $t \geq x_{(n)}$, la funzione rimane fissa a 1.




Figura 2: Esempio di Funzione di Ripartizione Empirica (a gradini). I salti avvengono in corrispondenza dei dati.

4.2 Percentili e Quantili

Motivazione introdotta a lezione: "Qual è la ricchezza minima del 5% più ricco della popolazione?" Si tratta di trovare il dato x_i tale per cui il 5% dei dati sia $\geq x_i$, ovvero (moralmente) il dato per cui $F_n(x_i) = 0.95$.

Dato un parametro $\beta = k/100$, il k -esimo percentile (o β -quantile) si calcola valutando il prodotto βn :

1. Se βn non è intero, il quantile è il dato in posizione arrotondata per eccesso (il più piccolo intero $> \beta n$). $= x_{(\lceil \beta n \rceil)}$
2. Se βn è intero, per convenzione si prende la media aritmetica tra i dati in posizione βn e $\beta n + 1$: $\frac{x_{(\beta n)} + x_{(\beta n + 1)}}{2}$.

Esempio (Stazione Manhattan delle dispense): $n = 36$. Cerchiamo Q_1 (25° percentile, $\beta = 1/4$).
 $\beta n = 36 \cdot \frac{1}{4} = 9$ (numero intero).
 $Q_1 = \frac{x_{(9)} + x_{(10)}}{2} = \frac{75 + 76}{2} = 75.5$

4.3 Boxplot e Outliers

Boxplot si disegna tracciando:

- Una linea dal minimo al massimo dei dati (esclusi gli outliers).
- Un rettangolo che va dal Primo Quartile (Q_1) al Terzo Quartile (Q_3). Il suo range è detto "scarto interquartile" ($L = Q_3 - Q_1$) e contiene il 50% centrale dei dati.
- Una linea divisoria in corrispondenza del Secondo Quartile (Q_2 o Mediana).

Outlier (valore anomalo): Valore che differisce in modo significativo dalla "grande maggioranza" dei dati. Perché troviamo outlier?

- Errori di misurazione (es. redditi con un valore inserito come 10^9 per sbaglio).
- Dati reali ma molto rari.
- La distribuzione della popolazione ha fisiologicamente una "coda" di dati molto distanti dagli altri.

Gli outlier influenzano pesantemente indici come la media e la varianza. Non esiste una regola assoluta per individuarli, ma una regola empirica diffusa considera outlier i dati al di fuori dell'intervallo:

$$[Q_1 - 1.5L, Q_3 + 1.5L] \quad (6)$$

STATISTICA DESCRITTIVA

Varianza, Funzione di Ripartizione e Quantili

1. Varianza Empirica e Valori Nulli


La formula operativa della varianza è:

$$\text{Var}(X) = [\sum a_j^2 \cdot p(a_j)] - \mu^2$$

Se $p(a_j) = 0$, il termine $a_j^2 \cdot 0$ si annulla completamente. La media μ risulterà calcolata solo sui valori con probabilità positiva, e il termine $-\mu^2$ viene sottratto una sola volta dal totale della sommatoria.

2. Grafico: FdR Empirica e Quantile

Il grafico seguente mostra la tipica funzione a gradini della Funzione di Ripartizione Empirica. Il quantile si trova partendo dall'asse y (probabilità p) e cercando il primo valore x dove la funzione "tocca" o supera quel livello.



3. Calcolo del Quantile

La definizione matematica è: $q(p) = \min \{ x : F_n(x) \geq p \}$.

4.2 Percentili e Quantili

Motivazione introdotta a lezione: "Qual è la ricchezza minima del 5% più ricco della popolazione?" Si tratta di trovare il dato x_i tale per cui il 5% dei dati sia $\geq x_i$, ovvero (moralmente) il dato per cui $F_n(x_i) = 0.95$.

Dato un parametro $\beta = k/100$, il k -esimo percentile (o β -quantile) si calcola valutando il prodotto βn :

1. Se βn non è intero, il quantile è il dato in posizione arrotondata per eccesso (il più piccolo intero $> \beta n$). $= x_{(\lceil \beta n \rceil)}$
2. Se βn è intero, per convenzione si prende la media aritmetica tra i dati in posizione βn e $\beta n + 1$: $\frac{x_{(\beta n)} + x_{(\beta n + 1)}}{2}$

Esempio (Stazione Manhattan delle dispense): $n = 36$. Cerchiamo Q_1 (25° percentile, $\beta = 1/4$).
 $n \cdot \beta = 36 \cdot \frac{1}{4} = 9$ (numero intero).
 $Q_1 = \frac{x_{(9)} + x_{(10)}}{2} = \frac{75 + 77}{2} = 76$.

4.3 Boxplot e Outliers

Boxplot si disegna tracciando:

- Una linea dal minimo al massimo dei dati (esclusi gli outliers).
- Un rettangolo che va dal Primo Quartile (Q_1) al Terzo Quartile (Q_3). Il suo range è detto "scarto interquartile" ($L = Q_3 - Q_1$) e contiene il 50% centrale dei dati.
- Una linea divisoria in corrispondenza del Secondo Quartile (Q_2 o Mediana).

Outlier (valore anomalo): Valore che differisce in modo significativo dalla "grande maggioranza" dei dati. Perché troviamo outlier?

- Errori di misurazione (es. redditi con un valore inserito come 10^9 per sbaglio).
- Dati reali ma molto rari.
- La distribuzione della popolazione ha fisiologicamente una "coda" di dati molto distanti dagli altri.

Gli outlier influenzano pesantemente indici come la media e la varianza. Non esiste una regola assoluta per individuarli, ma una regola empirica diffusa considera outlier i dati al di fuori dell'intervallo:

$$[Q_1 - 1.5L, Q_3 + 1.5L] \quad (6)$$

STATISTICA DESCRITTIVA

Varianza, Funzione di Ripartizione e Quantili

1. Varianza Empirica e Valori Nulli


La formula operativa della varianza è:

$$\text{Var}(X) = \left[\sum a_j^2 \cdot p(a_j) \right] - \mu^2$$

Se $p(a_j) = 0$, il termine $a_j^2 \cdot 0$ si annulla completamente. La media μ risulterà calcolata solo sui valori con probabilità positiva, e il termine $-\mu^2$ viene sottratto una sola volta dal totale della sommatoria.

2. Grafico: FdR Empirica e Quantile

Il grafico seguente mostra la tipica funzione a gradini della Funzione di Ripartizione Empirica. Il quantile si trova partendo dall'asse y (probabilità p) e cercando il primo valore x dove la funzione "tocca" o supera quel livello.



3. Calcolo del Quantile

La definizione matematica è: $q(p) = \min \{ x : F_n(x) \geq p \}$.

Esempio Pratico (Risparmio Inchiostro):

Dati: {10, 20, 30, 40}. $n = 4$. Per $p = 0.5$ (Mediana):

1. $k = 4 \cdot 0.5 = 2$ (Intero).
2. Quantile = media tra il 2° (20) e il 3° dato (30).
3. Risultato: 25.

Documento ottimizzato per la stampa (BN) - Versione 2.0




Figura 3: Esempio di Boxplot con i baffi, la scatola interquartile ($Q_3 - Q_1$), la mediana (Q_2) e due possibili outliers (i punti estremi a 5 e 95).

5 Esercizi Svolti

Esercizio 1.1 - Analisi terremoti in Italia

Testo: Classificare i dati (7, 4, 0, 2, 1, 3, 3, 3, 1, 1, 1, 3) e disegnare il grafico corrispondente.

Svolgimento: I dati rappresentano il "numero di terremoti" in un mese, quindi si tratta di una variabile che può assumere solo valori interi non negativi. Sono pertanto dati discreti. La rappresentazione corretta è un diagramma a barre.

Raggruppiamo i dati in una tabella di frequenze (dimensione totale $n = 12$):

N. terremoti (x_i)	Freq. Assoluta	Freq. Relativa ($p(x_i)$)
0	1	$1/12 \approx 0.083$
1	4	$4/12 \approx 0.333$
2	1	$1/12 \approx 0.083$
3	4	$4/12 \approx 0.333$
4	1	$1/12 \approx 0.083$
7	1	$1/12 \approx 0.083$




Figura 4: Esercizio 1.1: Diagramma a barre del numero di terremoti.

Esercizio 1.2 - Tempi di esecuzione server

Testo: Classificare i 20 tempi di esecuzione forniti e disegnarne il grafico. Determinarne la forma.

Svolgimento: I dati misurano il tempo in secondi, per cui sono grandezze misurabili con infiniti decimali: si tratta di dati continui. Si deve usare l'istogramma. Per costruirlo, dividiamo i dati in classi di ampiezza 0.5 secondi: $[0, 0.5)$, $[0.5, 1.0)$, $[1.0, 1.5)$, $[1.5, 2.0)$, $[2.0, 2.5)$. Conteggiando i valori che cadono in ogni intervallo otteniamo le frequenze assolute: 8, 4, 3, 2, 3.




Figura 5: Esercizio 1.2: Istogramma dei tempi di esecuzione.

La distribuzione presenta un picco evidente tra 0 e 0.5 secondi e una lunga coda verso i valori più alti. È quindi classificabile come **unimodale asimmetrica a destra** (right-skewed).

Esercizio 1.4 - Indici e Boxplot per gli Es. 1.1 e 1.2

Svolgimento per l'Es. 1.1 (Terremoti):

- **Media:** $\bar{x} = \frac{0+(1 \times 4)+2+(3 \times 4)+4+7}{12} = \frac{29}{12} \approx 2.417$
- **Mediana:** Dati ordinati: 0, 1, 1, 1, 1, 2, 3, 3, 3, 3, 4, 7. $n = 12$ (pari). Media tra 6° e 7° valore: $\frac{2+3}{2} = 2.5$.
- **Varianza e Deviazione Standard:** Usiamo la formula empirica per velocità. $\frac{1}{12} \sum x_i^2 = \frac{0+4+4+36+16+49}{12} = \frac{109}{12} \approx 9.083$. $Var_e = 9.083 - (2.417)^2 \approx 3.243$. La varianza campionaria è $Var(x) = \frac{12}{11} \times 3.243 \approx 3.538$. Dev. Standard $\sigma = \sqrt{3.538} \approx 1.88$.

SE FM FOSSE STATO NON UTILIZZO
 ⇒ SI ABBONDA ALL'INTERO SUCCESSIVO

• **Quartili:** βn intero per Q_1 ($0.25 \times 12 = 3$) e Q_3 ($0.75 \times 12 = 9$). Q_1 è la media tra il 3° e 4° dato: $\frac{1+1}{2} = 1$. Q_3 tra il 9° e 10°: $\frac{3+3}{2} = 3$.

• **Outliers:** Scarto interquartile $L = 3 - 1 = 2$. Soglia superiore: $Q_3 + 1.5L = 3 + 3 = 6$. Il dato 7 è un outlier.

Svolgimento per l'Es. 1.2 (Server):

- **Media:** $\bar{x} = \frac{17.88}{20} = 0.894$
- **Mediana:** $n = 20$ (pari). Media tra 10° e 11° valore ordinato (0.56 e 0.61): 0.585.
- **Deviazione Standard:** La somma dei quadrati è $\sum x_i^2 = 25.109$. La varianza campionaria è $Var(x) = \frac{1}{19}(25.109 - 20 \times 0.894^2) \approx 0.480$. Dev. Standard $\sigma \approx 0.693$.

- $\beta n = 5$ $\beta n = 15$
- **Quartili e Outliers:** $Q_1 = \frac{0.38+0.39}{2} = 0.385$, $Q_3 = \frac{1.17+1.60}{2} = 1.385$. $L = 1$. Il limite superiore è $1.385 + 1.5 = 2.885$. Il massimo è 2.42, quindi non ci sono outliers.




Figura 6: Esercizio 1.4: Boxplot a confronto per i due dataset.

Esercizio 1.5 - Unione di gruppi

Testo: Calcolare media e varianza empirica dell'intero campione (30 persone) sapendo che: Gruppo Laureati ($n_1 = 10$): $\bar{x}_1 = 30$, $\sigma_{e1} = 4$. Gruppo Non Laureati ($n_2 = 20$): $\bar{x}_2 = 25$, $\sigma_{e2} = 3$.

Svolgimento: La media totale è la media pesata dei due gruppi:

$$\bar{x} = \frac{n_1 \bar{x}_1 + n_2 \bar{x}_2}{n_1 + n_2} = \frac{10(30) + 20(25)}{30} = \frac{800}{30} \approx 26.67 \text{ mila euro}$$

Per la varianza empirica dell'intero gruppo, usiamo la formula $Var_e(x) = \left(\frac{1}{n} \sum x_i^2\right) - \bar{x}^2$. Dobbiamo prima ricavare la somma dei quadrati ($\sum x_i^2$) per i due gruppi isolati. Dal momento che $Var_e = \sigma_e^2$, abbiamo:

$$\text{Gruppo 1: } 16 = \frac{1}{10} \sum_{G1} x_i^2 - 30^2 \Rightarrow \sum_{G1} x_i^2 = 10(16 + 900) = 9160$$

$$\text{Gruppo 2: } 9 = \frac{1}{20} \sum_{G2} x_i^2 - 25^2 \Rightarrow \sum_{G2} x_i^2 = 20(9 + 625) = 12680$$

La somma totale dei quadrati è $9160 + 12680 = 21840$. Calcoliamo infine la varianza empirica totale:

$$Var_e(Totale) = \frac{21840}{30} - (26.67)^2 = 728 - 711.11 = 16.89 \text{ (mila euro)}^2$$

Esercizio 1.6 - Confronto concentrazione endotossine
Testo (sintesi): Confrontare indici di dispersione per campioni di case Urbane (U) e Rurali (F). r Svolgimento (Punti A e B):

- **Caso Urbane (U):** $n = 11$. Dati ordinati: 4, 5, 5, 6, 11, 17, 18, 23, 33, 35, 80.
 - Media: $\bar{x} = 21.55$.
 - Dev. Standard campionaria (σ): 23.00.
 - Quartili: $Q_1 = 5$, $Q_3 = 33$. Scarto Interquartile $L = 28$.
- **Caso Rurali (F):** $n = 15$. Dati ordinati: 0.3, 2, 3, 4, 4, 5, 8, 8.9, 9, 9, 9.2, 11, 14, 20, 21.
 - Media: $\bar{x} = 8.56$.
 - Dev. Standard campionaria (σ): 6.52.
 - Quartili: $Q_1 = 4$, $Q_3 = 11$. Scarto Interquartile $L = 7$.

Confronto: Il campione delle case Urbane è enormemente più variabile di quello Rurale (sia la σ sia il range interquartile sono molto più grandi). Da notare che per le case urbane la presenza dell'outlier estremo 80 gonfia molto la σ (23.0), ma l'IQR (28) restituisce un'informazione di alta dispersione perfettamente coerente.

Punto C - Boxplot Comparativo: Include anche i dati dalle borse aspirapolvere. (Valori calcolati dai dati forniti nel testo: Aspirapolvere U ha un IQR di 15 e un outlier a 1 e 104. Aspirapolvere F ha un IQR di 21 e un outlier a 64).




Figura 7: Esercizio 1.6: Boxplot comparativo dei 4 campioni.

6 Dati Multivariati

In questo capitolo estendiamo l'analisi statistica a situazioni in cui su ogni unità della popolazione vengono misurati simultaneamente due caratteri quantitativi. L'obiettivo non è più solo descrivere le singole variabili, ma **investigare l'esistenza di relazioni o dipendenze** tra di esse. Ci limiteremo all'analisi di coppie di dati, definiti **dati bivariati**.

Consideriamo un campione di n individui. I dati si presentano come un insieme di coppie ordinate:

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n) \quad (7)$$

dove (x_i, y_i) rappresenta il valore dei due caratteri (ad esempio x = tasso di fertilità, y = reddito) rilevato sull' i -esimo elemento.

6.1 Lo Scatterplot (Grafico di Dispersione)

Il primo passo nell'analisi bivariata è la visualizzazione grafica tramite lo **scatterplot**. In questo grafico, ogni coppia (x_i, y_i) è un punto sul **piano cartesiano**.

La disposizione dei punti permette di identificare tre scenari principali:

- **Assenza di relazione:** I punti sono sparsi uniformemente senza una direzione precisa.
- **Relazione lineare:** I punti tendono a disporsi lungo una linea retta. È il caso più semplice e comune studiato nella statistica descrittiva.
- **Relazione non lineare:** I punti seggono un andamento curvilineo (es. parabolico, esponenziale o logaritmico).

6.2 Covarianza e Correlazione

Per misurare numericamente la forza e la direzione della relazione lineare, introduciamo due indici fondamentali.

6.2.1 La Covarianza Campionaria ed Empirica

La covarianza misura come le due variabili "variano insieme".

CI BÀ SOLO INDICAZIONE DELLA DIREZIONE
NON CI DICE NULLA DI SIGNIFICATIVO SULLA FORZA

$$Cov(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (\text{Campionaria}) = \frac{n}{n-1} cov_e(x, y) \quad (8)$$

$$Cov_e(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (\text{Empirica}) \quad (9)$$

LA $COV(x, y)$ MISURA LA DIREZIONE DELLA RELAZIONE LINEARE TRA X E Y .

"SE X AUMENTA, Y AUMENTA, DIMINUISCE O NON CAMBIA"

"+" $\Rightarrow$ STESSA DIREZIONE (X TRENDE AD AUMENTARE, Y //) CORRELAZIONE POSITIVA

"-" $\Rightarrow$ DIREZIONI OPPOSITE

"0" $\Rightarrow$ NESSUNA RELAZIONE EVIDENTE (LINEARE) (GLI SCARTAMENTI MEDI SI COMPENSANO)

UNITÀ DI MISURA = PRODOTTO TRA LE 2 UNITÀ

Passaggi per la formula calcolatoria: Per facilitare il calcolo, sviluppiamo il prodotto nella sommatoria della covarianza empirica:

$$\begin{aligned} \text{FACOLTATIVO } \text{Cov}_e(x, y) &= \frac{1}{n} \sum_{i=1}^n (x_i y_i - \bar{x} \bar{y}) \\ &= \frac{1}{n} \sum_{i=1}^n x_i y_i - \frac{1}{n} \sum_{i=1}^n \bar{x} \bar{y} \\ &= \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{y} \left(\frac{1}{n} \sum_{i=1}^n x_i \right) - \bar{x} \left(\frac{1}{n} \sum_{i=1}^n y_i \right) + \bar{x} \bar{y} \\ &= \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \bar{x} \bar{y} - \bar{y} \bar{x} + \bar{x} \bar{y} = \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \bar{x} \bar{y} \end{aligned}$$

6.2.2 Il Coefficiente di Correlazione di Pearson (r)

La covarianza ha un limite: dipende dall'unità di misura dei dati. Dividendo la covarianza per il prodotto delle deviazioni standard, otteniamo un numero puro (adimensionale) $r \in [-1, 1]$:
 $r(x, y) = \frac{\text{Cov}(x, y)}{\sigma(x)\sigma(y)}$
 con $\sigma(x) \neq 0, \sigma(y) \neq 0$
 $r = 1$ PERFETTA CORR. +
 $r = -1$ PERFETTA CORR. -
 $r = 0$ NO CORR.

6.3 La Retta di Regressione Lineare

Il problema della regressione consiste nel trovare la curva che approssima meglio i dati. Nel caso lineare, cerchiamo la retta $y = a + bx$ che minimizza l'errore commesso.
 (QUANTO È BUONA L'APPROX CON LA CURVA TROVATA?)

6.3.1 Il Metodo dei Minimi Quadrati

Vogliamo minimizzare la somma degli scarti quadratici tra i valori osservati y_i e quelli predetti dalla retta ($a + bx_i$):

$$\min_{a, b} Q(a, b) = \frac{1}{n} \sum_{i=1}^n (y_i - a - bx_i)^2 \quad (11)$$

Derivazione dei parametri ottimali (a^*, b^*): Annullando le derivate parziali di Q rispetto ad a e b , otteniamo il sistema delle equazioni normali:

$$\begin{cases} \sum y_i - na - b \sum x_i = 0 \\ \sum x_i y_i - a \sum x_i - b \sum x_i^2 = 0 \end{cases}$$

Dividendo per n e risolvendo per a :

$$\bar{y} - a - b\bar{x} = 0 \Rightarrow a^* = \bar{y} - b^*\bar{x} \quad (12)$$

Sostituendo a nella seconda equazione si ottiene il coefficiente angolare:

$$b^* = \frac{\text{Cov}_e(x, y)}{\text{Var}_e(x)} = \frac{\text{Cov}(x, y)}{\text{Var}(x)} \quad (13)$$

SUPPONENDO $\sigma(x) \neq 0, \sigma(y) \neq 0$

IL MIN Q

SI HA PER

I VALORI

E VALE $\rightarrow \text{Var}_e(y) \cdot (1 - r^2)$



$$s^2 = \frac{1}{n} \sum_{i=1}^n (y_i - (a^* + b^* x_i))^2 \rightarrow \text{È UNA MEDIA (VARIANTE RESIDUA)}$$

SOMMA DELLE AREE DI TUTTI I QUADRATI FORNITI DA PUNTO E PUNTO PREDETTO


6.3.2 Interpretazione della bontà dell'adattamento

L'errore minimo (residuo) è la parte di variabilità di y che la retta non riesce a spiegare:

IL SEGNO DI r COINCIDE CON IL SEGNO DI $\text{COV}(x, y)$ CHE COINCIDE CON IL SEGNO DI b^* (COEFF. ANGOL.)


Se $r^2 = 1$ ($r = \pm 1$): L'errore è nullo. I punti sono perfettamente allineati sulla retta.
 Se r^2 è vicino a 1: L'approssimazione è ottima. (r VICINO A ± 1)
 Se $r \approx 0$: Non esiste una relazione lineare.

Formula (14): $\text{Errore Residuo} = \text{Var}_e(y) \cdot (1 - r^2)$
 L'ERRORE RESIDUO È LA PARTE DI VARIABILITÀ DI y CHE LA RETTA NON RIESCE A SPIEGARE.




6.4 Esempi Grafici di Correlazione


Correlazione Positiva ($r \approx 0.7$)




Correlazione Negativa ($r \approx -0.9$)



Dati Scorrelati ($r \approx 0$)



Dipendenza Non Lineare ($r \approx 0$)




Nota importante per l'esame: Se $r \approx 0$, i dati sono detti scorrelati. Tuttavia, l'ultimo grafico mostra che $r = 0$ non implica indipendenza: i punti seguono una parabola perfetta ($y = x^2$), quindi c'è una relazione deterministica forte, ma siccome non è una retta, il coefficiente di correlazione lineare non riesce a rilevarla.

8.3.3 Interpretazione della forza dell'adattamento
L'errore minimo (varianza) è la parte di variabilità di y che la regressione non riesce a spiegare.


- Se $r^2 = 1$ ($r = \pm 1$): L'errore è nullo. I punti sono perfettamente allineati sulla retta.
- Se r^2 è vicino a 1: L'approssimazione è ottima.
- Se $r^2 \approx 0$: Non esiste una relazione lineare.

8.4 Esempi Grafici di Correlazione



Nota importante per l'esame: Se $r \approx 0$, i dati sono detti scartati. Tuttavia, l'ultimo grafico mostra che $r = 0$ non implica indipendenza. I punti seguono una parabola ($y = x^2$), quindi c'è una relazione deterministica forte, ma siccome non è una retta, il coefficiente di correlazione lineare non riesce a rilevarla.

Relazione quadratica ($r = 0$ ma forte dipendenza)



7 Probabilità e Indipendenza

7.1 Spazi di Probabilità e Definizioni

La teoria della probabilità procede in direzione inversa rispetto alla statistica descrittiva: dato un esperimento di cui è nota la distribuzione teorica (modello) degli esiti, vogliamo dedurre informazioni sulle probabilità che si verifichino determinati eventi.

Definiamo i concetti fondamentali:

- **Esperimento aleatorio:** Un fenomeno (fisico, biologico, sociale, ecc.) il cui esito non è determinato con certezza a priori. Esempi: estrazione di una biglia da un'urna, tempo di esecuzione di un task da un server, lancio di un dado.
- **Spazio campionario (Ω):** L'insieme di tutti i possibili esiti (modalità) dell'esperimento.
- **Eventi ($A, B, \dots$):** Sottoinsiemi dello spazio campionario (Ω). Rappresentano affermazioni sull'esito dell'esperimento.
- **Eventi elementari:** I singoli esiti dell'esperimento ($\omega \in \Omega$). Costituiscono i mattoni base dello spazio campionario.
- **Evento certo:** L'intero spazio campionario Ω (accade sicuramente qualcosa).
- **Evento impossibile:** L'insieme vuoto $\emptyset$ (nessun esito si realizza).

Esempio pratico (Lancio di un dado): Lo spazio campionario è $\Omega = \{1, 2, 3, 4, 5, 6\}$. L'affermazione "esce un numero pari" corrisponde all'evento (sottoinsieme) $A = \{2, 4, 6\}$. L'evento elementare "esce 2" è $\{\omega\} = \{2\}$.

7.2 Dalla Logica alla Teoria degli Insiemi

Poiché gli eventi sono sottoinsiemi di Ω , le operazioni logiche tra le affermazioni si traducono in operazioni insiemistiche.

7.3 Le Interpretazioni della Probabilità

Vogliamo associare a ogni evento $A \subseteq \Omega$ un valore $P(A) \in [0, 1]$ che esprima il grado di fiducia che l'evento si realizzi, dove 0 indica l'evento impossibile e 1 l'evento certo.

Operazione Logica	Operazione Insiemistica	Esempio (Dato: $A = \{2, 4, 6\}$, $B = \{4, 5, 6\}$)
Accade A oppure B Accadono A e B Non accade A Accade A ma non B	Unione: $A \cup B$ Intersezione: $A \cap B$ Complementare: $A^c = \Omega \setminus A$ Differenza: $A \setminus B = A \cap B^c$	Pari ≥ 4 : $\{2, 4, 5, 6\}$ Pari ≥ 4 : $\{4, 6\}$ Dispari: $\{1, 3, 5\}$ Pari ma non ≥ 4 : $\{2\}$
Relazioni Logiche	Relazioni Insiemistiche	
Se accade A, allora accade B	Sottoinsieme: $A \subseteq B$	Se "esce 2" ($\{2\}$), allora "è pari" ($\{2, 4, 6\}$)
Non possono accadere ass.	Disgiunti (Incomp.): $A \cap B = \emptyset$	Gli eventi non si sovrappongono. Es: $A = \{3\}$, $B = \{2, 4, 6\}$

Tabella 2: Corrispondenza tra operazioni logiche e insiemistiche.

1. Definizione Classica (Laplace):

$$P(A) = \frac{\# \text{ casi favorevoli di } A}{\# \text{ casi possibili totali}} = \frac{\#A}{\#\Omega}$$

Pro e Contro: È perfetta per estrazioni da popolazioni reali finite (dadi, urne, monete equilibrate), ma richiede che tutti gli eventi elementari siano equiprobabili. Non è adatta per fenomeni fisici o per spazi infiniti.

2. Definizione Frequentista:

$$P(A) = \lim_{n \rightarrow \infty} \left(\frac{\text{frequenza assoluta di } A}{n} \right)$$

La probabilità è il limite della frequenza relativa in n prove ripetute dell'esperimento.

Esempio (Lancio di moneta): Se faccio 1000 lanci e ottengo 529 teste ($f_{rel} = 0.529$) e in altri 1000 lanci ottengo 493 teste, la frequenza totale si assesta su $(529 + 493)/2000 = 0.511$. Al tendere all'infinito delle prove dovrei raggiungere esattamente il 50%.

Pro e Contro: Adatta per popolazioni ideali e fenomeni empirici. Tuttavia, non sempre è possibile effettuare infinite prove, e matematicamente non è garantito che il limite esista in senso stretto.

3. Definizione Soggettivista (De Finetti):

$P(A)$ è definita come il grado di fiducia attribuito all'evento da un soggetto perfettamente razionale, in base alle informazioni a sua disposizione.

7.4 Definizione Assiomatica di Kolmogorov

Per superare i limiti delle definizioni precedenti, si usa un insieme di assiomi formali che definiscono in astratto una misura di probabilità. Dato uno spazio campionario Ω , una misura di probabilità $P: \mathcal{P}(\Omega) \rightarrow \mathbb{R}$ deve soddisfare tre postulati:

$$P(A) = \text{PROBABILITÀ DI } A \quad (A \subseteq \Omega) \quad 16 \quad P(\Omega) = \text{INSIEME DELLE PARTI, TUTTI I POSSIBILI EVENTI CHE POSSO COSTRUIRE CON QUEGLI ESITI}$$

ogni punto.
 $P: \text{EVENTO} \rightarrow \text{NUM. REALE}$

1. Positività: $0 \leq P(A) \leq 1 \quad \forall A \subseteq \Omega$.

2. Certezza: $P(\Omega) = 1$.

3. Additività: Se $A_1, A_2, \dots, A_n$ è una successione di eventi incompatibili a due a due ($A_i \cap A_j = \emptyset$ per ogni $i \neq j$), allora:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i) \quad \text{SOLO SE } A_1 \cap A_2 = \emptyset \quad (15)$$

(Questo vale anche per unioni infinite contabili, prendendo il limite per $n \rightarrow \infty$).

La coppia (Ω, P) costituisce uno **Spazio di Probabilità**.

7.4.1 Proprietà della Probabilità (Dimostrate dagli Assiomi)

Dagli assiomi discendono le regole classiche del calcolo delle probabilità.

• Probabilità del Complementare: $P(A^c) = 1 - P(A)$. In particolare, $P(\emptyset) = 0$.

Dimostrazione: A e A^c sono disgiunti ($A \cap A^c = \emptyset$) e la loro unione è Ω ($A \cup A^c = \Omega$). Per l'assioma 2 e 3: $P(A \cup A^c) = P(A) + P(A^c) = P(\Omega) = 1$. Spostando un termine otteniamo la tesi.

• Monotonia e Differenza: Se $B \subseteq A$, allora $P(A \setminus B) = P(A) - P(B)$. (Ne consegue che $P(A) \geq P(B)$).

Dimostrazione: Possiamo scrivere A come l'unione disgiunta $A = B \cup (A \setminus B)$. Per l'assioma dell'additività: $P(A) = P(B) + P(A \setminus B)$. Isolando la differenza si ottiene la formula.

• Probabilità dell'Unione di eventi generici:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \quad (16)$$

Dimostrazione: $A \cup B$ può essere scomposto in tre parti a due a due disgiunte: $(A \setminus B) \cup (A \cap B) \cup (B \setminus A)$. Sommando le probabilità: $P(A \cup B) = P(A \setminus B) + P(A \cap B) + P(B \setminus A)$. Sappiamo (per la proprietà precedente) che $P(A \setminus B) = P(A) - P(A \cap B)$ e $P(B \setminus A) = P(B) - P(A \cap B)$. Sostituendo $[P(A) - P(A \cap B)] + [P(B) - P(A \cap B)] + P(A \cap B)$ nella somma è semplificando si ottiene la tesi.

Se gli eventi generici da unire sono più di due, si usa la **Formula di Inclusione-Esclusione**:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{k=1}^n (-1)^{k+1} \sum_{1 \leq i_1 < \dots < i_k \leq n} P(A_{i_1} \cap \dots \cap A_{i_k}) \quad (17)$$

SOMMA LE PROBABILITÀ DI TUTTE LE POSSIBILI COMBINAZIONI DI K EVENTI

8 Modello Uniforme e Calcolo Combinatorio

Un **Modello Uniforme** è uno spazio di probabilità $(\Omega, \mathcal{P})$ tale per cui l'insieme Ω è finito e ogni esito elementare ω è equiprobabile. La probabilità del singolo esito è $P(\{\omega\}) = 1/\#\Omega$. In questo caso si usa la definizione classica di Laplace: $P(A) = \frac{\#A}{\#\Omega}$.

La **Combinatoria** permette di contare il numero di elementi degli insiemi. Dati n oggetti distinti, il numero di modi per estrarne k è dato da:

- **Disposizioni con ripetizione** (L'ordine conta, c'è rimpiazzo): n^k . (Es. lanci multipli di monete/dadi).
- **Disposizioni semplici** (L'ordine conta, niente rimpiazzo): $\frac{n!}{(n-k)!} = n \cdot (n-1) \cdot \dots \cdot (n-k+1)$.
- **Permutazioni** (Ordinare n elementi, $k = n$): $n!$.
- **Combinazioni semplici** (L'ordine NON conta, niente rimpiazzo): **Coefficiente Binomiale** $\binom{n}{k} = \frac{n!}{k!(n-k)!}$. (Es. estrazioni in blocco).

8.1 GUARDA INTEGRAZIONE PAGINA SUCCESSIVA


9 Probabilità Condizionata e Alberi

Motivazione: Quando si viene a conoscenza della realizzazione di un evento, la valutazione di probabilità degli altri eventi cambia. Se lanciamo un dado e sappiamo che è uscito un numero pari ($B = \{2, 4, 6\}$), qual è la probabilità che il numero sia ≥ 4 ($A = \{4, 5, 6\}$)? Lo spazio campionario si restringe a B . I casi favorevoli diventano l'intersezione $A \cap B = \{4, 6\}$. La nuova probabilità è $2/3$.

Definizione: Dato uno spazio di probabilità, sia B un evento non trascurabile ($P(B) > 0$). La **Probabilità Condizionata** di A dato B è:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

QUANTA PARTE DELL'EVENTO A È CONTENUTA IN B (CHE È IL NUOVO Ω) (18)



Nota bene: La funzione $P(\cdot|B)$ è essa stessa una vera e propria misura di probabilità, e rispetta tutti gli assiomi di Kolmogorov. Attenzione a non confondere il simbolo del condizionamento ($|$) con quello della differenza degli insiemi ($\setminus$).

Da questa definizione deriva la **Regola dei Prodotti**:

$$P(A \cap B) = P(A|B) \cdot P(B) = P(B|A) \cdot P(A) \quad (19)$$

$A \mapsto P(A|B)$
È UNA PROB.

Questa regola può essere estesa al condizionamento ripetuto (o regola della catena per intersezioni multiple):

$$P(A_1 \cap \dots \cap A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 \cap A_2) \dots P(A_n|A_1 \cap \dots \cap A_{n-1}) \quad (20)$$

9.1 Rappresentazione ad Albero

I diagrammi ad albero sono utili per modellizzare sequenze di sottoesperimenti. Ad ogni smodo (nodo) partono rami corrispondenti ai possibili esiti. Ad ogni ramo si associa la **probabilità condizionata**. La somma delle probabilità dei rami uscenti da un nodo deve fare 1.

Valgono due regole pratiche di calcolo:

INTEGRAZIONE 1/2

8 Modello Uniforme e Calcolo Combinatorio

Un **Modello Uniforme** è uno spazio di probabilità $(\Omega, \mathcal{P})$ tale per cui l'insieme Ω è finito e ogni esito elementare ω è equiprobabile. La probabilità del singolo esito è $P(\{\omega\}) = 1/\#\Omega$. In questo caso si usa la definizione classica di Laplace: $P(A) = \frac{\#A}{\#\Omega}$.

La **Combinatoria** permette di contare il numero di elementi degli insiemi. Dati n oggetti distinti, il numero di modi per estrarne k è dato da:

- **Disposizioni con ripetizione** (L'ordine conta, c'è rimpiazzo): n^k . (Es. lanci multipli di monete/dadi).
- **Disposizioni semplici** (L'ordine conta, niente rimpiazzo): $\frac{n!}{(n-k)!}$.
- **Permutazioni** (Ordinare n elementi, $k = n$): $n!$.
- **Combinazioni semplici** (L'ordine NON conta, niente rimpiazzo): **Coefficiente Binomiale** $\binom{n}{k} = \frac{n!}{k!(n-k)!}$. (Es. estrazioni in blocco).

8.1 Esempi di Modelli Uniformi: Le Estrazioni

Un'applicazione classica del modello uniforme riguarda gli esperimenti di estrazione da un'urna contenente n oggetti distinguibili (ad esempio, palline numerate da 1 a n). Se gli oggetti sono estratti in modo casuale, ogni configurazione possibile ha la stessa probabilità di verificarsi. Di conseguenza, possiamo usare la definizione classica di probabilità di Laplace:

$$P(A) = \frac{\#A}{\#\Omega}$$

A seconda di come viene effettuata l'estrazione di k oggetti, lo spazio campionario Ω e la sua cardinalità cambiano radicalmente. Vediamo i tre casi fondamentali:

8.1.1 1. Estrazioni CON ordine e CON rimpiazzo (Disposizioni con ripetizione)

In questo caso, estraiamo un oggetto, ne annotiamo il risultato e lo **reinseriamo** nell'urna prima dell'estrazione successiva. L'ordine in cui gli oggetti vengono estratti è rilevante.

- **Spazio campionario** (Ω): L'insieme di tutte le sequenze ordinate (o k -uple) in cui gli elementi possono ripetersi.

$$\Omega = \{(\omega_1, \omega_2, \dots, \omega_k) \mid \omega_i \in \{1, 2, \dots, n\}\} = \{1, 2, \dots, n\}^k$$

- **Cardinalità** ($\#\Omega$): Poiché per ognuna delle k estrazioni abbiamo sempre n scelte disponibili, i casi possibili sono:

$$\#\Omega = \underbrace{n \cdot n \cdot \dots \cdot n}_{k \text{ volte}} = n^k$$

- **Probabilità uniforme:** $P(A) = \frac{\#A}{n^k}$

Osservazione pratica: Questo è il modello matematico che si utilizza per descrivere il lancio ripetuto di dadi o monete equilibrate. Ad esempio, in k lanci di un dado a $n = 6$ facce, lo spazio campionario ha cardinalità 6^k .

8.1.2 2. Estrazioni CON ordine e SENZA rimpiazzo (Disposizioni semplici)

Qui estraiamo k oggetti uno dopo l'altro (con $k \leq n$), annotando l'ordine di estrazione, ma **senza** reinserirli nell'urna.

- **Spazio campionario** (Ω): L'insieme delle sequenze ordinate senza elementi ripetuti (tutti gli ω_i sono distinti tra loro).
- **Cardinalità** ($\#\Omega$): Alla prima estrazione abbiamo n scelte, alla seconda $n-1$, alla terza $n-2$ e così via, scendendo per k fattori.

$$\#\Omega = n \cdot (n-1) \cdot (n-2) \cdot \dots \cdot (n-k+1) = \frac{n!}{(n-k)!}$$

- **Probabilità uniforme**: $P(A) = \frac{\#A}{\#\Omega}$

8.1.3 3. Estrazioni SENZA ordine e SENZA rimpiazzo (Combinazioni semplici)

Questo è il caso in cui estraiamo k oggetti **simultaneamente** (in blocco), oppure li estraiamo uno alla volta senza reinserirli ma decidiamo di dimenticarci dell'ordine di estrazione (considerando, ad esempio, le sequenze (3, 7) e (7, 3) come lo stesso identico risultato).

- **Spazio campionario** (Ω): L'insieme di tutti i possibili sottoinsiemi di dimensione k estraibili dall'insieme di n elementi.

$$\Omega = \{C \subseteq \{1, 2, \dots, n\} \mid \#C = k\}$$

- **Cardinalità** ($\#\Omega$): È data dal coefficiente binomiale, che elimina le permutazioni superflue dividendo le disposizioni semplici per $k!$ (i modi di ordinare i k oggetti estratti).

$$\#\Omega = \binom{n}{k} = \frac{n!}{k!(n-k)!}$$

- **Probabilità uniforme**: $P(A) = \frac{\#A}{\#\Omega}$

Esempio di Calcolo Passo-Passo: Consideriamo l'estrazione senza ordine e senza rimpiazzo di 2 oggetti da un'urna che ne contiene 10. Qual è la cardinalità dello spazio campionario Ω ? Applichiamo la formula delle combinazioni con $n = 10$ e $k = 2$:

$$\begin{aligned} \#\Omega &= \binom{10}{2} = \frac{10!}{2!(10-2)!} = \frac{10!}{2! \cdot 8!} \\ &= \frac{10 \cdot 9 \cdot 8 \cdot 7 \cdot \dots \cdot 1}{(2 \cdot 1) \cdot (8 \cdot 7 \cdot \dots \cdot 1)} \end{aligned}$$

Semplificando il fattoriale 8! al numeratore e al denominatore, otteniamo:

$$\#\Omega = \frac{10 \cdot 9}{2} = \frac{90}{2} = 45 \text{ possibili esiti equiprobabili}$$

PRODOTTO
SOMMA

1. **Regola della Catena:** $P(\text{Ramo completo}) = \text{prodotto delle probabilità dei suoi sotto-rami.}$

2. **Regola della Fattorizzazione:** La probabilità di un evento è la somma delle probabilità di tutti i rami (distinti e disgiunti) che portano a quell'evento.

Esempio dell'Urna a Estrazioni Multiple: Abbiamo un'urna iniziale con 4 biglie Rosse (R) e 1 Blu (B). Estraiamo 1 biglia.


- Se è Blu (prob. $1/5$), l'esperimento finisce.

- Se è Rossa (prob. $4/5$), la teniamo fuori, ma aggiungiamo una nuova biglia misteriosa. Questa aggiunta sarà Rossa con probabilità $3/4$ o Blu con prob. $1/4$. Poi effettuiamo la 2° estrazione.

IP(RAMO) = PRODOTTO DELLE IP
DEI SOTTOCAMI (1)

IP(UNIONE RAMI) = SOMMA
DELLE IP
DEI RAMI (2)

IMAGINIAMO UN FIUME
(1): QUANTA ACQUA ARRIVA
IN UN SINGOLO PUNTO
(2): QUANTA ACQUA FINISCE IN
UN LAGO RACCOLGENDO TUTTI
I PUNTI CHE CI SFOCIANO



QUANDO VAI IN VERTICALE
MULTIPLICHI

QUANDO DEVI UNIRE RISULTATI
DI RAMI DIVERSI, SOMMI

Figura 8: Diagramma ad albero per esperimenti sequenziali.

Per calcolare $P(2^a \text{ estr.} = R)$, applichiamo le due regole viste:

$$\begin{aligned} P(2^a = R) &= P(1^a = R, \text{Agg.} = B, 2^a = R) + P(1^a = R, \text{Agg.} = R, 2^a = R) \\ &= \left(\frac{4}{5} \cdot \frac{1}{4} \cdot \frac{3}{5}\right) + \left(\frac{4}{5} \cdot \frac{3}{4} \cdot \frac{4}{5}\right) = \frac{3}{25} + \frac{12}{25} = \frac{15}{25} = \frac{3}{5} \end{aligned}$$

10 Probabilità Totale e Teorema di Bayes

10.1 Sistema di Alternative e Probabilità Totale

Un **sistema di alternative** è una **partizione** dello spazio campionario Ω : una collezione di eventi $B_1, \dots, B_n$ tali che:

- Siano a due a due disgiunti ($B_i \cap B_j = \emptyset, \forall i \neq j$).

• La loro unione faccia tutto lo spazio ($\bigcup B_i = \Omega$).

• Nessuno sia trascurabile ($P(B_i) > 0$).

Questo garantisce che durante l'esperimento accada uno e uno solo degli eventi B_i .

Formula della Probabilità Totale (o di fattorizzazione): Dato un evento $A \subseteq \Omega$ e un sistema di alternative $B_1, \dots, B_n$, si ha:

$$P(A) = \sum_{i=1}^n P(A \cap B_i) = \sum_{i=1}^n P(A|B_i) \cdot P(B_i) \quad (21)$$

→ INTEGRAZIONE

10.2 Teorema di Bayes

Utile per "invertire il condizionamento". Noti gli effetti (es. esito del test, colore della pallina), si vuole dedurre la probabilità della causa (es. malattia, urna). Siano A e B non trascurabili:

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)} \quad (22)$$

Se $B_1, \dots, B_n$ è un sistema di alternative, applicando la Probabilità Totale al denominatore, la formula si espande in:

$$P(B_i|A) = \frac{P(A|B_i) \cdot P(B_i)}{\sum_{j=1}^n P(A|B_j) \cdot P(B_j)} = \frac{P(A|B_i) \cdot P(B_i)}{P(A)} \quad (23)$$

Esempio 1: Scelta dell'urna. Scegliamo a caso una tra due urne (probabilità 1/2 ciascuna). L'urna 1 ha 5 palline Rosse e 5 Blu. L'urna 2 ha 8 palline Rosse e 2 Blu. Peschiamo una pallina ed è Rossa. Qual è la probabilità che abbiamo pescato dall'urna 1? Appliciamo Bayes ($P(R|U_1) = 5/10 = 1/2$, $P(R|U_2) = 8/10 = 4/5$):

$$P(U_1|R) = \frac{P(R|U_1)P(U_1)}{P(R)} = \frac{\frac{1}{2} \cdot \frac{1}{2}}{(\frac{1}{2} \cdot \frac{1}{2}) + (\frac{4}{5} \cdot \frac{1}{2})} = \frac{1/4}{1/4 + 4/10} = \frac{1/4}{13/20} = \frac{5}{13}$$

Esempio 2: Test Diagnostico. Indice di sensibilità (probabilità test positivo se malato) = 0.99. Specificità (probabilità test negativo se sano) = 0.97. L'1% della popolazione è malata ($P(m) = 0.01$). Se una persona risulta positiva (+), qual è la probabilità che sia malata? Denominatore (Prob. Totale di test positivo): $P(+) = P(+|m)P(m) + P(+|s)P(s) = (0.99 \cdot 0.01) + (0.03 \cdot 0.99) = 0.0396$.

$$P(m|+) = \frac{P(+|m)P(m)}{P(+)} = \frac{0.0099}{0.0396} = 0.25$$

Nonostante la precisione elevata, la bassa incidenza della malattia fa sì che il 75% dei positivi siano falsi allarmi.

11 Eventi Indipendenti

L'indipendenza esprime formalmente il concetto per cui la conoscenza del verificarsi di un evento B non altera la probabilità di A . Ovvero $P(A|B) = P(A)$. Dalla definizione di probabilità condizionata deriva la formula simmetrica:

$$P(A \cap B) = P(A) \cdot P(B) \quad (24)$$

Osservazioni chiave:

INTEGRAZIONE 1/2

1 Il Contesto Applicativo

Nella realtà, molti eventi non accadono in modo isolato, ma dipendono da una condizione iniziale o da uno scenario specifico. La **Formula di Fattorizzazione** (o Probabilità Totale) è lo strumento matematico che ci permette di calcolare la probabilità di un evento complesso sommandone le probabilità all'interno di ogni possibile scenario.

1.1 Cosa rappresentano A e B?

Per applicare correttamente la formula, dobbiamo identificare due tipi di oggetti logici:

• **Gli Scenari ($B_1, B_2, \dots, B_n$):** Rappresentano le "cause" o le condizioni di partenza. Per essere un sistema di alternative valido, devono essere:

1. **Incompatibili:** non possono verificarsi due scenari contemporaneamente.
2. **Esauritivi:** uno di questi scenari deve verificarsi per forza (la loro unione copre tutto lo spazio Ω).

Esempio: "Scegliere l'Urna 1" oppure "Scegliere l'Urna 2". Non puoi sceglierle entrambe come prima scelta, e non ci sono altre urne disponibili.

• **L'Evento finale (A):** È l'"effetto" o l'esito che vogliamo misurare. L'evento A può verificarsi in ognuno degli scenari B_i , ma con probabilità potenzialmente diverse. **Esempio:** "Estrarre una pallina rossa". La probabilità di avere una rossa cambia a seconda che io stia pescando dall'Urna 1 o dall'Urna 2.

1.2 La Formula

La probabilità totale di A è la somma pesata delle probabilità di A in ogni scenario:

$$P(A) = \sum_{i=1}^n P(A|B_i) \cdot P(B_i) \quad (1)$$

2 Esercizio 1: Il Modello delle Urne

Testo: Abbiamo due urne. L'Urna 1 contiene 5 palline Rosse e 5 Blu. L'Urna 2 contiene 3 palline Rosse e 1 Blu. Scegliamo un'urna a caso e peschiamo una pallina. Qual è la probabilità che sia Rossa?

Svolgimento

1. Definizione degli Scenari (B_i):

- B_1 : Scelta dell'Urna 1. Siccome la scelta è casuale, $P(B_1) = 0.5$.
- B_2 : Scelta dell'Urna 2. $P(B_2) = 0.5$.

2. Definizione dell'Evento finale (A):

- A : La pallina estratta è Rossa.

3. Analisi delle Probabilità Condizionate ($P(A|B_i)$):

- Se sono nell'Urna 1, la probabilità di Rossa è 5/10: $P(A|B_1) = 0.5$.
- Se sono nell'Urna 2, la probabilità di Rossa è 3/4: $P(A|B_2) = 0.75$.

4. Calcolo della Probabilità Totale:

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) \\ = (0.5 \cdot 0.5) + (0.75 \cdot 0.5) \\ = 0.25 + 0.375 = 0.625 \quad (\text{ovvero } 5/8)$$

3. Esercizio 2: Il Test Diagnostico

Testo: Una malattia colpisce l'1% della popolazione. Un test ha una sensibilità (positivo se malato) del 99% e una specificità (negativo se sano) del 97%. Qual è la probabilità che una persona scelta a caso risulti positiva al test?

Svolgimento

1. Definizione degli Scenari (B_i):

- B_1 (Malato): $P(B_1) = 0.01$.
- B_2 (Sano): $P(B_2) = 1 - 0.01 = 0.99$.

2. Definizione dell'Evento finale (A):

- A : Il test dà esito Positivo (+).

3. Analisi delle Probabilità Condizionate:

- Probabilità di positivo se malato: $P(A|B_1) = 0.99$.
- Probabilità di positivo se sano (falso positivo): $P(A|B_2) = 1 - 0.97 = 0.03$.

4. Calcolo della Probabilità Totale:

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) \\ = (0.99 \cdot 0.01) + (0.03 \cdot 0.99) \\ = 0.0099 + 0.0297 = 0.0396 \quad (\text{ovvero } 3.96\%)$$

$$IP(+) = IP(\text{PERSONA MALATA} \cap \text{IL TEST A TENDENZA POSITIVA}) \\ + IP(\text{PERSONA SANA} \cap \text{IL TEST A TENDENZA POSITIVA})$$

- B_1 : Scelta dell'Urna 1. Spesso la scelta è casuale. $P(B_1) = 0.2$.
- B_2 : Scelta dell'Urna 2. $P(B_2) = 0.8$.

5. Definizione dell'Evento finale (A):

- A : La pallina estratta è Rossa.

Esempio: Lancio di una moneta equilibrata 10 volte ($p = 1/2$). È più probabile ottenere 10 Croci oppure 6 Croci e 4 Teste?

$$P(k \text{ successi in } n \text{ prove}) = \binom{n}{k} p^k (1-p)^{n-k}$$

(ORDINE NON INTERESSE)

la formula della **Distribuzione Binomiale**:
curarci dell'ordine, dobbiamo moltiplicare per tutte le combinazioni possibili. Si ottiene
ha probabilità $p^k \cdot (1-p)^{n-k}$. Se però ci interessa solo l'avere esattamente k successi senza
L'evento ottenere una specifica sequenza ordinata con k successi (es. 1,1,1,0,0,0,0,0,0,0).

Consideriamo n prove ripetute indipendenti di un esperimento con esito dicotomico: "Successo" (1) o "Insuccesso" (0). Sia p la probabilità di successo nella singola prova e $(1-p)$ l'insuccesso.

11.2 Schema di Bernoulli

Le prove ripetute di uno stesso esperimento sotto le stesse condizioni garantiscono per costruzione l'indipendenza globale. (es. SURLENALOTTO, LANCIO DADO)

In generale, una famiglia di n eventi si dice **collettivamente indipendente** se la probabilità dell'intersezione di qualsiasi loro sottoinsieme è uguale al prodotto delle singole probabilità.

Controesempio a lezione: Tre lanci di moneta, ma il terzo è truccato per essere Testa se i primi due sono concordi, Croce altrimenti. Se prendiamo gli eventi "Testa al 1°", "Testa al 2°", "Testa al 3°", presi a coppie sono tutti indipendenti (prob. $1/4$). Ma globalmente l'intersezione dei tre eventi vale $1/4 \neq 1/8$. Non sono globalmente indipendenti.

- **Indipendenza globale:** $P(A \cap B \cap C) = P(A)P(B)P(C)$
- **Indipendenza pairwise:** $P(A \cap B) = P(A)P(B)$, $P(A \cap C) = \dots$, $P(B \cap C) = \dots$

soddisfare:

Per definire tre eventi A, B, C indipendenti, **NON basta** che lo siano a due a due. Devono

11.1 Indipendenza per più di due eventi

(QUESTO COVA VALE SOLO PER "SOMMA" E NON PER "COMPLESSO")

4. **Indipendenza non è Causalità:** Due eventi legati da una relazione fisica causale-effetto possono risultare probabilisticamente indipendenti (es. l'esito del 1° lancio del dado concorre fisicamente a formare la "Somma=7", ma l'evento "esce 3 al primo lancio" e l'evento "la somma è 7" sono matematicamente indipendenti, $P = 1/6 \cdot 1/6 = 1/36$).
SOMMA FA 7 = 1
SE ESCE 4 NON 3 = 1
SE ESCE 4 NON 3 = 1

3. **Complementari:** Se A e B sono indipendenti, lo sono anche le coppie (A^c, B) , (A, B^c) e (A^c, B^c) .

2. **Casi degeneri:** Se $P(A) = 0$ oppure $P(A) = 1$, allora A è indipendente da qualsiasi altro evento.

1. **Indipendenza non è incompatibilità:** Due eventi disgiunti (incompatibili, $A \cap B = \emptyset$) NON sono indipendenti (a meno che uno dei due non sia trascurabile). Infatti, se so che è accaduto B , sono sicuro che A non accadrà: $P(A|B) = 0 \neq P(A)$. L'incompatibilità è un forte legame di dipendenza!

$$(incompatibili) \Rightarrow A \cap B = \emptyset$$

$$\bullet P(10 \text{ Croci}) = \binom{10}{0} (1/2)^0 (1/2)^{10} = \frac{1}{1024}$$

$$\bullet P(6 \text{ Croci e 4 Teste}) = \binom{10}{4} (1/2)^4 (1/2)^6 = 210 \cdot \left(\frac{1}{2}\right)^{10} = \frac{210}{1024}$$

Ottenere 6C e 4T è enormemente più probabile (ci sono 210 sequenze diverse che generano quel risultato, contro 1 sola sequenza per le 10 croci).

3. Così otteniamo: se $A = \{1, 2, 3, 4, 5, 6\}$ e $B = \{1, 2, 3, 4, 5, 6\}$ allora otteniamo:

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

11.1 Indipendenza dei bin di due eventi

Due eventi A e B sono indipendenti se la probabilità di entrambi verificarsi è uguale al prodotto delle loro probabilità individuali.

$$P(A \cap B) = P(A) \cdot P(B)$$

$$P(A \cap B) = P(A) \cdot P(B) \iff P(A|B) = P(A) \text{ e } P(B|A) = P(B)$$

Consideriamo un esperimento con due eventi A e B . Se A e B sono indipendenti, allora la probabilità di A non cambia se B è noto o non è noto.

$$P(A|B) = P(A) \iff P(A \cap B) = P(A) \cdot P(B)$$

$$P(B|A) = P(B) \iff P(A \cap B) = P(A) \cdot P(B)$$

La proprietà di indipendenza è simmetrica: se A è indipendente da B , allora B è indipendente da A .

La proprietà di indipendenza è transitiva: se A è indipendente da B e B è indipendente da C , allora A è indipendente da C .

11.3 Schema di Bernoulli

Un esperimento con due risultati possibili, uno dei quali è considerato "successo", viene ripetuto n volte in modo indipendente.

La probabilità di ottenere k successi in n prove è data dalla formula:

$$P(k \text{ successi in } n \text{ prove}) = \binom{n}{k} p^k (1-p)^{n-k}$$

La distribuzione binomiale è una distribuzione discreta che modella il numero di successi in un numero fisso di prove.

La distribuzione binomiale è una distribuzione discreta che modella il numero di successi in un numero fisso di prove.

La distribuzione binomiale è una distribuzione discreta che modella il numero di successi in un numero fisso di prove.

La distribuzione binomiale è una distribuzione discreta che modella il numero di successi in un numero fisso di prove.

La distribuzione binomiale è una distribuzione discreta che modella il numero di successi in un numero fisso di prove.

La distribuzione binomiale è una distribuzione discreta che modella il numero di successi in un numero fisso di prove.

La distribuzione binomiale è una distribuzione discreta che modella il numero di successi in un numero fisso di prove.

20.3 Legge di Probabilità di una Variabile Aleatoria

Rigorosamente parlando, Ω è esclusivamente l'insieme dei possibili esiti dell'esperimento (lo spazio campionario). Tuttavia, nel calcolo delle probabilità, Ω è dotato di una misura P che assegna una probabilità ai vari eventi (sottoinsiemi di Ω).

La variabile aleatoria X associa a ogni esito in Ω un numero in $\mathbb{R}$. La sua "Legge" (o distribuzione) ci permette di lavorare direttamente sui numeri reali: per calcolare la probabilità che il risultato cada in un intervallo $A \subseteq \mathbb{R}$, dobbiamo "tornare indietro" tramite l'operatore di controimmagine $X^{-1}(A)$ e calcolare la probabilità P degli esiti in Ω che la funzione X ha mappato proprio dentro A . Questo meccanismo in matematica è noto come **misura immagine**.

Definizione 20.1 (Legge o Distribuzione di X). Sia $X: \Omega \rightarrow \mathbb{R}$ una variabile aleatoria. Definiamo **legge** (o **distribuzione**) di X la funzione $P_X: \mathcal{P}(\mathbb{R}) \rightarrow [0, 1]$ data da:

$$P_X(A) = P(X \in A) \quad \forall A \subseteq \mathbb{R}$$

dove l'espressione $\{X \in A\}$ è una notazione compatta per indicare la controimmagine $X^{-1}(A) = \{\omega \in \Omega \mid X(\omega) \in A\}$.

Proprietà 20.1. L'operatore di controimmagine X^{-1} commuta con le operazioni insiemistiche. Questo garantisce che P_X sia effettivamente una misura di probabilità valida su $\mathbb{R}$.

Esempio pratico. Consideriamo l'esperimento del lancio di un dado. Lo spazio campionario è $\Omega = \{\omega_1, \omega_2, \dots, \omega_6\}$ dove l'evento elementare ω_i significa "è uscito il numero i ". Definendo la probabilità uniforme, sappiamo che $P(\{\omega_i\}) = 1/6$.

Definiamo due variabili aleatorie su questo spazio:

1. $X: \Omega \rightarrow \mathbb{R}$, dove X esprime il numero esatto uscito ($X(\omega_i) = i$).

2. $Y: \Omega \rightarrow \mathbb{R}$, dove $Y(\omega_i) = 1$ se i è dispari, e $Y(\omega_i) = 0$ se i è pari.

La variabile aleatoria X associa a ogni esito in Ω un numero in $\mathbb{R}$. La sua "Legge" (o distribuzione) ci permette di lavorare direttamente sui numeri reali: per calcolare la probabilità che il risultato cada in un intervallo $A \subseteq \mathbb{R}$, dobbiamo "tornare indietro" tramite l'operatore di controimmagine $X^{-1}(A)$ e calcolare la probabilità P degli esiti in Ω che la funzione X ha mappato proprio dentro A . Questo meccanismo in matematica è noto come **misura immagine**.

Definizione 20.1 (Legge o Distribuzione di X). Sia $X: \Omega \rightarrow \mathbb{R}$ una variabile aleatoria. Definiamo **legge** (o **distribuzione**) di X la funzione $P_X: \mathcal{P}(\mathbb{R}) \rightarrow [0, 1]$ data da:

$$P_X(A) = P(X \in A) \quad \forall A \subseteq \mathbb{R}$$

dove l'espressione $\{X \in A\}$ è una notazione compatta per indicare la controimmagine $X^{-1}(A) = \{\omega \in \Omega \mid X(\omega) \in A\}$.

Proprietà 20.1. L'operatore di controimmagine X^{-1} commuta con le operazioni insiemistiche. Questo garantisce che P_X sia effettivamente una misura di probabilità valida su $\mathbb{R}$.

Esempio pratico. Consideriamo l'esperimento del lancio di un dado. Lo spazio campionario è $\Omega = \{\omega_1, \omega_2, \dots, \omega_6\}$ dove l'evento elementare ω_i significa "è uscito il numero i ". Definendo la probabilità uniforme, sappiamo che $P(\{\omega_i\}) = 1/6$.

Definiamo due variabili aleatorie su questo spazio:

1. $X: \Omega \rightarrow \mathbb{R}$, dove X esprime il numero esatto uscito ($X(\omega_i) = i$).

2. $Y: \Omega \rightarrow \mathbb{R}$, dove $Y(\omega_i) = 1$ se i è dispari, e $Y(\omega_i) = 0$ se i è pari.

La variabile aleatoria X associa a ogni esito in Ω un numero in $\mathbb{R}$. La sua "Legge" (o distribuzione) ci permette di lavorare direttamente sui numeri reali: per calcolare la probabilità che il risultato cada in un intervallo $A \subseteq \mathbb{R}$, dobbiamo "tornare indietro" tramite l'operatore di controimmagine $X^{-1}(A)$ e calcolare la probabilità P degli esiti in Ω che la funzione X ha mappato proprio dentro A . Questo meccanismo in matematica è noto come **misura immagine**.

Definizione 20.1 (Legge o Distribuzione di X). Sia $X: \Omega \rightarrow \mathbb{R}$ una variabile aleatoria. Definiamo **legge** (o **distribuzione**) di X la funzione $P_X: \mathcal{P}(\mathbb{R}) \rightarrow [0, 1]$ data da:

$$P_X(A) = P(X \in A) \quad \forall A \subseteq \mathbb{R}$$

dove l'espressione $\{X \in A\}$ è una notazione compatta per indicare la controimmagine $X^{-1}(A) = \{\omega \in \Omega \mid X(\omega) \in A\}$.

Proprietà 20.1. L'operatore di controimmagine X^{-1} commuta con le operazioni insiemistiche. Questo garantisce che P_X sia effettivamente una misura di probabilità valida su $\mathbb{R}$.

Esempio pratico. Consideriamo l'esperimento del lancio di un dado. Lo spazio campionario è $\Omega = \{\omega_1, \omega_2, \dots, \omega_6\}$ dove l'evento elementare ω_i significa "è uscito il numero i ". Definendo la probabilità uniforme, sappiamo che $P(\{\omega_i\}) = 1/6$.

Definiamo due variabili aleatorie su questo spazio:

1. $X: \Omega \rightarrow \mathbb{R}$, dove X esprime il numero esatto uscito ($X(\omega_i) = i$).

2. $Y: \Omega \rightarrow \mathbb{R}$, dove $Y(\omega_i) = 1$ se i è dispari, e $Y(\omega_i) = 0$ se i è pari.

La variabile aleatoria X associa a ogni esito in Ω un numero in $\mathbb{R}$. La sua "Legge" (o distribuzione) ci permette di lavorare direttamente sui numeri reali: per calcolare la probabilità che il risultato cada in un intervallo $A \subseteq \mathbb{R}$, dobbiamo "tornare indietro" tramite l'operatore di controimmagine $X^{-1}(A)$ e calcolare la probabilità P degli esiti in Ω che la funzione X ha mappato proprio dentro A . Questo meccanismo in matematica è noto come **misura immagine**.

Definizione 20.1 (Legge o Distribuzione di X). Sia $X: \Omega \rightarrow \mathbb{R}$ una variabile aleatoria. Definiamo **legge** (o **distribuzione**) di X la funzione $P_X: \mathcal{P}(\mathbb{R}) \rightarrow [0, 1]$ data da:

$$P_X(A) = P(X \in A) \quad \forall A \subseteq \mathbb{R}$$

dove l'espressione $\{X \in A\}$ è una notazione compatta per indicare la controimmagine $X^{-1}(A) = \{\omega \in \Omega \mid X(\omega) \in A\}$.

Proprietà 20.1. L'operatore di controimmagine X^{-1} commuta con le operazioni insiemistiche. Questo garantisce che P_X sia effettivamente una misura di probabilità valida su $\mathbb{R}$.

Esempio pratico. Consideriamo l'esperimento del lancio di un dado. Lo spazio campionario è $\Omega = \{\omega_1, \omega_2, \dots, \omega_6\}$ dove l'evento elementare ω_i significa "è uscito il numero i ". Definendo la probabilità uniforme, sappiamo che $P(\{\omega_i\}) = 1/6$.

Definiamo due variabili aleatorie su questo spazio:

1. $X: \Omega \rightarrow \mathbb{R}$, dove X esprime il numero esatto uscito ($X(\omega_i) = i$).

2. $Y: \Omega \rightarrow \mathbb{R}$, dove $Y(\omega_i) = 1$ se i è dispari, e $Y(\omega_i) = 0$ se i è pari.

La variabile aleatoria X associa a ogni esito in Ω un numero in $\mathbb{R}$. La sua "Legge" (o distribuzione) ci permette di lavorare direttamente sui numeri reali: per calcolare la probabilità che il risultato cada in un intervallo $A \subseteq \mathbb{R}$, dobbiamo "tornare indietro" tramite l'operatore di controimmagine $X^{-1}(A)$ e calcolare la probabilità P degli esiti in Ω che la funzione X ha mappato proprio dentro A . Questo meccanismo in matematica è noto come **misura immagine**.

Definizione 20.1 (Legge o Distribuzione di X). Sia $X: \Omega \rightarrow \mathbb{R}$ una variabile aleatoria. Definiamo **legge** (o **distribuzione**) di X la funzione $P_X: \mathcal{P}(\mathbb{R}) \rightarrow [0, 1]$ data da:

$$P_X(A) = P(X \in A) \quad \forall A \subseteq \mathbb{R}$$

dove l'espressione $\{X \in A\}$ è una notazione compatta per indicare la controimmagine $X^{-1}(A) = \{\omega \in \Omega \mid X(\omega) \in A\}$.

Proprietà 20.1. L'operatore di controimmagine X^{-1} commuta con le operazioni insiemistiche. Questo garantisce che P_X sia effettivamente una misura di probabilità valida su $\mathbb{R}$.

Esempio pratico. Consideriamo l'esperimento del lancio di un dado. Lo spazio campionario è $\Omega = \{\omega_1, \omega_2, \dots, \omega_6\}$ dove l'evento elementare ω_i significa "è uscito il numero i ". Definendo la probabilità uniforme, sappiamo che $P(\{\omega_i\}) = 1/6$.

Definiamo due variabili aleatorie su questo spazio:

1. $X: \Omega \rightarrow \mathbb{R}$, dove X esprime il numero esatto uscito ($X(\omega_i) = i$).

2. $Y: \Omega \rightarrow \mathbb{R}$, dove $Y(\omega_i) = 1$ se i è dispari, e $Y(\omega_i) = 0$ se i è pari.

La variabile aleatoria X associa a ogni esito in Ω un numero in $\mathbb{R}$. La sua "Legge" (o distribuzione) ci permette di lavorare direttamente sui numeri reali: per calcolare la probabilità che il risultato cada in un intervallo $A \subseteq \mathbb{R}$, dobbiamo "tornare indietro" tramite l'operatore di controimmagine $X^{-1}(A)$ e calcolare la probabilità P degli esiti in Ω che la funzione X ha mappato proprio dentro A . Questo meccanismo in matematica è noto come **misura immagine**.

Definizione 20.1 (Legge o Distribuzione di X). Sia $X: \Omega \rightarrow \mathbb{R}$ una variabile aleatoria. Definiamo **legge** (o **distribuzione**) di X la funzione $P_X: \mathcal{P}(\mathbb{R}) \rightarrow [0, 1]$ data da:

$$P_X(A) = P(X \in A) \quad \forall A \subseteq \mathbb{R}$$

dove l'espressione $\{X \in A\}$ è una notazione compatta per indicare la controimmagine $X^{-1}(A) = \{\omega \in \Omega \mid X(\omega) \in A\}$.


Proprietà 20.1. L'operatore di controimmagine X^{-1} commuta con le operazioni insiemistiche. Questo garantisce che P_X sia effettivamente una misura di probabilità valida su $\mathbb{R}$.

Esempio pratico. Consideriamo l'esperimento del lancio di un dado. Lo spazio campionario è $\Omega = \{\omega_1, \omega_2, \dots, \omega_6\}$ dove l'evento elementare ω_i significa "è uscito il numero i ". Definendo la probabilità uniforme, sappiamo che $P(\{\omega_i\}) = 1/6$.

Definiamo due variabili aleatorie su questo spazio:

1. $X: \Omega \rightarrow \mathbb{R}$, dove X esprime il numero esatto uscito ($X(\omega_i) = i$).

2. $Y: \Omega \rightarrow \mathbb{R}$, dove $Y(\omega_i) = 1$ se i è dispari, e $Y(\omega_i) = 0$ se i è pari.



Se vogliamo trovare la legge di probabilità di X e di Y , dobbiamo calcolare la probabilità delle loro controimmagini:

- $P_X(3) = P(X^{-1}(3)) = P(\{\omega_3\}) = \frac{1}{6}$
- Dato un sottoinsieme $A = \{3, 4\} \subseteq \mathbb{R}$, otteniamo:


$$P_X(\{3, 4\}) = P(X^{-1}(\{3, 4\})) = P(\{\omega_3\} \cup \{\omega_4\}) = \frac{1}{6} + \frac{1}{6} = \frac{1}{3}$$
- Calcoliamo la legge per $Y = 0$ (ovvero, dado pari): le controimmagini sono $Y^{-1}(0) = \{\omega_2, \omega_4, \omega_6\}$. Pertanto:

$$P_Y(0) = P(Y^{-1}(0)) = P(\{\omega_2\} \cup \{\omega_4\} \cup \{\omega_6\}) = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{1}{2}$$

Esempio pratico

Impostiamo $\Omega = \{C, T\}^2 = \{(\omega_1, \omega_2) \mid \omega_1, \omega_2 \in \{C, T\}\}$. Assumiamo una codifica numerica per cui Croce = 0 e Testa = 1, quindi $\Omega = \{0, 1\}^2$. La probabilità per il singolo lancio è $P(0) = P(1) = \frac{1}{2}$.

Definiamo X = numero totale di teste nei 2 lanci. X può assumere i valori $\{0, 1, 2\}$ sull'asse reale.



Calcoliamo rigorosamente la legge di X calcolando le probabilità delle rispettive controimmagini:

$$\begin{aligned}
 P_X(0) &= P(X^{-1}(0)) = P(\{(0,0)\}) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4} \\
 P_X(1) &= P(X^{-1}(1)) = P(\{(0,1)\} \cup \{(1,0)\}) = \left(\frac{1}{2} \cdot \frac{1}{2}\right) + \left(\frac{1}{2} \cdot \frac{1}{2}\right) = \frac{1}{2} \\
 P_X(2) &= P(X^{-1}(2)) = P(\{(1,1)\}) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}
 \end{aligned}$$

12 Variabili Aleatorie: Definizioni Fondamentali

Abbiamo un esperimento aleatorio di cui ci interessa solo una caratteristica (carattere) quantitativa degli esiti. Questa caratteristica è la variabile aleatoria, e la distribuzione di questa caratteristica è la sua legge.

Esempio pratico

Lo spazio campionario è $\Omega = \{0, 1\} \times \{0, 1\}$, dove 0 rappresenta "Croce" e 1 rappresenta "Testa". La probabilità P è uniforme.

Definiamo il carattere X = numero di teste nei due lanci. I valori possibili sono $\{0, 1, 2\} \subseteq \mathbb{R}$. Formalmente, $X: \Omega \rightarrow \mathbb{R}$ mappa gli eventi in questo modo:

- $(0,0) \mapsto 0$
- $(0,1) \mapsto 1$ e $(1,0) \mapsto 1$
- $(1,1) \mapsto 2$

Le probabilità associate (la legge di X) saranno: un insieme di numeri

- $P_X(\{0\}) = P(X=0) = \frac{1}{4}$
- $P_X(\{1\}) = P(X=1) = \frac{2}{4} = \frac{1}{2}$
- $P_X(\{2\}) = P(X=2) = \frac{1}{4}$

Definizione 12.1 (Variabile Aleatoria Reale). Una Variabile Aleatoria (v.a. o random variable, r.v.) è una funzione $X: \Omega \rightarrow \mathbb{R}$ misurabile definita su uno spazio di probabilità $(\Omega, \mathcal{F})$.

Definizione 12.2 (Legge o Distribuzione di X). È la probabilità P_X definita su $\mathbb{R}$ (precisamente $P_X: \mathcal{P}(\mathbb{R}) \rightarrow \mathbb{R}$) data da:

$$P_X(A) = P(\{X \in A\}) \quad \text{per } A \subseteq \mathbb{R} \quad (= P(X^{-1}(A))) \quad (26)$$

dove l'insieme $\{X \in A\}$ indica la controimmagine $X^{-1}(A) = \{\omega \in \Omega \mid X(\omega) \in A\}$.

Proprietà 12.1 (Commutatività delle operazioni insiemistiche). La controimmagine X^{-1} "commuta" con le operazioni insiemistiche. Questo è fondamentale per tradurre condizioni su $\mathbb{R}$ in eventi in Ω :

- $X^{-1}(A^c) = (X^{-1}(A))^c$
- $X^{-1}(A \cap B) = X^{-1}(A) \cap X^{-1}(B)$
- $X^{-1}(A \cup B) = X^{-1}(A) \cup X^{-1}(B)$

La legge P_X verifica tutti gli assiomi di Kolmogorov. Ad esempio, $P_X([a, b]) = P(\{\omega \in \Omega \mid X(\omega) \in [a, b]\})$.

Definizione 12.3 (Variabili Aleatorie Equidistribuite). Due v.a. X e Y si dicono equidistribuite se hanno la stessa legge, cioè se $P_X = P_Y$.

ESEMPIO PRATICO: $X = \text{numero di croci in 2 lanci di moneta}$

Prendendo le variabili $X = \text{numero di teste e } Y = \text{numero di croci in 2 lanci di moneta}$ equilibrata, vediamo che entrambe assumono valori $0, 1, 2$ con probabilità rispettive di $1/4, 1/2, 1/4$. Le variabili X e Y sono equidistribuite ma non uguali (allo stesso esito $(1, 0)$, $X = 1$ mentre $Y = 0$).

Notazione: Si utilizzano lettere minuscole ($x, y, z, \dots$) per indicare le v.a., e lettere minuscole ($a, b, x, \dots$) per indicare le modalità (i possibili valori assunti).

13 Variabili Aleatorie Discrete e Funzioni di Massa

Definizione 13.1 (V.a. discreta). Una v.a. X è discreta se assume un numero finito o numerabile di modalità (valori) $a_1, a_2, a_3, \dots$ ("valori ben separati").

Esempi classici: numero di teste in n lanci (modalità $0, 1, \dots, n$); numero di richieste a un server (modalità $N = \{0, 1, 2, \dots\}$).

Attenzione: a_i sono le possibili modalità, $a_i \in \mathbb{R}$; x_i è un dato, $x_i \in \mathbb{R}$ (v.a. discreta).


Definizione 13.2 (Funzione di Massa / Densità discreta). La funzione di massa p_X :

$$\{a_1, a_2, \dots\} \rightarrow \mathbb{R} \text{ di } X \text{ (o della sua legge } p^X) \text{ è definita da:}$$

$$p_X(a_i) = P(X = a_i) = P(X^{-1}(a_i)) = P(\{x \in \mathbb{R} : x = a_i\}) = P(\{a_i\}) = 1$$

Essa corrisponde intuitivamente alla frequenza relativa di a_i .

Si rappresenta graficamente tramite un **diagramma a barre**.



Il calcolo delle probabilità a partire da p_X si fa per semplice somma:

$$P(X \in A) = \sum_{a \in A} p_X(a) = P(X = a_1 \cup X = a_2 \cup \dots)$$

Ad esempio, $P(X \leq 1) = P(X = 0) + P(X = 1) = 1 - P(X = 2)$.

INTEGRAZIONE

Metodo generale per trovare la funzione di massa di $Y = g(X)$

La formula rigorosa per ricavare la funzione di massa di una variabile aleatoria discreta trasformata è:

$$p_Y(y) = P(Y = y) = \sum_{x \in S_X : g(x) = y} p_X(x)$$

dove S_X rappresenta il supporto della variabile aleatoria di partenza X .

Il Metodo in 3 Passaggi

1. Trova il supporto di Y : Applica la funzione $g(x)$ a tutti i valori possibili di X (il supporto S_X). Fai un elenco dei risultati ottenuti e scarta i doppi. Questo insieme è il nuovo supporto S_Y .
2. Raggruppa le controimmagini: Per ogni singolo valore $y \in S_Y$, risolvi l'equazione $g(x) = y$ per trovare quali specifici valori di x hanno generato quel risultato.
3. Somma le probabilità: Per ciascun y , applica la sommatoria della formula iniziale: prendi i valori di x trovati al passo precedente e somma le loro probabilità originarie $p_X(x)$.

Esempio Pratico

Sia X una variabile aleatoria con supporto $S_X = \{-1, 0, 1\}$ in cui ogni valore è equiprobabile, ovvero $p_X(x) = \frac{1}{3}$ per ogni $x \in S_X$. Definiamo la trasformazione $Y = X^2$.

- Passo 1 (Supporto di Y): Calcolando i quadrati dei valori di X otteniamo $(-1)^2 = 1, 0^2 = 0, 1^2 = 1$. Eliminando i doppi, il supporto della nuova variabile è $S_Y = \{0, 1\}$.
- Passi 2 e 3 per $y = 0$: L'unica soluzione dell'equazione $x^2 = 0$ è $x = 0$. Essendoci un solo termine nella sommatoria, abbiamo:

$$p_Y(0) = P(X = 0) = \frac{1}{3}$$

- Passi 2 e 3 per $y = 1$: Le soluzioni dell'equazione $x^2 = 1$ sono due: $x = 1$ e $x = -1$. In questo caso la sommatoria si sviluppa su due termini:

$$p_Y(1) = P(X = 1) + P(X = -1) = \frac{1}{3} + \frac{1}{3} = \frac{2}{3}$$

ib asiam lb enoixnuñ el enovot noj elanepno obotoM

(X,Y) = Y

$$\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = (n-1)s_{xy}$$

X, Y variabili aleatorie discrete con distribuzione congiunta

ipaganaE E ni obotoM II

X, Y variabili aleatorie discrete con distribuzione congiunta

X, Y variabili aleatorie discrete con distribuzione congiunta

X, Y variabili aleatorie discrete con distribuzione congiunta

X, Y variabili aleatorie discrete con distribuzione congiunta

X, Y variabili aleatorie discrete con distribuzione congiunta

X, Y variabili aleatorie discrete con distribuzione congiunta

X, Y variabili aleatorie discrete con distribuzione congiunta

X, Y variabili aleatorie discrete con distribuzione congiunta

X, Y variabili aleatorie discrete con distribuzione congiunta

X, Y variabili aleatorie discrete con distribuzione congiunta

X, Y variabili aleatorie discrete con distribuzione congiunta

X, Y variabili aleatorie discrete con distribuzione congiunta

X, Y variabili aleatorie discrete con distribuzione congiunta

Proprietà 13.1 (Proprietà della Funzione di Massa).

$$\sum_{i=1}^n p_X(a_i) = 1 \quad (\text{infatti } \sum_{i=1}^n p_X(a_i) = P(X \in \mathbb{R}) = 1)$$

Se una funzione $q: \{a_1, a_2, \dots\} \rightarrow \mathbb{R}$ soddisfa le proprietà (1) e (2), allora q è funzione di massa di una v.a. discreta X (cioè $q(a_i) = P(X = a_i)$).

13.1 Interpretazione Frequentista

Consideriamo l'estrazione casuale di un individuo da una popolazione (probabilità unitarie) e la misurazione di un carattere discreto (es. numero di figli in Italia). In questo caso, se si estraggono n individui, si ottengono n risultati indipendenti di una prova, con esiti "successo" (1) avente probabilità $p \in [0, 1]$ e "insuccesso" (0) avente probabilità $1 - p$. Quindi la probabilità $P(X = 2)$ equivale alla frequenza relativa del carattere $X = 2$ su tutta la popolazione (non su un campione).

14 Variabili Aleatorie Discrete Notevoli

14.1 Schema di Bernoulli e V.A. Binomiale

Lo Schema di Bernoulli descrive n ripetizioni indipendenti di una prova, con esiti "successo" (1) avente probabilità $p \in [0, 1]$ e "insuccesso" (0) avente probabilità $1 - p$. • Lancio di moneta: $p = P(\text{Testa})$ • Lancio di dado equilibrato: successo = "esce 4", quindi $p = 1/6$ • Lo spazio campionario è $\Omega = \{0, 1\}^n = \{(\omega_1, \dots, \omega_n) \mid \omega_i \in \{0, 1\}\}$. Poiché le prove sono indipendenti, la probabilità di una specifica sequenza è: $(p \text{ se } \omega_i = 1, 1-p \text{ se } \omega_i = 0)$

Definizione 14.1 (Variabile Binomiale $X \sim B(n, p)$): X è il numero di successi in n prove di Bernoulli.

$$X(\omega_1, \dots, \omega_n) = \sum_{i=1}^n \omega_i \quad (0+1+1+0+\dots)$$

La funzione di massa, per $k = 0, 1, 2, \dots, n$, è:


$$p_X(k) = P(X = k) = \binom{n}{k} p^k (1-p)^{n-k} \quad (32)$$

Dimostrazione: Esattamente k successi su n prove corrisponde alla somma delle probabilità di tutte le sequenze $(\omega_1, \dots, \omega_n)$ con k successi. Il numero di posizioni dei k indici dei successi è $\binom{n}{k}$, e ogni sequenza ha probabilità $p^k (1-p)^{n-k}$.

Esempio pratico

In 5 lanci di dado, qual è la probabilità che "4" appaia almeno due volte? Singola prova: lancio. Successo = "esce 4", quindi $p = 1/6$. Prove $n = 5$.

$$B(n, p) \text{ V.A. DISCRETA CON FUNZ. DI MASSA } P(k) = \binom{n}{k} \dots$$



$X = \text{numero di "5" } \sim B(6, 1/6)$. Vogliamo calcolare $P(X \geq 2)$.

$$P(X \geq 2) = 1 - P(X \leq 1) = 1 - P(X=0) - P(X=1) \quad (33)$$

$$P(X \geq 2) = 1 - \left[\binom{6}{0} \left(\frac{1}{6}\right)^0 \left(\frac{5}{6}\right)^6 + \binom{6}{1} \left(\frac{1}{6}\right)^1 \left(\frac{5}{6}\right)^5 \right]$$

$$= 1 - 1 \cdot 1 \cdot \left(\frac{5}{6}\right)^6 - 6 \cdot \left(\frac{1}{6}\right) \cdot \left(\frac{5}{6}\right)^5 = 1 - 2 \left(\frac{5}{6}\right)^5$$

I grafici a barre della Binomiale variano in base a p . Se $p < 1/2$ è asimmetrica a sinistra (picco prima di $n/2$). Se $p = 1/2$ è perfettamente simmetrica con picco in $np = n/2$. Se $p > 1/2$ è asimmetrica a destra. La "larghezza" della campana è proporzionale a $\sigma = \sqrt{np(1-p)}$.

14.2 V.A. Geometrica

Schema di Bernoulli con "infinita prove". Ci interessa determinare in quale prova avviene il primo successo. $\Omega = \{0, 1\}^{\mathbb{N}}$.

Definizione 14.2 (Variabile Geometrica $T \sim \text{Geom}(p)$). T è l'istante (n° della prova) del primo successo: $T(\omega_1, \omega_2, \dots) = \min\{n \in \mathbb{N}_+ : \omega_n = 1\}$. Nota: se la sequenza ha solo zeri, $T = +\infty$, ma tale evento ha probabilità nulla. T assume valori in $\mathbb{N}_+ = \{1, 2, 3, \dots\}$. funzione di massa:

$$P(T = k) = p(1-p)^{k-1} \quad (34)$$

Dimostrazione: Se $A_k = \{\text{successo alla } k\text{-esima prova}\}$, allora $P(T = k) = P(A_k \cap A_1^c \cap \dots \cap A_{k-1}^c)$. Essendo prove indipendenti, la probabilità diventa $P(A_k) \cdot P(A_1^c) \cdot \dots \cdot P(A_{k-1}^c) = (1-p)^{k-1} \cdot p$.

Proprietà 14.1 (Assenza di Memoria). Se $T \sim \text{Geom}(p)$, allora $\forall n, k \in \mathbb{N}_+$:

$$P(T = n+k | T > n) = P(T = k) \quad (35)$$

La distribuzione del 1° successo nel futuro non cambia sapendo che il successo non si è verificato nelle precedenti prove.

Esempio pratico

$T = \text{istante nel 4° lancio } \sim \text{Geom}\left(\frac{1}{6}\right)$


Lanci ripetuti di un dado.

a) Probabilità del primo "5" al 4° lancio? $T \sim \text{Geom}(1/6)$.

$P(T=4) = \left(1 - \frac{1}{6}\right)^3 \cdot \frac{1}{6} = \frac{5^3}{6^4} = \frac{125}{1296}$.

b) Probabilità del primo "5" al 6° lancio, sapendo che non è uscito nei primi 2 lanci?

$P(T=6 | T > 2) = P(T=4) = \frac{1}{6^4}$.



26 ALZAREMENTARE DI P LA FUNZ. DI PROBABILITÀ DELL'ESCE IN VEDENTE

Approfondimento Modelli Discreti

La Variabile di Poisson e la Variabile Ipergeometrica

Integrazione Appunti e Spiegazioni

(NON È SENZA RICHIEDA)

1 La Variabile di Poisson: Contare gli Eventi Rari

Intuizione: Il contatore di imprevisti

Immagina di essere seduto su una panchina. Sai che, in media, passano 3 cani ogni ora ($\lambda = 3$). La variabile di Poisson risponde alla domanda: "Visto che la media è 3, quante probabilità ho che nella prossima ora non ne passi nessuno? O magari ne passino 5?"

È chiamata "legge degli eventi rari" perché ogni singolo cane della città ha una probabilità quasi nulla di passare proprio di lì in quel momento, ma essendoci tantissimi cani, qualcuno alla fine passa. L'unica informazione che ti serve per fare i calcoli è il ritmo medio (λ).

Definizione Formale: Variabile di Poisson $\text{Pois}(\lambda)$

Una variabile aleatoria discreta X segue una distribuzione di Poisson di parametro $\lambda > 0$ se assume valori in $\mathbb{N} = \{0, 1, 2, \dots\}$ con funzione di massa:

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda} \quad (1)$$

La costante $e^{-\lambda}$ serve a "bilanciare" le probabilità in modo che la somma totale (da 0 a infinito) faccia esattamente 1 (il 100%).


Dimostrazione Matematica

Verifichiamo che sia una vera legge di probabilità. Sfruttiamo lo sviluppo in serie di Taylor della funzione esponenziale $e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!}$:

$$\sum_{k=0}^{\infty} P(X = k) = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} \cdot e^{\lambda} = 1 \quad (2)$$

Si dimostra inoltre che il Valore Atteso e la Varianza coincidono e valgono esattamente il parametro:

$$E[X] = \lambda \quad \text{e} \quad \text{Var}(X) = \lambda$$



1.1 Il legame magico: Poisson come limite della Binomiale

Perché usiamo una formula con il numero e per contare cose che sembrano nascere da scelte "Sì/No" (Binomiale)?

Intuizione: L'incrocio stradale e l'approssimazione ($\lambda \approx np$)

Osservi un incrocio per un'ora. Le migliaia di auto che passano sono le tue prove (n). La probabilità che una singola auto faccia un incidente è minuscola (p). Calcolare una Binomiale con $n = 10.000$ e $p = 0.0002$ farebbe impazzire chiunque (dovresti calcolare fattoriali enormi).

Tuttavia, la media degli incidenti è banalmente $\lambda = n \cdot p = 2$. Usare la formula di Poisson con $\lambda = 2$ ci dà un risultato quasi identico a quello della Binomiale, ma con un calcolo istantaneo!

La v.a. di Poisson è proprio l'approssimazione del numero di successi in n prove ripetute quando n è molto grande, p è molto piccola, e poniamo $\lambda \approx np$. Di norma, l'approssimazione si considera ottima quando $n \geq 50$ e $p \leq 0.1$.

Esempio Pratico: Le code al supermercato

Alle casse di un supermercato si presentano in media 3 clienti al minuto ($\lambda = 3$). Calcoliamo la probabilità che si presentino più di 4 clienti nel prossimo minuto:

$$P(X > 4) = 1 - P(X \leq 4) = 1 - (P(X=0) + P(X=1) + P(X=2) + P(X=3) + P(X=4))$$

Svolgendo i calcoli per i primi due termini:

$$P(X=0) = \frac{3^0}{0!} e^{-3} \approx 0.0498, \quad P(X=1) = \frac{3^1}{1!} e^{-3} \approx 0.1494$$

2 La Variabile Ipergeometrica: Estrazioni in Blocco

Intuizione: Pescare senza rimpiazzo

Immagina un sacchetto con 10 palline: 4 Rosse (successi) e 6 Blu. Tu ne pesci 3 senza rimetterle dentro. Se usassi la Binomiale, staresti assumendo che la probabilità di pescare rosso sia sempre fissa al 40%. Ma non è così! Se la prima è rossa, nel sacchetto rimangono solo 3 rosse su 9 totali: la probabilità scende al 33%. Ogni pescata "cambia" la storia. Per questo tipo di situazioni (eventi dipendenti) nasce l'Ipergeometrica.

Definizione Formale: Variabile Ipergeometrica $IP(N, F, n)$

Supponiamo di avere una popolazione totale di N unità, suddivise in F unità "favorevoli" e $N - F$ unità "non favorevoli". Se estraiamo in blocco (o una dopo l'altra senza rimpiazzo) un campione di n unità, la variabile X che conta i successi segue la legge Ipergeometrica:

$$P(X = k) = \frac{\binom{F}{k} \binom{N-F}{n-k}}{\binom{N}{n}} \quad (3)$$

Dimostrazione Matematica

Derivazione Combinatoria della Formula:

La probabilità è il classico rapporto tra Casi Favorevoli e Casi Possibili.

- **Casi possibili:** In quanti modi posso estrarre n elementi da un totale di N ? Semplice coefficiente binomiale $\binom{N}{n}$.
- **Casi favorevoli:** Voglio esattamente k elementi buoni e $n-k$ elementi cattivi. Devo scegliere k buoni tra gli F disponibili (lo posso fare in $\binom{F}{k}$ modi) e accoppiarli con gli $n-k$ cattivi scelti tra gli $N-F$ disponibili ($\binom{N-F}{n-k}$ modi). Moltiplicando queste due scelte ottengo il numeratore.

A causa della dipendenza tra le estrazioni, la Varianza presenta un fattore di correzione per popolazioni finite rispetto a quella della Binomiale:

$$E[X] = n \frac{F}{N}, \quad \text{Var}(X) = n \frac{F}{N} \left(1 - \frac{F}{N}\right) \frac{N-n}{N-1}$$

Esempio Pratico: Controllo Qualità di una Fornitura

Un'azienda riceve un lotto di $N = 20$ pezzi. Ne ispeziona $n = 5$ estrandoli dal pacco. La fornitura viene accettata solo se non viene trovato nessun pezzo difettoso. Sapendo che nel lotto ci sono in realtà $F = 6$ pezzi difettosi, qual è la probabilità che l'azienda accetti la fornitura?

Vogliamo $P(X = 0)$:

$$P(X = 0) = \frac{\binom{20}{5} \binom{14}{0}}{\binom{20}{5}} = \frac{1 \cdot \binom{14}{0}}{\binom{20}{5}} = \frac{1}{15504} \approx 0.00000645$$

$$= \frac{14!}{5! \cdot 15!} = \frac{14 \cdot 13 \cdot 12 \cdot 11 \cdot 10}{20 \cdot 19 \cdot 18 \cdot 17 \cdot 16} \approx 0.125 \text{ (12.5\%)}$$

$$\frac{14!}{5! \cdot 15!} = \frac{14 \cdot 13 \cdot 12 \cdot 11 \cdot 10}{20 \cdot 19 \cdot 18 \cdot 17 \cdot 16} \approx 0.125$$

Definizione 15.1 (V.A. con Densità / Assolutamente Continua). Una v.a. $X: \Omega \rightarrow \mathbb{R}$ si dice con densità se esiste una funzione $f: \mathbb{R} \rightarrow \mathbb{R}$ (chiamata funzione di densità) tale che, per ogni sottoinsieme $A \subseteq \mathbb{R}$:

$$P(X \in A) = \int_A f(x) dx \quad \forall A \subseteq \mathbb{R} \quad (37)$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x} = \frac{P(X \in [x, x + \delta x])}{\delta x}$$

14.3 V.A. di Poisson

Definizione 14.3 (Variabile di Poisson $X \sim \text{Pois}(\lambda)$). Con parametro $\lambda > 0$, è una v.a. discreta a valori in $N = \{0, 1, 2, \dots\}$ con funzione di massa:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k \in N \quad (36)$$

Essendo una densità discreta, la somma è uno: $\sum_{k=0}^{\infty} \frac{\lambda^k e^{-\lambda}}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = 1$.

La v.a. di Poisson conta il numero di eventi rari. È l'approssimazione del numero di successi in n prove ripetute (Binomiale) quando n è molto grande, p (probabilità di successo) è molto piccola, e poniamo $\lambda \approx np$.

Esempi di applicazione:

- N° di particelle α emesse da una sorgente in un dato intervallo (singola prova: emissione da un nucleo, probabilità molto bassa, ma ci sono tantissimi nuclei indipendenti).
- N° di clienti a uno sportello (molte persone indipendenti, bassa probabilità singola di andarci).
- N° di grandi terremoti in una certa area.

15 Variabili Aleatorie con Densità (Continue)

Fino ad ora abbiamo visto variabili che assumono valori "a salti". Tuttavia, molte grandezze fisiche (altezza, temperatura, tempo) variano con continuità. Per queste, la probabilità di assumere un singolo, esatto valore è zero: ad esempio, la probabilità che una persona sia alta esattamente 1.7325... metri è nulla. Ha senso invece calcolare la probabilità che l'altezza cada in un intervallo.

Definizione 15.1 (V.A. con Densità / Assolutamente Continua). Una v.a. $X: \Omega \rightarrow \mathbb{R}$ si dice con densità se esiste una funzione $f: \mathbb{R} \rightarrow \mathbb{R}$ (chiamata funzione di densità) tale che, per ogni sottoinsieme $A \subseteq \mathbb{R}$:

$$P(X \in A) = \int_A f(x) dx \quad \forall A \subseteq \mathbb{R} \quad (37)$$

La densità $f(x)$ non è una probabilità, ma una "probabilità per unità di lunghezza". Per un δx molto piccolo:

$$f(x) \approx \frac{P(X \in [x, x + \delta x])}{\delta x}$$

La probabilità corrisponde all'area sottesa dal grafico della densità.

Per gli intervalli, a prescindere che siano aperti o chiusi, vale:

$$P(a \leq X \leq b) = P(a < X < b) = \int_a^b f(x) dx$$

$$P(X \leq b) = \int_{-\infty}^b f(x) dx = \lim_{a \rightarrow -\infty} \int_a^b f(x) dx$$

$$P(X \geq a) = \int_a^{+\infty} f(x) dx = \lim_{b \rightarrow +\infty} \int_a^b f(x) dx$$

$$P(X \leq b) = \int_{-\infty}^b f(x) dx = \lim_{a \rightarrow -\infty} \int_a^b f(x) dx$$

$$P(X \geq a) = \int_a^{+\infty} f(x) dx = \lim_{b \rightarrow +\infty} \int_a^b f(x) dx$$

$$P(X \leq b) = \int_{-\infty}^b f(x) dx = \lim_{a \rightarrow -\infty} \int_a^b f(x) dx$$

$$P(X \geq a) = \int_a^{+\infty} f(x) dx = \lim_{b \rightarrow +\infty} \int_a^b f(x) dx$$

$$P(X \leq b) = \int_{-\infty}^b f(x) dx = \lim_{a \rightarrow -\infty} \int_a^b f(x) dx$$

$$P(X \geq a) = \int_a^{+\infty} f(x) dx = \lim_{b \rightarrow +\infty} \int_a^b f(x) dx$$

$$P(X \leq b) = \int_{-\infty}^b f(x) dx = \lim_{a \rightarrow -\infty} \int_a^b f(x) dx$$

$$P(X \geq a) = \int_a^{+\infty} f(x) dx = \lim_{b \rightarrow +\infty} \int_a^b f(x) dx$$

$$P(X \leq b) = \int_{-\infty}^b f(x) dx = \lim_{a \rightarrow -\infty} \int_a^b f(x) dx$$

$$P(X \geq a) = \int_a^{+\infty} f(x) dx = \lim_{b \rightarrow +\infty} \int_a^b f(x) dx$$

$$P(X \leq b) = \int_{-\infty}^b f(x) dx = \lim_{a \rightarrow -\infty} \int_a^b f(x) dx$$

$$P(X \geq a) = \int_a^{+\infty} f(x) dx = \lim_{b \rightarrow +\infty} \int_a^b f(x) dx$$

$$P(X \leq b) = \int_{-\infty}^b f(x) dx = \lim_{a \rightarrow -\infty} \int_a^b f(x) dx$$

$$\{ \omega \in \Omega \mid X(\omega) \in [a, b] \} \subseteq \Omega$$

Proprietà 15.1 (Proprietà Fondamentali della Densità). Affinché $f(x)$ sia una valida funzione di densità, deve soddisfare due condizioni:

1. $f(x) \geq 0 \quad \forall x \in \mathbb{R}$ (non ci sono probabilità negative)
2. $\int_{-\infty}^{+\infty} f(x) dx = 1$ (l'area totale deve essere il 100%)

Se f verifica queste due proprietà, allora esiste sempre una v.a. X che ammette f come densità. Inoltre, come anticipato:

$$P(X=a) = \int_{\{a\}} f(x) dx = 0 \quad \forall a \in \mathbb{R} \quad (38)$$

Interpretazione Frequentista: Immagina un istogramma della popolazione in cui l'ampiezza delle classi diventa infinitamente piccola. Il contorno dell'istogramma approssimerà perfettamente la curva continua $f(x)$. * c.c.


16 V.A. con Densità Notevoli

16.1 Variabile Uniforme

Rappresenta la scelta di un punto a caso in un intervallo limitato (α, β) , "senza preferenze". Qualsiasi sotto-intervallo della stessa lunghezza ha la stessa probabilità.

Definizione 16.1 (Uniforme $X \sim U(\alpha, \beta)$). È una v.a. avente densità costante sull'intervallo (α, β) .

$$f(x) = \begin{cases} \frac{1}{\beta - \alpha} & \text{se } x \in (\alpha, \beta) \\ 0 & \text{se } x \notin (\alpha, \beta) \end{cases} \quad (39)$$



Per un intervallo $[a, b] \subseteq (\alpha, \beta)$, la probabilità si calcola geometricamente:



$$P(a \leq X \leq b) = \int_a^b \frac{1}{\beta - \alpha} dx = \frac{b - a}{\beta - \alpha} = \frac{\text{lungh. dell'intervallo}}{\text{lungh. totale}} \quad (40)$$

16.2 Variabile Esponenziale

Mentre la variabile di Poisson conta quanti eventi rari avvengono, l'Esponenziale misura il tempo di attesa tra due di questi eventi (es. tempo tra due terremoti, o due emissioni radioattive).

Definizione 16.2 (Esponenziale $X \sim \text{Exp}(\lambda)$). Con parametro $\lambda > 0$, ha densità:

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{se } x > 0 \\ 0 & \text{se } x \leq 0 \end{cases} = \lambda e^{-\lambda x} \mathbb{I}_{(0, +\infty)}(x) \quad (41)$$



Tipo: UN COMMESSO IMPIEGA 10 MIN
 + CLIENTE
 $X = \text{EXP}(\lambda)$
 $\Rightarrow \lambda = \frac{1}{10} \text{ MIN}^{-1}$ con "TEMPO IN MIN
 + CLIENTE"

La Variabile Aleatoria Esponenziale

Tempi di attesa e il Processo di Poisson

Approfondimento Monografico

1 Introduzione: Cosa modella l'Esponenziale?

Intuizione: L'attesa tra due eventi rari

Mentre la distribuzione di Poisson serve a contare quanti eventi rari accadono in un certo periodo di tempo (es. "Quanti terremoti ci saranno in un anno?"), la distribuzione Esponenziale serve a misurare il tempo di attesa continuo che intercorre tra un evento e il successivo (es. "Quanto tempo passerà prima del prossimo terremoto?"). Altri esempi classici includono:

- Il tempo di attesa tra due emissioni di particelle α da una sorgente radioattiva.
- Il tempo di vita di un componente elettronico prima che si guasti.

2 Il Legame con il Processo di Poisson


Per capire davvero l'Esponenziale, dobbiamo guardare l'esperimento scorrere nel tempo. Immaginiamo di far partire un cronometro a $t = 0$ e di registrare ogni volta che accade un "evento raro".

Definiamo N_t come il numero totale di eventi rari accaduti dal tempo 0 fino al tempo t . La sequenza di questi conteggi nel tempo forma un Processo di Poisson, che gode di proprietà particolarissime:

1. Il numero di eventi in un qualsiasi intervallo di tempo tra s e t dipende solo dalla durata dell'intervallo. Formalmente: $N_t - N_s \sim \text{Pois}(\lambda(t - s))$.
2. Il numero di eventi in un nuovo intervallo è indipendente dalla storia passata (ovvero dai conteggi $N_{s_1}, N_{s_2}, \dots$ registrati prima del tempo s).

2.1 I Tempi di Salto (τ_n)

Se guardiamo il grafico di N_t , vediamo una funzione "a gradini" che sale di 1 ogni volta che accade un evento. Chiamiamo τ_n il tempo di salto da un evento all'altro (il tempo che intercorre tra l'evento n e l'evento $n+1$).



Il risultato teorico fondamentale è che ognuno di questi tempi di attesa τ_n si distribuisce in modo continuo proprio come una **Variabile Esponenziale di parametro λ** .

3 Definizione e Calcoli

Definizione Formale: Variabile Esponenziale $\text{Exp}(\lambda)$

Una variabile aleatoria continua $X \sim \text{Exp}(\lambda)$ con parametro $\lambda > 0$ descrive un tempo di attesa, quindi assume solo valori positivi. La sua funzione di densità è:

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{se } x > 0 \\ 0 & \text{se } x \leq 0 \end{cases} \quad (1)$$

La costante λ rappresenta il "tasso di guasto" o "frequenza media degli eventi" (es. 2 terremoti all'anno).

Esercizio Pratico: Calcolo di Probabilità (Integrazione)

Supponiamo che il tempo di vita di un macchinario sia descritto da una variabile $X \sim \text{Exp}(1/8)$. Qui il parametro è $\lambda = 1/8$.

Vogliamo calcolare la probabilità che il macchinario non si guasti nei primi 6 giorni, ovvero la probabilità che il tempo di attesa del primo guasto sia superiore a 6: $P(X > 6)$. Essendo una v.a. con densità, dobbiamo calcolare l'integrale della funzione $f(x)$ da 6 a $+\infty$:

$$\begin{aligned} P(X > 6) &= \int_6^{+\infty} \lambda e^{-\lambda x} dx \\ &= \int_6^{+\infty} \frac{1}{8} e^{-\frac{1}{8}x} dx \end{aligned}$$

Per risolvere questo integrale, ricordiamo che la derivata di $e^{-\lambda x}$ è proprio $-\lambda e^{-\lambda x}$. Quindi la primitiva di $\lambda e^{-\lambda x}$ è semplicemente $-e^{-\lambda x}$. Appliciamo il Teorema Fondamentale del Calcolo:

$$\begin{aligned} P(X > 6) &= [-e^{-\lambda x}]_{x=6}^{+\infty} \\ &= \lim_{x \rightarrow +\infty} (-e^{-\frac{1}{8}x}) - (-e^{-\frac{1}{8} \cdot 6}) \end{aligned}$$

Poiché $e^{-\infty}$ tende a 0:

$$P(X > 6) = -0 + e^{-\frac{6}{8}} = e^{-3/4} \approx 0.472 \text{ (circa 47.2\%)}$$

4 L'Assenza di Memoria

Dal fatto che i conteggi del Processo di Poisson sono **indipendenti dalla storia passata**, deriva la **proprietà** più famosa dell'Esponenziale.

Proprietà: Assenza di Memoria

Se $X \sim \text{Exp}(\lambda)$, allora per ogni coppia di istanti di tempo $s, t > 0$ vale che:

$$P(X > t + s \mid X > s) = P(X > t) \quad (2)$$

Intuizione: Cosa significa nella pratica?

Immagina un componente elettronico che non si consuma gradualmente, ma si rompe solo per colpi di sfortuna improvvisi. Se il componente ha già funzionato perfettamente per un tempo s (es. 100 giorni), la probabilità che sopravviva per un **ulteriore tempo t** (es. altri 20 giorni) è **esattamente identica alla probabilità che un componente nuovo di zecca, appena uscito di fabbrica, sopravviva per 20 giorni**. Il componente "non ha memoria" di essere già vecchio di 100 giorni. L'Esponenziale è l'unica distribuzione continua al mondo a possedere questa proprietà (l'equivalente discreto è la Geometrica).

Il Cambio di Variabile Spiegato Semplice

Dà dove spunta quella formula e perché ha senso

Guida Definitiva

1 Il Problema: Perché ci serve questa formula?


Immagina di essere in un casinò che genera numeri casuali.

- La variabile X è la **lunghezza del lato** di un **dado** di legno. Sappiamo perfettamente come si distribuisce questa lunghezza (conosciamo la sua **densità** f_X).
- A noi però non interessa il lato. Vogliamo calcolare il **Volume** del dado, che chiamiamo Y .

Sappiamo che il volume è il lato al cubo. Quindi la nostra **nuova variabile** è una funzione di X :

$$Y = X^3$$

In generale, diciamo che $Y = h(X)$, dove h è una **regola matematica** (in questo caso, "eleva al cubo").



La nuova variabile $Y = h(X)$

La grande domanda è: Se conosco la curva di probabilità di X (la densità f_X), come faccio a trovare la curva di probabilità di Y (la densità f_Y)?

2 Quando le cose si rompono (I casi in cui non si può fare)

Prima di dare la formula, i tuoi appunti fanno un'osservazione fondamentale. **Non tutte le trasformazioni h mantengono la variabile "continua"** (con densità).

Attenzione: Se la funzione h "schiaccia" tutto

Immagina di usare come funzione $h(x) = 5$ (una funzione costante). Indipendentemente dal lato del dado X , la nuova variabile Y varrà sempre 5. La variabile Y non sarà più "spalmata" (continua), ma sarà un singolo punto esatto (discreta). La densità f_Y non esiste più! Lo stesso vale se h assume solo un numero finito di valori.

Per questo motivo, per trovare la densità di Y , la funzione h deve essere "ben comportata". Deve essere un **diffeomorfismo**. Cosa significa in italiano?

1. **Biunivoca (Invertibile)**: Ad ogni volume Y deve corrispondere uno e un solo lato X . (Così possiamo usare la funzione inversa h^{-1}).
2. **Liscia (Derivabile)**: Non deve avere spigoli o salti. Anche la sua inversa deve essere derivabile.

3 Costruiamo la Formula Insieme

Ora arriva il bello. Vogliamo trovare $f_Y(y)$, cioè la probabilità che il volume sia (circa) y . Come facciamo? Dobbiamo "chiedere" a X .

3.1 Passo 1: Tornare Indietro

Se voglio sapere la probabilità di ottenere un volume $Y = 8$, devo chiedermi: "Quale lato X mi dà un volume di 8?". La risposta è la radice cubica di 8, cioè 2. In matematica, sto applicando la **funzione inversa** $x = h^{-1}(y)$. Quindi, la densità di Y in 8 dipende dalla densità di X in 2.

$$f_Y(y) \approx f_X(h^{-1}(y))$$

LA PROB. DEL VOLUME DIPENDE
TOTALMENTE E UNICAMENTE DALLA
PROB. DEL LATO

3.2 Passo 2: Il problema del righello (La Derivata)

Perché non basta la formula qui sopra? Perché la trasformazione $Y = X^3$ deforma l'asse dei numeri.

- Se X passa da 1 a 1.1 (lunghezza 0.1), Y passa da 1 a 1.331 (lunghezza 0.331).
- Se X passa da 2 a 2.1 (lunghezza 0.1), Y passa da 8 a 9.261 (lunghezza 1.261).

La funzione "stira" lo spazio in modo diverso a seconda di dove ci troviamo. Poiché la densità è una probabilità **diviso una lunghezza** (area = base $\times$ altezza), se stiro la base, l'altezza (la densità) deve abbassarsi per mantenere la stessa area (stessa probabilità).

Per compensare questo "stiramento del righello", dobbiamo moltiplicare per il **tasso di deformazione**, che in matematica è la **derivata della funzione inversa**. Mettiamo il valore assoluto perché la probabilità non può mai essere negativa.

L'Intuizione: L'intuizione infinitesimale (Il trucco dei fisici)

Negli appunti trovi questa scrittura informale, che è il cuore di tutto:

$$P(Y \in dy) \approx f_Y(y)dy \quad \text{e} \quad P(X \in dx) \approx f_X(x)dx$$

$dx \approx dy$
INFIN. PICCOLI

Poiché l'evento è lo stesso, le due probabilità devono essere uguali: (STESSA AREA)

$$f_Y(y)dy = f_X(x)dx$$

Da cui, isolando $f_Y(y)$:

$$f_Y(y) = f_X(x) \left| \frac{dx}{dy} \right|$$

Ma ricordiamo che $x = h^{-1}(y)$ (la funzione inversa). Sostituendo:

$$f_Y(y) = f_X(h^{-1}(y)) \cdot \left| \frac{d}{dy} h^{-1}(y) \right|$$

LA DERIVATA!
CI DICE QUANTO LO
SPAZIO SI È MODIFICATO
IN QUEL PUNTO

Eccola qui. La derivata serve semplicemente a compensare il fatto che dx e dy hanno "lunghezze" diverse.

4 Il Teorema Finale

Adesso che abbiamo capito ogni singolo pezzo, leggere il teorema formale tratto dai tuoi appunti sarà facilissimo.

Il Teorema Formale: Cambio di Variabile

Sia X una v.a. con densità f_X supportata su un intervallo aperto I (cioè $f_X = 0$ fuori da I).

Sia $h: I \rightarrow J$ un **diffeomorfismo** di classe C^1 (biunivoca e derivabile con inversa derivabile).

Allora la v.a. $Y = h(X)$ ammette densità f_Y data da:

$$f_Y(y) = \begin{cases} f_X(h^{-1}(y)) \cdot \left| \frac{d}{dy} h^{-1}(y) \right| & \text{per } y \in J \\ 0 & \text{per } y \notin J \end{cases} \quad (1)$$

4.1 Riassunto per l'esame: I tre step pratici

Se all'esame ti danno X e ti chiedono la densità di $Y = h(X)$, fai esattamente questi 3 passaggi:

1. **Trova l'inversa**: Ricava la X . Scrivi $x = h^{-1}(y)$.
2. **Fai la derivata**: Deriva quello che hai appena trovato rispetto a y e mettili il valore assoluto: $\left| \frac{d}{dy} x \right|$.
3. **Sostituisci**: Prendi la densità originale f_X , metti al posto della x la funzione trovata al passo 1, e moltiplica per la derivata del passo 2.

* E.C.

$$P(a \leq X \leq b) = \int_a^b f(x) \cdot dx \approx \text{FREQ. RELATIVA DI } \{a \leq X \leq b\} \text{ SU TUTTA LA POPOL.}$$

(CASO DI ESTRAGGIERE DA UNA POPOL. E MISURAZIONE DEL CARATTERE X)

Esempio pratico

Sia $X \sim \text{Exp}(1/8)$. Calcoliamo la probabilità che il tempo di attesa superi 6:

$$P(X > 6) = \int_6^{+\infty} \frac{1}{8} e^{-x/8} dx = \left[-e^{-x/8} \right]_{x=6}^{+\infty} = 0 - (-e^{-6/8}) = e^{-3/4} \quad (42)$$

Proprietà 16.1 (Assenza di memoria). Se $X \sim \text{Exp}(\lambda)$, allora $\forall s, t > 0$:

$$P(X > t+s | X > s) = P(X > t) \quad (43)$$

L'Esponenziale è l'unica distribuzione continua con questa proprietà.


17 Funzione di Ripartizione (FdR) e Quantili

Definizione 17.1 (Funzione di Ripartizione). Sia X una v.a. La sua **Funzione di Ripartizione** $F_X: \mathbb{R} \rightarrow \mathbb{R}$ (CDF in inglese) è:

$$F_X(x) = P(X \leq x) = P(\{\omega \in \Omega \mid X(\omega) \leq x\}) \quad (44)$$

Proprietà 17.1. Le proprietà fondamentali di F_X sono:

1. **Non decrescente:** $x_1 \leq x_2 \implies F_X(x_1) \leq F_X(x_2)$.
2. **Limiti:** $\lim_{x \rightarrow -\infty} F_X(x) = 0$ e $\lim_{x \rightarrow +\infty} F_X(x) = 1$.
3. **Continuità a destra:** F_X è continua da destra.




Nel caso di una v.a. con densità f , l'FdR si ottiene integrando:

$$F_X(x) = \int_{-\infty}^x f(y) dy \quad (45)$$

Inoltre, per il Teorema Fondamentale del Calcolo, se f è continua (o F_X è di classe C^1), vale la derivazione: $f(x) = \frac{d}{dx} F_X(x)$. Utilità pratica: $P(a < X \leq b) = F_X(b) - F_X(a)$. ∇x PER CUI CALCOLO PROB. IN INTERVALLO TRAMITE F_X . $F_X(x)$ È DERIVABILE.

17.1 Quantili e Formula di Cambio Variabile

Definizione 17.2 (β -quantile). Dato $\beta \in (0, 1)$, un β -quantile (o 100β -esimo percentile) è un numero $r_\beta \in \mathbb{R}$ tale che: $F_X(r_\beta) \geq \beta$.



$$P(X \leq r_\beta) \geq \beta \quad \text{e} \quad P(X \geq r_\beta) \geq 1 - \beta \quad (46)$$

Se F_X è invertibile, allora il quantile è unico e vale: $r_\beta = F_X^{-1}(\beta)$.

Spesso abbiamo una v.a. X e vogliamo trovare la densità di una trasformazione $Y = h(X)$.


Esempio pratico

Se X è la lunghezza di un cubetto aleatorio, la variabile $Y = X^3$ ne rappresenta il volume. Y ammette densità? (NON SEMPRE!)

$f_Y \in C^1$ DERIVABILE
 $\in f'_Y(x)$ CONTINUA

[Formula di Cambio Variabili] Sia X con densità f_X supportata su un intervallo aperto I . Sia $h: I \rightarrow J$ un diffeomorfismo di classe C^1 (funzione biunivoca, derivabile e con inversa derivabile). Allora la v.a. $Y = h(X)$ ammette densità su J data da:

$$f_Y(y) = \begin{cases} f_X(h^{-1}(y)) \cdot \left| \frac{d}{dy} h^{-1}(y) \right| & \text{se } y \in J \\ 0 & \text{altrimenti} \end{cases} \quad (47)$$



18 Variabili Gaussiane (Normali)

Fatto fondamentale dell'analisi: $\int_{-\infty}^{+\infty} e^{-x^2/2} dx = \sqrt{2\pi}$.

Definizione 18.1 (Gaussiana Standard $Z \sim N(0, 1)$). È una v.a. con densità $\varphi(x)$:

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad x \in \mathbb{R} \quad (48)$$

La Funzione di Ripartizione $\Phi(x) = P(Z \leq x)$ non esiste in forma chiusa. I suoi valori sono calcolati numericamente e tabulati. Tuttavia, per la simmetria (essendo $\varphi(x)$ pari), godiamo di ottime proprietà:


(1) • $\Phi(-x) = 1 - \Phi(x)$

(2) • $\Phi(0) = \frac{1}{2}$

(3) • $P(|Z| \leq a) = P(-a \leq Z \leq a) = \Phi(a) - \Phi(-a) = 2\Phi(a) - 1$

Valori notevoli: $P(|Z| \leq 1) \approx 0.68$, $P(|Z| \leq 2) \approx 0.95$, $P(|Z| \leq 3) \approx 0.997$.

Per i quantili (indicati con q_β tale che $\Phi(q_\beta) = \beta$), la simmetria garantisce che $q_{1-\beta} = -q_\beta$.



18.1 Gaussiana Generale

Definiamo una trasformazione affine $Y = \sigma Z + m$ con $\sigma > 0$ e $m \in \mathbb{R}$. Tramite la formula del cambio di variabili, si ottiene:

Definizione 18.2 (Gaussiana Generale $Y \sim N(m, \sigma^2)$). Ha densità:

$$f_Y(y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-m)^2}{2\sigma^2}\right) \quad (49)$$

INT. 1/5

Variabili Casuali Gaussiane: Teoria e Applicazioni

Appunti di Studio Avanzati

1 Introduzione alla Variabile Casuale Normale

La variabile casuale Gaussiana (o Normale) è il modello probabilistico più utilizzato per descrivere fenomeni naturali e misurazioni sperimentali [7]. Come indicato nei modelli teorici, essa descrive situazioni in cui i valori hanno una probabilità più alta di cadere attorno alla media, decrescendo simmetricamente verso le "code" della distribuzione [7, 7].

2 La Gaussiana Standard $N(0, 1)$

La forma più semplice è la Normale Standard, indicata con $Z \sim N(0, 1)$ [7, 7]. Essa ha media nulla ($m = 0$) e varianza unitaria ($\sigma^2 = 1$).

2.1 La Funzione di Densità $\varphi(x)$

La funzione di densità $\varphi(x)$ definisce la probabilità "locale" ed è data da [7, 7]:


$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad x \in \mathbb{R} \quad (1)$$

Il grafico di questa funzione è la celebre **Campana di Gauss**. Un requisito fondamentale è che l'area totale sotto la curva sia pari a 1 [7]. Questo è garantito dal valore dell'integrale notevole [7, 7]:

$$\int_{-\infty}^{+\infty} e^{-x^2/2} dx = \sqrt{2\pi} \quad (2)$$

2.2 Visualizzazione della Densità

Di seguito viene riportata la rappresentazione grafica della densità $\varphi(x)$.



FDR/CDF

3 La Funzione di Ripartizione $\Phi(x)$

Mentre la densità $\varphi(x)$ ci dà la "forma" della distribuzione, per calcolare effettivamente le probabilità utilizziamo la Funzione di Ripartizione (CDF), indicata convenzionalmente con la lettera greca maiuscola Φ [cite: 13, 93]:

$$\Phi(x) = P(Z \leq x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy, \quad x \in \mathbb{R} \quad (3)$$


3.1 Assenza di una Formula Chiusa

È fondamentale notare che per l'integrale della Gaussiana non esiste una formula analitica chiusa espressa tramite funzioni elementari [cite: 19, 20, 121]. Per questo motivo, i valori di $\Phi(x)$ sono:

- Calcolati tramite integrazione numerica [cite: 24].
- Tabulati in apposite tavole statistiche con alta precisione [cite: 23, 128].

3.2 Visualizzazione della Probabilità Cumulata

Il valore $\Phi(x)$ corrisponde graficamente all'area della regione compresa tra l'asse delle ascisse e la curva di densità, calcolata da $-\infty$ fino al punto x [cite: 18].



4 Proprietà Fondamentali e Simmetrie

La simmetria della campana rispetto all'origine permette di derivare proprietà che semplificano drasticamente i calcoli [cite: 35, 106].

4.1 Il Complemento e la Coda Sinistra

Dato che l'area totale è 1, la probabilità della "coda sinistra" di un valore negativo è pari a 1 meno la probabilità del corrispondente valore positivo:

$$\Phi(-x) = 1 - \Phi(x) \quad (4)$$

4.2 Probabilità su un Intervallo e Intervalli Simmetrici

Per calcolare la probabilità che Z cada tra due valori a e b :


$$P(a \leq Z \leq b) = \Phi(b) - \Phi(a) \quad (5)$$

In particolare, per un intervallo simmetrico attorno allo zero $[-a, a]$:

$$P(|Z| \leq a) = \Phi(a) - \Phi(-a) = 2\Phi(a) - 1 \quad (6)$$

PER $x \geq 0$, $\Phi(x) \approx 1$

$$\Phi(0) = \frac{1}{2}$$





5 I Quantili della Gaussiana Standard

Un concetto strettamente legato alla Funzione di Ripartizione è quello di quantile. Fissato un livello di probabilità $\beta \in (0, 1)$, si definisce β -quantile (indicato con q_β) il valore sull'asse delle ascisse tale per cui l'area sotto la curva alla sua sinistra è esattamente pari a β . In formula, è l'inversa della Funzione di Ripartizione:

$$\Phi(q_\beta) = \beta \iff q_\beta = \Phi^{-1}(\beta) \quad (7)$$

$q_{1-\alpha} = -q_\alpha$
 $\Rightarrow$ L'AREA FINO A q_α È α ,
 FINO A $q_{1-\alpha}$ È $1-\alpha$
 QUELLA DOPO È α



PER $\alpha \in (\frac{1}{2}, 1)$, q_α è c.c. $\Phi(q_\alpha) = \alpha$
 PER $\alpha \in (0, \frac{1}{2})$, $q_\alpha = -q_{1-\alpha}$

5.1 Calcolo dei Quantili per Valori Negativi

Le tavole statistiche tipicamente riportano i quantili solo per $\beta \geq 0.5$. Per probabilità inferiori ($\beta < 0.5$), si sfrutta nuovamente la simmetria della curva rispetto all'asse delle ordinate:

$$q_\beta = -q_{1-\beta} \quad (8)$$

Ad esempio, sapendo che $q_{0.9} \approx 1.28$ [7], possiamo dedurre immediatamente che $q_{0.1} = -q_{0.9} = -1.28$

6 Variabili Gaussiani Generali $N(m, \sigma^2)$

Nella realtà empirica, i fenomeni non hanno quasi mai media 0 e varianza 1. Consideriamo una generica variabile gaussiana Y , caratterizzata da una media $m \in \mathbb{R}$ e una varianza $\sigma^2 > 0$. La indichiamo con $Y \sim N(m, \sigma^2)$

6.1 Densità e Diffeomorfismo

La variabile Y può essere ottenuta a partire dalla gaussiana standard Z tramite una trasformazione lineare (o diffeomorfismo) $h: \mathbb{R} \rightarrow \mathbb{R}$ definita come $Y = h(Z) = \sigma Z + m$. Applicando

la formula del cambio di variabile per le densità, la funzione di densità di Y risulta:

$$h(z) = \sigma Z + m = Y \quad f_Y(y) = \varphi\left(\frac{y-m}{\sigma}\right) \cdot \frac{1}{\sigma} = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y-m)^2}{2\sigma^2}\right) \quad (9)$$

$$Z = \frac{Y-m}{\sigma} \quad = f_Z\left(h^{-1}(y)\right) \cdot \left|\frac{dh(y)}{dy}\right|$$

7 La Standardizzazione
Il teorema fondamentale per operare con le gaussiane generali consiste nel percorso inverso: ricondursi alla gaussiana standard Z per poter utilizzare le tavole di $\Phi(x)$. Se $Y \sim N(m, \sigma^2)$, allora la variabile standardizzata Z si ottiene sottraendo la media e dividendo per la deviazione standard

$$Z = \frac{Y-m}{\sigma} \sim N(0, 1) \quad (10)$$

Questo ci permette di calcolare la probabilità per qualsiasi intervallo $[a, b]$ [?]:

$$P(a \leq Y \leq b) = P\left(\frac{a-m}{\sigma} \leq Z \leq \frac{b-m}{\sigma}\right) = \Phi\left(\frac{b-m}{\sigma}\right) - \Phi\left(\frac{a-m}{\sigma}\right) \quad (11)$$

$$P(m-3\sigma \leq Y \leq m+3\sigma) = P(|Y-m| \leq 3\sigma) = P(|Z| \leq 3) \approx 0.997$$

8 Proprietà di Riproducibilità (Trasformazioni Affini)

Un'importantissima proprietà delle variabili gaussiane riguarda le loro trasformazioni lineari (o affini). Se partiamo da una variabile gaussiana $Y \sim N(m, \sigma^2)$ e creiamo una nuova variabile $V = \alpha Y + \beta$ (con $\alpha, \beta \in \mathbb{R}$ e $\alpha \neq 0$), il risultato sarà ancora una distribuzione normale, con media e varianza scalate di conseguenza [?]:

$$Y \sim N(m, \sigma^2) \quad V \sim N(\alpha m + \beta, \alpha^2 \sigma^2) \quad (12)$$

$$V = \alpha Y + \beta$$

IL RISULTATO È UNA GAUSSIANA!

8.1 Dimostrazione

Possiamo dimostrare questa proprietà riconducendoci alla gaussiana standard Z [?]. Sappiamo che:

$$Y \sim N(m, \sigma^2) \Rightarrow Z = \frac{Y-m}{\sigma} \sim N(0, 1) \quad (13)$$

Sostituendo $V = \alpha Y + \beta$, esplicitiamo Y e lo inseriamo nella formula di Z [?]:

$$Y = \frac{V-\beta}{\alpha} \Rightarrow Z = \frac{\frac{V-\beta}{\alpha} - m}{\sigma} = \frac{V-\beta-\alpha m}{\alpha\sigma} = \frac{V-(\alpha m + \beta)}{\alpha\sigma} \quad (14)$$

Questa ultima espressione ha esattamente la forma della standardizzazione di una variabile con media $(\alpha m + \beta)$ e deviazione standard $(\alpha\sigma)$. Pertanto, dedurremo che $V \sim N(\alpha m + \beta, \alpha^2 \sigma^2)$ [?].

9 Esercizio Svolto: Produzione Industriale di Viti

Vediamo un'applicazione pratica che richiede l'uso combinato della standardizzazione e dei quantili [?]. Una fabbrica produce delle viti, la cui lunghezza Y in centimetri segue una distribuzione normale con media 1.7 e deviazione standard 0.6 [?]:

$$Y \sim N(1.7, 0.6^2) \quad (15)$$

9.1 Caso A: Calcolo di una Probabilità

Problema: Calcolare la probabilità che la lunghezza di una vite estratta a caso sia minore di 1.6 cm [?].

Svolgimento: Dobbiamo calcolare $P(Y < 1.6)$ [?]. Poiché non disponiamo delle tavole per questa specifica gaussiana, standardizziamo i valori [?]:

$$P(Y < 1.6) = P\left(\frac{Y-1.7}{0.6} < \frac{1.6-1.7}{0.6}\right) = P\left(Z < -\frac{0.1}{0.6}\right) \approx P(Z < -0.17) \quad (16)$$

Utilizzando la Funzione di Ripartizione Φ e le sue proprietà di simmetria [?]:

$$\Phi(-0.17) = 1 - \Phi(0.17) \approx 1 - 0.567 = 0.433 \quad (17)$$

Dunque, c'è circa il 43.3% di probabilità di estrarre una vite più corta di 1.6 cm [?].

9.2 Caso B: Ricerca di un Limite Inferiore (Quantili)

Problema: Determinare un valore $t \in \mathbb{R}$ tale che il 95% delle viti abbia lunghezza almeno t [?].
Svolgimento: Questa volta conosciamo la probabilità e dobbiamo trovare il valore corrispondente. Impostiamo l'equazione [?]:

$$P(Y \geq t) = 0.95 \Rightarrow 1 - P(Y \leq t) = 0.95 \Rightarrow P(Y \leq t) = 0.05 \quad (18)$$


Standardizziamo il valore ignoto t [?]:

$$P\left(Z \leq \frac{t-1.7}{0.6}\right) = 0.05 \Rightarrow \Phi\left(\frac{t-1.7}{0.6}\right) = 0.05 \quad (19)$$

Stiamo cercando il quantile $q_{0.05}$ [?]. Sapendo che $q_{0.05} = -q_{0.95}$ e che dalle tavole $q_{0.95} \approx 1.645$ [?], [?]:

$$\frac{t-1.7}{0.6} = -1.645 \Rightarrow t = 1.7 - (1.645 \cdot 0.6) = 1.7 - 0.987 \approx 0.713 \text{ cm} \quad (20)$$

Il 95% delle viti prodotte sarà lungo almeno 0.713 cm [?].



la formula del cambio di variabile per le densità, la funzione di densità di Y risulta:

$$h(z) = \sigma Z + m = Y \quad f_Y(y) = \varphi\left(\frac{y-m}{\sigma}\right) \cdot \frac{1}{\sigma} = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y-m)^2}{2\sigma^2}\right) \quad (9)$$

$$Z = \frac{Y-m}{\sigma} \quad = \Phi_Z\left(h^{-1}(y)\right) \cdot \left|\frac{dh(y)}{dy}\right|$$

7 La Standardizzazione
Il teorema fondamentale per operare con le gaussiane generali consiste nel percorso inverso: ricondursi alla gaussiana standard Z per poter utilizzare le tavole di $\Phi(x)$. Se $Y \sim N(m, \sigma^2)$, allora la variabile standardizzata Z si ottiene sottraendo la media e dividendo per la deviazione standard

$$Z = \frac{Y-m}{\sigma} \sim N(0,1) \quad (10)$$

Questo ci permette di calcolare la probabilità per qualsiasi intervallo $[a, b]$ [?]:

$$P(a \leq Y \leq b) = P\left(\frac{a-m}{\sigma} \leq Z \leq \frac{b-m}{\sigma}\right) = \Phi\left(\frac{b-m}{\sigma}\right) - \Phi\left(\frac{a-m}{\sigma}\right) \quad (11)$$

$$P(m-3\sigma \leq Y \leq m+3\sigma) = P(|Y-m| \leq 3\sigma) = P(|Z| \leq 3) \approx 0.997$$

8 Proprietà di Riproducibilità (Trasformazioni Affini)

Un'importantissima proprietà delle variabili gaussiane riguarda le loro trasformazioni lineari (o affini). Se partiamo da una variabile gaussiana $Y \sim N(m, \sigma^2)$ e creiamo una nuova variabile $V = \alpha Y + \beta$ (con $\alpha, \beta \in \mathbb{R}$ e $\alpha \neq 0$), il risultato sarà ancora una distribuzione normale, con media e varianza scalate di conseguenza [?]:

$$Y \sim N(m, \sigma^2) \quad V \sim N(\alpha m + \beta, \alpha^2 \sigma^2) \quad (12)$$

CREARE UNA GAUSSIANA!

8.1 Dimostrazione

Possiamo dimostrare questa proprietà riconducendoci alla gaussiana standard Z [?]. Sappiamo che:

$$Y \sim N(m, \sigma^2) \Rightarrow Z = \frac{Y-m}{\sigma} \sim N(0,1) \quad (13)$$

Sostituendo $V = \alpha Y + \beta$, esplicitiamo Y e lo inseriamo nella formula di Z [?]:

$$Y = \frac{V-\beta}{\alpha} \Rightarrow Z = \frac{\frac{V-\beta}{\alpha} - m}{\sigma} = \frac{V-\beta-\alpha m}{\alpha\sigma} = \frac{V-(\alpha m + \beta)}{\alpha\sigma} \quad (14)$$

Questa ultima espressione ha esattamente la forma della standardizzazione di una variabile con media $(\alpha m + \beta)$ e deviazione standard $(\alpha\sigma)$. Pertanto, dedurremo che $V \sim N(\alpha m + \beta, \alpha^2 \sigma^2)$ [?].

9 Esercizio Svolto: Produzione Industriale di Viti

Vediamo un'applicazione pratica che richiede l'uso combinato della standardizzazione e dei quantili [?]. Una fabbrica produce delle viti, la cui lunghezza Y in centimetri segue una distribuzione normale con media 1.7 e deviazione standard 0.6 [?]:

$$Y \sim N(1.7, 0.6^2) \quad (15)$$

9.1 Caso A: Calcolo di una Probabilità

Problema: Calcolare la probabilità che la lunghezza di una vite estratta a caso sia minore di 1.6 cm [?].

Svolgimento: Dobbiamo calcolare $P(Y < 1.6)$ [?]. Poiché non disponiamo delle tavole per questa specifica gaussiana, standardizziamo i valori [?]:

$$P(Y < 1.6) = P\left(\frac{Y-1.7}{0.6} < \frac{1.6-1.7}{0.6}\right) = P\left(Z < -\frac{0.1}{0.6}\right) \approx P(Z < -0.17) \quad (16)$$

Utilizzando la Funzione di Ripartizione Φ e le sue proprietà di simmetria [?]:

$$\Phi(-0.17) = 1 - \Phi(0.17) \approx 1 - 0.567 = 0.433 \quad (17)$$

Dunque, c'è circa il 43.3% di probabilità di estrarre una vite più corta di 1.6 cm [?].

9.2 Caso B: Ricerca di un Limite Inferiore (Quantili)

Problema: Determinare un valore $t \in \mathbb{R}$ tale che il 95% delle viti abbia lunghezza almeno t [?].

Svolgimento: Questa volta conosciamo la probabilità e dobbiamo trovare il valore corrispondente. Impostiamo l'equazione [?]:

$$P(Y \geq t) = 0.95 \Rightarrow 1 - P(Y \leq t) = 0.95 \Rightarrow P(Y \leq t) = 0.05 \quad (18)$$


Standardizziamo il valore ignoto t [?]:

$$P\left(Z \leq \frac{t-1.7}{0.6}\right) = 0.05 \Rightarrow \Phi\left(\frac{t-1.7}{0.6}\right) = 0.05 \quad (19)$$

Stiamo cercando il quantile $q_{0.05}$ [?]. Sapendo che $q_{0.05} = -q_{0.95}$ e che dalle tavole $q_{0.95} \approx 1.645$ [?, ?]:

$$\frac{t-1.7}{0.6} = -1.645 \Rightarrow t = 1.7 - (1.645 \cdot 0.6) = 1.7 - 0.987 \approx 0.713 \text{ cm} \quad (20)$$

Il 95% delle viti prodotte sarà lungo almeno 0.713 cm [?].



Parte 2

Appunti Completi: Valore Atteso, Momenti e Varianza

Guida allo Studio Definitiva

Indice

1	Introduzione: Dalla Statistica Descrittiva alla Probabilità	1
2	Il Valore Atteso (Speranza Matematica)	1
2.1	Significato del Valore Atteso	1
2.2	Esempi Fondamentali di Valore Atteso	2
2.3	Esistenza del Valore Atteso: Quando è definito?	2
3	Valore Atteso di una Funzione di V.A. (Teorema di Trasferimento)	3
4	Proprietà del Valore Atteso	3
5	Momenti di una Variabile Aleatoria	4
6	Disuguaglianze Notevoli: Markov e Chebyshev	4
7	Varianza e Deviazione Standard	5
7.1	Formula Pratica per il Calcolo e Proprietà	5
7.2	Disuguaglianza di Chebyshev	6
8	Variabili Aleatorie Notevoli Discrete	6
8.1	Variabile di Bernoulli: $X \sim Be(p)$	6
8.2	Variabile Binomiale: $X \sim B(n, p)$	6
8.3	Variabile di Poisson: $X \sim P(\lambda)$	7
9	Variabili Aleatorie Notevoli Continue	7
9.1	Variabile Uniforme Continua: $X \sim U([a, b])$	7
9.2	Variabile Esponenziale: $X \sim Exp(\lambda)$	8
9.3	Variabile Normale (Gaussiana)	8
9.3.1	Caso Standard: $Z \sim N(0, 1)$	8
9.3.2	Caso Generale: $X \sim N(m, \sigma^2)$	8
10	Ulteriori Variabili Discrete Notevoli	9
10.1	Variabile Geometrica: $T \sim Geom(p)$	9
10.2	Variabile Ipergeometrica: $X \sim H(N, K, n)$	9

11 Variabili Aleatorie Multivariate (Leggi Congiunte e Marginali)	11
11.1 Legge Congiunta e Leggi Marginali	11
11.1.1 Il Caso Discreto	12
12 Indipendenza di Variabili Aleatorie	13
12.1 Proprietà di Riproducibilità	13
13 Valore Atteso, Covarianza e Correlazione	14
13.1 Valore Atteso di Funzioni di V.A. Doppie	14
13.2 Covarianza e Correlazione	14
13.3 Varianza della Somma	15
14 Introduzione all'Inferenza e Teoremi Limite in Probabilità	16
15 Il Teorema del Limite Centrale (TCL)	17
15.1 L'intuizione: lo "Zoom" sulla Media Campionaria	17
15.2 Convergenza in Legge e Formulazione del Teorema	18
15.3 Caso Particolare: Approssimazione Normale della Binomiale	19
16 Introduzione alla Statistica Inferenziale	21
16.1 Il Modello Statistico e il Campione	21
17 Statistiche Campionarie e Stimatori	22
17.1 Come valutare l'efficacia di uno stimatore?	22
17.1.1 1. Correttezza (Non Distorsione)	22
17.1.2 2. Consistenza	22
17.1.3 3. Efficienza (Rischio Quadratico)	23
17.2 Esempio: Stima della probabilità di un evento (Frequenza Relativa)	23
18 Il Metodo della Massima Verosimiglianza	23
18.1 La Funzione di Verosimiglianza	23
18.2 Definizione di Stimatore MLE	24
18.3 Esempi Notevoli di MLE	24
18.3.1 1. Distribuzione di Poisson ($X \sim \text{Poisson}(\lambda)$)	24
18.3.2 2. Distribuzione Esponenziale ($X \sim \text{Exp}(\theta)$)	24
18.3.3 3. Distribuzione Uniforme su $[0, \theta]$	25
18.3.4 4. Distribuzione Normale $N(m, \sigma^2)$ con m noto	25
Approfondimento Teorico-Pratico: Esercizi MLE e Grafici	25
19 Intervalli di Fiducia	28
19.1 Scopo e Definizione	28
19.2 Caso 1: Media di popolazione Gaussiana con Varianza Nota	28
19.3 Caso 2: Media di popolazione Gaussiana con Varianza Non Nota	30
19.4 Caso 3: Grandi Campioni (Teorema del Limite Centrale)	32
19.5 Caso 4: Intervalli di Fiducia per una Proporzione	33
19.6 Esercizi Riassuntivi e Applicazioni	34

1 Introduzione: Dalla Statistica Descrittiva alla Probabilità

Per comprendere a fondo il comportamento delle variabili aleatorie (v.a.), è utile portare i concetti cardine della statistica descrittiva all'interno del contesto probabilistico. Nella statistica descrittiva, dato un campione di dati $(x_1, \dots, x_n)$, si utilizzano indici specifici per riassumerne le caratteristiche:

- **Media Campionaria ($\bar{x}$):** Indica il centro della distribuzione dei dati e si calcola come $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \sum_{j=1}^J a_j \cdot p(a_j)$. a_j : MODALITÀ, $p(a_j)$: FREQ. RELATIVA SUL CAMPIONE
- **Varianza Campionaria ($\text{Var}(x)$):** Indica la dispersione dei dati attorno alla media e si calcola come $\text{Var}(x) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$.

L'obiettivo è introdurre concetti analoghi (media e varianza) per un intero carattere o popolazione descritto da una variabile aleatoria X .

2 Il Valore Atteso (Speranza Matematica)

Il **Valore Atteso**, indicato con $E[X]$ (oppure μ), è un indice di posizione che ci fornisce un'informazione fondamentale su dove sia "centrata" la distribuzione della variabile aleatoria. Può essere chiamato anche *speranza* o *momento primo*.

Definizione: Valore Atteso

A seconda della natura della variabile aleatoria, il calcolo del valore atteso differisce:

- **Caso Discreto:** Sia X una v.a. discreta a valori in $\{a_1, a_2, \dots\}$ con funzione di massa di probabilità $p_X(a_j) = P(X = a_j)$. Il valore atteso è definito come:

$$E[X] = \sum_j a_j \cdot p_X(a_j) \quad (1)$$

Se le modalità sono in numero infinito (es. $\mathbb{N}$), si tratta di una serie: $E[X] = \lim_{n \rightarrow \infty} \sum_{j=1}^n a_j \cdot p_X(a_j)$.

- **Caso Assolutamente Continuo (con densità):** Sia X una v.a. con funzione di densità $f(x)$. Il valore atteso è:

$$E[X] = \int_{-\infty}^{+\infty} x \cdot f(x) dx \quad \left(\lim_{b \rightarrow +\infty} \dots \right) \quad (2)$$

2.1 Significato del Valore Atteso

Il valore atteso può essere interpretato fisicamente come il **baricentro della distribuzione**. Nel caso discreto, è una media pesata dei valori assunti dalla variabile, dove i pesi sono le probabilità: i valori più probabili contano di più.

Approccio Frequentista (Legge dei Grandi Numeri - LGN): Nel caso di estrazione da una popolazione, se ripetiamo l'esperimento n volte, il limite della media aritmetica dei valori assunti da X tenderà esattamente al valore atteso $E[X]$ per $n \rightarrow \infty$.

$$E(X) = \sum_j a_j \cdot \underbrace{p_X(a_j)}_{\text{DI TUTTA LA POPOLAZIONE}} = \text{MEDIA CAMPIONARIA}$$


FREQ. RELATIVA DI a_j SU TUTTA LA POPOLAZIONE

SE $f(x)$ È SIMM.
 $\Rightarrow E[X] =$
 = CENTRO DI SIMMETRIA
 LA MODA È IL VALORE PIÙ FREQUENTE, DOVE $f(x)$ HA IL PICCO

Appunti di Statistica e Probabilità

Valore Atteso e Varianza

SIGNIFICA (CASO DENSA):
 $E(X) = \text{INTEGRALE PESATO DELLE DENSA}$



2.2 Esempi Fondamentali di Valore Atteso

Esempio: Esito lancio di un dado equilibrato

Sia X l'esito del lancio di un dado. I valori assumibili sono $a_k \in \{1, 2, \dots, 6\}$ con probabilità $P(X = k) = \frac{1}{6}$.

$$E[X] = \sum_{k=1}^6 k \cdot \frac{1}{6} = \frac{1}{6} (1 + 2 + 3 + 4 + 5 + 6) = \frac{1}{6} \cdot \frac{6 \cdot 7}{2} = \frac{7}{2} = 3.5$$

Esempio: Variabile Uniforme Continua $U(0,1)$

Sia $X \sim U(0,1)$. La funzione di densità è $f(x) = 1$ per $x \in (0,1)$, e 0 altrimenti.

$$E[X] = \int_{-\infty}^{+\infty} x \cdot f(x) dx = \int_0^1 x dx = \left[\frac{1}{2} x^2 \right]_0^1 = \frac{1}{2}$$

In generale, per $X \sim U(\alpha, \beta)$, dove $f(x) = \frac{1}{\beta - \alpha}$, si ha:

$$E[X] = \int_{\alpha}^{\beta} x \cdot \frac{1}{\beta - \alpha} dx = \frac{1}{\beta - \alpha} \left[\frac{x^2}{2} \right]_{\alpha}^{\beta} = \frac{\beta^2 - \alpha^2}{2(\beta - \alpha)} = \frac{\alpha + \beta}{2}$$

2.3 Esistenza del Valore Atteso: Quando è definito?

Il valore atteso non è sempre finito e potrebbe anche non essere definito.

$\sum_{j=1}^{\infty} a_j \cdot P(a_j) = E[X]$, ammettendo che possa anche risultare $+\infty$. Quindi $E[X] \in [0, +\infty]$.

Se X è generica, si dice che **ammette valore atteso** se è assolutamente convergente:

- Caso discreto: se $\sum_k |a_k| P(X = a_k) < \infty$.

- Caso continuo: se $\int_{-\infty}^{+\infty} |x| f(x) dx < \infty$.

Nota:

Se X assume solo un numero finito di valori, oppure se la densità $f(x)$ è supportata su un intervallo limitato $[a, b]$, allora X ammette sempre valore atteso reale (non diverge).

$E = 0$ FUORI

DA UN INTERVALLO

LIMITATO $[a, b]$ ($P\{X \in [a, b]\} = 1$)

Appunti di Statistica: Trasformazioni di Variabili Aleatorie e LOTUS

Riassunto della conversazione

1 Il Teorema dell'Esististico Incompleto (LOTUS)

Domanda: Perché $E[g(X)] = \int g(x) f(x) dx$ e non si moltiplica per $f(x)$?

Il motivo per cui valiamo la densità $f(x)$ è che stiamo integrando rispetto a x e non a $f(x)$. Se $f(x)$ è la densità, allora $f(x) dx$ è l'elemento di misura. Se $f(x)$ è la densità, allora $f(x) dx$ è l'elemento di misura. Se $f(x)$ è la densità, allora $f(x) dx$ è l'elemento di misura.

Se $f(x)$ è la densità, allora $f(x) dx$ è l'elemento di misura. Se $f(x)$ è la densità, allora $f(x) dx$ è l'elemento di misura. Se $f(x)$ è la densità, allora $f(x) dx$ è l'elemento di misura.

2 La conservazione della Probabilità

Domanda: Se cambia x con $g(x)$, allora anche la probabilità $f(x)$ non è più corretta perché la probabilità di x può essere cambiata?

Questo è un dubbio legittimo, ma succede un'altra cosa: la probabilità non cambia. Quando si cambia x con $g(x)$, la probabilità $f(x)$ si trasforma in $f(g(x))$. La probabilità $f(x)$ si trasforma in $f(g(x))$.

Esempio Numerico Discreto
 Consideriamo una variabile X che assume solo i valori -2 e 2 , ciascuno con probabilità 0.5 . Definiamo $Y = X^2$.

Metodo LOTUS (usando la probabilità di X):
 $E[Y] = E[X^2] = (-2)^2 \cdot 0.5 + (2)^2 \cdot 0.5 = 4 \cdot 0.5 + 4 \cdot 0.5 = 4$

Abbiamo usato la probabilità originale (0.5).

Metodo Classico (usando la densità di Y): Poiché da -2 a 2 il quadrato fa 4 , la nuova variabile Y assume il valore 4 con probabilità 1 .

$$E[Y] = 4 \cdot 1 = 4$$

Il rischio è che il LOTUS funzioni perché basta che la formula sia corretta, non importa se la probabilità originale che viene a scovare, non corrisponde a calcolare la nuova distribuzione.

3 Applicazioni e Limiti del LOTUS

Domanda: Il LOTUS lo possiamo usare solo nel caso particolare del valore atteso?

Il LOTUS serve per il calcolo del valore atteso, ma può essere usato per tutti gli indici statistici derivati dal valore atteso, come la varianza e la covarianza.

Domanda: Come PUOI calcolare con il LOTUS?

• Varianza: $\text{Var}(g(X)) = E[g(X)^2] - (E[g(X)])^2 = \int g(x)^2 f(x) dx - \mu^2$

• Momenti: $E[g(X)^k] = \int g(x)^k f(x) dx$

• Probabilità di eventi: $P(g(X) \in A) = \int_A f(g(x)) dx$

Cosa NON PUOI calcolare con il LOTUS? Non puoi usare questo teorema per studiare la "forma" della nuova distribuzione. Non ti dà mai qual è la funzione di densità $f(g(x))$, la Moda o la Mediana di Y . Per questo, serve usare la funzione di ripartizione.

4 Probabilità tramite Funzione di Ripartizione

Domanda: Se so che $P(X < 3) = 0.8$ e $Y = X^2$, non posso trovare $P(Y < 3)$ senza calcolare la densità?

Assolutamente sì! Puoi risolverlo senza passare per la densità e senza usare il LOTUS, semplicemente applicando il Metodo della Funzione di Ripartizione. Il trucco è tradurre la condizione su Y in una condizione equivalente su X .

Vogliamo calcolare:

$$P(Y < 3)$$

$$P(X^2 < 3)$$

Sostituendo Y con X^2 :

Risolviamo la disuguaglianza rispetto a X :

$$P(-\sqrt{3} < X < \sqrt{3})$$

Questo passaggio geometrico è illustrato nel grafico accanto. Come al volo del grafico, l'evento $Y < 3$ si verifica se e solo se X cade nell'intervallo $(-\sqrt{3}, \sqrt{3})$. A questo punto, per ottenere un numero, basterà utilizzare la funzione di ripartizione di X (se nota):

$$P(Y < 3) = P(X^2 < 3) = P(-\sqrt{3} < X < \sqrt{3})$$

Non abbiamo avuto bisogno di derivare o calcolare alcuna formula per $f(x)$!




Figura 1. Visualizzazione della trasformazione $Y = X^3$. Richiediamo che $Y < 3$ (area ombreggiata in rosso) equivale a richiedere che la variabile originale X si trovi nell'intervallo tra $-\sqrt{3}$ e $\sqrt{3}$.

$$(II) \Rightarrow 1_A(x) = \begin{cases} 1 & \text{se } x \in A \\ 0 & \text{se } x \notin A \end{cases}$$

Appunti di Statistica e Probabilità

Valore Atteso e Varianza

Esempio: Un caso di divergenza a $+\infty$

Sia X con densità $f_X(x) = \frac{1}{x^2} 1_{(1,+\infty)}(x) \rightarrow \begin{cases} 1/x^2 & \text{se } x > 1 \\ 0 & \text{se } x \leq 1 \end{cases}$

$$E[X] = \int_1^{+\infty} x \cdot \frac{1}{x^2} dx = \int_1^{+\infty} \frac{1}{x} dx = [\log(x)]_1^{+\infty} = +\infty$$

3 Valore Atteso di una Funzione di V.A. (Teorema di Trasferimento)

Sia X una v.a. e sia $g: \mathbb{R} \rightarrow \mathbb{R}$ una funzione. Allora $Y = g(X)$ è ancora una variabile aleatoria. Come si calcola $E[g(X)]$?

Proprietà / Teorema: Teorema di Trasferimento

1) Se X è discreta con funzione di massa p_X :

$$E[g(X)] = \sum_k g(a_k) \cdot p_X(a_k) \quad (3)$$

2) Se X è assolutamente continua con densità f_X :

$$E[g(X)] = \int_{-\infty}^{+\infty} g(x) f_X(x) dx \quad (4)$$


Esempio:

Sia X l'esito del lancio di un dado e sia $g(X) = X^2$.

$$E[X^2] = \sum_{k=1}^6 k^2 \cdot \frac{1}{6} = \frac{1}{6} (1 + 4 + 9 + 16 + 25 + 36) = \frac{91}{6}$$

4 Proprietà del Valore Atteso

Siano X e Y due variabili aleatorie e $a, b \in \mathbb{R}$. Il valore atteso gode delle seguenti proprietà fondamentali:



Es. 2.2
 $X \sim \text{UNIF}(0,1) \quad f_X(x) = \begin{cases} 1 & \text{se } x \in (0,1) \\ 0 & \text{se } x \notin (0,1) \end{cases}$

$$E[X^2] = \int_{-\infty}^{+\infty} x^2 \cdot f_X(x) \cdot dx = \int_0^1 x^2 \cdot 1 \cdot dx = \int_0^1 x^2 \cdot dx = \left[\frac{x^3}{3} \right]_0^1 = \frac{1}{3} - 0 = \frac{1}{3}$$

- ANCHE SE
 g NON È
 UN DIFFERENZIALE
 IN TAL CASO
 NON TAVI
 $f_X(y)$ È
 QUINDI UTILI
 LA F.D.R.
 $P(Y \leq y) =$
 $= P(g(X) \leq y)$
 $= F_Y(y)$
 es.
 $P(X^2 < 3) =$
 $= P(-\sqrt{3} < X < \sqrt{3})$

X, Y v.a. $\in \mathbb{R}$

Proprietà / Teorema: Linearità e Monotonia

1. Linearità della somma: $E[X + Y] = E[X] + E[Y]$.
2. Linearità del prodotto per scalare e traslazione: $E[aX + b] = aE[X] + b$.
3. Di conseguenza, la speranza di una costante è la costante stessa: $E[b] = b$.
4. Monotonia (positività): Se $X \geq 0$, allora $E[X] \geq 0$.
5. Monotonia fra variabili: Se $X \geq Y$, allora $E[X] \geq E[Y]$. In particolare, $|E[X]| \leq E[|X|]$.

Esempio: Somma di due dadi

Consideriamo il lancio di due dadi equilibrati. X = "esito 1° lancio", Y = "esito 2° lancio". Qual è il valore atteso della somma? Sapendo che $E[X] = E[Y] = \frac{7}{2}$, per la linearità si ottiene:

$$E[X + Y] = E[X] + E[Y] = \frac{7}{2} + \frac{7}{2} = 7$$

5 Momenti di una Variabile Aleatoria

Definizione: Momento di ordine n

Data una variabile aleatoria X e un intero $n = 1, 2, 3, \dots$, si definisce **momento di ordine n di X** il valore atteso della v.a. X^n , ovvero $E[X^n]$. (Il valore atteso classico è il momento di ordine 1).

$$E[X^n] = \begin{cases} \sum_k a_k^n \cdot p_X(a_k) & \text{caso discreto} \\ \int_{-\infty}^{+\infty} x^n f(x) dx & \text{caso continuo} \end{cases} \quad (5)$$

Osservazione: Si dice che X ammette momento di ordine n se la quantità in valore assoluto è finita: $E[|X|^n] < +\infty$. Se una v.a. ammette momenti di ordine alto, significa $E[X] \in \mathbb{R}$ che ha "code leggere" (la probabilità di ottenere valori estremi è molto piccola).

$$E[|X|^n] < +\infty \Rightarrow X \text{ ha code "leggere" (n=10)}$$

6 Disuguaglianze Notevoli: Markov

Queste disuguaglianze ci permettono di stimare la probabilità di eventi rari conoscendo solo pochi indici (come la media e la varianza).

Proprietà / Teorema: Disuguaglianza di Markov

Sia X una v.a. non negativa ($X \geq 0$) e sia $a > 0$. Allora:

$$P(X \geq a) \leq \frac{1}{a} E[X]$$

* Se conosco solo la media, qual è la probabilità massima di avere valori estremi "disastrosi"?

Dim. $X \geq Y$, con $Y = \begin{cases} a & \text{se } X \geq a \\ 0 & \text{se } X < a \end{cases}$

$$\Rightarrow E[X] \geq E[Y] = a \cdot P(X \geq a) + 0 \cdot P(X < a) = a \cdot P(X \geq a)$$

$X \geq Y$ si intende solo stesso esperimento.
 $X(\omega) \geq Y(\omega)$

Appunti di Statistica: Media Campionaria vs Valore Atteso

La Legge dei Grandi Numeri

1 Due mondi a confronto

In statistica e probabilità, il termine "media" può essere ambiguo perché si riferisce a due entità distinte che appartengono a mondi diversi.

1.1 1. La Media Campionaria ($\bar{X}$): Il Mondo dei Dati

È la media aritmetica calcolata su un insieme di n osservazioni reali.

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

- È una **variabile aleatoria**: se ripeti l'esperimento, otterrai dati diversi e quindi una media diversa.
- È **empirica**: dipende da ciò che hai effettivamente misurato. ($E[X]$ non è empirico, è un valore atteso)

1.2 2. Il Valore Atteso ($E[X]$): Il Mondo della Teoria

È la **media teorica** (o "baricentro") della distribuzione di probabilità.

$$E[X] = \int_{-\infty}^{+\infty} x f(x) dx \quad (\text{continuo}) \quad \text{oppure} \quad \sum_i x_i P(x_i) \quad (\text{discreto})$$

- È un **numero fisso**: non cambia, è una **proprietà intrinseca** della distribuzione.
- È **ideale**: rappresenta ciò che accadrebbe "in media" se potessimo osservare infiniti dati.

2 La Legge dei Grandi Numeri (LLN)

Il legame tra questi due mondi è fornito dalla Legge dei Grandi Numeri. Essa afferma che, all'aumentare della dimensione del campione ($n \rightarrow \infty$), la media campionaria converge al valore atteso:

$$P\left(\lim_{n \rightarrow \infty} \bar{X}_n = E[X]\right) = 1$$

Intuizione: Più dati raccogliamo, più il "rumore" dei singoli dati si annulla, facendo emergere la struttura teorica sottostante (il valore atteso).

3 Visualizzazione della Convergenza

Il grafico seguente mostra una simulazione del lancio di un dado a 6 facce. Il valore atteso teorico è $E[X] = 3.5$. Si nota come, per n piccoli, la media campionaria oscilla violentemente, per poi stabilizzarsi vicino a 3.5 al crescere di n .

Proprietà / Teorema: Linearità e Monotonia

1. Linearità della somma: $E[X + Y] = E[X] + E[Y]$.
2. Linearità del prodotto per scalare e traslazione: $E[aX + b] = aE[X] + b$.
3. Di conseguenza, la speranza di una costante è la costante stessa: $E[b] = b$.
4. Monotonia (positività): Se $X \geq 0$, allora $E[X] \geq 0$.
5. Monotonia fra variabili: Se $X \geq Y$, allora $E[X] \geq E[Y]$. In particolare, $E[X] \leq E[Y]$.

$X \geq Y$ si
intende su
stesso
spazio
campionario.
 $X(\omega) \geq Y(\omega)$

Esempio: Somma di due dadi

Consideriamo il lancio di due dadi equilibrati. X = "esito 1° lancio", Y = "esito 2° lancio". Qual è il valore atteso della somma? Sapendo che $E[X] = E[Y] = \frac{7}{2}$, per la linearità si ottiene:

$$E[X + Y] = E[X] + E[Y] = \frac{7}{2} + \frac{7}{2} = 7$$

5 Momenti di una Variabile Aleatoria

Definizione: Momento di ordine n

Data una variabile aleatoria X e un intero $n = 1, 2, 3, \dots$, si definisce **momento di ordine n** di X il valore atteso della v.a. X^n , ovvero $E[X^n]$. (Il valore atteso classico è il momento di ordine 1).

$$E[X^n] = \begin{cases} \sum_{k=1}^n a_k^n \cdot p_X(a_k) & \text{caso discreto} \\ \int_{-\infty}^{+\infty} x^n f(x) dx & \text{caso continuo} \end{cases} \quad (5)$$

Osservazione: Si dice che X ammette momento di ordine n se la quantità in valore assoluto è finita: $E[|X|^n] < +\infty$. Se una v.a. ammette momenti di ordine alto, significa che ha "code leggere" (la probabilità di ottenere valori estremi è molto piccola).

$$E[|X|^n] < +\infty \Rightarrow X \text{ ha code "leggere"} (n=10)$$

6 Disuguaglianze Notevoli: Markov

Queste disuguaglianze ci permettono di stimare la probabilità di eventi rari conoscendo solo pochi indici (come la media e la varianza).

Proprietà / Teorema: Disuguaglianza di Markov

Sia X una v.a. non negativa ($X \geq 0$) e sia $a > 0$. Allora:

$$P(X \geq a) \leq \frac{1}{a} E[X] \quad (6)$$

ES. ✓
VAL. ATTESO
DELLA V.A.
MEHA STIPEN
a 1500€
(TUTTI I 20)
QUAL È LA
% MASIMA DI
PERSONE CHE
GUADAGNANO
≥ 6000€?

$$\text{Dim. } X \geq Y, \text{ con } Y = \begin{cases} a & \text{se } X \geq a \\ 0 & \text{se } X < a \end{cases}$$

$$\Rightarrow E[X] \geq E[Y] = a \cdot P(X \geq a) + 0 \cdot P(X < a) = a \cdot P(X \geq a)$$

Appunti di Statistica: Media Campionaria vs Valore Atteso

La Legge dei Grandi Numeri

1 Due mondi a confronto

In statistica e probabilità, il termine "media" può essere ambiguo perché si riferisce a due entità distinte che appartengono a mondi diversi.

1.1 1. La Media Campionaria ($\bar{X}$): Il Mondo dei Dati

È la media aritmetica calcolata su un insieme di n osservazioni reali.

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

- È una variabile aleatoria: se ripeti l'esperimento, otterrai dati diversi e quindi una media diversa.
- È empirica: dipende da ciò che hai effettivamente misurato. ($E[X]$ NON È EMPIRICO) (NON ESISTE L'ESPERIMENTO)

1.2 2. Il Valore Atteso ($E[X]$): Il Mondo della Teoria

È la media teorica (o "baricentro") della distribuzione di probabilità.

$$E[X] = \int_{-\infty}^{+\infty} x f(x) dx \quad (\text{continuo}) \quad \text{oppure} \quad \sum_i x_i P(x_i) \quad (\text{discreto})$$

- È un numero fisso: non cambia, è una proprietà intrinseca della distribuzione.
- È ideale: rappresenta ciò che accadrebbe "in media" se potessimo osservare infiniti dati.

2 La Legge dei Grandi Numeri (LLN)

Il legame tra questi due mondi è fornito dalla Legge dei Grandi Numeri. Essa afferma che, all'aumentare della dimensione del campione ($n \rightarrow \infty$), la media campionaria converge al valore atteso:

$$P\left(\lim_{n \rightarrow \infty} \bar{X}_n = E[X]\right) = 1$$

Intuizione: Più dati raccogliamo, più il "rumore" dei singoli dati si annulla, facendo emergere la struttura teorica sottostante (il valore atteso).

3 Visualizzazione della Convergenza

Il grafico seguente mostra una simulazione del lancio di un dado a 6 facce. Il valore atteso teorico è $E[X] = 3.5$. Si nota come, per n piccoli, la media campionaria oscilla violentemente, per poi stabilizzarsi vicino a 3.5 al crescere di n .




Figura 1: Simulazione della convergenza della media campionaria verso il valore atteso (Lancio di un dado).

4 Risposta al dubbio sulle probabilità

"Ma se X assume valori grandi con probabilità minuscola?"

Il valore atteso $E[X]$ ne tiene già conto! Se un valore è enorme ($x = 1.000.000$) ma la sua probabilità è quasi nulla ($P = 0.000001$), il suo contributo alla media sarà piccolissimo ($x \cdot P = 1$).

Quando calcoli la media campionaria reale, quel valore enorme apparirà molto raramente. Nella stragrande maggioranza dei campioni non lo vedrai mai, e la tua $\bar{X}$ sarà bassa. Solo ogni tanto "pescherà" il valore gigante e la media schizzerà in alto. Sul lunghissimo periodo (LLN), questi rari eventi compenseranno esattamente il valore atteso teorico.

Corollario: Se X ammette momento n -esimo, si può generalizzare come $P(|X| \geq a) \leq \frac{1}{a^n} E[|X|^n]$. Questa versione deriva direttamente dall'osservare che l'evento $\{|X| \geq a\}$ è equivalente a $\{|X|^n \geq a^n\}$.

7 Varianza e Deviazione Standard

Mentre il **valore atteso** indica il "centro", la **varianza** misura la **dispersione** della distribuzione attorno al centro. Si tratta dell'equivalente probabilistico della varianza empirica della statistica descrittiva.

Definizione: Varianza e Deviazione Standard


Sia X una v.a. che ammette momento secondo (ovvero $E[X^2] < \infty$). La **Varianza** di X è definita come il valore atteso degli scarti al quadrato rispetto alla media:

$$Var(X) = E[(X - E[X])^2] \quad (X - E[X])^2 = g(X) \quad (7)$$

La **Deviazione Standard** (o scarto quadratico medio) è semplicemente la radice quadrata della varianza: $\sigma(X) = \sqrt{Var(X)}$.

$E[X]$: PUNTO DI EQUILIBRIO

$E[(X - E[X])^2]$: DISPERSIONE



$X - E[X]$ SCARTO IN O
IL CENTRO DELLA DISTRIBUZIONE
 $(\cdot)^2$ DA DISTANZE AD ALTE

7.1 Formula Pratica per il Calcolo e Proprietà

Sviluppando il quadrato nella definizione, otteniamo la formula di calcolo:

$$Var(X) = E[X^2 - 2XE[X] + E[X]^2] = E[X^2] - 2E[X]E[X] + E[X]^2 = E[X^2] - E[X]^2 \quad (8)$$

Proprietà / Teorema: Proprietà della Varianza

Siano $a, b \in \mathbb{R}$.

- Proprietà di Scaling e Invarianza per Traslazione:** $Var(aX + b) = a^2 \cdot Var(X)$. (D.M. PER ESPERIMENTI)
- Varianza di una Costante:** In particolare, se calcoliamo la varianza di un numero fisso otteniamo zero: $Var(b) = 0$.
- Condizione per Varianza Nulla:** $Var(X) = 0 \iff X$ è una variabile costante.

D.M.

$$(\Rightarrow) Var(X) = 0 \Rightarrow P(|X - E[X]| \leq \frac{1}{\sqrt{0}}) = 0 = 0$$

$$(\Leftarrow) X \text{ è COSTANTE} = E[X] \Rightarrow Var(X) = E[(X - E[X])^2] = E[(c - c)^2] = E[0] = 0$$

$E[X] = c \cdot P(X=c) = c \cdot 1 = c$

Esempio: Varianza di un Dado

Sappiamo che $E[X] = \frac{7}{2}$ e $E[X^2] = \frac{91}{6}$.

$$Var(X) = E[X^2] - E[X]^2 = \frac{91}{6} - \left(\frac{7}{2}\right)^2 = \frac{91}{6} - \frac{49}{4} = \frac{182 - 147}{12} = \frac{35}{12}$$

7.2 Disuguaglianza di Chebyshev

Basandosi sulla varianza, questa disuguaglianza lega la dispersione dei dati alla probabilità che la variabile si allontani dalla sua media di una certa distanza d .

Proprietà / Teorema: Disuguaglianza di Chebyshev

Sia X una v.a. con momento secondo finito e $d > 0$. Allora:

$$P(|X - E[X]| \geq d) \leq \frac{1}{d^2} \cdot Var(X) \quad (9)$$

Significato: La probabilità che la variabile X si discosti dal suo valore atteso per più di d è limitata superiormente dalla varianza divisa per d^2 . Se d è piccolo la frazione risulta grande; fornendo un limite debole; altrimenti se d è grande il limite garantisce che l'evento sia molto raro. Questa disuguaglianza deriva direttamente dall'applicazione di Markov alla variabile aleatoria $(X - E[X])^2$. ($Var(X) = 0 \Leftrightarrow X = \text{costante} = E(X)$)

8 Variabili Aleatorie Notevoli Discrete

Le variabili discrete "famose" descrivono modelli ricorrenti nella realtà (successi/insuccessi, conteggi).

8.1 Variabile di Bernoulli: $X \sim Be(p)$

Descrive un esperimento con due soli esiti: "Successo" (1) con probabilità p , o "Insuccesso" (0) con probabilità $q = 1 - p$.

- Valore Atteso: $E[X] = 1 \cdot p + 0 \cdot (1 - p) = p$ ($\sum a_k \cdot P(X = a_k)$)
- Varianza: $E[X^2] = 1^2 \cdot p + 0^2 \cdot (1 - p) = p \Rightarrow Var(X) = p - p^2 = p(1 - p)$

8.2 Variabile Binomiale: $X \sim B(n, p)$

Rappresenta il numero di successi in n prove indipendenti di Bernoulli.

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k \in \{0, 1, \dots, n\} \quad (10)$$

Per la linearità del valore atteso (essendo la somma di n Bernoulli indipendenti):

- $E[X] = n \cdot p$ ($E[X_1 + X_2 + \dots + X_n]$)
- $Var(X) = n \cdot p(1 - p)$

8.3 Variabile di Poisson: $X \sim P(\lambda)$

Modella il numero di eventi che avvengono in un intervallo di tempo o spazio fisso (es. arrivi in un centralino, difetti in un tessuto).

Nota: Significato del parametro

λ rappresenta il tasso medio (o intensità): è il numero medio di successi nell'intervallo considerato. Deve essere strettamente positivo ($\lambda > 0$).

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k \in \{0, 1, 2, \dots\} \quad (11)$$

[Calcolo di Valore Atteso e Varianza] Valore Atteso:

$$E[X] = \sum_{k=0}^{+\infty} k \cdot e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=1}^{+\infty} \frac{\lambda \cdot \lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} \sum_{j=0}^{+\infty} \frac{\lambda^j}{j!} = \lambda e^{-\lambda} e^{\lambda} = \lambda$$

Varianza: Calcoliamo prima il momento fattoriale $E[X(X-1)]$:

$$E[X(X-1)] = \sum_{k=2}^{+\infty} k(k-1) e^{-\lambda} \frac{\lambda^k}{k!} = \lambda^2 e^{-\lambda} \sum_{j=0}^{+\infty} \frac{\lambda^j}{j!} = \lambda^2$$

Quindi $E[X^2] = E[X(X-1)] + E[X] = \lambda^2 + \lambda$.

$$Var(X) = E[X^2] - (E[X])^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

9 Variabili Aleatorie Notevoli Continue


9.1 Variabile Uniforme Continua: $X \sim U([a, b])$

Rappresenta una scelta "completamente a caso" tra due estremi a e b .

Nota: Significato delle variabili

a e b sono i supporti (minimo e massimo). La densità è costante tra di essi, il che significa che ogni sotto-intervallo della stessa ampiezza ha la medesima probabilità.

Densità: $f(x) = \frac{1}{b-a}$ per $x \in [a, b]$, zero altrove.



[Valore Atteso e Varianza] $E[X] = \int_a^b \frac{x}{b-a} dx = \frac{1}{b-a} \left[\frac{x^2}{2} \right]_a^b = \frac{b^2 - a^2}{2(b-a)} = \frac{b+a}{2}$ (Punto medio).

$$Var(X) = E[X^2] - E[X]^2 = \int_a^b \frac{x^2}{b-a} dx - \left(\frac{b+a}{2} \right)^2 = \dots = \frac{(b-a)^2}{12}$$

9.2 Variabile Esponenziale: $X \sim \text{Exp}(\lambda)$

Utilizzata per modellare il tempo di attesa continuo tra eventi (es. durata di un componente elettronico, tempo fino al prossimo arrivo).

$\lambda > 0$ rappresenta il tasso di guasto o di arrivo. Un λ elevato indica che l'evento avverrà mediamente in poco tempo.

Densità: $f(x) = \lambda e^{-\lambda x}$ per $x > 0$, altrimenti 0.
[Calcolo di Valore Atteso e Varianza] Calcoliamo $E[X]$ tramite integrazione per parti (fattore finito x , fattore differenziale $\lambda e^{-\lambda x}$):

$$E[X] = \int_0^{+\infty} x \lambda e^{-\lambda x} dx = [x(-e^{-\lambda x})]_0^{+\infty} - \int_0^{+\infty} 1 \cdot (-e^{-\lambda x}) dx$$

$$= 0 + \int_0^{+\infty} e^{-\lambda x} dx = \left[-\frac{1}{\lambda} e^{-\lambda x} \right]_0^{+\infty} = \frac{1}{\lambda}$$

Per la varianza, serve il momento secondo $E[X^2]$, integrando sempre per parti:

$$E[X^2] = \int_0^{+\infty} x^2 \lambda e^{-\lambda x} dx = [x^2(-e^{-\lambda x})]_0^{+\infty} + \int_0^{+\infty} 2x e^{-\lambda x} dx$$

$$= 0 + \frac{2}{\lambda} \int_0^{+\infty} x e^{-\lambda x} dx = \frac{2}{\lambda} E[X] = \frac{2}{\lambda} \cdot \frac{1}{\lambda} = \frac{2}{\lambda^2}$$

Quindi: $\text{Var}(X) = E[X^2] - E[X]^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$

9.3 Variabile Normale (Gaussiana)

9.3.1 Caso Standard: $Z \sim N(0,1)$

Densità: $\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$. $E[Z] = \int_{-\infty}^{+\infty} z \cdot \varphi(z) \cdot dz = 0$

• Valore Atteso: $E[Z] = 0$ (per simmetria della densità, la funzione integranda $z\varphi(z)$ è dispari).

• Varianza: $E[Z^2] = \int_{-\infty}^{+\infty} z^2 \varphi(z) dz$. Per parti: $[z(-\varphi(z))]_{-\infty}^{+\infty} + \int_{-\infty}^{+\infty} \varphi(z) dz = 0 + 1 = 1$.

$$f'(x) = (-x) \cdot f(x) \Rightarrow \int x \cdot f(x) dx = -f(x)$$

9.3.2 Caso Generale: $X \sim N(m, \sigma^2)$

Si ottiene come trasformazione lineare: $X = \sigma Z + m$.

• m (media): Determina il centro della campana e la posizione del picco (asse di simmetria).

• σ^2 (varianza): Determina la dispersione. Se σ^2 è grande, la curva si appiattisce; se è piccola, la curva diventa alta e stretta.

4.59 (226)

$$X \geq 0$$

$X =$ "RICCHEZZA DI UN IND. DELLA POPOL."

$$P(X \geq r_{1-\alpha}) = \alpha$$

K t.c. $P(Y \geq K) = 0.95$ $n = 1000$

$Y =$ "MHI. TOT. TESTE" $= Y_1 + Y_2 + \dots + Y_n \sim B(1000, 0.5)$

$0.95 = P(X \geq K) = P\left(\frac{X-500}{\sqrt{250}} \geq \frac{K-500}{\sqrt{250}}\right) = P\left(Z \geq \frac{K-500}{\sqrt{250}}\right)$

$Z \sim N(0,1)$

$P\left(Z \geq \frac{K-500}{\sqrt{250}}\right) = 1 - P\left(Z < \frac{K-500}{\sqrt{250}}\right) = 1 - \Phi\left(\frac{K-500}{\sqrt{250}}\right)$

$1 - \Phi\left(\frac{K-500}{\sqrt{250}}\right) = 0.95$

$\Phi\left(\frac{K-500}{\sqrt{250}}\right) = 0.05 \Rightarrow \frac{K-500}{\sqrt{250}} =$

$\Phi^{-1}(0.05) = 1.65$

$\Rightarrow \frac{K-500}{\sqrt{250}} = 1.65$

$-K + 500 = 1.65 \cdot \sqrt{250}$

$K = 500 - 1.65 \cdot \sqrt{250} = 473.912$

$X \sim \text{GEOM}(p)$

$P(X=m) = (1-p)^{m-1} \cdot p$

$E[X] = \sum_{i=0}^{\infty} a_i \cdot P(X=a_i)$

$= \sum_{i=0}^{\infty} a_i \cdot (1-p)^{a_i-1} \cdot p$

mediAbout

13 SX
29 SX

$$[wZ] \exists w \cdot 0 =$$

$$- [wZw] \exists = [wX] \exists$$

21

GRUPPO 1 (1, 2, ..., 13)

GRUPPO 2

LA PERDARE UN MONEDINO $\frac{13}{42}$ E POI CHE SIA IN QUEL GRUPPO $\frac{1}{2}$
 CHE UNO SIA SX NEL GRUPPO 1 $\frac{13}{42} \cdot \frac{1}{2} = \frac{13}{84}$

$\frac{1}{2} \cdot \frac{1}{2} \cdot \dots \cdot \frac{1}{2} \cdot \frac{1}{2}$
 21

E C'2 BANDO LE STESE PROB., IN ESTIMAZIONE HO $\frac{13}{42}$ SX

$$SX \text{ IN 21 PROVE} = \frac{13}{42} \cdot \frac{21}{2} \cdot \binom{21}{1}$$


$$\left(\frac{21}{42} \right)^{21-k} \cdot \binom{21}{k}$$

$$h(y) = \sigma y + m$$

$$P(\sigma y + m < 3)$$

$$P(y < \frac{3-m}{\sigma})$$

71k-70k



[Momenti Normale Generale] Sfruttando le proprietà di linearità della media e della varianza:

- $E[X] = E[\sigma Z + m] = \sigma E[Z] + m = \sigma(0) + m = m$
- $Var(X) = Var(\sigma Z + m) = \sigma^2 Var(Z) = \sigma^2(1) = \sigma^2$

$$E[X^m] = \begin{cases} 0 & \text{se } m \text{ è dispari} \\ \sigma^m \cdot (m-1)!! & \text{se } m \text{ è pari} \end{cases}$$

NOTA: MOLTIPLICA SOLO I DISPARI

10 Ulteriori Variabili Discrete Notevoli

10.1 Variabile Geometrica: $T \sim \text{Geom}(p)$

Modella il numero di prove necessarie per ottenere il primo successo.

Nota: Significato delle variabili

p : Probabilità di successo in una singola prova indipendente.

$1-p$ (spesso indicato con q): Probabilità di insuccesso.

$$P(T=k) = p(1-p)^{k-1}, \quad k \in \{1, 2, \dots\} \quad (12)$$

- Valore Atteso: $E[T] = \frac{1}{p}$. (Se la probabilità è 1/10, in media servono 10 lanci).

- Varianza: $Var(T) = \frac{1-p}{p^2}$

$$E[T] = \overbrace{p \cdot 1}^{\text{CASO SUCCESSO}} + \overbrace{(1-p) \cdot (1 + E[T])}^{\text{CASO INSUCCESSO}}$$

PER ALCUNA DI MEMORIA

10.2 Variabile Ipergeometrica: $X \sim H(N, K, n)$ (NON C'E')

Utilizzata per estrazioni senza reimmissione da una popolazione finita.

Nota: Significato delle variabili

- N : Numero totale di elementi nella popolazione.
- K : Numero di elementi "favorevoli" (successi) presenti nella popolazione totale.
- n : Numero di elementi estratti (ampiezza del campione).
- k : Numero di successi trovati nel campione estratto.

$$P(X=k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}} \quad (13)$$

- Valore Atteso: $E[X] = n \cdot \frac{K}{N}$. (Nota la somiglianza con la Binomiale np , dove $p = K/N$).
- Varianza: $Var(X) = n \cdot \frac{K}{N} \cdot (1 - \frac{K}{N}) \cdot \frac{N-1}{N}$.

11 Variabili Aleatorie Multivariate (Leggi Congiunte e Marginali)

Spesso un esperimento aleatorio non è esaurientemente descritto da una singola variabile, ma richiede l'osservazione simultanea di più caratteristiche.


Definizione: Variabile Aleatoria Doppia (o Bivariata)

Dato uno spazio di probabilità $(\Omega, \mathcal{F}, P)$, una **variabile aleatoria doppia** (X, Y) è una funzione che associa ad ogni esito $\omega \in \Omega$ una coppia di numeri reali $(x, y) \in \mathbb{R}^2$:

$$(X, Y) : \Omega \rightarrow \mathbb{R}^2 \text{ con } \omega \mapsto (X(\omega), Y(\omega))$$

Nota: Attenzione alla notazione

La v.a. doppia valuta lo stesso individuo ω su due caratteristiche diverse. Ad esempio: $(X, Y)(\omega) = (\text{Voto di } \omega, \text{Mesi per il primo impiego di } \omega)$. Non confondere con coppie di individui diversi $(X(\omega_1), Y(\omega_2))$.



11.1 Legge Congiunta e Leggi Marginali

Definizione: Legge Congiunta


La **legge (o distribuzione) congiunta** di (X, Y) è la distribuzione di probabilità della coppia. Esprime la probabilità che le variabili assumano congiuntamente valori in un certo insieme $A \subseteq \mathbb{R}^2$: $(X, Y) : \Omega \rightarrow \mathbb{R}^2$ v.a. bivariate

$$P^{(X,Y)}(A) = P(\{(X, Y) \in A\}) = P(\{\omega \in \Omega \mid (X(\omega), Y(\omega)) \in A\})$$


Nel caso in cui l'insieme A sia un prodotto cartesiano $A = A_1 \times A_2$, si ha:

$$P((X, Y) \in A_1 \times A_2) = P(X \in A_1, Y \in A_2) = P(\{X \in A_1\} \cap \{Y \in A_2\})$$

La legge congiunta contiene informazioni essenziali non solo sui singoli fenomeni, ma soprattutto sulla relazione statistica e il legame di dipendenza tra X e Y .



PROB. CHE
X ASSUMA
UN VALORE
E A1
AND
Y E A2



Definizione: Leggi Marginali

Le distribuzioni di probabilità delle singole variabili, prese isolatamente, sono dette **leggi marginali**.

$$P_X(B) = P(X \in B) \quad \text{e} \quad P_Y(C) = P(Y \in C)$$

11.1.1 Il Caso Discreto

(SOMMA DISCRETE)

Se X e Y assumono un numero finito (o numerabile) di valori, (X, Y) è una v.a. discreta.

Definiamo la funzione di massa congiunta:

$$p_{(X,Y)}(x_i, y_j) = P(X = x_i, Y = y_j) \geq 0 \quad \forall i, j \quad \sum_i \sum_j p_{(X,Y)}(x_i, y_j) = 1$$

Dalla congiunta si possono sempre ricavare le funzioni di massa marginali saturando (sommando) rispetto all'altra variabile:

$$p^X(x_i) = P(X = x_i) = \sum_j P(X = x_i, Y = y_j) \quad p^Y(y_j) = P(Y = y_j) = \sum_i P(X = x_i, Y = y_j)$$

Proprietà / Teorema: Relazione tra Congiunta e Marginali


1. La funzione congiunta determina univocamente le marginali (tramite le somme sulle righe o sulle colonne). (DIMOSTRAZIONE...)
2. Le funzioni marginali **NON** determinano univocamente la congiunta (ci sono infinite congiunte che possono avere le stesse marginali).

Sia $\alpha \in (0, 1)$ un parametro. Consideriamo la seguente tabella di densità congiunta per due V.A. binarie $X, Y \in \{0, 1\}$: $P(X=0) = \left(\frac{\alpha}{2}\right) + \left(\frac{1-\alpha}{2}\right) = \frac{1}{2}$

BASCONIA 2
MONETE TRUC

α FUNGE DA
"PARAMETRO" DI
QUANTO SI
INFLUENZA UNO

$X \setminus Y$	0	1	$P(X = x_i)$ (Tot Marginale)
0	$\frac{\alpha}{2}$	$\frac{1-\alpha}{2}$	$\frac{1}{2}$
1	$\frac{1-\alpha}{2}$	$\frac{\alpha}{2}$	$\frac{1}{2}$
$P(Y = y_j)$	$\frac{1}{2}$	$\frac{1}{2}$	1



QUESTO SONO LE P.M. MARGINALI
LEGGERE CESTRANO NON BASTA
PER CONOSCERE
(INTERA)

Come si nota, indipendentemente dal valore di α , le distribuzioni marginali di X e Y sono sempre uniformi ($P(X=0) = \frac{1}{2}$, ecc.). Tuttavia, al variare di α , la legge congiunta cambia drasticamente, dimostrando che le marginali non contengono informazioni sulla dipendenza tra le variabili.

Nota: Il Caso Continuo

Se X e Y sono continue, ammettono una funzione di densità congiunta $f(x, y)$: $\mathbb{R}^2 \rightarrow \mathbb{R}$ tale che:

$$P((X, Y) \in A) = \iint_A f(x, y) dx dy \quad (\text{d.a. } A = [a, b] \times [c, d])$$

12 Indipendenza di Variabili Aleatorie

L'indipendenza traduce l'idea che l'informazione sul valore assunto da una variabile **non** altera le probabilità relative ai valori assunti dall'altra.

Definizione: Variabili Aleatorie Indipendenti

Le variabili $X_1, X_2, \dots, X_n$ si dicono **indipendenti** se per ogni scelta di insiemi $A_1, A_2, \dots, A_n \subseteq \mathbb{R}$, gli eventi $\{X_i \in A_i\}$ sono indipendenti:

$$P(X_1 \in A_1, X_2 \in A_2, \dots, X_n \in A_n) = P(X_1 \in A_1) \cdot P(X_2 \in A_2) \cdots P(X_n \in A_n)$$

Criterio per V.A. Discrete: X e Y sono indipendenti $\iff \forall (x_i, y_j)$ vale:

$$P(X = x_i, Y = y_j) = P(X = x_i) \cdot P(Y = y_j)$$

Proprietà / Teorema: Stabilità dell'Indipendenza per Composizione

Se $X_1, \dots, X_n, Y_1, \dots, Y_m$ sono V.A. indipendenti e $h: \mathbb{R}^n \rightarrow \mathbb{R}, k: \mathbb{R}^m \rightarrow \mathbb{R}$ sono funzioni, allora le nuove variabili:


$$h(X_1, \dots, X_n) \quad \text{e} \quad k(Y_1, \dots, Y_m) \quad \text{sono indipendenti.}$$

Funzioni di gruppi disgiunti di variabili indipendenti sono a loro volta indipendenti.
Ad esempio, se si lanciano 6 dadi ($X_1 \dots X_6$), la somma $X_2 + X_3$ e il massimo $\max\{X_4, X_5\}$ sono V.A. indipendenti.

12.1 Proprietà di Riproducibilità

Se X e Y sono indipendenti, la loro somma appartiene alla stessa famiglia di distribuzioni (con parametri sommati) per queste specifiche leggi:

- **Binomiale:** $X \sim B(n, p), Y \sim B(m, p) \implies X + Y \sim B(n + m, p)$
- **Poisson:** $X \sim P(\lambda), Y \sim P(\mu) \implies X + Y \sim P(\lambda + \mu)$
- **Normale:** $X \sim N(m_1, \sigma_1^2), Y \sim N(m_2, \sigma_2^2) \implies X + Y \sim N(m_1 + m_2, \sigma_1^2 + \sigma_2^2)$



Nota: L'importanza dell'indipendenza

L'ipotesi di indipendenza è cruciale per la riproducibilità. Se consideriamo $X \sim B(1, p)$ e definiamo $Y = X$, le due variabili non sono indipendenti. Se consideriamo la somma $X + Y = 2X$, questa **non** è una binomiale $B(2, p)$. (Infatti, $2X$ può assumere solo i valori 0 e 2, mentre una $B(2, p)$ assume anche il valore 1 con probabilità non nulla).

IN PARTICOLARE:

$$X_i \sim N(m_i, \sigma_i^2) \quad \text{INDIPENDENTI} \quad i = 1, \dots, m$$

$$a_1, \dots, a_m, b \in \mathbb{R}$$

$$\implies \left(\sum_{i=1}^m a_i X_i \right) + b \sim N \left(\left(\sum_{i=1}^m a_i \cdot m_i \right) + b, \sum_{i=1}^m a_i^2 \cdot \sigma_i^2 \right)$$

ESEMPIO

13 Valore Atteso, Covarianza e Correlazione

13.1 Valore Atteso di Funzioni di V.A. Doppie

Data una funzione $g: \mathbb{R}^2 \rightarrow \mathbb{R}$, se X, Y sono discrete, si ha:

$$E[g(X, Y)] = \sum_i \sum_j g(x_i, y_j) \cdot P(X = x_i, Y = y_j)$$

Proprietà / Teorema: Valore Atteso del Prodotto di V.A. Indipendenti

Siano X, Y V.A. indipendenti (con valore atteso finito). Allora:

$$E[X \cdot Y] = E[X] \cdot E[Y]$$

Più in generale: $E[g(X)h(Y)] = E[g(X)] \cdot E[h(Y)]$.

13.2 Covarianza e Correlazione

Definizione: Covarianza

Date due V.A. X, Y con momento secondo finito, la covarianza misura la tendenza delle variabili a variare in modo concorde:

$$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$$

Sviluppando il prodotto, si ottiene la formula di calcolo operativa:

$$\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$$

Proprietà / Teorema: Proprietà della Covarianza

1. Simmetria: $\text{Cov}(X, Y) = \text{Cov}(Y, X)$.

X, Y, Z V.A. con MOM 2°

2. Legame con la Varianza: $\text{Cov}(X, X) = \text{Var}(X)$.

3. Bilinearità: $\text{Cov}(aX + bY + c, Z) = a\text{Cov}(X, Z) + b\text{Cov}(Y, Z)$.

Per ovviare alla dipendenza della covarianza dalle unità di misura, si introduce un indice standardizzato.

Definizione: Coefficiente di Correlazione Lineare

Se $\text{Var}(X) \neq 0$ e $\text{Var}(Y) \neq 0$, il coefficiente di correlazione ρ è:

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} \quad \text{con } -1 \leq \rho \leq 1$$

ESEMPIO UTILE: 1/2

Esempio: Prove ripetute ed estrazioni di un campione

Consideriamo le prove ripetute di un esperimento (effettuate nelle medesime condizioni): le variabili aleatorie associate a ripetizioni distinte sono indipendenti. Un'applicazione cruciale è l'estrazione di un campione da una popolazione. Sia S una popolazione e $X: S \rightarrow \mathbb{R}$ una variabile aleatoria che rappresenta un certo carattere. Ad esempio: $X(\omega) =$ numero di case possedute da ω , con $S = \{\text{cittadini italiani}\}$.

Estraiamo un campione di n elementi in questo modo: effettuiamo n estrazioni casuali con rimpiazzo. Lo spazio campionario totale è:

$$\Omega = S^n = \{(\omega_1, \dots, \omega_n) \mid \omega_i \in S \forall i\} \quad \text{con probabilità } P \text{ uniforme su } \Omega$$

Definiamo X_i come il carattere dell' i -esimo individuo estratto:

$$X_i(\omega_1, \dots, \omega_n) = X(\omega_i)$$

ovvero, il numero di case possedute dall'individuo i -esimo del campione. Da questa costruzione deduciamo due fatti fondamentali:

1. Le variabili X_i sono indipendenti (perché si tratta di estrazioni ripetute con rimpiazzo).
2. Le variabili X_i hanno la stessa distribuzione del carattere X misurato sull'intera popolazione.

In termini matematici, la probabilità che l' i -esimo individuo assuma un certo valore a equivale esattamente alla frequenza relativa di quel valore in tutta la popolazione:

$$P(X_i = a) = \text{Frequenza relativa di } \{X = a\} \text{ sulla popolazione } S$$

Ad esempio: $P(X_3 = 1)$ equivale alla frequenza relativa delle persone che hanno esattamente 1 casa nell'intera popolazione S . Questo giustifica l'uso delle successioni i.i.d. nella statistica inferenziale.

Domanda: Qual è la probabilità di avere almeno 3 errori in 2 giorni consecutivi? [cite: 2]

Definiamo le variabili aleatorie:

• X = numero di errori al giorno 1 $\sim P(2.5)$

• Y = numero di errori al giorno 2 $\sim P(2.5)$

Essendo X e Y indipendenti, per la proprietà di riproducibilità, la variabile somma $X + Y$ (che conta gli errori totali nei due giorni) si distribuisce ancora come una Poisson con parametro pari alla somma dei parametri [cite: 2]:

$$X + Y \sim P(2.5 + 2.5) \Rightarrow X + Y \sim P(5)$$

Vogliamo calcolare $P(X + Y \geq 3)$ [cite: 2]. Passando all'evento complementare [cite: 2]:

$$P(X + Y \geq 3) = 1 - P(X + Y < 3) = 1 - (P(X + Y = 0) + P(X + Y = 1) + P(X + Y = 2))$$

Ricordando che la funzione di massa di probabilità per una $P(\lambda)$ è $P(Z = z) = \frac{e^{-\lambda} \lambda^z}{z!}$ [cite: 2]:

$$P(X + Y \geq 3) = 1 - \left(\frac{e^{-5} \cdot 5^0}{0!} + \frac{e^{-5} \cdot 5^1}{1!} + \frac{e^{-5} \cdot 5^2}{2!} \right) \text{ [cite: 2]}$$

$$= 1 - e^{-5} - 5e^{-5} - \frac{25}{2}e^{-5} \text{ [cite: 2]}$$

$$\approx 0.8755 \quad (87.55\%) \text{ [cite: 2]}$$

Nota:

È del tutto indifferente che i due giorni siano consecutivi: il calcolo sarebbe stato identico scegliendo "2 giorni a caso", proprio in virtù dell'indipendenza delle variabili [cite: 2].

Proprietà / Teorema: Indipendenza e Scorrrelazione

Se $\rho(X, Y) = 0$ (ovvero $\text{Cov}(X, Y) = 0$), le variabili si dicono **scorrelate**.

Indipendenza $\Rightarrow$ Scorrrelazione

(Dimostrazione: Se X, Y indipendenti, $E[XY] = E[X]E[Y]$, quindi $\text{Cov}(X, Y) = 0$). Il **viceversa NON è vero**: due variabili possono essere scorrelate ma fortemente dipendenti (se la dipendenza non è lineare).

Esempio: Variabili scorrelate ma dipendenti

Sia X con distribuzione uniforme discreta su $\{-1, 0, 1\}$. Quindi $E[X] = 0$. Sia $Y = X^2$. Chiaramente Y dipende in modo esatto da X . Tuttavia:

$$\text{Cov}(X, Y) = E[X \cdot X^2] - E[X]E[X^2] = E[X^3] - 0 \cdot E[X^2] = E[X^3] = 0$$

Le variabili sono **scorrelate** ($\rho = 0$), **ma fortemente dipendenti**.

Proprietà / Teorema: Significato Matematico della Correlazione (ρ)


ρ misura unicamente la dipendenza lineare. Cercando l'approssimazione lineare ottima di Y tramite X (minimizzando l'errore quadratico medio), si ha:

$$\min_{a, b} E[(Y - (a + bX))^2] = \text{Var}(Y)(1 - \rho(X, Y)^2)$$


Più $|\rho|$ è vicino a 1, più l'errore di approssimazione tende a zero (altissima dipendenza lineare). Più ρ è vicino a 0, peggiore sarà l'approssimazione con una retta.

$\rho \approx 1$


$\Rightarrow$ RELAZIONE
APPROSSIMABILE DA
UNA RETTA



$\rho \approx 1$ (Concordi)



$\rho \approx 0$ (Scorrelate)



$\rho \approx -1$ (Discordi)

PRESTI a, b CHE
REALIZZANO IL MINIMO
 $\Rightarrow$ LA RETTA $Y = a + bX$
È LA MIGLIORE APPROX
LINEARE TRA X E Y

13.3 Varianza della Somma

Siano $X_1, \dots, X_n$ V.A. con momento secondo finito.

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y) \xrightarrow{\text{SE COSE}} \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

$$\text{Dim. } \text{Var}(X + Y) = \text{Cov}(X + Y, X + Y) = \text{Cov}(X, X) + \text{Cov}(X, Y) + \text{Cov}(Y, X) + \text{Cov}(Y, Y) = \text{Var}(X) + \text{Cov}(X, Y) + \text{Cov}(X, Y) + \text{Var}(Y)$$

Proprietà / Teoremi:

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{i < j} \text{Cov}(X_i, X_j)$$

CHE IMPLICA
CORRELAZIONE

Se le V.A. sono a due a due scorrelate (e a maggior ragione se sono indipendenti), i termini di covarianza si annullano, portando a:

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i)$$

Consideriamo il moto di un ubriaco, con $X_i \in \{+1, -1\}$ con probabilità $\frac{1}{2}$ (indipendenti). La posizione al passo n è data da $W_n = \sum_{i=1}^n X_i$.

- $E[W_n] = \sum_{i=1}^n E[X_i] = 0$ (mediamente è nell'origine).
- Poiché le X_i sono indipendenti: $\text{Var}(W_n) = \sum_{i=1}^n \text{Var}(X_i) = \sum_{i=1}^n (E[X_i^2] - E[X_i]^2) = \sum_{i=1}^n 1 = n$.

L'ubriaco mediamente percorre una "distanza quadratica" pari a n , ovvero una distanza assoluta dell'ordine di $\sqrt{n}$. La varianza della somma cattura le compensazioni tra i passi avanti e indietro.

14 Introduzione all'Inferenza e Teoremi Limite in Probabilità

I teoremi limite studiano il comportamento di V.A. "medie" quando il numero di prove ripetute tende all'infinito, creando un ponte logico verso la *Statistica Inferenziale* (che punta ad ottenere informazioni su una popolazione da un campione).

Definizione: Successione i.i.d.

Una successione di V.A. $X_1, X_2, \dots, X_n, \dots$ si dice i.i.d. (indipendenti e identicamente distribuite) se:

1. Sono mutuamente indipendenti.
2. Hanno tutte la stessa distribuzione di probabilità (P_{X_i} è la stessa $\forall i$).

Questa definizione modella matematicamente le estrazioni campionarie (con rimpiazzo) o le prove ripetute sotto le medesime condizioni. (- X_i è un CARATTERE PARTICOLARE RIPETIBILE)

Sia data una successione i.i.d. Definiamo le seguenti statistiche campionarie:

- **Media Campionaria:** $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$
- **Varianza Campionaria:** $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$

La Danza della Media Campionaria

Guida alla Convergenza in Probabilità

Dalla Variabile Aleatoria al Numero Fisso

1 Punto di Partenza: La Media Campionaria è una V.A.

Immaginiamo di avere una sequenza di variabili aleatorie $X_1, X_2, \dots, X_n$ indipendenti e identicamente distribuite (i.i.d.), ciascuna con media $E[X_i] = m$ e varianza $\text{Var}(X_i) = \sigma^2$. Definiamo la Media Campionaria come:

$$\bar{X}_n = \frac{X_1 + X_2 + \dots + X_n}{n}$$

È fondamentale capire che $\bar{X}_n$ è ancora una variabile aleatoria. Non è un numero finché non raccogliamo i dati. Poiché è una V.A., possiede un suo "centro di massa" e una sua "dispersione".

2 Il Centro di Massa: La Traslazione

Come abbiamo discusso, il centro di gravità di $\bar{X}_n$ è esattamente m . Per linearità del valore atteso:

$$E[\bar{X}_n] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} (n \cdot m) = m$$

Se definiamo una nuova variabile aleatoria Z_n che misura lo scarto dalla media:

$$Z_n = \bar{X}_n - m$$

allora il centro di massa di Z_n è ancorato sullo zero:

$$E[Z_n] = E[\bar{X}_n - m] = m - m = 0$$


3 Il Miracolo della Varianza che Collassa

Il cuore della convergenza sta nel calcolo della varianza di $\bar{X}_n$. Grazie all'indipendenza delle X_i :

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} (n\sigma^2) = \frac{\sigma^2}{n}$$

Notiamo l' n al denominatore: man mano che aggiungiamo campioni, la distribuzione si stringe attorno al centro.

Evoluzione della distribuzione di $\bar{X}_n - m$



4 La Convergenza Formalizzata (ϵ)

Veniamo alla formula che abbiamo discusso. Siano $\epsilon > 0$ un margine di errore arbitrariamente piccolo. Vogliamo sapere quanta probabilità rimane nelle "code" della distribuzione, ovvero lontano dallo zero.

$$P(|\bar{X}_n - m| > \epsilon) \rightarrow 0 \quad \text{per } n \rightarrow \infty$$

Spiegazione intuitiva:

1. $|\bar{X}_n - m|$ è la distanza della media campionaria dal suo obiettivo teorico.
2. Al crescere di n , la "campana" si schiaccia così tanto che tutta la massa si sposta verso il centro.
3. Fuori dall'intervallo $[-\epsilon, \epsilon]$ (le code), non rimane più alcuna probabilità.

5 Conclusione

La media campionaria inizia la sua vita come una variabile aleatoria incerta e "ballerina". Tuttavia, accumulando informazioni (aumentando n), la sua aleatorietà viene sconfitta. La distribuzione collassa in un unico punto: il valore atteso m .

In questo senso, la statistica trasforma il caos dei singoli eventi nella certezza delle medie.

6 Generalizzazione: Convergenza tra due V.A.

Finora abbiamo visto una variabile aleatoria ($\bar{X}_n$) che converge a un numero fisso (m). Ma i teoremi limite della probabilità sono molto più potenti: permettono di studiare una successione di variabili aleatorie (X_n) che converge verso un'altra variabile aleatoria X .

Definizione (Convergenza in Probabilità):

Date delle variabili aleatorie X e $X_1, X_2, \dots$ definite sullo stesso spazio di probabilità, si dice che X_n converge in probabilità a X per $n \rightarrow \infty$ se:

$$\forall \epsilon > 0, \quad \lim_{n \rightarrow \infty} P(|X_n - X| > \epsilon) = 0$$

Cosa significa intuitivamente? In questo scenario generale, il "bersaglio" X non è fermo, ma è esso stesso aleatorio (potrebbe essere, ad esempio, l'andamento della borsa). Dire che X_n converge a X significa che, per n grande, l'errore o la distanza tra le due variabili ($X_n - X$) diventa praticamente nullo. Anche se continuano a "ballare" casualmente, iniziano a ballare in perfetta sincronia.

6.1 Il ritorno alla costante: La Proposizione 5.4.1

Il libro precisa subito dopo: "Il limite può anche essere una costante $X = c$ ". Una costante non è altro che una variabile aleatoria "degenere" (che non balla mai). Questo ci riporta esattamente al nostro studio sulla Legge dei Grandi Numeri!

Per dimostrare che una successione X_n si "congela" su un numero fisso c , il libro fornisce una condizione sufficiente che è letteralmente il riassunto di tutto il nostro ragionamento precedente.

Proposizione (Condizione sufficiente):

Supponiamo che si abbia:

$$\lim_{n \rightarrow \infty} E[X_n] = c \in \mathbb{R}, \quad \lim_{n \rightarrow \infty} \text{Var}(X_n) = 0$$

allora la successione $(X_n)_{n \geq 1}$ converge in probabilità alla costante c .

Perché questa proposizione è la chiave di tutto? Ci sta dicendo che per "uccidere" l'aleatorietà e far atterrare una V.A. su un numero, devono succedere esattamente le due cose che abbiamo visto nei grafici precedenti:

1. **Il centro di massa deve andare sul bersaglio:** La media della variabile deve tendere a c . Nel caso della media campionaria, abbiamo visto che $E[\bar{X}_n] = m$ sempre, quindi il limite è già centrato.
2. **La campana deve schiacciarsi a spillo:** La varianza deve tendere a zero. Nel nostro caso, $\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}$. Quando $n \rightarrow \infty$, questa frazione va a 0, spegnendo l'incertezza.

In sintesi, la Legge (Debole) dei Grandi Numeri non è altro che un'applicazione diretta di questa proposizione del tuo libro, in cui X_n prende le vesti della nostra "Media Campionaria" e la costante c prende le vesti del "Valore Atteso Teorico".

X_i V.A. i.i.d. $\Rightarrow$ TUTTE PRESENTANO LO STESSO ANDAMENTO, HANNO TUTTE LA STESSA MEDIA μ TEORICA

Appunti di Statistica e Probabilità

Valore Atteso e Varianza

Poiché dipendono dal campione stocastico ω , $\bar{X}_n$ e S_n^2 sono a loro volta variabili aleatorie. $\bar{X} \in$ V.A. DIPENDE DA ω $\bar{X}(\omega) = \frac{1}{n} \sum_{i=1}^n X_i(\omega)$, $\omega \in \Omega$

LGN
DEMOIS

Proprietà / Teorema: Legge dei Grandi Numeri (LGN) - Formulazione debole

Sia $X_1, X_2, \dots$ una successione di V.A. i.i.d. con momento secondo finito. Siano $\mu = E[X_1]$ e $\sigma^2 = \text{Var}(X_1)$.

Allora la media campionaria $\bar{X}_n$ converge in probabilità al valore atteso μ per $n \rightarrow \infty$. Ovvero:

$$\forall \epsilon > 0, \lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \epsilon) = 0$$

Traduzione intuitiva: Per n grande, la media campionaria collassa sul valore atteso teorico con probabilità tendente al 100%.

Inoltre, per la varianza campionaria vale lo stesso risultato: S_n^2 converge in probabilità a σ^2 .

$$\text{ovvero } S_n^2 \rightarrow S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2, \lim_{n \rightarrow \infty} P(|S_n^2 - \sigma^2| \geq \epsilon) = 0$$

Note: 1) Cruciale: Frequenza che tende alla Probabilità

Si consideri lo schema di Bernoulli a n prove. Definiamo X_i l'indicatore del successo all' i -esima prova: $X_i \sim B(p)$. Il numero totale di successi è $\sum_{i=1}^n X_i$. La media campionaria in questo caso è:

$A = \text{SUCCESSO CON PROVA } p$

$$\bar{X}_n = \frac{\# \text{ successi}}{\# \text{ prove}} = \text{Frequenza Relativa dell'evento (successo)} \rightarrow \text{PROBABILITÀ } p$$

Dato che $E[X_i] = p$, per la LGN si ha che $\bar{X}_n \xrightarrow{\text{prob}} p$. Questo giustifica rigorosamente l'approccio frequentista alla probabilità: su un numero infinito di esperimenti, la frequenza relativa converge alla probabilità teorica.

$\{X_i\}_{i \in \mathbb{N}}$
LGN in PROVA
A V.A. $X_i \in$
 $\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \epsilon) = 0$
ESEMPIO
MATE
 $\bar{X}_{1000} = 3.5$
 $E[X_i] = 3.5$

$X_i = \begin{cases} 1 & \text{se } \text{successo} \\ 0 & \text{se } \text{fallimento} \end{cases}$

DEMOST.
 $\rightarrow$

15 Il Teorema del Limite Centrale (TCL)

Mentre la Legge dei Grandi Numeri (LGN) ci garantisce che la media campionaria $\bar{X}_n$ converge al valore atteso μ [cite: 1, 2], il Teorema del Limite Centrale ci fornisce informazioni fondamentali su come avviene questa convergenza e su quale sia la distribuzione dell'errore statistico per n grande [cite: 1].

15.1 L'intuizione: lo "Zoom" sulla Media Campionaria

Sappiamo che per una successione i.i.d. con $E[X_i] = \mu$ e $\text{Var}(X_i) = \sigma^2$, si ha:

$$E[\bar{X}_n] = \mu \quad \text{e} \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} \quad \rightarrow \quad \text{LA TENDENZA FACILMENTE}$$

Per semplicità, supponiamo $\mu = 0$. Per la LGN, $\bar{X}_n \rightarrow 0$. Man mano che n cresce, la distribuzione di $\bar{X}_n$ diventa un "pizzo" sempre più stretto attorno allo zero, poiché la sua varianza tende a zero [cite: 1]. Se vogliamo studiare la forma di questa distribuzione senza che collassi, dobbiamo applicare uno "zoom" moltiplicando $\bar{X}_n$ per un fattore a_n [cite: 1].

Cerchiamo a_n tale che la varianza non svanisca:

$$\text{Var}(a_n \bar{X}_n) = a_n^2 \text{Var}(\bar{X}_n) = a_n^2 \frac{\sigma^2}{n} \quad (\text{ASIMIAMO } \text{Var}(X_i) = \sigma^2 > 0)$$

Se scegliamo $a_n = \sqrt{n}$, otteniamo $\text{Var}(\sqrt{n} \bar{X}_n) = \sigma^2 > 0$ [cite: 1]. Il limite della distribuzione scalata $\sqrt{n} \bar{X}_n$ assumerà una forma ben definita [cite: 1].

15.2 Convergenza in Legge e Formulazione del Teorema

Definizione: Convergenza in Legge (o in Distribuzione)

Sia (Y_n) una successione di variabili aleatorie e Y una V.A. Supponiamo che F_n e F siano le rispettive funzioni di ripartizione e che F sia continua [cite: 2]. Diciamo che Y_n converge in legge a Y , e scriviamo $Y_n \xrightarrow{(d)} Y$.

$$\lim_{n \rightarrow \infty} F_n(t) = F(t) \quad \forall t \in \mathbb{R} \text{ [cite: 2]}$$

Proprietà / Teorema: Teorema del Limite Centrale

Sia $X_1, X_2, \dots$ una successione di variabili aleatorie i.i.d. con momento secondo finito [cite: 1, 2]. Siano:

- $\mu = E[X_i]$ il valore atteso [cite: 1, 2]
- $\sigma^2 = \text{Var}(X_i) > 0$ la varianza (escludendo il caso di X_i costanti) [cite: 1, 2]
- $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ la media campionaria [cite: 1, 2]


Allora la variabile standardizzata converge in distribuzione a una Normale Standard $N(0,1)$ per $n \rightarrow \infty$: (ANCHE QUELLA NON STANDARDIZZATA ASSUME FORMA A CAMPANA)

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{(d)} Z \sim N(0,1)$$

Ciò significa che per ogni intervallo $[a, b]$ (con $-\infty \leq a < b \leq +\infty$):

$$\lim_{n \rightarrow \infty} P\left(a \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq b\right) = P(a \leq Z \leq b) = \Phi(b) - \Phi(a)$$

dove Φ è la funzione di ripartizione della Normale Standard



QUESTO È IL MODO CORRETTO DI NON PIÙ... MA... DIST. NORMALE... (MOLTO) TEA... CAMPANA.

LA P. CORRETTA È QUELLA CHE CARICA SOTTO UN CERTO INTERVALLO IN X = AREA DELL'INTERVALLO CORRETTA IN Z.

18
= 95% STADN
-1 a 2 DEV. STD.

CON $\bar{X}_n$ LA CAMPANA SI MODIFICA AL CAMBIARE DI n O σ .
MENTRE Z È UNA GAV. STD. CHE CI DICE COME UN PALLETO (ES. $X = 100 \text{ kg}$) CAMBIA POSIZIONE.
 Z_n STAGIO
RICHIESTA UNIVERSALE
CALCOLORE CARICA A SX DI $\bar{X}_n - \mu$ DA LO STESSO VALORE DI $\sigma/\sqrt{n}$ A SX.

Nota: Approfondimento: Perché $E[\bar{X}_n] = \mu$?

Spesso nei passaggi logici si dà per scontato che il valore atteso della media campionaria coincida esattamente con la media teorica della popolazione (μ). Ecco la dimostrazione passo-passo e il suo significato.

1. La Dimostrazione Matematica

Partiamo dalla definizione di Media Campionaria ($\bar{X}_n$), che è la media aritmetica delle variabili aleatorie del nostro campione:

$$\bar{X}_n = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{1}{n} \sum_{i=1}^n X_i$$

Calcoliamo ora il Valore Atteso $E[\dots]$ di questa quantità, sfruttando le proprietà di linearità dell'operatore:

$$\begin{aligned} E[\bar{X}_n] &= E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] \\ &= \frac{1}{n} E\left[\sum_{i=1}^n X_i\right] \quad (\text{le costanti moltiplicative escono fuori}) \\ &= \frac{1}{n} \sum_{i=1}^n E[X_i] \quad (\text{il valore atteso di una somma è la somma dei valori attesi}) \end{aligned}$$

A questo punto sfruttiamo l'ipotesi chiave: le X_i sono i.i.d. (indipendenti e identicamente distribuite). Avendo la stessa distribuzione, hanno tutte la medesima media teorica, ovvero $E[X_i] = \mu \quad \forall i$. Sostituendo μ nella sommatoria otteniamo:

$$E[\bar{X}_n] = \frac{1}{n} (\underbrace{\mu + \mu + \dots + \mu}_{n \text{ volte}}) = \frac{1}{n} (n\mu) = \mu$$

2. Il Significato Intuitivo (Correttezza dello Stimatore)

Questa equazione ci garantisce che $\bar{X}_n$ è uno stimatore corretto (o "non distorto") per μ . Intuitivamente: un singolo campione di n elementi potrebbe fornirci una stima sfortunata (tutti valori molto alti o molto bassi), ma se ripetessimo il campionamento infinite volte e facessimo la media di tutte le medie campionarie, otterremmo esattamente la media reale della popolazione.

3. Il Collegamento con il TCL

Nello "zoom" del Teorema del Limite Centrale, usiamo questo risultato per centrare la curva. Poiché in media $\bar{X}_n$ vale μ , il termine $(\bar{X}_n - \mu)$ avrà un valore atteso esattamente pari a 0. Questo assicura che la Gaussiana limite $N(0,1)$ sia perfettamente centrata nell'origine.

*2

Nota: Che fine ha fatto la $\sqrt{n}$ del TCL?

Guardando la standardizzazione della Binomiale $\frac{Y_n - np}{\sqrt{np(1-p)}}$, potresti chiederti dove sia finita la $\sqrt{n}$ presente nella formula generale del TCL ($\sqrt{n} \frac{\bar{X}_n - \mu}{\sigma}$). La risposta è che sono la stessa identica formula, ma scritta per la Somma invece che per la Media. Ricordiamo che Y_n (numero totale di successi) è legato a $\bar{X}_n$ (frequenza relativa dei successi) dalla relazione $Y_n = n\bar{X}_n$. Sostituendo questa espressione nella standardizzazione di Y_n , otteniamo:

$$Z_n = \frac{Y_n - np}{\sqrt{np(1-p)}} = \frac{n\bar{X}_n - np}{\sqrt{n} \sqrt{p(1-p)}} = \frac{n(\bar{X}_n - p)}{\sqrt{n} \sqrt{p(1-p)}} = \sqrt{n} \frac{\bar{X}_n - p}{\sqrt{p(1-p)}}$$

Abbiamo così ritrovato l'esatta espressione del TCL generale, dove $\mu = p$ e $\sigma = \sqrt{p(1-p)}$. Si preferisce usare la formula con Y_n semplicemente perché negli esercizi è più pratico lavorare con il numero totale di successi piuttosto che con le frazioni.

Nota: Cosa stiamo standardizzando nel TCL?

È fondamentale capire che la formula del Teorema del Limite Centrale non è una formula "inventata", ma è la semplice standardizzazione applicata alla variabile aleatoria Media Campionaria ($\bar{X}_n$). La regola universale per standardizzare una qualsiasi variabile V è:

$$Z = \frac{V - E[V]}{\sqrt{\text{Var}(V)}} \quad \left(\begin{array}{l} \text{LO PUOI FARE CON UNA} \\ \text{SUA DIST. INDIV., LA STAI CENTRANDO SU 0} \\ \text{E SCALANDO, HA SOLO QUANDO V È UNA} \\ \text{MEDIA CAMPIONARIA } \bar{V}_n \\ \text{CHE VALE IL TCL} \end{array} \right)$$

Sostituiamo V con la nostra media campionaria $\bar{X}_n$. Sappiamo che:

- Il suo valore atteso è $E[\bar{X}_n] = \mu$
- La sua varianza è $\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}$

La deviazione standard (o "errore standard") di $\bar{X}_n$ è quindi la radice della varianza, ovvero $\frac{\sigma}{\sqrt{n}}$. Inserendo questi elementi nella formula di standardizzazione otteniamo:

$$Z_n = \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}}$$

Per le proprietà delle frazioni, il termine $\sqrt{n}$ passa al denominatore, restituendoci l'esatta formula del TCL:

$$Z_n = \sqrt{n} \frac{\bar{X}_n - \mu}{\sigma} \xrightarrow{(d)} N(0,1)$$

Nota: L'Universalità del TCL e la Regola Empirica

Il TCL è un risultato di universalità: la legge di partenza delle X_i può essere qualunque (purché ammetta varianza finita), ma la loro somma standardizzata si comporterà sempre approssimativamente come una gaussiana per n grande [cite: 1]. Quanto deve essere grande n nella pratica? Una regola empirica comunemente accettata (sebbene dipenda dalla simmetria della distribuzione originale) è che l'approssimazione sia affidabile per $n \geq 30$, ed eccellente per $n \geq 50$ [cite: 1].

Proprietà / Teorema: Corollario con Varianza Campionaria

Sia $X_1, X_2, \dots$ una successione i.i.d. con momento quarto finito [cite: 1]. Se si sostituisce la varianza teorica σ con la varianza campionaria S_n , il risultato limite rimane valido [cite: 1]:

$$\sqrt{n} \frac{\bar{X}_n - \mu}{S_n} \xrightarrow{(d)} Z \sim N(0,1) \quad (\text{per } n \text{ grande})$$

15.3 Caso Particolare: Approssimazione Normale della Binomiale *2

Consideriamo un esperimento dicotomico (successo/insuccesso) ripetuto n volte.

Sia $X_i \sim B(1, p)$ una variabile di Bernoulli, dove $X_i = 1$ in caso di successo (con probabilità p) e $X_i = 0$ altrimenti [cite: 1, 2]. Le X_i sono i.i.d. e la loro somma $Y_n = \sum_{i=1}^n X_i$ rappresenta il numero totale (frequenza assoluta) di successi su n prove [cite: 1, 2]. Sappiamo che $Y_n \sim B(n, p)$ [cite: 1, 2].

Essendo una somma di V.A. indipendenti, possiamo applicare il TCL. Sappiamo che:

$$E[Y_n] = np \quad \text{e} \quad \text{Var}(Y_n) = np(1-p)$$

Standardizzando Y_n otteniamo:

$$\frac{Y_n - E[Y_n]}{\sqrt{\text{Var}(Y_n)}} = \frac{Y_n - np}{\sqrt{np(1-p)}} \sim N(0,1)$$

Per il TCL, per n sufficientemente grande, questa quantità è ben approssimata da una $N(0,1)$ [cite: 1, 2].

Regola Empirica per la Binomiale: L'approssimazione normale è considerata valida se $np(1-p) \geq 10$ [cite: 1, 2].

Una moneta equilibrata ($p = 0.5$) viene lanciata $n = 1000$ volte[cite: 1, 2]. Definiamo Y il numero di teste ottenute. $Y \sim B(1000, 0.5)$ [cite: 1, 2]. Verifichiamo la regola empirica: $np(1-p) = 1000 \cdot 0.5 \cdot 0.5 = 250 \geq 10$ (ampiamente soddisfatta)[cite: 1, 2].

Quesito A: Probabilità di ottenere almeno 480 teste? Vogliamo calcolare $P(Y \geq 480)$ [cite: 1, 2]. Utilizzando il TCL:

$$P(Y \geq 480) = P\left(\frac{Y - np}{\sqrt{np(1-p)}} \geq \frac{480 - 500}{\sqrt{250}}\right) \approx P\left(Z \geq \frac{-20}{\sqrt{250}}\right) \approx P(Z \geq -1.26)[\text{cite: 1, 2}]$$

Utilizzando la proprietà della funzione Φ per la normale standard:

$$P(Z \geq -1.26) = 1 - \Phi(-1.26) = 1 - (1 - \Phi(1.26)) = \Phi(1.26) \approx 0.896[\text{cite: 1, 2}]$$

La probabilità è circa l'89.6%[cite: 1, 2].

Quesito B: Qual è il numero k di teste tale che la probabilità di ottenere almeno k teste sia circa il 95%?

Cerchiamo k tale che $P(Y \geq k) = 0.95$ [cite: 1, 2]. Poiché la probabilità richiesta (95%) è maggiore di quella del caso precedente (89.6%), sappiamo in anticipo che il valore di k dovrà essere inferiore a 480[cite: 2]. Applicando l'approssimazione:

$$0.95 \approx P(Y \geq k) \approx P\left(Z \geq \frac{k - 500}{\sqrt{250}}\right) = 1 - \Phi\left(\frac{k - 500}{\sqrt{250}}\right)[\text{cite: 1, 2}]$$

Da cui ricaviamo:

$$\Phi\left(\frac{k - 500}{\sqrt{250}}\right) = 1 - 0.95 = 0.05[\text{cite: 1, 2}]$$

Dalle tavole della normale, sappiamo che il quantile $q_{0.05} = -q_{0.95} \approx -1.64$ [cite: 1, 2]. Pertanto:

$$\frac{k - 500}{\sqrt{250}} = -1.64 \Rightarrow k = 500 - 1.64\sqrt{250} \approx 500 - 1.64(15.81) \approx 473.91[\text{cite: 1, 2}]$$

Essendo k un numero intero di lanci, per garantire che la probabilità superi il 95%, arrotondiamo per difetto ottenendo $k = 473$ (o al più 474 a seconda del rigore richiesto nella stima)[cite: 1, 2].

0.1 Dimostrazione della Legge dei Grandi Numeri (LGN)

Per dimostrare la convergenza in probabilità, dobbiamo prima calcolare il valore atteso e la varianza della media campionaria $\bar{X}_n$ [cite: 1, 2]. Sappiamo che le X_i sono indipendenti e identicamente distribuite con $E[X_i] = \mu$ e $\text{Var}(X_i) = \sigma^2$ [cite: 1, 2].

• **Valore atteso di $\bar{X}_n$:**

$$E[\bar{X}_n] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n}(n\mu) = \mu[\text{cite: 1, 2}]$$

• **Varianza di $\bar{X}_n$:** Poiché le X_i sono indipendenti (quindi scorrelate), la varianza della somma è la somma delle varianze:

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) = \frac{1}{n^2}(n\sigma^2) = \frac{\sigma^2}{n}[\text{cite: 1, 2}]$$

Come si nota, per $n \rightarrow \infty$, la varianza $\frac{\sigma^2}{n}$ tende a zero[cite: 1, 2]. Appliciamo ora la Disuguaglianza di Chebyshev, la quale afferma che per ogni $\epsilon > 0$:

$$P(|\bar{X}_n - \mu| \geq \epsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2}[\text{cite: 1}]$$

Passando al limite per $n \rightarrow \infty$, il termine $\frac{\sigma^2}{n\epsilon^2}$ tende a zero[cite: 1]. Questo dimostra formalmente che:

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \epsilon) = 0[\text{cite: 1}]$$

La dimostrazione della LGN

- **Lanci di un dado:** Se definiamo X_i come l'esito dell' i -esimo lancio di un dado equilibrato, sappiamo che $E[X_i] = 3.5$ [cite: 1]. Per la LGN, su 1000 lanci, la media aritmetica degli esiti sarà molto vicina al valore teorico: $\bar{X}_{1000} \approx 3.5$ [cite: 1, 2].
- **Successo di un Server:** Un server processa richieste con una probabilità di successo di $p = \frac{2}{3}$ [cite: 1]. Su 10^6 processi (un numero grandissimo), la frequenza relativa dei successi $\bar{X}_n$ convergerà alla probabilità teorica p , attestandosi circa al 67%[cite: 1].

1 Esercizi Riassuntivi Svolti

Siano X_1, X_2 gli esiti di due lanci di un dado equilibrato[cite: 1]. Definiamo:

$$U = \min\{X_1, X_2\}, \quad V = \max\{X_1, X_2\} \quad \text{[cite: 1]} \quad \begin{matrix} U \leq V \\ \text{INDEP.} \end{matrix}$$

Calcolare la funzione di massa congiunta di (U, V) .

Soluzione: La coppia (X_1, X_2) ha distribuzione uniforme su $\{1, \dots, 6\}^2$, quindi ogni specifica coppia di valori ha probabilità $\frac{1}{36}$ [cite: 1]. Le variabili (U, V) assumono valori nell'insieme delle coppie (h, k) con $h \leq k$ [cite: 1]. Valutiamo la probabilità congiunta $P(U = h, V = k)$ in due casi distinti:

1. Se $h = k$ (i dadi danno lo stesso risultato):

$$P(U = h, V = h) = P(X_1 = h, X_2 = h) = \frac{1}{36} \quad \text{[cite: 1]}$$

2. Se $h < k$ (i dadi danno risultati diversi): Questo evento si verifica se il primo dado dà h e il secondo dà k , OPPURE se il primo dà k e il secondo dà h [cite: 1].

$$\begin{aligned} P(U = h, V = k) &= P((X_1 = h \text{ e } X_2 = k) \cup (X_1 = k \text{ e } X_2 = h)) \quad \text{[cite: 1]} \\ &= P(X_1 = h, X_2 = k) + P(X_1 = k, X_2 = h) = \frac{1}{36} + \frac{1}{36} = \frac{2}{36} = \frac{1}{18} \quad \text{[cite: 1]} \end{aligned}$$

Sia il numero di guasti di un server in un giorno distribuito come $P(1.5)$ [cite: 1]. Qual è la probabilità che, su 5 giorni consecutivi, in almeno 4 di essi si verifichi al massimo un guasto?[cite: 1]

Soluzione: Prima troviamo la probabilità di successo del singolo "esperimento" (il singolo giorno). L'evento di successo è "al massimo un guasto", ovvero $\{X_i \leq 1\}$ [cite: 1]:

$$p = P(X_i \leq 1) = P(X_i = 0) + P(X_i = 1) = e^{-1.5} + 1.5e^{-1.5} = 2.5e^{-1.5} \approx 0.5578 \quad \text{[cite: 1]}$$

Avendo 5 giorni (prove indipendenti), siamo in presenza di uno Schema di Bernoulli[cite: 1]. Sia N il numero di giorni con al massimo un guasto: $N \sim B(5, p)$ [cite: 1]. La probabilità cercata è:

$$P(N \geq 4) = P(N = 4) + P(N = 5) \approx 0.268 \quad \text{[cite: 1]}$$

Esempio: Esperimento S.I.S. TCL su 100 lanci e Somma di Secondi

Un dado equilibrato viene lanciato ripetutamente[cite: 1]. a) Probabilità di avere pari almeno 55 volte sui primi 100 lanci, E almeno 55 volte sui secondi 100 lanci?[cite: 1]

Sia $Y_{100} \sim B(100, \frac{1}{2})$ il numero di pari nei primi 100 lanci[cite: 1]. Sia $V_{100} \sim B(100, \frac{1}{2})$ il numero di pari nei lanci da 101 a 200[cite: 1]. Y_{100} e V_{100} sono indipendenti[cite: 1]. Per il TCL su Y_{100} ($np = 50$, $np(1-p) = 25$):

$$P(Y_{100} \geq 55) = P\left(Z \geq \frac{55 - 50}{\sqrt{25}}\right) = P(Z \geq 1) = 1 - \Phi(1) = 0.1587 \quad \text{[cite: 1]}$$

Per l'indipendenza, la probabilità congiunta è il prodotto delle probabilità:

$$P(Y_{100} \geq 55, V_{100} \geq 55) = P(Y_{100} \geq 55) \cdot P(V_{100} \geq 55) = (0.1587)^2 \approx 0.0252 \quad \text{[cite: 1]}$$

b) Si scommette su un "pari" per ogni lancio da 1 a 100 (vinci se esce pari) e su " ≤ 2 " per i lanci da 101 a 200[cite: 1]. Probabilità di vincere almeno 90 volte in totale?[cite: 1]

Le vittorie nei primi 100 sono $Y_{100} \sim B(100, \frac{1}{2})$ [cite: 1]. Le vittorie nei secondi 100 sono $W_{100} \sim B(100, \frac{2}{3}) = B(100, \frac{1}{3})$ [cite: 1]. Vogliamo $P(Y_{100} + W_{100} \geq 90)$ [cite: 1]. Invece di sommare le binomiali (difficile avendo p diverse), usiamo l'approssimazione normale prima e sommiamo le normali poi (sfruttando la riproducibilità della Normale)[cite: 1].

$$\bullet Y_{100} \approx \mathcal{N}(np, np(1-p)) = \mathcal{N}(50, 25) \quad \text{[cite: 1]}$$

$$\bullet W_{100} \approx \mathcal{N}\left(100 \cdot \frac{1}{3}, 100 \cdot \frac{1}{3} \cdot \frac{2}{3}\right) = \mathcal{N}\left(\frac{100}{3}, \frac{200}{9}\right) \approx \mathcal{N}(33.33, 22.22) \quad \text{[cite: 1]}$$

Essendo Y_{100} e W_{100} indipendenti, la loro somma è approssimativamente normale:

$$Y_{100} + W_{100} \approx \mathcal{N}\left(50 + \frac{100}{3}, 25 + \frac{200}{9}\right) = \mathcal{N}(83.33, 47.22) \quad \text{[cite: 1]}$$

Calcoliamo infine la probabilità richiesta:

$$P(Y_{100} + W_{100} \geq 90) = P\left(Z \geq \frac{90 - 83.33}{\sqrt{47.22}}\right) \approx P(Z \geq 0.97) = 1 - \Phi(0.97) \approx 0.166 \quad \text{[cite: 1]}$$

Un server riceve email con dimensione media $\mu = 4.73$ MB e deviazione standard $\sigma = 0.53$ MB[cite: 1]. In un giorno, riceve 70 email[cite: 1]. a) Probabilità che la dimensione totale superi i 340 MB[cite: 1]
b) Trovare la capacità y tale che con probabilità del 95% la dimensione totale sia $\leq y$ [cite: 1].
Soluzione a): Sia X_i la dimensione dell' i -esima mail. Assumiamo siano i.i.d[cite: 1]. Poiché $n = 70 \geq 30$, possiamo usare il TCL[cite: 1]:

$$\frac{\bar{X}_{70} - 4.73}{0.53/\sqrt{70}} \approx N(0,1)[cite: 1]$$

L'evento "dimensione totale > 340 " si scrive come $\sum_{i=1}^{70} X_i > 340$, ovvero $\bar{X}_{70} > \frac{340}{70}$ [cite: 1]. Standardizzando:

$$P\left(\bar{X}_{70} > \frac{340}{70}\right) = P\left(Z > \frac{\frac{340}{70} - 4.73}{0.53/\sqrt{70}}\right) \approx P(Z > 2.01)[cite: 1]$$

Utilizzando la tabella della normale: $P(Z > 2.01) = 1 - \Phi(2.01) = 1 - 0.9778 = 0.0222$ (2.22%)[cite: 1].

Soluzione b): Cerchiamo y tale che $P(\sum_{i=1}^{70} X_i \leq y) = 0.95$ [cite: 1]. Standardizzando l'incognita:

$$0.95 \approx P\left(Z \leq \frac{\frac{y}{70} - 4.73}{0.53/\sqrt{70}}\right) = \Phi(z_y)[cite: 1]$$

Dalle tabelle, il quantile $\Phi_{0.95}$ è 1.64 (negli appunti riportato come 1.66 per differenze di interpolazione/tavole specifiche)[cite: 1]. Usando il valore degli appunti ($z_y = 1.66$):

$$\frac{\frac{y}{70} - 4.73}{0.53/\sqrt{70}} = 1.66 \Rightarrow y \approx 338.37 \text{ MB}[cite: 1]$$

16 Introduzione alla Statistica Inferenziale

Mentre nella teoria della probabilità studiamo campioni generati da una popolazione completamente nota (metodo deduttivo), lo scopo della statistica inferenziale è l'opposto: ottenere informazioni sulla distribuzione di una popolazione (reale o ideale) studiando i dati rilevati su un campione[cite: 4, 71, 72]. Si procede quindi in modo induttivo[cite: 5].

16.1 Il Modello Statistico e il Campione

Consideriamo una popolazione non nota[cite: 5]. Il carattere che vogliamo studiare è rappresentato da una variabile aleatoria X con distribuzione P_X sconosciuta, in parte o totalmente[cite: 8]. Questa distribuzione rappresenta il risultato di un esperimento aleatorio, come l'estrazione e misurazione di un carattere[cite: 83, 84].

Per studiare P_X , la statistica parametrica suppone che la distribuzione appartenga a una famiglia nota, dipendente da uno o più parametri θ (o β)[cite: 20, 23, 86, 88]. Ad esempio, potremmo ipotizzare che l'altezza segua una normale $X \sim N(m, \sigma^2)$, dove la forma a campana è assunta, ma i parametri m e σ^2 sono ignoti[cite: 12, 92, 94]. Chiamiamo Θ l'insieme dei valori ammissibili per il parametro[cite: 21, 115].

Nota: Statistica Parametrica vs. Non Parametrica

Nella teoria frequentista classica (che stiamo studiando), la distribuzione P_X e i suoi parametri θ sono valori numerici fissi, sebbene incogniti[cite: 98, 99, 101, 102]. All'opposto, nella statistica Bayesiana, i parametri stessi sono considerati variabili aleatorie[cite: 104].

Per determinare il parametro, effettuiamo estrazioni dalla popolazione. Un Campione Statistico di taglia n è definito da una n -upla $(X_1, X_2, \dots, X_n)$ di variabili aleatorie che godono della proprietà i.i.d. (indipendenti e identicamente distribuite)[cite: 9, 10, 85]. L'ipotesi i.i.d. garantisce due cose chiave[cite: 6]:

1. **Indipendenza:** Ogni nuova estrazione è indipendente dalle precedenti[cite: 6].
2. **Identica Distribuzione:** L'estrazione di ogni individuo è fatta in modo identico, seguendo la stessa legge P_X della popolazione originale[cite: 6, 11, 85].

[Il dualismo del Campione: X_i vs x_i] Perché a volte usiamo le lettere maiuscole e a volte le minuscole? Questa distinzione è vitale!

- **Le Variabili (X_i):** Sono oggetti matematici (funzioni) che rappresentano il campione "prima dei risultati delle misurazioni"[cite: 107]. Essendo variabili aleatorie, possiedono valori attesi e varianze.
- **Le Realizzazioni (x_i):** Sono i valori numerici concreti assunti dopo aver effettuato la misurazione (es. $x_i = X_i(\omega)$)[cite: 108]. Sono numeri fissi ("esiti"), non più funzioni[cite: 109].

• $a_1, a_2, \dots$ MODALITÀ. VALORI POSSIBILI PER LE X_i

$$E[X] = \sum_j a_j \cdot P(X = a_j) = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \quad \text{MEDIA CAMPIONARIA}$$

$$(i.i.d. \ E[X_n] = E[X_1] = \mu)$$

17 Statistiche Campionarie e Stimatori

Una statistica campionaria è una qualsiasi funzione $g(X_1, \dots, X_n)$ del campione [cite: 24, 118]. Quando utilizziamo una statistica campionaria con l'obiettivo specifico di approssimare il valore del parametro ignoto θ , essa prende il nome di **Stimatore** [cite: 25, 119].

I due stimatori "usuali" più importanti sono [cite: 124, 125, 126]:

- **Media Campionaria:** $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$, utilizzata per stimare il valore atteso $E[X]$ [cite: 26, 121, 124].

- **Varianza Campionaria:** $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$, utilizzata per stimare la varianza $Var(X)$ [cite: 125, 126].

Poiché uno stimatore è funzione del campione aleatorio, lo stimatore è esso stesso una variabile aleatoria [cite: 127]: il suo risultato numerico (la stima) cambierà al variare degli esiti del campione pescato [cite: 128].

17.1 Come valutare l'efficacia di uno stimatore?

Per decidere se uno stimatore è "buono", la statistica richiede che rispetti alcune proprietà fondamentali [cite: 129, 130].

17.1.1 1. Correttezza (Non Distorsione)

Uno stimatore $g(X_1, \dots, X_n)$ del parametro θ si dice **corretto** (o non distorto) se il suo valore atteso coincide esattamente con il parametro da stimare: $E[g(X_1, \dots, X_n)] = \theta$ per ogni $\theta \in \Theta$ [cite: 30, 131, 133, 134]. Questo significa che, mediando su tutte le possibili realizzazioni infinite del campione, lo stimatore centra perfettamente il bersaglio [cite: 135].

Dimostrazione per la Media Campionaria [cite: 35, 137]: Sappiamo che $E[X_i] = \mu$ (identicamente distribuite). Per linearità del valore atteso:

$$E[\bar{X}_n] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} (n \cdot \mu) = \mu$$

Dunque $\bar{X}_n$ è corretto per μ [cite: 33, 35, 136].

Nota: Perché la Varianza Campionaria divide per $n-1$?

Anche S_n^2 diviso per $(n-1)$ è uno stimatore corretto per la varianza σ^2 [cite: 33, 138].

Se dividessimo semplicemente per n , calcoleremmo $E\left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2\right] = \frac{n-1}{n} \sigma^2$, ottenendo uno stimatore distorto che sottostima la vera varianza [cite: 140, 141]. Dividere per $n-1$ funge da fattore di correzione.

17.1.2 2. Consistenza

Mentre la correttezza riguarda la "mira", la consistenza riguarda cosa succede raccogliendo infiniti dati. (Una successione di stimatori) $g_n(X_1, \dots, X_n)$ è **consistente** per θ se, per $n \rightarrow \infty$, converge in probabilità al parametro vero [cite: 38, 142, 143]:

$$\lim_{n \rightarrow \infty} P(|g_n(X_1, \dots, X_n) - \theta| \geq \epsilon) = 0 \quad \forall \epsilon > 0$$

$$g_n(X_1, \dots, X_n) \rightarrow \theta$$

Significato: per una grande taglia del campione, lo stimatore sarà arbitrariamente vicino a θ con probabilità tendente a 1 [cite: 144, 145, 147].

Dimostrazione [cite: 42, 43]: La media campionaria $\bar{X}_n$ è consistente grazie alla Legge dei Grandi Numeri (LGN) (assumendo varianza finita) [cite: 41, 149, 150, 152]. Analogo ragionamento (corollario della LGN) rende consistente anche S_n^2 [cite: 41, 153].

17.1.3 3. Efficienza (Rischio Quadratico)

Tra più stimatori corretti per lo stesso parametro, quale scegliamo? Quello che "batta" di meno. Dati due stimatori g e h , g è più efficiente se possiede un **Rischio Quadratico** minore: $E[(g - \theta)^2] < E[(h - \theta)^2]$ ($Var(g) < Var(h)$) se $E[g] = E[h] = \theta$.

Se gli stimatori sono corretti, il rischio quadratico coincide esattamente con la loro Varianza [cite: 157, 158]. Ad esempio, calcolando la varianza della media campionaria:

$$Var(\bar{X}_n) = Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n Var(X_i) = \frac{n \cdot Var(X)}{n^2} = \frac{Var(X)}{n}$$

Questo dimostra che all'aumentare di n , la varianza diventa sempre più piccola (il risultato si disperde meno) [cite: 46, 47, 160].

17.2 Esempio: Stima della probabilità di un evento (Frequenza Relativa)

Se consideriamo un evento A (il "successo") con probabilità incognita p , possiamo modelarlo con variabili di Bernoulli $X_i \sim B(p)$, dove $X_i = 1$ se A si verifica e 0 altrimenti [cite: 161, 162, 163, 164, 166]. La stima di p è data dalla media campionaria $\bar{X}_n$, che in questo caso rappresenta la frequenza relativa di A nel campione [cite: 167]. Poiché $p = E[X_i]$, la frequenza relativa è sia corretta che consistente per stimare una percentuale [cite: 168].

Es: Su 1000 lanci escono 423 teste; la stima della probabilità di testa è proprio $\hat{p} = \frac{423}{1000}$.

$E[X_i] = 1 \cdot p + 0 \cdot (1-p) = p$, $E[\bar{X}_n] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} (n \cdot p) = p$

18 Il Metodo della Massima Verosimiglianza

Una domanda centrale della statistica è: "Dato un campione $(x_1, \dots, x_n)$, come scegliamo un buon stimatore per il parametro θ ?" Uno dei metodi più potenti e utilizzati è il Metodo della Massima Verosimiglianza (Maximum Likelihood Estimation - MLE).

18.1 La Funzione di Verosimiglianza

L'idea alla base è ribaltare la prospettiva della funzione di densità. Invece di considerare θ fisso e variare x , consideriamo i dati x_i come fissi e variamo θ . Sia $(X_1, \dots, X_n)$ un campione i.i.d. di X con parametro $\theta \in \Theta$. Definiamo la Funzione di Verosimiglianza $L_\theta(x_1, \dots, x_n)$ come:

• **Caso Discreto:** È la probabilità congiunta di ottenere esattamente quei dati:

$$L_\theta(x_1, \dots, x_n) = P^\theta(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n p_\theta(x_i)$$

$$L_\theta = L(\theta, \cdot) : \mathcal{K}^n \rightarrow \mathbb{R}$$

• Caso Continuo: È il prodotto delle densità nei punti osservati:

$$L_{\theta}(x_1, \dots, x_n) = \prod_{i=1}^n f_{\theta}(x_i)$$

La funzione di verosimiglianza ci dice quanto sono "plausibili" i dati osservati sotto diverse ipotesi di θ . Ad esempio, se lanciando una moneta 5 volte otteniamo (1, 1, 0, 1, 0), il valore $L_{0.5} \approx 0.031$ è maggiore di $L_{0.3} \approx 0.005$. Questo significa che è molto più plausibile che la moneta sia equa ($\theta = 0.5$) piuttosto che sbilanciata ($\theta = 0.2$).

18.2 Definizione di Stimatore MLE

Lo Stimatore di Massima Verosimiglianza $\hat{\theta}$ è quel valore del parametro che massimizza la funzione L_{θ} . Formalmente:

$$\hat{\theta} \in \Theta \text{ t.c. } L_{\hat{\theta}}(x_1, \dots, x_n) = \max_{\theta \in \Theta} L_{\theta}(x_1, \dots, x_n) \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n$$

Procedura Pratica: Poiché la funzione logaritmo è strettamente crescente, massimizzare L_{θ} equivale a massimizzare la Log-verosimiglianza $\ell(\theta) (= \log L_{\theta})$. Questo è estremamente utile perché trasforma i prodotti in somme, facilitando il calcolo delle derivate:

$$\frac{d}{d\theta} \log L_{\theta} = 0 \Rightarrow \hat{\theta}$$

18.3 Esempi Notevoli di MLE

18.3.1 1. Distribuzione di Poisson ($X \sim \text{Poisson}(\lambda)$)

Dalla funzione di massa $p_{\lambda}(k) = \frac{\lambda^k}{k!} e^{-\lambda}$, otteniamo:

$$\log L(\lambda) = \log \left(\prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = \sum_{i=1}^n \log \left(\frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = \sum_{i=1}^n \left(x_i \log(\lambda) - \log(x_i!) - \lambda \right)$$

Applicando il logaritmo e derivando rispetto a λ , si ottiene lo stimatore:

$$\hat{\lambda}_{MLE} = \bar{X}_n$$

La media campionaria è l'unico MLE per la Poisson, ed è corretto e consistente.

18.3.2 2. Distribuzione Esponenziale ($X \sim \text{Exp}(\theta)$)

Con densità $f_{\theta}(x) = \theta e^{-\theta x}$, la log-verosimiglianza è $\log L_{\theta} = n \log \theta - \theta \sum x_i$. Derivando e ponendo uguale a zero: $\frac{n}{\theta} - \sum x_i = 0$.

$$\hat{\theta}_{MLE} = \frac{1}{\bar{X}_n}$$

1 Derivazioni Matematiche degli Stimatori MLE Notevoli

In questa sezione analizziamo i passaggi algebrici rigorosi per determinare lo stimatore di massima verosimiglianza $\hat{\theta}$. Sfrutteremo intensamente due proprietà fondamentali dei logaritmi: 1. $\log(A \cdot B) = \log(A) + \log(B)$ (il logaritmo di un prodotto è la somma dei logaritmi). 2. $\log(A^B) = B \cdot \log(A)$ (l'esponente diventa un moltiplicatore).

1.1 Distribuzione di Poisson ($X \sim \text{Poisson}(\lambda)$)

Sia $X_1, \dots, X_n$ un campione i.i.d. discreto. La funzione di massa per il singolo elemento è $p_{\lambda}(x_i) = \frac{\lambda^{x_i}}{x_i!} e^{-\lambda}$.

1. Funzione di Verosimiglianza (L): Moltiplichiamo le n probabilità. Raggruppiamo i termini simili: le λ si moltiplicano sommando gli esponenti, gli $e^{-\lambda}$ si moltiplicano n volte, e i fattoriali finiscono tutti a denominatore.

$$L(\lambda) = \prod_{i=1}^n \left(\frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right)$$

$$L(\lambda) = \frac{\lambda^{x_1} \cdot \lambda^{x_2} \cdot \dots \cdot \lambda^{x_n}}{x_1! \cdot x_2! \cdot \dots \cdot x_n!} \cdot (e^{-\lambda} \cdot e^{-\lambda} \cdot \dots \cdot e^{-\lambda})$$

$$L(\lambda) = \left(\prod_{i=1}^n \frac{1}{x_i!} \right) \cdot \lambda^{\sum_{i=1}^n x_i} \cdot e^{-n\lambda}$$

2. Log-Verosimiglianza (ℓ): Appliciamo il logaritmo naturale ($\log$ o $\ln$) a tutta l'espressione per trasformare i prodotti in somme.

$$\ell(\lambda) = \log \left[\left(\prod_{i=1}^n \frac{1}{x_i!} \right) \cdot \lambda^{\sum x_i} \cdot e^{-n\lambda} \right]$$

$$\ell(\lambda) = \log \left(\prod_{i=1}^n \frac{1}{x_i!} \right) + \log(\lambda^{\sum x_i}) + \log(e^{-n\lambda})$$

Applichiamo le proprietà degli esponenti (l'esponente "scende" davanti al logaritmo) e ricordiamo che $\log(e) = 1$:

$$\ell(\lambda) = \log \left(\prod_{i=1}^n \frac{1}{x_i!} \right) + \left(\sum_{i=1}^n x_i \right) \log(\lambda) - n\lambda$$

3. Ricerca del Massimo (Derivata): Deriviamo l'intera equazione rispetto a λ . Il primo termine è una costante (non contiene λ), quindi la sua derivata è 0. La derivata di $\log(\lambda)$ è $\frac{1}{\lambda}$. La derivata di $-n\lambda$ è $-n$.

$$\frac{d\ell}{d\lambda} = 0 + \left(\sum_{i=1}^n x_i \right) \cdot \frac{1}{\lambda} - n$$

$$\frac{d\ell}{d\lambda} = \frac{\sum x_i}{\lambda} - n$$

Poniamo la derivata uguale a zero per trovare il punto di stazionarietà:

$$\frac{\sum x_i}{\lambda} - n = 0 \Rightarrow \frac{\sum x_i}{\lambda} = n \Rightarrow \lambda = \frac{\sum x_i}{n}$$

Poiché $\frac{\sum x_i}{n}$ è la definizione esatta della media campionaria, concludiamo che $\hat{\lambda}_{MLE} = \bar{X}_n$.

1.2 Distribuzione Esponenziale ($X \sim \text{Exp}(\theta)$)

Sia $X_1, \dots, X_n$ un campione i.i.d. continuo con densità $f_\theta(x_i) = \theta e^{-\theta x_i}$.
1. Funzione di Verosimiglianza (L):

$$L(\theta) = \prod_{i=1}^n (\theta e^{-\theta x_i})$$

$$L(\theta) = (\theta \cdot \theta \cdots \theta) \cdot (e^{-\theta x_1} \cdot e^{-\theta x_2} \cdots e^{-\theta x_n})$$

$$L(\theta) = \theta^n \cdot e^{-\theta \sum_{i=1}^n x_i}$$

2. Log-Verosimiglianza (ℓ): Appliciamo il logaritmo per "smontare" il prodotto:

$$\ell(\theta) = \log(\theta^n \cdot e^{-\theta \sum x_i})$$

$$\ell(\theta) = \log(\theta^n) + \log(e^{-\theta \sum x_i})$$

$$\ell(\theta) = n \log(\theta) - \theta \sum_{i=1}^n x_i$$

3. Ricerca del Massimo (Derivata): Deriviamo rispetto all'incognita θ :

$$\frac{d\ell}{d\theta} = n \cdot \frac{1}{\theta} - \sum_{i=1}^n x_i$$

$$\frac{d\ell}{d\theta} = \frac{n}{\theta} - \sum_{i=1}^n x_i$$

Poniamo uguale a zero per trovare il massimo:

$$\frac{n}{\theta} - \sum_{i=1}^n x_i = 0 \Rightarrow \frac{n}{\theta} = \sum_{i=1}^n x_i \Rightarrow \theta = \frac{n}{\sum_{i=1}^n x_i}$$

Notiamo che il termine a destra è esattamente il reciproco della media campionaria ($\frac{1}{\bar{x}}$), da cui $\hat{\theta}_{MLE} = \frac{1}{\bar{x}}$.
Notiamo che il termine a destra è esattamente il reciproco della media campionaria ($\frac{1}{\bar{x}}$), da cui $\hat{\theta}_{MLE} = \frac{1}{\bar{x}}$.
NOTA: IL TERMINE A DESTRA NON FA SENSO SE NON SI SOSTITUISCE IL VALORE ATTESO CON LA SUA VERSIONE CAMPIONARIA ($\bar{X}_n$)

1.3 Varianza della Normale con Media m Nota

Sia $X \sim \mathcal{N}(m, \sigma^2)$ con m noto. Vogliamo stimare la varianza, che per comodità chiamiamo $\theta = \sigma^2$. La densità del singolo campione è $f_\theta(x_i) = \frac{1}{\sqrt{2\pi\theta}} \exp\left(-\frac{(x_i - m)^2}{2\theta}\right)$.

1. Funzione di Verosimiglianza (L): Ricordiamo che $\sqrt{\theta} = \theta^{1/2}$, quindi a denominatore abbiamo $(2\pi\theta)^{-1/2}$.

$$L(\theta) = \prod_{i=1}^n \left[(2\pi\theta)^{-1/2} \cdot \exp\left(-\frac{1}{2\theta}(x_i - m)^2\right) \right]$$

$$L(\theta) = (2\pi\theta)^{-n/2} \cdot \exp\left(\sum_{i=1}^n \left[-\frac{1}{2\theta}(x_i - m)^2\right]\right)$$

$$L(\theta) = (2\pi)^{-n/2} \cdot \theta^{-n/2} \cdot \exp\left(-\frac{1}{2\theta} \sum_{i=1}^n (x_i - m)^2\right)$$

2. Log-Verosimiglianza (ℓ):

$$\ell(\theta) = \log[(2\pi)^{-n/2}] + \log(\theta^{-n/2}) + \log\left[\exp\left(-\frac{1}{2\theta} \sum_{i=1}^n (x_i - m)^2\right)\right]$$

$$\ell(\theta) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\theta) - \frac{1}{2\theta} \sum_{i=1}^n (x_i - m)^2$$

3. Ricerca del Massimo (Derivata): Ora deriviamo rispetto a θ . Attenzione: il termine $\frac{1}{2\theta}$ è uguale a $\frac{1}{2} \cdot \theta^{-1}$. La sua derivata è $\frac{1}{2} \cdot (-1\theta^{-2}) = -\frac{1}{2\theta^2}$.

$$\frac{d\ell}{d\theta} = 0 - \frac{n}{2} \cdot \frac{1}{\theta} - \left(-\frac{1}{2\theta^2}\right) \sum_{i=1}^n (x_i - m)^2$$

$$\frac{d\ell}{d\theta} = -\frac{n}{2\theta} + \frac{1}{2\theta^2} \sum_{i=1}^n (x_i - m)^2$$

Poniamo la derivata uguale a zero:

$$-\frac{n}{2\theta} + \frac{1}{2\theta^2} \sum_{i=1}^n (x_i - m)^2 = 0$$

Per semplificare, moltiplichiamo l'intera equazione per $2\theta^2$ (supponendo $\theta > 0$):

$$-n\theta + \sum_{i=1}^n (x_i - m)^2 = 0$$

$$n\theta = \sum_{i=1}^n (x_i - m)^2$$

$$\theta = \frac{1}{n} \sum_{i=1}^n (x_i - m)^2$$

Dunque lo stimatore di massima verosimiglianza per la varianza è $\hat{\theta}_{MLE} = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2$.

VALUTIAMO LA COERENZA TRA TEGER DELLA POPOL. E SOSTENUTA DEL CAMPIONE, SE $X \sim U[0, \theta]$ RUGERA HA DENSITÀ PIATTO, $E[X] = 0 + \theta = \frac{\theta}{2}$ (PUNTO MEDIO), QUINDI NEL MONDO IDEALE DELLA POPOLAZIONE $\theta = 2E[X]$ (IL DOPO DELLA MEDIA) $\Rightarrow$ UN CANDIDATO NATURALE PER STIMARE θ È $\hat{\theta} = 2 \cdot \bar{X}_n$ E È CORRETTO MENTRE MAX... È DISTETTO, MA NON MASSIMIZZA LA VERO SOSTENUTA!

Appunti di Statistica e Probabilità

Valore Atteso e Varianza

18.3.3 3. Distribuzione Uniforme su $[0, \theta]$

$$X \sim U[0, \theta] \quad \theta > 0 \text{ NON NOTO} \quad f_{\theta}(x) = \begin{cases} \frac{1}{\theta} & x \in [0, \theta] \\ 0 & \text{altrimenti} \end{cases}$$

In questo caso la densità è $f_{\theta}(x) = \frac{1}{\theta} \mathbb{I}_{[0, \theta]}(x)$. La verosimiglianza è $\frac{1}{\theta^n}$ se tutti gli x_i sono $\leq \theta$, altrimenti è 0. Per massimizzare $\frac{1}{\theta^n}$ dobbiamo scegliere il più piccolo θ possibile, ma con il vincolo che θ deve essere maggiore o uguale di tutti i dati osservati.

$$L_{\theta}(x_1, \dots, x_n) = \begin{cases} \frac{1}{\theta^n} & \text{se } \theta \geq \max(x_1, \dots, x_n) \\ 0 & \text{altrimenti} \end{cases}$$

Essendo DECRE. L_{θ} , SI MASSIMIZZA PER IL PIÙ PICCOLO θ (IL VAL. MAX DEL CAMPIONE)

— [Il caso del Minimo] Consideriamo una densità $f_{\theta}(x) = \frac{1}{\theta} \mathbb{I}_{(\theta, +\infty)}(x)$. Qual è l'MLE?

Seguendo la logica dell'uniforme, la verosimiglianza è $L_{\theta} = \theta^n \prod \frac{1}{x_i}$ purché $\theta \leq x_i$ per ogni i . Per massimizzare θ^n , dobbiamo scegliere il valore di θ più grande possibile che rispetti il vincolo $\theta \leq \min(x_i)$.

$$\hat{\theta}_{MLE} = \min(x_1, \dots, x_n)$$

Attenzione: Questo stimatore è consistente (per $n \rightarrow \infty$ si avvicina a θ), ma non è corretto per $n > 1$. Infatti, calcolando il valore atteso tramite la distribuzione del minimo, si trova $E[\hat{\theta}] = \frac{n}{n+1} \theta \neq \theta$.

18.3.4 4. Distribuzione Normale $N(m, \sigma^2)$ con m noto

Se la media m è nota, l'MLE per la varianza $\theta = \sigma^2$ si trova massimizzando:

$$L_{\theta} \propto \frac{1}{\theta^{n/2}} \exp\left(-\frac{1}{2\theta} \sum (x_i - m)^2\right)$$

Il risultato è:

$$\hat{\sigma}^2_{MLE} = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2$$

$$\bar{X}_n \approx E[X]$$

VALORE SEMPLICE PER CALCOLARE GRABILI.

Questo stimatore risulta essere sia corretto che consistente.

Approfondimento Teorico-Pratico: Esercizi MLE e Grafici

IL CALCOLO

$E[X] = \theta$

CAMBIA A

SECONDA

DELLA DISTR.

Per comprendere veramente il Metodo della Massima Verosimiglianza, applichiamo passo dopo passo a tre scenari classici, integrando le visualizzazioni grafiche del comportamento delle funzioni.

Esercizio 1: MLE per la Poisson

Sia $X \sim \text{Poisson}(\lambda)$ con $\lambda > 0$ incognito. Abbiamo un campione $(X_1, \dots, X_n)$ e vogliamo trovare lo stimatore MLE per λ . La densità discreta è $p_{\lambda}(k) = \frac{\lambda^k}{k!} e^{-\lambda}$.

La funzione di verosimiglianza è il prodotto delle densità:

$$L(\lambda, x_1, \dots, x_n) = \prod_{i=1}^n \left(\frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = \left(\prod_{i=1}^n \frac{1}{x_i!} \right) \lambda^{\sum_{i=1}^n x_i} e^{-n\lambda}$$

Passiamo alla log-verosimiglianza (su $\lambda \in (0, +\infty)$):

$$\log L(\lambda) = \log \left(\prod_{i=1}^n \frac{1}{x_i!} \right) + \left(\sum_{i=1}^n x_i \right) \log \lambda - n\lambda$$

Deriviamo rispetto a λ e poniamo uguale a zero per trovare il massimo:

$$\frac{d}{d\lambda} \log L = \sum_{i=1}^n \frac{x_i}{\lambda} - n \geq 0 \iff \lambda \leq \frac{\sum_{i=1}^n x_i}{n} = \bar{x}_n$$

Quindi la log-verosimiglianza cresce fino a $\bar{x}_n$ e poi decresce. L'unico MLE è $\hat{\lambda} = \bar{x}_n$.
Sappiamo dalla teoria che $\bar{x}_n$ è sia corretto che consistente per $E[X_i] = \lambda$.

Esercizio 2: Il caso critico della densità decrescente

Questo è un esercizio fondamentale perché lo stimatore non è la media campionaria. Sia X con densità $f_\theta(x) = \frac{\theta}{x^2} \mathbb{I}_{(\theta, +\infty)}(x)$, con $\theta > 0$ incognito.

a) Trovare lo stimatore MLE

Dato che $f_\theta(x) = 0$ per $x \leq \theta$, possiamo supporre che tutti i dati osservati siano $x_i > 0$.

$$L_\theta(x_1, \dots, x_n) = \prod_{i=1}^n \frac{\theta}{x_i^2} \mathbb{I}_{x_i \geq \theta} = \frac{\theta^n}{\prod_{i=1}^n x_i^2} \mathbb{I}_{\min x_i \geq \theta}$$

La funzione L_θ cresce con θ^n , ma precipita a zero non appena θ supera il valore del dato più piccolo osservato ($\min x_i$). Per massimizzare L_θ , dobbiamo spingere θ il più a destra possibile senza oltrepassare $\min x_i$. L'unico MLE è quindi $\hat{\theta} = \min_i X_i$.

Funzione di Verosimiglianza per $f(x) = \theta/x^2$




Figura 1: Il massimo si trova sul "bordo" del dominio valido.

b) Consistenza dello stimatore


Per $n \rightarrow \infty$, il minimo campionario $\min X_i$ è coerente? Calcoliamo la probabilità che si discosti dal valore vero θ di un errore ϵ :

$$P(|\hat{\theta}_n - \theta| > \epsilon) = P(\min X_i > \theta + \epsilon) = P(X_1 > \theta + \epsilon)$$

Poiché il minimo è maggiore di una soglia solo se tutti i campioni lo sono (e sono indipendenti):

$$= \prod_{i=1}^n P(X_i > \theta + \epsilon) = [P(X_1 > \theta + \epsilon)]^n$$

Questa probabilità base è un numero strettamente minore di 1 (poiché è l'area della coda della distribuzione). Elevando una frazione < 1 alla potenza n per $n \rightarrow \infty$, il limite fa zero. Lo stimatore è consistente.



DENSITÀ DELLA
V.A. DI PARETO
(SOPRANIMMO A ESSO)

Figura 2: L'area rossa rappresenta $P(X_i > \theta + \epsilon)$. Essendo < 1 , elevata alla n tende a 0.

c) Correttezza dello stimatore ($E[\hat{\theta}] = \theta$)

La Funzione di Ripartizione del minimo è $1 - (1 - F_X(x))^n$. Integrando la nostra densità, troviamo $F_X(x) = 1 - \frac{\theta}{x}$ per $x \geq \theta$. Quindi:

$$F_{\min X_i}(x) = 1 - \left(\frac{\theta}{x}\right)^n$$

La densità del minimo si ottiene derivando: $f_{\min X_i}(x) = n\theta^n x^{-n-1} \mathbb{I}_{(x \geq \theta)}$. Calcoliamo il valore atteso:

$$E[\min X_i] = \int_{\theta}^{\infty} x \cdot n\theta^n x^{-n-1} dx = \frac{n}{n-1} \theta \neq \theta$$

Poiché il risultato ha un fattore di distorsione $\frac{n}{n-1}$, lo stimatore non è corretto (anche se, per n enorme, la frazione tende a 1, confermando la consistenza).

Esercizio 3: MLE per la Varianza della Normale

Sia $X \sim \mathcal{N}(m, \sigma^2)$ con la media m nota. Cerchiamo l'MLE per $\theta = \sigma^2 \in (0, +\infty)$. La funzione di verosimiglianza è:

$$L_\theta(x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\theta}} \exp\left(-\frac{(x_i - m)^2}{2\theta}\right) = \frac{1}{(2\pi)^{n/2} \theta^{n/2}} \exp\left(-\frac{1}{2\theta} \sum_{i=1}^n (x_i - m)^2\right)$$

Passiamo alla log-verosimiglianza:

$$\log L_\theta = \log \frac{1}{(2\pi)^{n/2}} - \frac{n}{2} \log \theta - \frac{1}{2\theta} \sum_{i=1}^n (x_i - m)^2$$

Deriviamo rispetto a θ :

$$\frac{d}{d\theta} \log L_\theta = -\frac{n}{2\theta} + \frac{1}{2\theta^2} \sum_{i=1}^n (x_i - m)^2 \geq 0 \iff \theta \leq \frac{1}{n} \sum_{i=1}^n (x_i - m)^2$$

Il punto di massimo (MLE) è quindi $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2$. Poiché $\hat{\theta}$ è esattamente la media campionaria della variabile aleatoria $(X_i - m)^2$, esso è uno stimatore corretto e consistente per $E[(X_1 - m)^2] = \text{Var}(X) = \sigma^2$.

Parte 2 Appunti Completi: Valore Atteso, Momenti e Varianza Guida allo Studio Definitiva

Indice

Dimostrazione della Consistenza di $\bar{X}_n$

Sia $X_1, X_2, \dots, X_n$ un campione statistico di variabili aleatorie i.i.d. con momento secondo finito, ovvero $E[X_i] = \mu$ e $Var(X_i) = \sigma^2 < \infty$. [cite: 32, 40, 152]

Vogliamo dimostrare che:

$$\forall \epsilon > 0, \lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \epsilon) = 0$$

[cite: 144-145]

Passaggio 1: Applicazione della Disuguaglianza di Chebyshev

Sappiamo che per ogni variabile aleatoria Y con media $E[Y]$ e varianza $Var(Y)$, vale:

$$P(|Y - E[Y]| \geq \epsilon) \leq \frac{Var(Y)}{\epsilon^2}$$

Passaggio 2: Sostituzione con la Media Campionaria

Sostituiamo $Y = \bar{X}_n$. Sappiamo già che:

- $E[\bar{X}_n] = \mu$ (lo stimatore è corretto). [cite: 33, 136]
- $Var(\bar{X}_n) = \frac{\sigma^2}{n}$.

Otteniamo quindi:

$$P(|\bar{X}_n - \mu| \geq \epsilon) \leq \frac{\sigma^2}{n \cdot \epsilon^2}$$

Passaggio 3: Calcolo del limite (LGN)

Passando al limite per $n \rightarrow \infty$:

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \epsilon) \leq \lim_{n \rightarrow \infty} \frac{\sigma^2}{n \cdot \epsilon^2} = 0$$

[cite: 43, 152]

Poiché una probabilità non può essere negativa, il limite è esattamente 0. Questo conclude la dimostrazione: per la Legge dei Grandi Numeri (LGN), la media campionaria è uno stimatore consistente per il valore atteso della popolazione. [cite: 43, 152]

1 Verifica di Correttezza: Il caso del Minimo Campionario

Consideriamo il campione i.i.d. $X_1, \dots, X_n$ estratto da una popolazione con densità:

$$f_\theta(x) = \frac{\theta}{x^2} \mathbb{1}_{(\theta, +\infty)}(x)$$

Abbiamo stabilito tramite il metodo della massima verosimiglianza che lo stimatore ideale è il minimo del campione: $\hat{\theta} = \min(X_1, \dots, X_n)$ [cite: 280]. Vogliamo ora verificare se tale stimatore è corretto, ovvero se $E[\hat{\theta}] = \theta$ [cite: 296].

Fase 1: Determinazione della Funzione di Ripartizione del Minimo

Per calcolare il valore atteso di $\hat{\theta}$, dobbiamo prima conoscere la sua densità. Partiamo dalla probabilità che il minimo sia maggiore di un valore generico x :

$$P(\min X_i > x) = P(X_1 > x, X_2 > x, \dots, X_n > x)$$

Per l'indipendenza delle variabili (i.i.d.), la probabilità congiunta è il prodotto delle probabilità singole [cite: 317]:

$$P(\min X_i > x) = \prod_{i=1}^n P(X_i > x) = [P(X_1 > x)]^n$$

Calcoliamo $P(X_1 > x)$ integrando la densità della popolazione da x a $+\infty$:

$$P(X_1 > x) = \int_x^{+\infty} \frac{\theta}{y^2} dy = \theta \left[-\frac{1}{y} \right]_x^{+\infty} = \theta \left(0 - \left(-\frac{1}{x} \right) \right) = \frac{\theta}{x}$$

Sostituendo, otteniamo la probabilità complementare della ripartizione del minimo [cite: 323]:

$$P(\min X_i > x) = \left(\frac{\theta}{x} \right)^n$$

Dunque, la Funzione di Ripartizione (Fdr) del minimo è [cite: 324]:

$$F_{\min}(x) = 1 - P(\min X_i > x) = 1 - \left(\frac{\theta}{x} \right)^n$$

Fase 2: Determinazione della Densità del Minimo

Deriviamo la Fdr rispetto a x per ottenere la funzione di densità $f_{\min}(x)$ [cite: 325]:

$$f_{\min}(x) = \frac{d}{dx} \left[1 - \theta^n x^{-n} \right] = 0 - \theta^n (-n) x^{-n-1} = n \theta^n x^{-n-1}$$

Questa densità è definita per $x \in (\theta, +\infty)$.

(DEFINIZIONE DELLA DENSITÀ)

Fase 3: Calcolo del Valore Atteso

Applichiamo la definizione di valore atteso $E[Y] = \int y \cdot f(y) dy$:

$$E^{\theta}[\min X_i] = \int_0^{+\infty} x \cdot (n\theta^n x^{-n-1}) dx$$

Semplifichiamo le potenze di x ($x^1 \cdot x^{-n-1} = x^{-n}$) e portiamo fuori le costanti:

$$E^{\theta}[\min X_i] = n\theta^n \int_0^{+\infty} x^{-n} dx$$

Risolviamo l'integrale (valido per $n > 1$):

$$\int_0^{+\infty} x^{-n} dx = \left[\frac{x^{-n+1}}{-n+1} \right]_0^{+\infty} = \left[\frac{1}{(1-n)x^{n-1}} \right]_0^{+\infty}$$

Valutando agli estremi:

- Per $x \rightarrow +\infty$, il termine tende a 0 (poiché $n > 1$).
- Per $x = 0$, sottraiamo il valore: $-\frac{1}{(1-n)\theta^{n-1}} = \frac{1}{(n-1)\theta^{n-1}}$.

Mettendo tutto insieme:

$$E^{\theta}[\min X_i] = n\theta^n \cdot \frac{1}{(n-1)\theta^{n-1}} = \frac{n}{n-1} \cdot \frac{\theta^n}{\theta^{n-1}} = \frac{n}{n-1} \theta$$

Conclusione sulla Correttezza

Poiché $E^{\theta}[\min X_i] = \frac{n}{n-1} \theta \neq \theta$ [cite: 325-326], lo stimatore non è corretto. Esso produce sistematicamente una stima superiore al valore vero θ (bias positivo). Tuttavia, osserviamo che per $n \rightarrow \infty$, il fattore $\frac{n}{n-1} \rightarrow 1$, confermando che lo stimatore è consistente [cite: 281, 288].

1 Distribuzione del Minimo e del Massimo Campionario

Sia $X_1, X_2, \dots, X_n$ un campione di variabili aleatorie i.i.d. (indipendenti e identicamente distribuite). Indichiamo con $F(x) = P(X \leq x)$ la Funzione di Ripartizione (FDR) della popolazione. A seconda del caso, indichiamo con $f(x)$ la densità (caso continuo) o con $p(x) = P(X = x)$ la funzione di massa di probabilità (caso discreto).

1.1 Il caso banale ($n = 1$)

Se estraiamo un solo elemento dal campione, il massimo e il minimo coincidono ovviamente con l'unico elemento estratto:

$$\max(X_1) = \min(X_1) = X_1$$

Di conseguenza, la distribuzione del massimo e del minimo coincide esattamente con la distribuzione della popolazione originale:

- FdR: $F_{\max}(x) = F_{\min}(x) = F(x)$
- Densità/Massa: $f_{\max}(x) = f_{\min}(x) = f(x)$ (o $p(x)$ nel caso discreto).

1.2 Il caso generale ($n > 1$)

Quando $n > 1$, la distribuzione del minimo e del massimo si allontana da quella della popolazione originaria.

1. Distribuzione del Massimo ($M_n = \max\{X_1, \dots, X_n\}$)

Il massimo del campione è minore o uguale a x se e solo se tutti gli elementi del campione sono minori o uguali a x .

$$\begin{aligned} F_{M_n}(x) &= P(\max(X_1, \dots, X_n) \leq x) \\ &= P(X_1 \leq x, X_2 \leq x, \dots, X_n \leq x) \\ &= \prod_{i=1}^n P(X_i \leq x) = [F(x)]^n \end{aligned}$$

A partire dalla FdR, ricaviamo le funzioni per i casi specifici:

- Caso Continuo (Densità): Deriviamo la FdR rispetto a x usando la regola della catena:

$$f_{M_n}(x) = \frac{d}{dx} [F(x)]^n = n[F(x)]^{n-1} f(x)$$

- Caso Discreto (Probabilità): La probabilità in un punto esatto è la differenza della FdR:

$$P(M_n = x) = F_{M_n}(x) - \lim_{t \rightarrow x^-} F_{M_n}(t) = [F(x)]^n - [F(x^-)]^n$$

(Se i dati sono numeri interi, la formula diventa semplicemente $[F(x)]^n - [F(x-1)]^n$).

2. Distribuzione del Minimo ($m_n = \min(X_1, \dots, X_n)$)

Il minimo del campione è strettamente maggiore di x se e solo se tutti gli elementi del campione sono strettamente maggiori di x .

$$P(m_n > x) = P(X_1 > x, \dots, X_n > x)$$

$$= \prod_{i=1}^n P(X_i > x) = [1 - F(x)]^n$$

La FdR si ottiene per complemento:

$$(1 - \alpha)$$

$$F_{m_n}(x) = P(m_n \leq x) = 1 - P(m_n > x) = 1 - [1 - F(x)]^n$$

Da qui, ricaviamo i due casi specifici:

- **Caso Continuo (Densità):** Deriviamo la FdR rispetto a x :

$$f_{m_n}(x) = \frac{d}{dx} \{1 - [1 - F(x)]^n\} = 0 - n[1 - F(x)]^{n-1} \cdot (-f(x)) = n[1 - F(x)]^{n-1} f(x)$$

- **Caso Discreto (Probabilità):** Lavoriamo sulle probabilità di sopravvivenza. Il minimo è esattamente x se tutti i valori sono $\geq x$, ma non tutti sono $> x$:

$$P(m_n = x) = P(m_n \geq x) - P(m_n > x) = [1 - F(x^-)]^n - [1 - F(x)]^n$$

(Se i dati sono numeri interi, si traduce in $P(X \geq x) - P(X \geq x+1)$).

19 Intervalli di Fiducia

19.1 Scopo e Definizione

Il secondo scopo fondamentale della statistica inferenziale, dopo la stima puntuale, è fornire una stima intervallare. Sulla base dei dati estratti da un campione, vogliamo determinare una regione (un intervallo) entro la quale il parametro vero incognito θ si trovi con un'alta probabilità, definita a priori. Tale probabilità prende il nome di **fiducia** [cite: 5, 6, 8].

Definizione: Intervallo di Fiducia

Sia $(X_1, \dots, X_n)$ un campione i.i.d. dipendente da un parametro ignoto $\theta \in \Theta$. Dato un valore $\alpha \in (0, 1)$ piccolo (es. $\alpha = 0.05$), un **Intervallo di Fiducia (I.F.)** per θ di livello $1 - \alpha$ è un intervallo aleatorio del tipo:

$$I = [a(X_1, \dots, X_n), b(X_1, \dots, X_n)]$$

dove gli estremi sono due statistiche campionarie, tale che:

$$P(\theta \in I) \geq 1 - \alpha \quad \forall \theta \in \Theta$$

[cite: 9-12]

[L'aleatorietà risiede nell'intervallo] È cruciale interpretare correttamente la notazione $P(\theta \in I) \geq 1 - \alpha$. Il parametro θ non è una variabile aleatoria: esso è un numero fisso, seppur incognito [cite: 17]. Ciò che cambia al ripetersi dell'esperimento sono gli estremi dell'intervallo I , poiché dipendono dal campione estratto [cite: 16]. Pertanto, il livello di fiducia $1 - \alpha$ va interpretato in ottica frequentista: se estraessimo infiniti campioni e calcolassimo i rispettivi intervalli, almeno una proporzione pari a $(1 - \alpha)$ di essi "intrappolerebbe" il valore vero θ [cite: 18, 19].

Un intervallo di fiducia ideale possiede due caratteristiche in contrasto tra loro [cite: 30]:

1. Un livello di fiducia $1 - \alpha$ molto elevato (es. 95% o 99%).

2. Un'ampiezza dell'intervallo piccola (alta precisione).

Purtroppo, a parità di dati, per aumentare la certezza (livello) è necessario allargare l'intervallo [cite: 30]. L'unico modo per aumentare la precisione senza sacrificare la fiducia è aumentare la numerosità del campione n .

19.2 Caso 1: Media di popolazione Gaussiana con Varianza

Nota $(X_1, \dots, X_n)$ i.i.d.

$$X = \bar{X}$$

Supponiamo che la popolazione segua una distribuzione Normale $X \sim N(m, \sigma^2)$, dove la varianza σ^2 è un parametro noto, mentre la media m è incognita [cite: 37].

Poiché $\bar{X}_n$ è lo stimatore naturale per la media, cerchiamo un intervallo simmetrico centrato su di esso:

$$I = [\bar{X}_n - d, \bar{X}_n + d]$$

dove d rappresenta la **semiampiezza** (o precisione della stima) [cite: 40, 41].

INCOSNITA

Derivazione matematica

Sappiamo dalla teoria (proprietà riproduttiva della Normale) che la distribuzione della media campionaria è $\bar{X}_n \sim N(m, \frac{\sigma^2}{n})$ [cite: 44, 45]. Standardizzando, otteniamo una variabile pivotale (ovvero con distribuzione nota e indipendente dal parametro ignoto):

$$Z = \frac{\bar{X}_n - m}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Vogliamo che $P(m \in [\bar{X}_n \pm d]) = 1 - \alpha$. Questo equivale a richiedere che l'errore standardizzato cada nell'area centrale della campana:

$$P\left(-\frac{\sqrt{n}d}{\sigma} \leq Z \leq \frac{\sqrt{n}d}{\sigma}\right) = 1 - \alpha$$

[cite: 42, 47, 49]

Per lasciare un'area pari ad α divisa equamente sulle due code (cioè $\alpha/2$ a sinistra e $\alpha/2$ a destra), il limite deve corrispondere al quantile $q_{1-\alpha/2}$ della Normale Standard [cite: 55].

$$2 \Phi\left(\frac{\sqrt{n}d}{\sigma}\right) = 1 - \alpha + 1$$

$$\Phi\left(\frac{\sqrt{n}d}{\sigma}\right) = 1 - \frac{\alpha}{2}$$

$$\frac{\sqrt{n}d}{\sigma} = q_{1-\alpha/2}$$

$$d = \frac{\sigma}{\sqrt{n}} q_{1-\alpha/2}$$

$$q_{1-\alpha/2} \in N(0, 1)$$

Uguagliando l'argomento della probabilità al quantile:

$$\frac{\sqrt{n}d}{\sigma} = q_{1-\alpha/2} \Rightarrow d = \frac{\sigma}{\sqrt{n}} q_{1-\alpha/2}$$

[cite: 55]

Proprietà / Teorema: Intervallo di Fiducia per m

Sia $(X_1, \dots, X_n)$ un campione casuale estratto da $N(m, \sigma^2)$ con $\sigma^2 > 0$ nota.

L'Intervallo di Fiducia per la media m di livello $1 - \alpha$ è dato da:

$$I = \left[\bar{X}_n - \frac{\sigma}{\sqrt{n}} q_{1-\alpha/2}, \bar{X}_n + \frac{\sigma}{\sqrt{n}} q_{1-\alpha/2} \right]$$

[cite: 57, 58]

Osservando la formula della semiampiezza d , notiamo tre dipendenze fondamentali [cite: 81]:

- Cresce al crescere del livello di fiducia desiderato $1 - \alpha$ (poiché aumenta il quantile q) [cite: 82].

- Cresce al crescere della variabilità intrinseca del fenomeno σ^2 [cite: 84, 85].
- Decresce (con proporzionalità inversa alla radice) al crescere della numerosità campionaria n [cite: 86].

Esempio Pratico: Il peso dei Salmoni

Un biologo vuole stimare il peso medio m di una certa specie di salmoni. Si assume che il peso segua una distribuzione $N(m, \sigma^2)$ con deviazione standard nota $\sigma = 0.4$ kg. Da un campione di $n = 10$ esemplari, si calcola un peso medio campionario $\bar{x}_{10} = 3.58$ kg [cite: 66, 67].

Quesito A: Calcolare l'I.F. al livello del 95%. [cite: 68] Poiché $1 - \alpha = 0.95$, si ha $\alpha = 0.05$ e $\alpha/2 = 0.025$. Il quantile da cercare nelle tavole della Normale Standard è $q_{0.975} = 1.96$ [cite: 71, 72, 73]. Sostituendo i valori:

$$I = \left[3.58 \pm \frac{0.4}{\sqrt{10}} \cdot 1.96 \right] = [3.58 \pm 0.248] = [3.332, 3.828]$$

[cite: 74, 75]

Quesito B (Dimensionamento): Quanti salmoni bisogna campionare affinché il margine di errore d non superi 0.1 kg, mantenendo il 95% di fiducia? [cite: 76-78] Dobbiamo risolvere la disuguaglianza rispetto a n :

$$d = \frac{\sigma}{\sqrt{n}} q_{1-\alpha/2} \leq 0.1 \Rightarrow \sqrt{n} \geq \frac{\sigma}{0.1} q_{1-\alpha/2}$$

Elevando al quadrato:

$$n \geq \left(\frac{0.4}{0.1} \cdot 1.96 \right)^2 = 61.46$$

[cite: 79] Poiché n deve essere un intero, il biologo dovrà pesare almeno $n = 62$ salmoni [cite: 80].

19.3 Caso 2: Media di popolazione Gaussiana con Varianza Non Nota

Nella pratica statistica, è rarissimo conoscere la vera varianza σ^2 della popolazione se non se ne conosce la media. Se abbiamo un campione i.i.d. $X_1, \dots, X_n \sim N(m, \sigma^2)$ dove entrambi i parametri sono ignoti, non possiamo più utilizzare la variabile standardizzata $Z = \frac{\bar{X}_n - m}{\sigma/\sqrt{n}}$, perché σ ci è sconosciuta [cite: 92, 94, 95].

La soluzione "naturale" è sostituire il parametro ignoto σ^2 con il suo miglior stimatore campionario: la varianza campionaria [cite: 96, 99].

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \Rightarrow S_n = \sqrt{S_n^2}$$

[cite: 96, 98]

Inserendo S_n al posto di σ , otteniamo una nuova statistica:

$$T = \sqrt{n} \frac{\bar{X}_n - m}{S_n}$$

[cite: 100] Poiché S_n è una variabile aleatoria (cambia da campione a campione) e non una costante come σ , questa nuova statistica T introduce ulteriore incertezza. Pertanto, non si distribuisce più come una Normale Standard, ma segue una distribuzione più "larga" sulle code, chiamata t di Student [cite: 101, 102].


La Distribuzione t di Student

La distribuzione t_k di Student è parametrizzata da un valore intero k chiamato gradi di libertà. Nel nostro caso, per un campione di taglia n , i gradi di libertà sono $k = n - 1$ [cite: 103, 104].

[Caratteristiche della t -Student] La densità $f_k(x) = c_k \left(1 + \frac{x^2}{k}\right)^{-\frac{k+1}{2}}$ presenta le seguenti peculiarità [cite: 106]:

1. È simmetrica, pari e a forma di campana, proprio come la Normale [cite: 107].
2. Ha le code più pesanti rispetto alla Normale $N(0, 1)$. Questo significa che i valori estremi sono più probabili [cite: 115]. Di conseguenza, i suoi quantili (indicati con τ) sono maggiori dei rispettivi quantili della Normale: $\tau_{1-\alpha/2, k} > q_{1-\alpha/2}$ per α vicino a 1 [cite: 116-118].
3. Convergenza asintotica: All'aumentare dei gradi di libertà $k \rightarrow \infty$, l'incertezza su S_n svanisce e la distribuzione t_k converge alla Normale Standard $N(0, 1)$ (nel senso della convergenza delle densità) [cite: 120, 122].

[Regola Pratica per l'Esame] Il professore indica che per $k \geq 50$, l'approssimazione è talmente buona che è consentito utilizzare i quantili della Normale q al posto dei quantili τ della t -Student per semplificare i calcoli [cite: 124].



Costruzione dell'Intervallo

Sostituendo il quantile q della Normale con il quantile τ della t -Student e σ con S_n , otteniamo la formula definitiva per il caso realistico [cite: 125, 126]:

Proprietà / Teorema: Intervallo di Fiducia per m

Sia $(X_1, \dots, X_n)$ un campione casuale estratto da $N(m, \sigma^2)$ con varianza ignota [cite: 127]. L'Intervallo di Fiducia per la media m di livello $1 - \alpha$ è:

$$I = \left[\bar{X}_n - \frac{S_n}{\sqrt{n}} \tau_{1-\alpha/2, n-1}, \bar{X}_n + \frac{S_n}{\sqrt{n}} \tau_{1-\alpha/2, n-1} \right]$$

[cite: 129]

Esempio Pratico: Il peso dei Salmoni (Varianza ignota)

Riprendiamo l'esempio dei salmoni ($n = 10$ esemplari misurati). Questa volta, il biologo non conosce la varianza della popolazione, ma la calcola direttamente dai 10 salmoni estratti, trovando una deviazione standard campionaria $s_{10} = 0.4$ kg e una media $\bar{x}_{10} = 3.58$ kg [cite: 130-132].

Vogliamo calcolare l'IF. di livello 95% [cite: 133].

1. I gradi di libertà sono $k = n - 1 = 10 - 1 = 9$.
2. Il livello di fiducia richiede un'area centrale del 95%, quindi $\alpha/2 = 0.025$.
3. Sulle tavole della t -Student, cerchiamo il quantile $\tau_{0.975, 9}$. Troviamo il valore 2.26 [cite: 134].

Calcoliamo l'intervallo [cite: 134, 135]:

$$I = \left[3.58 \pm \frac{0.4}{\sqrt{10}} \cdot 2.26 \right] = [3.58 \pm 0.286] = [3.294, 3.866]$$

19.4 Caso 3: Grandi Campioni (Teorema del Limite Centrale)

Quando la dimensione del campione è sufficientemente elevata ($n \geq 50$), non è più necessario richiedere che la popolazione sia distribuita normalmente [cite: 142, 143]. Grazie al Teorema del Limite Centrale (TCL), la statistica pivotale converge alla Normale Standard indipendentemente dalla legge di X [cite: 145-147].

Proprietà / Teorema: I.F. per Grandi Campioni

Per n sufficientemente grande, un intervallo di fiducia approssimato di livello $1 - \alpha$ per la media m è dato da:

• Se σ^2 è nota: $I \approx [\bar{X}_n \pm \frac{\sigma}{\sqrt{n}} q_{1-\alpha/2}]$ [cite: 152, 153].

• Se σ^2 è incognita: $I \approx [\bar{X}_n \pm \frac{S_n}{\sqrt{n}} q_{1-\alpha/2}]$ [cite: 156, 158].

In questo caso, si utilizza il quantile q della Normale anche se la varianza è stimata, poiché per grandi n l'approssimazione è giustificata [cite: 158].

[Qualità dell'approssimazione] L'approssimazione fornita dal TCL è tanto più affidabile quanto più il livello di fiducia $1 - \alpha$ è lontano da 1. Per valori vicini a 1, l'approssimazione funziona peggio [cite: 159, 160].

$$\frac{\bar{X}_n - m}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

$$\frac{\bar{X}_n - m}{\frac{S_n}{\sqrt{n}}} \sim N(0, 1)$$

$$\lim_{n \rightarrow \infty} P(m \in [\bar{X}_n \pm \cdot]) = 1 - \alpha$$

$(X_1, \dots, X_n)$

i.i.d.

$X \sim ?$

$m = E[X]$

Non noto

CASO PARTICOLARE
POSSIBILE LA

19.5 Caso 4: Intervalli di Fiducia per una Proporzione

Un caso di fondamentale importanza riguarda la stima della probabilità $p = P(A)$ di un evento A . In questo contesto, le variabili X_i seguono una legge di Bernoulli, dove $X = 1$ se si verifica l'evento A , $X = 0$ altrimenti [cite: 166-168]. Sappiamo che:

$$X \sim B(p)$$

$$(X_1, \dots, X_n)$$

$$iid$$

- Il valore atteso è $E[X] = p$
- La varianza è $Var(X) = p(1-p)$
- Lo stimatore di p è la frequenza relativa campionaria $\bar{X}_n$ [cite: 170].

Proprietà / Teoremi: I.F. per la Proporzione - Grandi Campioni

Sotto la condizione di applicabilità del TCL (solitamente verificata se $n\bar{X}_n(1-\bar{X}_n) \geq 10$) [cite: 175], l'I.F. di livello approssimato $1-\alpha$ per p è [cite: 181]:

$$I \approx \left[\bar{X}_n - \sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n}} \cdot q_{1-\alpha/2}, \bar{X}_n + \sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n}} \cdot q_{1-\alpha/2} \right]$$

[Indipendenza dalla Popolazione] Le stime non dipendono dalla taglia della popolazione.

Dimensionamento del campione per i sondaggi

Per garantire che la semiampiezza d (il margine di errore) sia inferiore a una soglia prestabilita ϵ (es. $d \leq 0.01$) [cite: 200, 201]:

$$d = \sqrt{\frac{\bar{X}_n(1-\bar{X}_n)}{n}} \cdot q_{1-\alpha/2} \leq \epsilon$$

Poiché $\bar{X}_n$ non è noto a priori [cite: 202], si procede in due modi [cite: 203, 216]:

1. 1° Soluzione (Conservativa): Si sfrutta il fatto che il massimo di $x(1-x)$ per $x \in [0, 1]$ è $1/4$ [cite: 208, 209]. Imponendo il caso peggiore, si ottiene:

$$\frac{1}{2\sqrt{n}} \cdot q_{1-\alpha/2} \leq \epsilon \Rightarrow n \geq \left(\frac{q_{1-\alpha/2}}{2\epsilon} \right)^2$$

[cite: 210-213] A posteriori, si verificherà che $n\bar{X}_n(1-\bar{X}_n) \geq 10$ [cite: 214, 215].

2. 2° Soluzione (Con info preliminari): Se disponiamo di una stima preliminare che confina X_n in un range (es. $[0.37, 0.63]$), stimiamo il massimo di $x(1-x)$ in quel range e imponiamo la disuguaglianza [cite: 216].

Esempio: Sondaggio d'opinione

$$(X_1, \dots, X_{1000}) \text{ i.i.d. } X_i \sim B(p)$$

In un sondaggio su 1000 intervistati, 400 dichiarano di voler votare per il partito A ($\bar{X}_n = 0.4$) [cite: 185, 186, 193]. Calcoliamo l'I.F. al 95%. Essendo $n\bar{X}_n(1-\bar{X}_n) = 1000 \cdot 0.4 \cdot 0.6 = 240 \geq 10$ [cite: 197], usiamo il TCL:

$$I = \left[0.4 \pm \sqrt{\frac{0.4 \cdot 0.6}{1000}} \cdot 1.96 \right] = [0.4 \pm 0.03] = [37\%, 43\%]$$

$$X \sim B(p \text{ (VOTO PER A)})$$

IL RISCHIO QUANTITATIVO = VAR. QUANDO LO STIMABBE
E CORRETTO, SEQUELLE IL VAL. MAX NELLE INTERV. NOTO A PRIORI
SERVE A MINIMIZZARE QUESTO RISCHIO. ALL'AUMENTARE DI n
LA VAL. (QUANDO IL RISCHIO) DECEDE (INCLINAMENTO)
MA NON SIA IL CENTRO

[cite: 198, 199, 204, 205] Se il margine di errore desiderato fosse stato dell'1% ($d \leq 0.01$), avremmo avuto bisogno di un campione conservativo di [cite: 212, 213]:

$$n \geq \left(\frac{1.96}{2 \cdot 0.01} \right)^2 = 9604 \text{ persone}$$

19.6 Esercizi Riassuntivi e Applicazioni

Esercizio 7.1: Misura del pH (Varianza Nota)

Sia X la misura del pH di una soluzione, con $X \sim N(\mu, 0.1^2)$. Effettuiamo $n = 50$ misurazioni ottenendo una media $\bar{X}_n = 8.19$ [cite: 231-233].

1. Calcolo dell'I.F. al 95% [cite: 234]: Essendo la varianza nota, usiamo il quantile della Normale $q_{0.975} = 1.96$ [cite: 235, 236].

$$I = \left[8.19 \pm \frac{0.1}{\sqrt{50}} \cdot 1.96 \right] = [8.19 \pm 0.0277]$$

[cite: 236-238]

2. Dimensionamento [cite: 239]: Per avere un margine di errore $d \leq 0.01$, calcoliamo [cite: 243, 244]:

$$n = \left(\frac{\sigma \cdot q_{1-\alpha/2}}{d} \right)^2 = \left(\frac{0.1 \cdot 1.96}{0.01} \right)^2 = 384.16 \Rightarrow n = 385$$

[cite: 245]

Esercizio 7.2: Errori di un Server (Proporzione)

Un server commette 50 errori su 1000 richieste ($\bar{X}_n = 0.05$) [cite: 247, 248, 252].

1. Calcolo dell'I.F. al 95% [cite: 249]: Prima verifichiamo la condizione del TCL: $n\bar{X}_n(1-\bar{X}_n) = 1000 \cdot 0.05 \cdot 0.95 = 47.5 \geq 10$ [cite: 254, 256].


$$I = \left[0.05 \pm \sqrt{\frac{0.05 \cdot 0.95}{1000}} \cdot 1.96 \right] = [0.05 \pm 0.0135]$$

[cite: 257]

2. Dimensionamento per errore $d \leq 0.003$ [cite: 258, 259]:


• I Modo (Conservativo): Massimizzando $x(1-x)$ a $1/4$, si ottiene $\frac{1}{2\sqrt{n}} \cdot 1.96 \leq 0.003 \Rightarrow n \geq 106711$ [cite: 260-263].

• II Modo (Con Info Preliminari): Sappiamo che $x \in [0.05 \pm 0.0135] = [0.0365, 0.0635]$. Il valore che massimizza $x(1-x)$ in questo range è l'estremo superiore, ovvero $x = 0.0635$. Calcoliamo $\max = 0.0635 \cdot (1 - 0.0635) = 0.0595$ [cite: 266-270]. Imponendo $\frac{1}{2\sqrt{n}} \cdot 1.96 \leq 0.003$, otteniamo $n \geq 25397$. Un notevole risparmio campionario [cite: 268, 271]!



Esercizio 7.6: Sondaggio Elettorale A vs B

Un sondaggio assegna il 53% al candidato A e il 47% al candidato B, con un margine di errore del 0.04 al livello del 95% [cite: 280-284]. Possiamo affermare con fiducia che A sarà eletto [cite: 285]? **Risposta: Falso** [cite: 286]. L'intervallo di fiducia per A è $[0.53 - 0.04, 0.53 + 0.04] = [0.49, 0.57]$ [cite: 287-290]. Poiché l'intervallo contiene valori < 0.50 , esiste la probabilità che A perda. Lo si evince chiaramente dal grafico delle sovrapposizioni:



Esercizio 7.5: Temperature Medie a Milano (t-Student)

Si considerano le temperature medie di $n = 6$ anni. Si rileva una media campionaria $\bar{x}_0 = 20.83$ e una deviazione standard campionaria $s_0 = 1.35$ [cite: 298-300]. La varianza della popolazione non è nota [cite: 302, 306].

1. Calcolo dell'I.F. al 95% [cite: 303, 304]: Usiamo la t-Student con $k = 6 - 1 = 5$ gradi di libertà. Il quantile è $t_{0.975,5} = 2.5706$ [cite: 308].

$$I = \left[20.83 \pm \frac{1.35}{\sqrt{6}} \cdot 2.5706 \right] = [20.83 \pm 1.42]$$

[cite: 309-314]

2. Dimensionamento complesso (con t-Student): Trovare n affinché la semipiezza sia ≤ 1 [cite: 315]. Imponiamo $\frac{s_0}{\sqrt{n}} \cdot t_{1-\alpha/2, n-1} \leq 1$ [cite: 316]. Questo calcolo è circolare poiché t dipende da n . Stimiamo $t_{1-\alpha/2, n-1}$ con $t_{1-\alpha/2, 5}$ poiché la funzione è decrescente in n [cite: 320, 321]. Risolviamo:

$$\frac{1.35}{\sqrt{n}} \cdot 2.5706 \leq 1 \Rightarrow \sqrt{n} \geq 1.35 \cdot 2.5706 = 3.47 \Rightarrow n \geq 12.04$$

Dunque $n \geq 13$ [cite: 322].