

Appunti di Introduzione alla Statistica Matematica



Indice

1	Introduzione: Le tre parti del corso	1
1.1	Definizioni Fondamentali ed Esempi	2
2	Frequenze e Rappresentazioni Grafiche	2
2.1	Caratteri Discreti e Diagramma a Barre	2
2.2	Caratteri Continui e Istogramma	3
2.3	Forme delle Distribuzioni e Relazione tra Indici	3
3	Indici Statistici	4
3.1	Indici di Centralità	4
3.2	Indici di Dispersione	4
4	Funzione di Ripartizione Empirica e Quantili	5
4.1	Funzione di Ripartizione Empirica (ECDF)	5
4.2	Percentili e Quantili	6
4.3	Boxplot e Outliers	6
5	Esercizi Svolti	8
6	Dati Multivariati	12
6.1	Lo Scatterplot (Grafico di Dispersione)	12
6.2	Covarianza e Correlazione	12
6.2.1	La Covarianza Campionaria ed Empirica	12
6.2.2	Il Coefficiente di Correlazione di Pearson (r)	13
6.3	La Retta di Regressione Lineare	13
6.3.1	Il Metodo dei Minimi Quadrati	13
6.3.2	Interpretazione della bontà dell'adattamento	14
6.4	Esempi Grafici di Correlazione	14
7	Probabilità e Indipendenza	15
7.1	Spazi di Probabilità e Definizioni	15
7.2	Dalla Logica alla Teoria degli Insiemi	15
7.3	Le Interpretazioni della Probabilità	15
7.4	Definizione Assiomatica di Kolmogorov	16
7.4.1	Proprietà della Probabilità (Dimostrate dagli Assiomi)	17
8	Modello Uniforme e Calcolo Combinatorio	17

9 Probabilità Condizionata e Alberi	18
9.1 Rappresentazione ad Albero	18
10 Probabilità Totale e Teorema di Bayes	19
10.1 Sistema di Alternative e Probabilità Totale	19
10.2 Teorema di Bayes	20
11 Eventi Indipendenti	20
11.1 Indipendenza per più di due eventi	21
11.2 Schema di Bernoulli	21
12 Variabili Aleatorie: Definizioni Fondamentali	22
13 Variabili Aleatorie Discrete e Funzioni di Massa	23
13.1 Interpretazione Frequentista	24
14 Variabili Aleatorie Discrete Notevoli	24
14.1 Schema di Bernoulli e V.A. Binomiale	24
14.2 V.A. Geometrica	25
14.3 V.A. di Poisson	26
15 Variabili Aleatorie con Densità (Continue)	26
16 V.A. con Densità Notevoli	27
16.1 Variabile Uniforme	27
16.2 Variabile Esponenziale	27
17 Funzione di Ripartizione (FdR) e Quantili	28
17.1 Quantili e Formula di Cambio Variabile	29
18 Variabili Gaussiane (Normali)	29
18.1 Gaussiana Generale	30

1 Introduzione: Le tre parti del corso

Il corso si divide concettualmente in tre rami fondamentali, che rispondono a domande diverse:

1. **Statistica Descrittiva:** Analisi dei dati del campione, senza trarne conclusioni sull'intera popolazione. *Esempio:* Calcolare l'altezza media sul campione di 10 italiani.
2. **Probabilità:** Data la distribuzione teorica della popolazione, si calcola la probabilità di ottenere un certo campione. *Esempio:* Data una moneta con probabilità di testa p , su 10 lanci qual è la probabilità di ottenere 3 teste?
3. **Statistica Inferenziale:** Dato un campione, si ricavano informazioni (inferenze) sulla popolazione. *Esempio:* Se otteniamo 3 teste su 10 lanci, che cosa possiamo dire della probabilità reale p della moneta?

1.1 Definizioni Fondamentali ed Esempi

- **Popolazione:** L'insieme completo degli oggetti da studiare.
 - *Popolazione reale:* Popolazione italiana, le 10 biglie in un'urna.
 - *Popolazione ideale:* Tutti i possibili esiti di un esperimento fisico, tutti i possibili esiti del lancio di una moneta.
- **Campione statistico (Sample):** Un sottoinsieme della popolazione, "scelto per rappresentarla". La sua dimensione è la *taglia n*. *Esempi:* 10 italiani, 3 biglie, 5 lanci di moneta.
- **Carattere:** La caratteristica degli individui della popolazione, ottenuta con la stessa procedura di misura. Può essere:
 - *Quantitativo:* Le modalità sono numeri paragonabili tra loro. *Esempio:* L'altezza.
 - *Qualitativo:* Le modalità non sono numeri paragonabili. *Esempi:* Il colore di una biglia, il nome di una persona, testa/croce.
- **Modalità:** I possibili valori che il carattere può assumere. *Esempi:* Altezza (numeri reali positivi), Colore (rosso, blu, giallo), Moneta (testa/croce).
- **Dati:** Gli esiti effettivi delle misure del carattere sul campione. *Esempi:* Altezze dei 10 italiani (1.72, 1.68, 1.63...), Lanci (T, C, T, T, C).

2 Frequenze e Rappresentazioni Grafiche

Dato un possibile esito della misura (modalità a), definiamo:

- **Frequenza assoluta:** Il numero di volte in cui la modalità a compare nei dati.
- **Frequenza relativa:** La frazione di volte in cui la modalità a compare nei dati. Si indica con $p(a)$:

$$p(a) = \frac{\text{frequenza assoluta di } a}{n} \quad (1)$$

Esempio pratico: Consideriamo 10 lanci di un dado con i seguenti dati: 6, 2, 3, 1, 2, 5, 6, 5, 5, 1.

- Frequenza assoluta di "1" = 2. Frequenza assoluta di "4" = 0.
- Frequenza relativa di "1" = $\frac{2}{10} = 0.2 = 20\%$.

La collezione delle frequenze relative definisce la **distribuzione del campione**.

2.1 Caratteri Discreti e Diagramma a Barre

Per un carattere discreto (quantità finita e non troppo grande di modalità, ben separate, es. esiti del dado o risposte a un sondaggio), si usa il **diagramma a barre**. Consiste in barre verticali con altezza proporzionale alla frequenza relativa. *Nota bene:* Le frequenze (e la loro rappresentazione) dipendono dal campione e non coincidono in generale con quelle dell'intera popolazione.




Figura 1: Diagramma a barre per i dati del dado: 6, 2, 3, 1, 2, 5, 6, 5, 5, 1. L'etichetta sopra le barre indica la frazione (frequenza relativa).

2.2 Caratteri Continui e Istogramma

Per un carattere continuo (es. altezza, temperatura in Kelvin), che può assumere un grande numero di modalità in un intervallo, la frequenza relativa della singola modalità è troppo bassa. Si raggruppano i dati in intervalli e si usa l'**istogramma**.

Nell'istogramma, è l'*area* (non l'altezza) a rappresentare la frequenza relativa. L'altezza rappresenta la densità di frequenza:

$$\text{Densità di freq.} = \frac{\text{Frequenza relativa}}{\text{Ampiezza dell'intervallo}} \quad (2)$$

L'utilizzo dell'area è fondamentale quando gli intervalli hanno ampiezza diversa. Il professore fa notare che bisogna fare attenzione a *"come scegliere gli intervalli dell'istogramma (non troppi e non troppo pochi)"*.

Altezza	Freq. Assoluta	Freq. Relativa	Densità di frequenza
1.55 - 1.58	10	10/200	$(10/200) \cdot (1/0.03)$
1.58 - 1.61	25	25/200	$(25/200) \cdot (1/0.03)$
1.61 - 1.64	35	35/200	$(35/200) \cdot (1/0.03)$

Tabella 1: Esempio di calcolo della densità per l'istogramma (200 individui).

2.3 Forme delle Distribuzioni e Relazione tra Indici

Osservando l'istogramma o il diagramma a barre, si possono identificare diverse forme tipiche:

- **Normale:** Simile a una campana simmetrica. In questo caso $Media = Mediana = Moda$.

- **Unimodale / Bimodale:** Si concentra attorno a una o due colonne più alte. Nel caso simmetrico bimodale, $Media = Mediana$, ma differiscono dalle due mode.
- **Asimmetrica (Skewed) a destra/sinistra:**
 - *Asimmetrica a destra (caso standard):* I dati si allungano verso destra. Generalmente si ha $Moda < Mediana < Media$. Ad esempio, con frequenze $1(2/20), 2(7/20), 3(4/20), 4(3/20), 5(2/20), 6(2/20)$, abbiamo $Moda=2$, $Mediana=3$, $Media=3.3$.
 - *Attenzione - Esempio controintuitivo:* Non vale per *tutti* i casi unimodali asimmetrici a destra. Se i dati sono $1(20/100), 2(25/100), 3(40/100), 4(11/100), 5(1/100), 6(1/100)$ la forma ha coda a destra, ma si ottiene $Moda=3$, $Mediana=3$, $Media=2.74$ ($Media < Moda$).

3 Indici Statistici

3.1 Indici di Centralità

Indicano il "centro" della distribuzione.

- **Media campionaria ($\bar{x}$):** Media aritmetica dei dati.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \sum_{j=1}^M a_j p(a_j) \quad (3)$$

Esempio redditi (in migliaia di €): 25, 32, 41, 19, 47, 35, 51, 32, 29, 500. La media è $\bar{x} = 81.1$. **Nota del prof:** La media è molto sensibile ai valori estremi (outliers).

- **Mediana campionaria:** Ordinando i dati in senso crescente, è il valore centrale.
 - Se n dispari: dato in posizione $\frac{n+1}{2}$.
 - Se n pari: media dei due dati centrali $\frac{1}{2} \left(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)} \right)$.

Esempio redditi ordinati: 19, 25, 29, 32, **32, 35**, 41, 47, 51, 500. $Mediana = (32 + 35)/2 = 33.5$. **Nota del prof:** La mediana "non vede le modalità del gruppo più grande", è molto più robusta.

- **Media sfrondata (Trimmed mean):** Ottenuta togliendo una frazione q dei dati più grandi e più piccoli, calcolando la media sui rimanenti. *Esempio del prof:* La "media olimpica" (si tolgono i voti più alti e più bassi) o il "prezzo giusto in appalti".

3.2 Indici di Dispersione

Indicano quanto i dati sono dispersi attorno al valore centrale. *Esempio del prof:* I dati $X = (1, 2, 3)$ e i dati $Y = (-10, 2, 14)$ hanno entrambi media 2, ma Y è visibilmente molto più disperso.

- **Varianza campionaria ($Var(x)$):**

$$Var(x) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (4)$$

- **Varianza empirica** ($Var_e(x)$): Media esatta degli scarti quadratici.

$$Var_e(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \left(\frac{1}{n} \sum_{i=1}^n x_i^2 \right) - \bar{x}^2 \quad (5)$$

Relazione fondamentale: $Var(x) = \frac{n}{n-1} Var_e(x)$. La varianza è zero se e solo se tutti i dati x_i sono uguali.

Esempio di calcolo varianza (dati dato di prima):

$$Var_e(x) = \frac{1}{10} (1^2 \cdot 2 + 2^2 \cdot 2 + 3^2 \cdot 1 + 4^2 \cdot 0 + 5^2 \cdot 3 + 6^2 \cdot 2) - 3.6^2 \approx 3.64.$$

$$\text{Quindi } Var(x) = \frac{10}{9} \cdot 3.64 \approx 4.04.$$

- **Scarto quadratico medio (Deviazione standard):** $\sigma(x) = \sqrt{Var(x)}$. Ha il vantaggio di mantenere la stessa unità di misura dei dati originali.

4 Funzione di Ripartizione Empirica e Quantili

4.1 Funzione di Ripartizione Empirica (ECDF)

La funzione di ripartizione empirica $F_e(t)$ è definita come la frequenza relativa dei dati che sono $\leq t$. Per disegnarla o calcolarla:

1. Si ordinano i dati $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$.
2. Per $t < x_{(1)}$, $F_e(t) = 0$.
3. La funzione fa un salto verso l'alto pari a $1/n$ in corrispondenza di ogni dato (o $2/n$, $3/n$ se ci sono più dati uguali).
4. Per $t \geq x_{(n)}$, la funzione rimane fissa a 1.




Figura 2: Esempio di Funzione di Ripartizione Empirica (a gradini). I salti avvengono in corrispondenza dei dati.

4.2 Percentili e Quantili

Motivazione introdotta a lezione: "Qual è la ricchezza minima del 5% più ricco della popolazione?" Si tratta di trovare il dato x_i tale per cui il 5% dei dati sia $\geq x_i$, ovvero (moralmente) il dato per cui $F_e(x_i) = 0.95$.

Dato un parametro $\beta = k/100$, il **k -esimo percentile** (o β -quantile) si calcola valutando il prodotto βn :

1. Se βn non è intero, il quantile è il dato in posizione arrotondata per eccesso (il più piccolo intero $> \beta n$).
2. Se βn è intero, per convenzione si prende la media aritmetica tra i dati in posizione βn e $\beta n + 1$: $\frac{x_{(\beta n)} + x_{(\beta n + 1)}}{2}$.

Esempio (Stazione Manhattan delle dispense): $n = 36$. Cerchiamo Q_1 (25° percentile, $\beta = 1/4$).

$$n \cdot \beta = 36 \cdot \frac{1}{4} = 9 \text{ (numero intero).}$$

$$Q_1 = \frac{x_{(9)} + x_{(10)}}{2} = \frac{75 + 77}{2} = 76.$$

4.3 Boxplot e Outliers

Il **Boxplot** si disegna tracciando:

- Una linea dal minimo al massimo dei dati (esclusi gli outliers).
- Un rettangolo che va dal Primo Quartile (Q_1) al Terzo Quartile (Q_3). Il suo range è detto "scarto interquartile" ($L = Q_3 - Q_1$) e contiene il 50% centrale dei dati.
- Una linea divisoria in corrispondenza del Secondo Quartile (Q_2 o Mediana).

Outlier (valore anomalo): Valore che differisce in modo significativo dalla "grande maggioranza" dei dati. *Perché troviamo outlier?*

- Errori di misurazione (es. redditi con un valore inserito come 10^9 per sbaglio).
- Dati reali ma molto rari.
- La distribuzione della popolazione ha fisiologicamente una "coda" di dati molto distanti dagli altri.

Gli outlier influenzano pesantemente indici come la media e la varianza. Non esiste una regola assoluta per individuarli, ma una *regola empirica* diffusa considera outlier i dati al di fuori dell'intervallo:

$$[Q_1 - 1.5L, Q_3 + 1.5L] \tag{6}$$




Figura 3: Esempio di Boxplot con i baffi, la scatola interquartile ($Q_1 - Q_3$), la mediana (Q_2) e due possibili outliers (i punti estremi a 5 e 95).

5 Esercizi Svolti

Esercizio 1.1 - Analisi terremoti in Italia

Testo: Classificare i dati (7, 4, 0, 2, 1, 3, 3, 3, 1, 1, 1, 3) e disegnare il grafico corrispondente.

Svolgimento: I dati rappresentano il "numero di terremoti" in un mese, quindi si tratta di una variabile che può assumere solo valori interi non negativi. Sono pertanto **dati discreti**. La rappresentazione corretta è un diagramma a barre.

Raggruppiamo i dati in una tabella di frequenze (dimensione totale $n = 12$):

N. terremoti (x_i)	Freq. Assoluta	Freq. Relativa ($p(x_i)$)
0	1	$1/12 \approx 0.083$
1	4	$4/12 \approx 0.333$
2	1	$1/12 \approx 0.083$
3	4	$4/12 \approx 0.333$
4	1	$1/12 \approx 0.083$
7	1	$1/12 \approx 0.083$




Figura 4: Esercizio 1.1: Diagramma a barre del numero di terremoti.

Esercizio 1.2 - Tempi di esecuzione server

Testo: Classificare i 20 tempi di esecuzione forniti e disegnarne il grafico. Determinarne la forma.

Svolgimento: I dati misurano il tempo in secondi, per cui sono grandezze misurabili con infiniti decimali: si tratta di **dati continui**. Si deve usare l'**istogramma**. Per costruirlo, dividiamo i dati in classi di ampiezza 0.5 secondi: $[0, 0.5)$, $[0.5, 1.0)$, $[1.0, 1.5)$, $[1.5, 2.0)$, $[2.0, 2.5]$. Conteggiando i valori che cadono in ogni intervallo otteniamo le frequenze assolute: 8, 4, 3, 2, 3.




Figura 5: Esercizio 1.2: Istogramma dei tempi di esecuzione.

La distribuzione presenta un picco evidente tra 0 e 0.5 secondi e una lunga coda verso i valori più alti. È quindi classificabile come **unimodale asimmetrica a destra** (right-skewed).

Esercizio 1.4 - Indici e Boxplot per gli Es. 1.1 e 1.2

Svolgimento per l'Es. 1.1 (Terremoti):

- **Media:** $\bar{x} = \frac{0+(1 \times 4)+2+(3 \times 4)+4+7}{12} = \frac{29}{12} \approx 2.417$
- **Mediana:** Dati ordinati: 0, 1, 1, 1, 1, 2, 3, 3, 3, 3, 4, 7. $n = 12$ (pari). Media tra 6° e 7° valore: $\frac{2+3}{2} = 2.5$.
- **Varianza e Deviazione Standard:** Usiamo la formula empirica per velocità. $\frac{1}{12} \sum x_i^2 = \frac{0+4+4+36+16+49}{12} = \frac{109}{12} \approx 9.083$. $Var_e = 9.083 - (2.417)^2 \approx 3.243$. La varianza campionaria è $Var(x) = \frac{12}{11} \times 3.243 \approx 3.538$. Dev. Standard $\sigma = \sqrt{3.538} \approx 1.88$.
- **Quartili:** βn intero per Q_1 ($0.25 \times 12 = 3$) e Q_3 ($0.75 \times 12 = 9$). Q_1 è la media tra il 3° e 4° dato: $\frac{1+1}{2} = 1$. Q_3 tra il 9° e 10°: $\frac{3+3}{2} = 3$.
- **Outliers:** Scarto interquartile $L = 3 - 1 = 2$. Soglia superiore: $Q_3 + 1.5L = 3 + 3 = 6$. Il dato **7** è un outlier.

Svolgimento per l'Es. 1.2 (Server):

- **Media:** $\bar{x} = \frac{17.88}{20} = 0.894$
- **Mediana:** $n = 20$ (pari). Media tra 10° e 11° valore ordinato (0.56 e 0.61): 0.585.
- **Deviazione Standard:** La somma dei quadrati è $\sum x_i^2 = 25.109$. La varianza campionaria è $Var(x) = \frac{1}{19}(25.109 - 20 \times 0.894^2) \approx 0.480$. Dev. Standard $\sigma \approx 0.693$.

- **Quartili e Outliers:** $Q_1 = \frac{0.38+0.39}{2} = 0.385$, $Q_3 = \frac{1.17+1.60}{2} = 1.385$. $L = 1$. Il limite superiore è $1.385 + 1.5 = 2.885$. Il massimo è 2.42, quindi **non ci sono outliers**.




Figura 6: Esercizio 1.4: Boxplot a confronto per i due dataset.

Esercizio 1.5 - Unione di gruppi

Testo: Calcolare media e varianza empirica dell'intero campione (30 persone) sapendo che: Gruppo Laureati ($n_1 = 10$): $\bar{x}_1 = 30$, $\sigma_{e1} = 4$. Gruppo Non Laureati ($n_2 = 20$): $\bar{x}_2 = 25$, $\sigma_{e2} = 3$.

Svolgimento: La media totale è la media pesata dei due gruppi:

$$\bar{x} = \frac{n_1\bar{x}_1 + n_2\bar{x}_2}{n_1 + n_2} = \frac{10(30) + 20(25)}{30} = \frac{800}{30} \approx 26.67 \text{ mila euro}$$

Per la varianza empirica dell'intero gruppo, usiamo la formula $Var_e(x) = \left(\frac{1}{n} \sum x_i^2\right) - \bar{x}^2$. Dobbiamo prima ricavare la somma dei quadrati ($\sum x_i^2$) per i due gruppi isolati. Dal momento che $Var_e = \sigma_e^2$, abbiamo:

$$\text{Gruppo 1: } 16 = \frac{1}{10} \sum_{G1} x_i^2 - 30^2 \implies \sum_{G1} x_i^2 = 10(16 + 900) = 9160$$

$$\text{Gruppo 2: } 9 = \frac{1}{20} \sum_{G2} x_i^2 - 25^2 \implies \sum_{G2} x_i^2 = 20(9 + 625) = 12680$$

La somma totale dei quadrati è $9160 + 12680 = 21840$. Calcoliamo infine la varianza empirica totale:

$$Var_e(Totale) = \frac{21840}{30} - (26.67)^2 = 728 - 711.11 = 16.89 \text{ (mila euro)}^2$$

Esercizio 1.6 - Confronto concentrazione endotossine

Testo (sintesi): Confrontare indici di dispersione per campioni di case Urbane (U) e Rurali (F). r **Svolgimento (Punti A e B):**

- **Case Urbane (U):** $n = 11$. Dati ordinati: 4, 5, 5, 6, 11, 17, 18, 23, 33, 35, 80.
 - Media: $\bar{x} = 21.55$.
 - Dev. Standard campionaria (σ): 23.00.
 - Quartili: $Q_1 = 5$, $Q_3 = 33$. Scarto Interquartile $L = 28$.
- **Case Rurali (F):** $n = 15$. Dati ordinati: 0.3, 2, 3, 4, 4, 5, 8, 8.9, 9, 9, 9.2, 11, 14, 20, 21.
 - Media: $\bar{x} = 8.56$.
 - Dev. Standard campionaria (σ): 6.52.
 - Quartili: $Q_1 = 4$, $Q_3 = 11$. Scarto Interquartile $L = 7$.

Confronto: Il campione delle case Urbane è enormemente più variabile di quello Rurale (sia la σ sia il range interquartile sono molto più grandi). Da notare che per le case urbane la presenza dell'outlier estremo 80 gonfia molto la σ (23.0), ma l'IQR (28) restituisce un'informazione di alta dispersione perfettamente coerente.

Punto C - Boxplot Comparativo: Include anche i dati dalle borse aspirapolvere. (Valori calcolati dai dati forniti nel testo: Aspirapolvere U ha un IQR di 15 e un outlier a 1 e 104. Aspirapolvere F ha un IQR di 21 e un outlier a 64).




Figura 7: Esercizio 1.6: Boxplot comparativo dei 4 campioni.

6 Dati Multivariati

In questo capitolo estendiamo l'analisi statistica a situazioni in cui su ogni unità della popolazione vengono misurati simultaneamente due caratteri quantitativi. L'obiettivo non è più solo descrivere le singole variabili, ma investigare l'esistenza di **relazioni** o **dipendenze** tra di esse. Ci limiteremo all'analisi di coppie di dati, definiti **dati bivariati**.

Consideriamo un campione di n individui. I dati si presentano come un insieme di coppie ordinate:

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n) \quad (7)$$

dove (x_i, y_i) rappresenta il valore dei due caratteri (ad esempio x = tasso di fertilità, y = reddito) rilevato sull' i -esimo elemento.

6.1 Lo Scatterplot (Grafico di Dispersione)

Il primo passo nell'analisi bivariata è la visualizzazione grafica tramite lo **scatterplot**. In questo grafico, ogni coppia (x_i, y_i) è un punto sul piano cartesiano.

La disposizione dei punti permette di identificare tre scenari principali:

- **Assenza di relazione:** I punti sono sparsi uniformemente senza una direzione precisa.
- **Relazione lineare:** I punti tendono a disporsi lungo una linea retta. È il caso più semplice e comune studiato nella statistica descrittiva.
- **Relazione non lineare:** I punti seguono un andamento curvilineo (es. parabolico, esponenziale o logaritmico).

6.2 Covarianza e Correlazione

Per misurare numericamente la forza e la direzione della relazione lineare, introduciamo due indici fondamentali.

6.2.1 La Covarianza Campionaria ed Empirica

La covarianza misura come le due variabili "variano insieme".

$$Cov(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (\text{Campionaria}) \quad (8)$$

$$Cov_e(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (\text{Empirica}) \quad (9)$$

Passaggi per la formula calcolatoria: Per facilitare il calcolo, sviluppiamo il prodotto nella sommatoria della covarianza empirica:

$$\begin{aligned}
 Cov_e(x, y) &= \frac{1}{n} \sum_{i=1}^n (x_i y_i - x_i \bar{y} - \bar{x} y_i + \bar{x} \bar{y}) \\
 &= \frac{1}{n} \sum x_i y_i - \frac{1}{n} \sum x_i \bar{y} - \frac{1}{n} \sum \bar{x} y_i + \frac{1}{n} \sum \bar{x} \bar{y} \\
 &= \frac{1}{n} \sum x_i y_i - \bar{y} \left(\frac{1}{n} \sum x_i \right) - \bar{x} \left(\frac{1}{n} \sum y_i \right) + \bar{x} \bar{y} \\
 &= \left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \bar{x} \bar{y} - \bar{x} \bar{y} + \bar{x} \bar{y} = \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{y}_i \right) - \bar{\mathbf{x}} \bar{\mathbf{y}}
 \end{aligned}$$

6.2.2 Il Coefficiente di Correlazione di Pearson (r)

La covarianza ha un limite: dipende dall'unità di misura dei dati. Dividendo la covarianza per il prodotto delle deviazioni standard, otteniamo un numero puro (adimensionale) $r \in [-1, 1]$:

$$r(x, y) = \frac{Cov(x, y)}{\sigma(x)\sigma(y)} \quad (10)$$

6.3 La Retta di Regressione Lineare

Il problema della regressione consiste nel trovare la curva che approssima meglio i dati. Nel caso lineare, cerchiamo la retta $y = a + bx$ che minimizza l'errore commesso.

6.3.1 Il Metodo dei Minimi Quadrati

Vogliamo minimizzare la somma degli scarti quadratici tra i valori osservati y_i e quelli predetti dalla retta ($a + bx_i$):

$$\min_{a,b} Q(a, b) = \frac{1}{n} \sum_{i=1}^n (y_i - a - bx_i)^2 \quad (11)$$

Derivazione dei parametri ottimali (a^*, b^*): Annullando le derivate parziali di Q rispetto ad a e b , otteniamo il sistema delle *equazioni normali*:

$$\begin{cases} \sum y_i - na - b \sum x_i = 0 \\ \sum x_i y_i - a \sum x_i - b \sum x_i^2 = 0 \end{cases}$$

Dividendo per n e risolvendo per a :

$$\bar{y} - a - b\bar{x} = 0 \implies \mathbf{a}^* = \bar{\mathbf{y}} - \mathbf{b}^* \bar{\mathbf{x}} \quad (12)$$

Sostituendo a nella seconda equazione si ottiene il coefficiente angolare:

$$\mathbf{b}^* = \frac{\mathbf{Cov}_e(\mathbf{x}, \mathbf{y})}{\mathbf{Var}_e(\mathbf{x})} = \frac{\mathbf{Cov}(\mathbf{x}, \mathbf{y})}{\mathbf{Var}(\mathbf{x})} \quad (13)$$

6.3.2 Interpretazione della bontà dell'adattamento


L'errore minimo (residuo) è la parte di variabilità di y che la retta non riesce a spiegare:

$$\text{Errore Residuo} = \text{Var}_e(y) \cdot (1 - r^2) \quad (14)$$


- Se $r^2 = 1$ ($r = \pm 1$): L'errore è nullo. I punti sono perfettamente allineati sulla retta.
- Se r^2 è vicino a 1: L'approssimazione è ottima.
- Se $r \approx 0$: Non esiste una relazione *lineare*.

6.4 Esempi Grafici di Correlazione


Correlazione Positiva ($r \approx 0.7$)




Correlazione Negativa ($r \approx -0.9$)



Dati Scorrelati ($r \approx 0$)




Dipendenza Non Lineare ($r \approx 0$)



Nota importante per l'esame: Se $r \approx 0$, i dati sono detti **scorrelati**. Tuttavia, l'ultimo grafico mostra che $r = 0$ non implica indipendenza: i punti seguono una parabola perfetta ($y = x^2$), quindi c'è una relazione deterministica forte, ma siccome non è una retta, il coefficiente di correlazione lineare non riesce a rilevarla.

Relazione quadratica ($r = 0$ ma forte dipendenza)



7 Probabilità e Indipendenza

7.1 Spazi di Probabilità e Definizioni

La teoria della probabilità procede in direzione inversa rispetto alla statistica descrittiva: dato un esperimento di cui è nota la distribuzione teorica (modello) degli esiti, vogliamo dedurre informazioni sulle probabilità che si verifichino determinati eventi.

Definiamo i concetti fondamentali:

- **Esperimento aleatorio:** Un fenomeno (fisico, biologico, sociale, ecc.) il cui esito non è determinato con certezza a priori. *Esempi:* estrazione di una biglia da un'urna, tempo di esecuzione di un task da un server, lancio di un dado.
- **Spazio campionario (Ω):** L'insieme di tutti i possibili esiti (modalità) dell'esperimento.
- **Eventi ($A, B, \dots$):** Sottoinsiemi dello spazio campionario (Ω). Rappresentano *affermazioni* sull'esito dell'esperimento.
- **Eventi elementari:** I singoli esiti dell'esperimento ($\omega \in \Omega$). Costituiscono i mattoni base dello spazio campionario.
- **Evento certo:** L'intero spazio campionario Ω (accade sicuramente qualcosa).
- **Evento impossibile:** L'insieme vuoto $\emptyset$ (nessun esito si realizza).

Esempio pratico (Lancio di un dado): Lo spazio campionario è $\Omega = \{1, 2, 3, 4, 5, 6\}$. L'affermazione "esce un numero pari" corrisponde all'evento (sottoinsieme) $A = \{2, 4, 6\}$. L'evento elementare "esce 2" è $\{\omega\} = \{2\}$.

7.2 Dalla Logica alla Teoria degli Insiemi

Poiché gli eventi sono sottoinsiemi di Ω , le operazioni logiche tra le affermazioni si traducono in operazioni insiemistiche.

7.3 Le Interpretazioni della Probabilità

Vogliamo associare a ogni evento $A \subseteq \Omega$ un valore $\mathbb{P}(A) \in [0, 1]$ che esprima il grado di fiducia che l'evento si realizzi, dove 0 indica l'evento impossibile e 1 l'evento certo.

Operazione Logica	Operazione Insiemistica	Esempio (Dado: $A = \{2, 4, 6\}$, $B = \{4, 5, 6\}$)
Accade A oppure B	Unione: $A \cup B$	Pari o ≥ 4 : $\{2, 4, 5, 6\}$
Accadono A e B	Intersezione: $A \cap B$	Pari e ≥ 4 : $\{4, 6\}$
Non accade A	Complementare: $A^c = \Omega \setminus A$	Dispari: $\{1, 3, 5\}$
Accade A ma non B	Differenza: $A \setminus B = A \cap B^c$	Pari ma non ≥ 4 : $\{2\}$
Relazioni Logiche	Relazioni Insiemistiche	
Se accade A , allora accade B	Sottoinsieme: $A \subseteq B$	Se "esce 2" ($\{2\}$), allora "è pari" ($\{2, 4, 6\}$)
Non possono accadere ass.	Disgiunti (Incomp.): $A \cap B = \emptyset$	Gli eventi non si sovrappongono. Es: $A = \{3\}$, $B = \{2, 4, 6\}$

Tabella 2: Corrispondenza tra operazioni logiche e insiemistiche.

1. Definizione Classica (Laplace):

$$\mathbb{P}(A) = \frac{\# \text{ casi favorevoli di } A}{\# \text{ casi possibili totali}} = \frac{\#A}{\#\Omega}$$

Pro e Contro: È perfetta per estrazioni da popolazioni reali finite (dadi, urne, monete equilibrate), ma richiede che tutti gli eventi elementari siano *equiprobabili*. Non è adatta per fenomeni fisici o per spazi infiniti.

2. Definizione Frequentista:

$$\mathbb{P}(A) = \lim_{n \rightarrow \infty} \left(\frac{\text{frequenza assoluta di } A}{n} \right)$$

La probabilità è il limite della frequenza relativa in n prove ripetute dell'esperimento.

Esempio (Lancio di moneta): Se faccio 1000 lanci e ottengo 529 teste ($f_{rel} = 0.529$) e in altri 1000 lanci ottengo 493 teste, la frequenza totale si assesta su $(529 + 493)/2000 = 0.511$. Al tendere all'infinito delle prove dovrei raggiungere esattamente il 50%.

Pro e Contro: Adatta per popolazioni ideali e fenomeni empirici. Tuttavia, non sempre è possibile effettuare infinite prove, e matematicamente non è garantito che il limite esista in senso stretto.

3. Definizione Soggettivista (De Finetti):

$\mathbb{P}(A)$ è definita come il grado di fiducia attribuito all'evento da un soggetto perfettamente razionale, in base alle informazioni a sua disposizione.

7.4 Definizione Assiomatica di Kolmogorov

Per superare i limiti delle definizioni precedenti, si usa un insieme di assiomi formali che definiscono in astratto una misura di probabilità. Dato uno spazio campionario Ω , una misura di probabilità $\mathbb{P} : \mathcal{P}(\Omega) \rightarrow \mathbb{R}$ deve soddisfare tre postulati:

1. **Positività:** $0 \leq \mathbb{P}(A) \leq 1 \quad \forall A \subseteq \Omega$.

2. **Certezza:** $\mathbb{P}(\Omega) = 1$.

3. **Additività:** Se $A_1, A_2, \dots, A_n$ è una successione di eventi *incompatibili* a due a due ($A_i \cap A_j = \emptyset$ per ogni $i \neq j$), allora:

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n \mathbb{P}(A_i) \quad (15)$$

(Questo vale anche per unioni infinite contabili, prendendo il limite per $n \rightarrow \infty$).

La coppia $(\Omega, \mathbb{P})$ costituisce uno **Spazio di Probabilità**.

7.4.1 Proprietà della Probabilità (Dimostrate dagli Assiomi)

Dagli assiomi discendono le regole classiche del calcolo delle probabilità.

- **Probabilità del Complementare:** $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$. In particolare, $\mathbb{P}(\emptyset) = 0$.

Dimostrazione: A e A^c sono disgiunti ($A \cap A^c = \emptyset$) e la loro unione è Ω ($A \cup A^c = \Omega$). Per l'assioma 2 e 3: $\mathbb{P}(A \cup A^c) = \mathbb{P}(A) + \mathbb{P}(A^c) = \mathbb{P}(\Omega) = 1$. Spostando un termine otteniamo la tesi.

- **Monotonia e Differenza:** Se $B \subseteq A$, allora $\mathbb{P}(A \setminus B) = \mathbb{P}(A) - \mathbb{P}(B)$. (Ne consegue che $\mathbb{P}(A) \geq \mathbb{P}(B)$).

Dimostrazione: Possiamo scrivere A come l'unione disgiunta $A = B \cup (A \setminus B)$. Per l'assioma dell'additività: $\mathbb{P}(A) = \mathbb{P}(B) + \mathbb{P}(A \setminus B)$. Isolando la differenza si ottiene la formula.

- **Probabilità dell'Unione di eventi generici:**

$$\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \quad (16)$$

Dimostrazione: $A \cup B$ può essere scomposto in tre parti a due a due disgiunte: $(A \setminus B) \cup (A \cap B) \cup (B \setminus A)$. Sommando le probabilità: $\mathbb{P}(A \cup B) = \mathbb{P}(A \setminus B) + \mathbb{P}(A \cap B) + \mathbb{P}(B \setminus A)$. Sappiamo (per la proprietà precedente) che $\mathbb{P}(A \setminus B) = \mathbb{P}(A) - \mathbb{P}(A \cap B)$ e $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A \cap B)$. Sostituendo nella somma e semplificando si ottiene la tesi.

Se gli eventi generici da unire sono più di due, si usa la **Formula di Inclusione-Esclusione**:

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n (-1)^{k+1} \sum_{1 \leq i_1 < \dots < i_k \leq n} \mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k}) \quad (17)$$

8 Modello Uniforme e Calcolo Combinatorio

Un **Modello Uniforme** è uno spazio di probabilità $(\Omega, \mathbb{P})$ tale per cui l'insieme Ω è finito e ogni esito elementare ω è equiprobabile. La probabilità del singolo esito è $\mathbb{P}(\{\omega\}) = 1/\#\Omega$. In questo caso si usa la definizione classica di Laplace: $\mathbb{P}(A) = \frac{\#A}{\#\Omega}$.

La **Combinatoria** permette di contare il numero di elementi degli insiemi. Dati n oggetti distinti, il numero di modi per estrarne k è dato da:

- **Disposizioni con ripetizione** (L'ordine conta, c'è rimpiazzo): n^k . (Es. lanci multipli di monete/dadi).
- **Disposizioni semplici** (L'ordine conta, niente rimpiazzo): $\frac{n!}{(n-k)!}$.
- **Permutazioni** (Ordinare n elementi, $k = n$): $n!$.
- **Combinazioni semplici** (L'ordine NON conta, niente rimpiazzo): **Coefficiente Binomiale** $\binom{n}{k} = \frac{n!}{k!(n-k)!}$. (Es. estrazioni in blocco).

9 Probabilità Condizionata e Alberi

Motivazione: Quando si viene a conoscenza della realizzazione di un evento, la valutazione di probabilità degli altri eventi cambia. Se lanciamo un dado e *sappiamo* che è uscito un numero pari ($B = \{2, 4, 6\}$), qual è la probabilità che il numero sia ≥ 4 ($A = \{4, 5, 6\}$)? Lo spazio campionario si restringe a B . I casi favorevoli diventano l'intersezione $A \cap B = \{4, 6\}$. La nuova probabilità è $2/3$.

Definizione: Dato uno spazio di probabilità, sia B un evento *non trascurabile* ($\mathbb{P}(B) > 0$). La **Probabilità Condizionata** di A dato B è:

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \quad (18)$$

Nota bene: La funzione $\mathbb{P}(\cdot|B)$ è essa stessa una vera e propria misura di probabilità, e rispetta tutti gli assiomi di Kolmogorov. Attenzione a non confondere il simbolo del condizionamento ($|$) con quello della differenza degli insiemi ($\setminus$).

Da questa definizione deriva la **Regola dei Prodotti**:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A|B) \cdot \mathbb{P}(B) = \mathbb{P}(B|A) \cdot \mathbb{P}(A) \quad (19)$$

Questa regola può essere estesa al **condizionamento ripetuto** (o regola della catena per intersezioni multiple):

$$\mathbb{P}(A_1 \cap \dots \cap A_n) = \mathbb{P}(A_1)\mathbb{P}(A_2|A_1)\mathbb{P}(A_3|A_1 \cap A_2) \dots \mathbb{P}(A_n|A_1 \cap \dots \cap A_{n-1}) \quad (20)$$

9.1 Rappresentazione ad Albero

I diagrammi ad albero sono utili per modellizzare sequenze di sottoesperimenti. Ad ogni snodo (nodo) partono rami corrispondenti ai possibili esiti. Ad ogni ramo si associa la probabilità condizionata. La somma delle probabilità dei rami uscenti da un nodo deve fare 1.

Valgono due regole pratiche di calcolo:

1. **Regola della Catena:** $\mathbb{P}(\text{Ramo completo}) = \text{prodotto delle probabilità dei suoi sotorami}$.
2. **Regola della Fattorizzazione:** La probabilità di un evento è la somma delle probabilità di tutti i rami (distinti e disgiunti) che portano a quell'evento.

Esempio dell'Urna a Estrazioni Multiple: Abbiamo un'urna iniziale con 4 biglie Rosse (R) e 1 Blu (B). Estraiamo 1 biglia.

- Se è Blu (prob. $1/5$), l'esperimento finisce.

- Se è Rossa (prob. $4/5$), la teniamo fuori, ma aggiungiamo una nuova biglia misteriosa. Questa aggiunta sarà Rossa con probabilità $3/4$ o Blu con prob. $1/4$. Poi effettuiamo la 2° estrazione.




Figura 8: Diagramma ad albero per esperimenti sequenziali.

Per calcolare $\mathbb{P}(2^{\text{a}} \text{ estr.} = R)$, applichiamo le due regole viste:

$$\begin{aligned} \mathbb{P}(2^{\text{a}} = R) &= \mathbb{P}(1^{\text{a}} = R, \text{Agg.} = B, 2^{\text{a}} = R) + \mathbb{P}(1^{\text{a}} = R, \text{Agg.} = R, 2^{\text{a}} = R) \\ &= \left(\frac{4}{5} \cdot \frac{1}{4} \cdot \frac{3}{5} \right) + \left(\frac{4}{5} \cdot \frac{3}{4} \cdot \frac{4}{5} \right) = \frac{3}{25} + \frac{12}{25} = \frac{15}{25} = \frac{3}{5} \end{aligned}$$

10 Probabilità Totale e Teorema di Bayes

10.1 Sistema di Alternative e Probabilità Totale

Un **sistema di alternative** è una partizione dello spazio campionario Ω : una collezione di eventi $B_1, \dots, B_n$ tali che:

- Siano a due a due disgiunti ($B_i \cap B_j = \emptyset, \forall i \neq j$).
- La loro unione faccia tutto lo spazio ($\bigcup B_i = \Omega$).
- Nessuno sia trascurabile ($\mathbb{P}(B_i) > 0$).

Questo garantisce che durante l'esperimento accada *uno e uno solo* degli eventi B_i .

Formula della Probabilità Totale (o di fattorizzazione): Dato un evento $A \subseteq \Omega$ e un sistema di alternative $B_1, \dots, B_n$, si ha:

$$\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A \cap B_i) = \sum_{i=1}^n \mathbb{P}(A|B_i) \cdot \mathbb{P}(B_i) \quad (21)$$

10.2 Teorema di Bayes

Utile per "invertire il condizionamento". Noti gli effetti (es. esito del test, colore della pallina), si vuole dedurre la probabilità della causa (es. malattia, urna). Siano A e B non trascurabili:

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(A|B) \cdot \mathbb{P}(B)}{\mathbb{P}(A)} \quad (22)$$

Se $B_1, \dots, B_n$ è un sistema di alternative, applicando la Probabilità Totale al denominatore, la formula si espande in:

$$\mathbb{P}(B_i|A) = \frac{\mathbb{P}(A|B_i) \cdot \mathbb{P}(B_i)}{\sum_{j=1}^n \mathbb{P}(A|B_j) \cdot \mathbb{P}(B_j)} \quad (23)$$

Esempio 1: Scelta dell'urna Scegliamo a caso una tra due urne (probabilità $1/2$ ciascuna). L'urna 1 ha 5 palline Rosse e 5 Blu. L'urna 2 ha 8 palline Rosse e 2 Blu. Peschiamo una pallina ed è **Rossa**. Qual è la probabilità che abbiamo pescato dall'urna 1? Appliciamo Bayes ($\mathbb{P}(R|U_1) = 5/10 = 1/2$, $\mathbb{P}(R|U_2) = 8/10 = 4/5$):

$$\mathbb{P}(U_1|R) = \frac{\mathbb{P}(R|U_1)\mathbb{P}(U_1)}{\mathbb{P}(R)} = \frac{\frac{1}{2} \cdot \frac{1}{2}}{(\frac{1}{2} \cdot \frac{1}{2}) + (\frac{4}{5} \cdot \frac{1}{2})} = \frac{1/4}{1/4 + 4/10} = \frac{1/4}{13/20} = \frac{5}{13}$$

Esempio 2: Test Diagnostico Indice di sensibilità (probabilità test positivo se malato) = 0.99. Specificità (probabilità test negativo se sano) = 0.97. L'1% della popolazione è malata ($\mathbb{P}(m) = 0.01$). Se una persona risulta positiva (+), qual è la probabilità che sia malata? Denominatore (Prob. Totale di test positivo): $\mathbb{P}(+) = \mathbb{P}(+|m)\mathbb{P}(m) + \mathbb{P}(+|s)\mathbb{P}(s) = (0.99 \cdot 0.01) + (0.03 \cdot 0.99) = 0.0396$.

$$\mathbb{P}(m|+) = \frac{\mathbb{P}(+|m)\mathbb{P}(m)}{\mathbb{P}(+)} = \frac{0.0099}{0.0396} = \mathbf{0.25}$$

Nonostante la precisione elevata, la bassa incidenza della malattia fa sì che il 75% dei positivi siano falsi allarmi.

11 Eventi Indipendenti

L'indipendenza esprime formalmente il concetto per cui la conoscenza del verificarsi di un evento B non altera la probabilità di A . Ovvero $\mathbb{P}(A|B) = \mathbb{P}(A)$. Dalla definizione di probabilità condizionata deriva la formula simmetrica:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B) \quad (24)$$

Osservazioni chiave:

- 1. Indipendenza non è incompatibilità:** Due eventi disgiunti (incompatibili, $A \cap B = \emptyset$) **NON** sono indipendenti (a meno che uno dei due non sia trascurabile). Infatti, se so che è accaduto B , sono sicuro che A non accadrà: $\mathbb{P}(A|B) = 0 \neq \mathbb{P}(A)$. L'incompatibilità è un forte legame di dipendenza!
- 2. Casi degeneri:** Se $\mathbb{P}(A) = 0$ oppure $\mathbb{P}(A) = 1$, allora A è indipendente da *qualsiasi* altro evento.

3. **Complementari:** Se A e B sono indipendenti, lo sono anche le coppie (A^c, B) , (A, B^c) e (A^c, B^c) .
4. **Indipendenza non è Causalità:** Due eventi legati da una relazione fisica causa-effetto possono risultare probabilisticamente indipendenti (es. l'esito del 1° lancio del dado concorre fisicamente a formare la "Somma=7", ma l'evento "esce 3 al primo lancio" e l'evento "la somma è 7" sono matematicamente indipendenti, $\mathbb{P} = 1/6 \cdot 1/6 = 1/36$).

11.1 Indipendenza per più di due eventi

Per definire tre eventi A, B, C indipendenti, **NON basta** che lo siano a due a due. Devono soddisfare:

- Indipendenza pairwise: $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$, $\mathbb{P}(A \cap C) = \dots$, $\mathbb{P}(B \cap C) = \dots$
- Indipendenza globale: $\mathbb{P}(A \cap B \cap C) = \mathbb{P}(A)\mathbb{P}(B)\mathbb{P}(C)$

Controesempio a lezione: Tre lanci di moneta, ma il terzo è truccato per essere Testa se i primi due sono concordi, Croce altrimenti. Se prendiamo gli eventi "Testa al 1°", "Testa al 2°", "Testa al 3°", presi a coppie sono tutti indipendenti (prob. $1/4$). Ma globalmente, l'intersezione dei tre eventi vale $1/4 \neq 1/8$. Non sono globalmente indipendenti.

In generale, una famiglia di n eventi si dice **collettivamente indipendente** se la probabilità dell'intersezione di *qualsiasi* loro sottoinsieme è uguale al prodotto delle singole probabilità.

Le prove ripetute di uno stesso esperimento sotto le stesse condizioni garantiscono per costruzione l'indipendenza globale.

11.2 Schema di Bernoulli

Consideriamo n prove ripetute indipendenti di un esperimento con esito dicotomico: "Successo" (1) o "Insuccesso" (0). Sia p la probabilità di successo nella singola prova e $(1-p)$ l'insuccesso.

L'evento ottenere una specifica sequenza ordinata con k successi (es. $1, 1, 1, 0, 0 \dots$) ha probabilità $p^k \cdot (1-p)^{n-k}$. Se però ci interessa solo l'*avere esattamente k successi* senza curarci dell'ordine, dobbiamo moltiplicare per tutte le combinazioni possibili. Si ottiene la formula della **Distribuzione Binomiale**:

$$\mathbb{P}(k \text{ successi in } n \text{ prove}) = \binom{n}{k} p^k (1-p)^{n-k} \quad (25)$$

Esempio: Lancio di una moneta equilibrata 10 volte ($p = 1/2$). È più probabile ottenere 10 Croci oppure 6 Croci e 4 Teste?

- $\mathbb{P}(10 \text{ Croci}) = \binom{10}{0} (1/2)^0 (1/2)^{10} = \frac{1}{1024}$
- $\mathbb{P}(6 \text{ Croci e } 4 \text{ Teste}) = \binom{10}{4} (1/2)^4 (1/2)^6 = 210 \cdot \left(\frac{1}{2}\right)^{10} = \frac{210}{1024}$

Ottenere 6C e 4T è enormemente più probabile (ci sono 210 sequenze diverse che generano quel risultato, contro 1 sola sequenza per le 10 croci).

12 Variabili Aleatorie: Definizioni Fondamentali

Abbiamo un esperimento aleatorio di cui ci interessa solo una caratteristica (carattere) quantitativa degli esiti. Questa caratteristica è la **variabile aleatoria**, e la distribuzione di questa caratteristica è la sua **legge**.

Esempio: 2 lanci di moneta equilibrata

Lo spazio campionario è $\Omega = \{0, 1\} \times \{0, 1\}$, dove 0 rappresenta "Croce" e 1 rappresenta "Testa". La probabilità $\mathbb{P}$ è uniforme.

Definiamo il carattere X = numero di teste nei due lanci. I valori possibili sono $\{0, 1, 2\} \subseteq \mathbb{R}$. Formalmente, $X : \Omega \rightarrow \mathbb{R}$ mappa gli eventi in questo modo:

- $(0, 0) \mapsto 0$
- $(0, 1) \mapsto 1$ e $(1, 0) \mapsto 1$
- $(1, 1) \mapsto 2$

Le probabilità associate (la legge di X) saranno:

- $\mathbb{P}^X(\{0\}) = \mathbb{P}(X = 0) = \frac{1}{4}$
- $\mathbb{P}^X(\{1\}) = \mathbb{P}(X = 1) = \frac{2}{4} = \frac{1}{2}$
- $\mathbb{P}^X(\{2\}) = \mathbb{P}(X = 2) = \frac{1}{4}$

Definizione 12.1 (Variabile Aleatoria Reale). *Una Variabile Aleatoria (v.a. o random variable, r.v.) è una funzione $X : \Omega \rightarrow \mathbb{R}$ misurabile definita su uno spazio di probabilità $(\Omega, \mathbb{P})$.*

Definizione 12.2 (Legge o Distribuzione di X). *È la probabilità $\mathbb{P}^X$ definita su $\mathbb{R}$ (precisamente $\mathbb{P}^X : \mathcal{P}(\mathbb{R}) \rightarrow \mathbb{R}$) data da:*

$$\mathbb{P}^X(A) = \mathbb{P}(\{X \in A\}) \quad \text{per } A \subseteq \mathbb{R} \quad (26)$$

dove l'insieme $\{X \in A\}$ indica la controimmagine $X^{-1}(A) = \{\omega \in \Omega \mid X(\omega) \in A\}$.

Proprietà 12.1 (Commutatività delle operazioni insiemistiche). *La controimmagine X^{-1} "commuta" con le operazioni insiemistiche. Questo è fondamentale per tradurre condizioni su $\mathbb{R}$ in eventi in Ω :*

- $X^{-1}(A^c) = (X^{-1}(A))^c$
- $X^{-1}(A \cap B) = X^{-1}(A) \cap X^{-1}(B)$
- $X^{-1}(A \cup B) = X^{-1}(A) \cup X^{-1}(B)$

La legge $\mathbb{P}^X$ verifica tutti gli assiomi di Kolmogorov. Ad esempio, $\mathbb{P}^X([a, b]) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) \in [a, b]\})$.

Definizione 12.3 (Variabili Aleatorie Equidistribuite). *Due v.a. X e Y si dicono equidistribuite se hanno la stessa legge, cioè se $\mathbb{P}^X = \mathbb{P}^Y$.*

Esempio:

Prendendo le variabili X = numero di teste e Y = numero di croci in 2 lanci di moneta equilibrata, vediamo che entrambe assumono valori 0, 1, 2 con probabilità rispettive di $1/4$, $1/2$, $1/4$. Le variabili X e Y sono **equidistribuite ma non uguali** (sullo stesso esito (1, 0), $X = 1$ mentre $Y = 1$, ma su (1, 1), $X = 2$ e $Y = 0$).

Notazione: Si utilizzano lettere maiuscole ($X, Y, T, \dots$) per indicare le v.a., e lettere minuscole ($a, b, x, \dots$) per indicare le modalità (i possibili valori assunti).

13 Variabili Aleatorie Discrete e Funzioni di Massa

Definizione 13.1 (V.a. discreta). *Una v.a. X è discreta se assume un numero finito o numerabile di modalità (valori) $a_1, a_2, a_3, \dots$ ("valori ben separati").*

Esempi classici: numero di teste in n lanci (modalità $0, 1, \dots, n$); numero di richieste a un server (modalità $\mathbb{N} = \{0, 1, 2, \dots\}$).

Attenzione: a_i sono le possibili modalità.


Definizione 13.2 (Funzione di Massa / Densità discreta). *La funzione di massa $p_X : \{a_1, a_2, \dots\} \rightarrow \mathbb{R}$ di X (o della sua legge $\mathbb{P}^X$) è definita da:*

$$p_X(a_i) = \mathbb{P}(X = a_i) \quad (27)$$

Essa corrisponde intuitivamente alla frequenza relativa di a_i .

Si rappresenta graficamente tramite un **diagramma a barre**.

Diagramma a barre per 2 lanci di moneta



Il calcolo delle probabilità a partire da p_X si fa per semplice somma:

$$\mathbb{P}(X \in A) = \sum_{a \in A} p_X(a) \quad (28)$$

Ad esempio, $\mathbb{P}(X \leq 1) = \mathbb{P}(X = 0) + \mathbb{P}(X = 1) = 1 - \mathbb{P}(X = 2)$.

Proprietà 13.1 (Proprietà della Funzione di Massa). 1. $p_X(a_i) \geq 0 \quad \forall a_i$

2. $\sum_i p_X(a_i) = 1$ (infatti $\sum_i p_X(a_i) = \mathbb{P}(X \in \mathbb{R}) = 1$)

Proposizione:

Se una funzione $q : \{a_1, a_2, \dots\} \rightarrow \mathbb{R}$ soddisfa le proprietà (1) e (2), allora q è funzione di massa di una v.a. discreta X (cioè $q(a_i) = \mathbb{P}(X = a_i)$).

13.1 Interpretazione Frequentista

Consideriamo l'estrazione casuale di un individuo da una popolazione (probabilità uniforme) e la misurazione di un carattere discreto (es. numero di figli in Italia). In questo caso:

$$\mathbb{P}(X = a_i) = \frac{\#\{\text{individui con } X = a_i\}}{\#\text{popolazione}} \quad (29)$$

Quindi la probabilità $\mathbb{P}(X = 2)$ equivale alla frequenza relativa del carattere $X = 2$ su *tutta* la popolazione (non su un campione).

14 Variabili Aleatorie Discrete Notevoli

14.1 Schema di Bernoulli e V.A. Binomiale

Lo **Schema di Bernoulli** descrive n ripetizioni indipendenti di una prova, con esiti "successo" (1) avente probabilità $p \in [0, 1]$ e "insuccesso" (0) avente probabilità $1 - p$.

- Lancio di moneta: $p = \mathbb{P}(\text{Testa})$
- Lancio di dado equilibrato: successo = "esce 4", quindi $p = 1/6$

Lo spazio campionario è $\Omega = \{0, 1\}^n = \{(\omega_1, \dots, \omega_n) \mid \omega_i \in \{0, 1\}\}$. Poiché le prove sono indipendenti, la probabilità di una specifica sequenza è:

$$\mathbb{P}(\omega_1, \dots, \omega_n) = p^{\#\text{ successi}} \cdot (1 - p)^{\#\text{ insuccessi}} \quad (30)$$

Definizione 14.1 (Variabile Binomiale $X \sim B(n, p)$). X è il numero di successi in n prove di Bernoulli.

$$X(\omega_1, \dots, \omega_n) = \sum_{i=1}^n \omega_i \quad (31)$$

La funzione di massa, per $k = 0, 1, 2, \dots, n$, è:

$$p_X(k) = \mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k} \quad (32)$$

Dimostrazione: Esattamente k successi su n prove corrisponde alla somma delle probabilità di tutte le sequenze $(\omega_1, \dots, \omega_n)$ con k successi. Il numero di posizioni dei k indici dei successi è $\binom{n}{k}$, e ogni sequenza ha probabilità $p^k (1 - p)^{n-k}$.

Esempio:

In 5 lanci di dado, qual è la probabilità che "4" appaia almeno due volte?
Singola prova: lancio. Successo = "esce 4", quindi $p = 1/6$. Prove $n = 5$.

$X = \text{numero di "4"} \sim B(5, 1/6)$. Vogliamo calcolare $\mathbb{P}(X \geq 2)$.

$$\mathbb{P}(X \geq 2) = 1 - \mathbb{P}(X < 2) = 1 - \mathbb{P}(X = 0) - \mathbb{P}(X = 1) \quad (33)$$

$$\begin{aligned} \mathbb{P}(X \geq 2) &= 1 - \left[\binom{5}{0} \left(\frac{1}{6}\right)^0 \left(\frac{5}{6}\right)^5 + \binom{5}{1} \left(\frac{1}{6}\right)^1 \left(\frac{5}{6}\right)^4 \right] \\ &= 1 - 1 \cdot 1 \cdot \left(\frac{5}{6}\right)^5 - 5 \cdot \frac{1}{6} \cdot \left(\frac{5}{6}\right)^4 = 1 - 2 \left(\frac{5}{6}\right)^5 \end{aligned}$$

Intuizione:

I grafici a barre della Binomiale variano in base a p . Se $p < 1/2$ è asimmetrica a sinistra (picco prima di $n/2$). Se $p = 1/2$ è perfettamente simmetrica con picco in $np = n/2$. Se $p > 1/2$ è asimmetrica a destra. La "larghezza" della campana è proporzionale a $\sigma = \sqrt{np(1-p)}$.

14.2 V.A. Geometrica

Schema di Bernoulli con "infinite prove". Ci interessa determinare in quale prova avviene il **primo successo**. $\Omega = \{0, 1\}^{\mathbb{N}_+}$.

Definizione 14.2 (Variabile Geometrica $T \sim \text{Geom}(p)$). T è l'istante (n° della prova) del primo successo. $T(\omega_1, \omega_2, \dots) = \min\{n \in \mathbb{N}_+ \mid \omega_n = 1\}$. Nota: se la sequenza ha solo zeri, $T = +\infty$, ma tale evento ha probabilità nulla. T assume valori in $\mathbb{N}_+ = \{1, 2, 3, \dots\}$.

Funzione di massa:

$$\mathbb{P}(T = k) = p(1-p)^{k-1} \quad (34)$$

Dimostrazione: Se $A_k = \{\text{successo alla } k\text{-esima prova}\}$, allora $\mathbb{P}(T = k) = \mathbb{P}(A_1^c \cap A_2^c \cap \dots \cap A_{k-1}^c \cap A_k)$. Essendo prove indipendenti, la probabilità diventa $\mathbb{P}(A_1^c) \dots \mathbb{P}(A_{k-1}^c) \mathbb{P}(A_k) = (1-p)^{k-1}p$.

Proprietà 14.1 (Assenza di Memoria). Se $T \sim \text{Geom}(p)$, allora $\forall n, k \in \mathbb{N}_+$:

$$\mathbb{P}(T = n+k \mid T > n) = \mathbb{P}(T = k) \quad (35)$$

"La distribuzione del 1° successo nel futuro non cambia sapendo che il successo non si è verificato nelle precedenti n prove".

Esempio:

Lanci ripetuti di un dado.

a) Probabilità del primo "5" al 4° lancio? $T \sim \text{Geom}(1/6)$.

$$\mathbb{P}(T = 4) = \left(1 - \frac{1}{6}\right)^3 \cdot \frac{1}{6} = \frac{5^3}{6^4}.$$

b) Probabilità del primo "5" al 6° lancio, sapendo che non è uscito nei primi 2 lanci?

$$\mathbb{P}(T = 6 \mid T > 2) = \mathbb{P}(T = 4) = \frac{5^3}{6^4}.$$

14.3 V.A. di Poisson

Definizione 14.3 (Variabile di Poisson $X \sim \text{Pois}(\lambda)$). Con parametro $\lambda > 0$, è una v.a. discreta a valori in $\mathbb{N} = \{0, 1, 2, \dots\}$ con funzione di massa:

$$\mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k \in \mathbb{N} \quad (36)$$

Essendo una densità discreta, la somma è uno: $\sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{\lambda} \implies \sum \mathbb{P}(X = k) = e^{-\lambda} e^{\lambda} = 1$.

Intuizione:

La v.a. di Poisson conta il numero di **eventi rari**. È l'approssimazione del numero di successi in n prove ripetute (Binomiale) quando n è molto grande, p (probabilità di successo) è molto piccola, e poniamo $\lambda \approx np$.

Esempi di applicazione:

- N° di particelle α emesse da una sorgente in un dato intervallo (singola prova: emissione da un nucleo, probabilità molto bassa, ma ci sono tantissimi nuclei indipendenti).
- N° di clienti a uno sportello (molte persone indipendenti, bassa probabilità singola di andarci).
- N° di grandi terremoti in una certa area.

15 Variabili Aleatorie con Densità (Continue)

Fino ad ora abbiamo visto variabili che assumono valori "a salti". Tuttavia, molte grandezze fisiche (altezza, temperatura, tempo) variano con continuità. Per queste, la probabilità di assumere un *singolo, esatto* valore è zero: ad esempio, la probabilità che una persona sia alta *esattamente* 1.7325... metri è nulla. Ha senso invece calcolare la probabilità che l'altezza cada in un *intervallo*.

Definizione 15.1 (V.A. con Densità / Assolutamente Continua). Una v.a. $X : \Omega \rightarrow \mathbb{R}$ si dice con densità se esiste una funzione $f : \mathbb{R} \rightarrow \mathbb{R}$ (chiamata funzione di densità) tale che, per ogni sottoinsieme $A \subseteq \mathbb{R}$:

$$\mathbb{P}(X \in A) = \int_A f(x) dx \quad (37)$$

Intuizione:

La densità $f(x)$ non è una probabilità, ma una "probabilità per unità di lunghezza". Per un δx molto piccolo:

$$f(x) \approx \frac{\mathbb{P}(X \in [x, x + \delta x])}{\delta x}$$

La probabilità corrisponde **all'area sottesa** dal grafico della densità.

Per gli intervalli, a prescindere che siano aperti o chiusi, vale:

$$\begin{aligned}\mathbb{P}(a \leq X \leq b) &= \mathbb{P}(a < X < b) = \int_a^b f(x) dx \\ \mathbb{P}(X \leq b) &= \int_{-\infty}^b f(x) dx = \lim_{a \rightarrow -\infty} \int_a^b f(x) dx \\ \mathbb{P}(X \geq a) &= \int_a^{+\infty} f(x) dx = \lim_{b \rightarrow +\infty} \int_a^b f(x) dx\end{aligned}$$

Proprietà 15.1 (Proprietà Fondamentali della Densità). *Affinché $f(x)$ sia una valida funzione di densità, deve soddisfare due condizioni:*

1. $f(x) \geq 0 \quad \forall x \in \mathbb{R}$ (non ci sono probabilità negative)
2. $\int_{-\infty}^{+\infty} f(x) dx = 1$ (l'area totale deve essere il 100%)

Se f verifica queste due proprietà, allora esiste sempre una v.a. X che ammette f come densità. Inoltre, come anticipato:

$$\mathbb{P}(X = a) = \int_{\{a\}} f(x) dx = 0 \quad \forall a \in \mathbb{R} \quad (38)$$

Interpretazione Frequentista: Immagina un istogramma della popolazione in cui l'ampiezza delle classi diventa infinitamente piccola. Il contorno dell'istogramma approssimerà perfettamente la curva continua $f(x)$.

16 V.A. con Densità Notevoli


16.1 Variabile Uniforme

Intuizione:

Rappresenta la scelta di un punto a caso in un intervallo limitato (α, β) , "senza preferenze". Qualsiasi sotto-intervallo della stessa lunghezza ha la stessa probabilità.

Definizione 16.1 (Uniforme $X \sim U(\alpha, \beta)$). *È una v.a. avente densità costante sull'intervallo (α, β) :*

$$f(x) = \begin{cases} \frac{1}{\beta - \alpha} & \text{se } x \in (\alpha, \beta) \\ 0 & \text{se } x \notin (\alpha, \beta) \end{cases} \quad (39)$$



Per un intervallo $[a, b] \subseteq (\alpha, \beta)$, la probabilità si calcola geometricamente:

$$\mathbb{P}(a \leq X \leq b) = \int_a^b \frac{1}{\beta - \alpha} dx = \frac{b - a}{\beta - \alpha} = \frac{\text{lungh. dell'intervallo}}{\text{lungh. totale}} \quad (40)$$

16.2 Variabile Esponenziale

Intuizione:

Mentre la variabile di Poisson conta *quanti* eventi rari avvengono, l'Esponenziale misura il *tempo di attesa* tra due di questi eventi (es. tempo tra due terremoti, o due emissioni radioattive).

Definizione 16.2 (Esponenziale $X \sim \text{Exp}(\lambda)$). Con parametro $\lambda > 0$, ha densità:

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{se } x > 0 \\ 0 & \text{se } x \leq 0 \end{cases} = \lambda e^{-\lambda x} \mathbb{I}_{(0,+\infty)}(x) \quad (41)$$

Esempio:

Sia $X \sim \text{Exp}(1/8)$. Calcoliamo la probabilità che il tempo di attesa superi 6:

$$\mathbb{P}(X > 6) = \int_6^{+\infty} \frac{1}{8} e^{-\frac{1}{8}x} dx = \left[-e^{-\frac{1}{8}x} \right]_{x=6}^{+\infty} = -0 - \left(-e^{-\frac{1}{8} \cdot 6} \right) = e^{-3/4} \quad (42)$$

Proprietà 16.1 (Assenza di memoria). Se $X \sim \text{Exp}(\lambda)$, allora $\forall s, t > 0$:

$$\mathbb{P}(X > t + s \mid X > s) = \mathbb{P}(X > t) \quad (43)$$

L'Esponenziale è l'unica distribuzione continua con questa proprietà.

17 Funzione di Ripartizione (FdR) e Quantili

Definizione 17.1 (Funzione di Ripartizione). Sia X una v.a. La sua Funzione di Ripartizione $F_X : \mathbb{R} \rightarrow \mathbb{R}$ (CDF in inglese) è:

$$F_X(x) = \mathbb{P}(X \leq x) = \mathbb{P}(\{\omega \in \Omega \mid X(\omega) \leq x\}) \quad (44)$$

Proprietà 17.1. Le proprietà fondamentali di F_X sono:

1. **Non decrescente:** $x_1 \leq x_2 \implies F_X(x_1) \leq F_X(x_2)$.
2. **Limiti:** $\lim_{x \rightarrow -\infty} F_X(x) = 0$ e $\lim_{x \rightarrow +\infty} F_X(x) = 1$.
3. **Continuità a destra:** F_X è continua da destra.

Nel caso di una v.a. con densità f , l'FdR si ottiene integrando:

$$F_X(x) = \int_{-\infty}^x f(y) dy \quad (45)$$

Inoltre, per il Teorema Fondamentale del Calcolo, se f è continua (o F_X è di classe C^1), vale la derivazione: $f(x) = \frac{d}{dx} F_X(x)$. Utilità pratica: $\mathbb{P}(a < X \leq b) = F_X(b) - F_X(a)$.

17.1 Quantili e Formula di Cambio Variabile

Definizione 17.2 (β -quantile). Dato $\beta \in (0, 1)$, un β -quantile (o 100β -esimo percentile) è un numero $r_\beta \in \mathbb{R}$ tale che:

$$\mathbb{P}(X \leq r_\beta) \geq \beta \quad e \quad \mathbb{P}(X \geq r_\beta) \geq 1 - \beta \quad (46)$$

Se F_X è invertibile, allora il quantile è unico e vale: $r_\beta = F_X^{-1}(\beta)$.

Spesso abbiamo una v.a. X e vogliamo trovare la densità di una trasformazione $Y = h(X)$.

Esempio:

Se X è la lunghezza di un cubetto aleatorio, la variabile $Y = X^3$ ne rappresenta il volume. Y ammette densità?

Proposizione: Formula di Cambio Variabili

Sia X con densità f_X supportata su un intervallo aperto I . Sia $h : I \rightarrow J$ un diffeomorfismo di classe C^1 (funzione biunivoca, derivabile e con inversa derivabile). Allora la v.a. $Y = h(X)$ ammette densità su J data da:

$$f_Y(y) = \begin{cases} f_X(h^{-1}(y)) \cdot \left| \frac{d}{dy} h^{-1}(y) \right| & \text{se } y \in J \\ 0 & \text{altrimenti} \end{cases} \quad (47)$$

18 Variabili Gaussiane (Normali)

Fatto fondamentale dell'analisi: $\int_{-\infty}^{+\infty} e^{-x^2/2} dx = \sqrt{2\pi}$.

Definizione 18.1 (Gaussiana Standard $Z \sim N(0, 1)$). È una v.a. con densità $\varphi(x)$:


$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad x \in \mathbb{R} \quad (48)$$

La Funzione di Ripartizione $\Phi(x) = \mathbb{P}(Z \leq x)$ **non esiste in forma chiusa**. I suoi valori sono calcolati numericamente e tabulati. Tuttavia, per la simmetria (essendo $\varphi(x)$ pari), godiamo di ottime proprietà:

- $\Phi(-x) = 1 - \Phi(x)$
- $\Phi(0) = \frac{1}{2}$
- $\mathbb{P}(|Z| \leq a) = \mathbb{P}(-a \leq Z \leq a) = \Phi(a) - \Phi(-a) = 2\Phi(a) - 1$

Valori notevoli: $\mathbb{P}(|Z| \leq 1) \approx 0.68$, $\mathbb{P}(|Z| \leq 2) \approx 0.95$, $\mathbb{P}(|Z| \leq 3) \approx 0.997$.

Per i quantili (indicati con q_β tale che $\Phi(q_\beta) = \beta$), la simmetria garantisce che $q_{1-\beta} = -q_\beta$.



18.1 Gaussiana Generale

Definiamo una trasformazione affine $Y = \sigma Z + m$ con $\sigma > 0$ e $m \in \mathbb{R}$. Tramite la formula del cambio di variabili, si ottiene:

Definizione 18.2 (Gaussiana Generale $Y \sim N(m, \sigma^2)$). *Ha densità:*

$$f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y-m)^2}{2\sigma^2}\right) \quad (49)$$

Parte 2

Appunti Completi: Valore Atteso, Momenti e Varianza

Guida allo Studio Definitiva

Indice

1	Introduzione: Dalla Statistica Descrittiva alla Probabilità	1
2	Il Valore Atteso (Speranza Matematica)	1
2.1	Significato del Valore Atteso	1
2.2	Esempi Fondamentali di Valore Atteso	2
2.3	Esistenza del Valore Atteso: Quando è definito?	2
3	Valore Atteso di una Funzione di V.A. (Teorema di Trasferimento)	3
4	Proprietà del Valore Atteso	3
5	Momenti di una Variabile Aleatoria	4
6	Disuguaglianze Notevoli: Markov e Chebyshev	4
7	Varianza e Deviazione Standard	5
7.1	Formula Pratica per il Calcolo e Proprietà	5
7.2	Disuguaglianza di Chebyshev	6
8	Variabili Aleatorie Notevoli Discrete	6
8.1	Variabile di Bernoulli: $X \sim Be(p)$	6
8.2	Variabile Binomiale: $X \sim B(n, p)$	6
8.3	Variabile di Poisson: $X \sim \mathcal{P}(\lambda)$	7
9	Variabili Aleatorie Notevoli Continue	7
9.1	Variabile Uniforme Continua: $X \sim U([a, b])$	7
9.2	Variabile Esponenziale: $X \sim Exp(\lambda)$	8
9.3	Variabile Normale (Gaussiana)	8
9.3.1	Caso Standard: $Z \sim N(0, 1)$	8
9.3.2	Caso Generale: $X \sim N(m, \sigma^2)$	8
10	Ulteriori Variabili Discrete Notevoli	9
10.1	Variabile Geometrica: $T \sim Geom(p)$	9
10.2	Variabile Ipergeometrica: $X \sim H(N, K, n)$	9

11 Variabili Aleatorie Multivariate (Leggi Congiunte e Marginali)	11
11.1 Legge Congiunta e Leggi Marginali	11
11.1.1 Il Caso Discreto	12
12 Indipendenza di Variabili Aleatorie	13
12.1 Proprietà di Riproducibilità	13
13 Valore Atteso, Covarianza e Correlazione	14
13.1 Valore Atteso di Funzioni di V.A. Doppie	14
13.2 Covarianza e Correlazione	14
13.3 Varianza della Somma	15
14 Introduzione all'Inferenza e Teoremi Limite in Probabilità	16
15 Il Teorema del Limite Centrale (TCL)	17
15.1 L'intuizione: lo "Zoom" sulla Media Campionaria	17
15.2 Convergenza in Legge e Formulazione del Teorema	18
15.3 Caso Particolare: Approssimazione Normale della Binomiale	19
16 Introduzione alla Statistica Inferenziale	21
16.1 Il Modello Statistico e il Campione	21
17 Statistiche Campionarie e Stimatori	22
17.1 Come valutare l'efficacia di uno stimatore?	22
17.1.1 1. Correttezza (Non Distorsione)	22
17.1.2 2. Consistenza	22
17.1.3 3. Efficienza (Rischio Quadratico)	23
17.2 Esempio: Stima della probabilità di un evento (Frequenza Relativa)	23
18 Il Metodo della Massima Verosimiglianza	23
18.1 La Funzione di Verosimiglianza	23
18.2 Definizione di Stimatore MLE	24
18.3 Esempi Notevoli di MLE	24
18.3.1 1. Distribuzione di Poisson ($X \sim \text{Poisson}(\lambda)$)	24
18.3.2 2. Distribuzione Esponenziale ($X \sim \text{Exp}(\theta)$)	24
18.3.3 3. Distribuzione Uniforme su $[0, \theta]$	25
18.3.4 4. Distribuzione Normale $\mathcal{N}(m, \sigma^2)$ con m noto	25
Approfondimento Teorico-Pratico: Esercizi MLE e Grafici	25
19 Intervalli di Fiducia	28
19.1 Scopo e Definizione	28
19.2 Caso 1: Media di popolazione Gaussiana con Varianza Nota	28
19.3 Caso 2: Media di popolazione Gaussiana con Varianza Non Nota	30
19.4 Caso 3: Grandi Campioni (Teorema del Limite Centrale)	32
19.5 Caso 4: Intervalli di Fiducia per una Proporzione	33
19.6 Esercizi Riassuntivi e Applicazioni	34

1 Introduzione: Dalla Statistica Descrittiva alla Probabilità

Per comprendere a fondo il comportamento delle variabili aleatorie (v.a.), è utile portare i concetti cardine della statistica descrittiva all'interno del contesto probabilistico. Nella statistica descrittiva, dato un campione di dati $(x_1, \dots, x_n)$, si utilizzano indici specifici per riassumerne le caratteristiche:

- **Media Campionaria ($\bar{x}$):** Indica il centro della distribuzione dei dati e si calcola come $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$.
- **Varianza Campionaria ($Var(x)$):** Indica la dispersione dei dati attorno alla media e si calcola come $Var(x) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$.

L'obiettivo è introdurre concetti analoghi (media e varianza) per un intero carattere o popolazione descritto da una variabile aleatoria X .

2 Il Valore Atteso (Speranza Matematica)

Il **Valore Atteso**, indicato con $\mathbb{E}[X]$ (oppure μ), è un indice di posizione che ci fornisce un'informazione fondamentale su dove sia "centrata" la distribuzione della variabile aleatoria. Può essere chiamato anche *speranza* o *momento primo*.

Definizione: Valore Atteso

A seconda della natura della variabile aleatoria, il calcolo del valore atteso differisce:

- **Caso Discreto:** Sia X una v.a. discreta a valori in $\{a_1, a_2, \dots\}$ con funzione di massa di probabilità $p_X(a_j) = P(X = a_j)$. Il valore atteso è definito come:

$$\mathbb{E}[X] = \sum_j a_j \cdot p_X(a_j) \quad (1)$$

Se le modalità sono in numero infinito (es. $\mathbb{N}$), si tratta di una serie: $\mathbb{E}[X] = \lim_{n \rightarrow \infty} \sum_{j=1}^n a_j \cdot p_X(a_j)$.


- **Caso Assolutamente Continuo (con densità):** Sia X una v.a. con funzione di densità $f(x)$. Il valore atteso è:

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x \cdot f(x) dx \quad (2)$$

2.1 Significato del Valore Atteso

Il valore atteso può essere interpretato fisicamente come il **baricentro della distribuzione**. Nel caso discreto, è una media pesata dei valori assunti dalla variabile, dove i pesi sono le probabilità: i valori più probabili contano di più.

Approccio Frequentista (Legge dei Grandi Numeri - LGN): Nel caso di estrazione da una popolazione, se ripetiamo l'esperimento n volte, il limite della media aritmetica dei valori assunti da X tenderà esattamente al valore atteso $\mathbb{E}[X]$ per $n \rightarrow \infty$.



2.2 Esempi Fondamentali di Valore Atteso

Esempio: Esito lancio di un dado equilibrato

Sia X l'esito del lancio di un dado. I valori assumibili sono $a_k \in \{1, 2, \dots, 6\}$ con probabilità $P(X = k) = \frac{1}{6}$.

$$\mathbb{E}[X] = \sum_{k=1}^6 k \cdot \frac{1}{6} = \frac{1}{6}(1 + 2 + 3 + 4 + 5 + 6) = \frac{1}{6} \cdot \frac{6 \cdot 7}{2} = \frac{7}{2} = 3.5$$

Esempio: Variabile Uniforme Continua $U(0, 1)$

Sia $X \sim U(0, 1)$. La funzione di densità è $f(x) = 1$ per $x \in (0, 1)$, e 0 altrimenti.

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x \cdot f(x) dx = \int_0^1 x dx = \left[\frac{1}{2}x^2 \right]_0^1 = \frac{1}{2}$$

In generale, per $X \sim U(\alpha, \beta)$, dove $f(x) = \frac{1}{\beta - \alpha}$, si ha:

$$\mathbb{E}[X] = \int_{\alpha}^{\beta} x \cdot \frac{1}{\beta - \alpha} dx = \frac{1}{\beta - \alpha} \left[\frac{x^2}{2} \right]_{\alpha}^{\beta} = \frac{\beta^2 - \alpha^2}{2(\beta - \alpha)} = \frac{\alpha + \beta}{2}$$

2.3 Esistenza del Valore Atteso: Quando è definito?

Il valore atteso non è sempre finito e potrebbe anche non essere definito.

- Se X (discreta o continua) è **non negativa** ($X \geq 0$), ha sempre senso calcolare $\mathbb{E}[X]$, ammettendo che possa anche risultare $+\infty$. Quindi $\mathbb{E}[X] \in [0, +\infty]$.
- Se X è generica, si dice che **ammette valore atteso** se è assolutamente convergente:
 - Caso discreto: se $\sum_k |a_k| p_X(a_k) < \infty$.
 - Caso continuo: se $\int_{-\infty}^{+\infty} |x| f(x) dx < \infty$.

Nota:

Se X assume solo un numero *finito* di valori, oppure se la densità $f(x)$ è supportata su un intervallo limitato $[a, b]$, allora X ammette sempre valore atteso reale (non diverge).

Esempio: Un caso di divergenza a $+\infty$

Sia X con densità $f_X(x) = \frac{1}{x^2} \mathbb{I}_{(1,+\infty)}(x)$.

$$\mathbb{E}[X] = \int_1^{+\infty} x \cdot \frac{1}{x^2} dx = \int_1^{+\infty} \frac{1}{x} dx = [\log(x)]_1^{+\infty} = +\infty$$

3 Valore Atteso di una Funzione di V.A. (Teorema di Trasferimento)

Sia X una v.a. e sia $g : \mathbb{R} \rightarrow \mathbb{R}$ una funzione. Allora $Y = g(X)$ è ancora una variabile aleatoria. Come si calcola $\mathbb{E}[g(X)]$?

Proprietà / Teorema: Teorema di Trasferimento

- Se X è discreta con funzione di massa p :

$$\mathbb{E}[g(X)] = \sum_k g(a_k) \cdot p(a_k) \quad (3)$$

- Se X è assolutamente continua con densità f :

$$\mathbb{E}[g(X)] = \int_{-\infty}^{+\infty} g(x)f(x) dx \quad (4)$$

Esempio:

Sia X l'esito del lancio di un dado e sia $g(X) = X^2$.

$$\mathbb{E}[X^2] = \sum_{k=1}^6 k^2 \frac{1}{6} = \frac{1}{6}(1 + 4 + 9 + 16 + 25 + 36) = \frac{91}{6}$$

4 Proprietà del Valore Atteso

Siano X e Y due variabili aleatorie e $a, b \in \mathbb{R}$. Il valore atteso gode delle seguenti proprietà fondamentali:

Proprietà / Teorema: Linearità e Monotonia

1. **Linearità della somma:** $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$.
2. **Linearità del prodotto per scalare e traslazione:** $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$.
Di conseguenza, la speranza di una costante è la costante stessa: $\mathbb{E}[b] = b$.
3. **Monotonia (positività):** Se $X \geq 0$, allora $\mathbb{E}[X] \geq 0$.
4. **Monotonia fra variabili:** Se $X \geq Y$, allora $\mathbb{E}[X] \geq \mathbb{E}[Y]$. In particolare, $|\mathbb{E}[X]| \leq \mathbb{E}[|X|]$.

Esempio: Somma di due dadi

Consideriamo il lancio di due dadi equilibrati. X = "esito 1° lancio", Y = "esito 2° lancio". Qual è il valore atteso della somma? Sapendo che $\mathbb{E}[X] = \mathbb{E}[Y] = \frac{7}{2}$, per la linearità si ottiene:

$$\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y] = \frac{7}{2} + \frac{7}{2} = 7$$

5 Momenti di una Variabile Aleatoria

Definizione: Momento di ordine n

Data una variabile aleatoria X e un intero $n = 1, 2, 3, \dots$, si definisce **momento di ordine n** di X il valore atteso della v.a. X^n , ovvero $\mathbb{E}[X^n]$. (Il valore atteso classico è il momento di ordine 1).

$$\mathbb{E}[X^n] = \begin{cases} \sum_k a_k^n \cdot p_X(a_k) & \text{caso discreto} \\ \int_{-\infty}^{+\infty} x^n f(x) dx & \text{caso continuo} \end{cases} \quad (5)$$

Osservazione: Si dice che X *ammette* momento di ordine n se la quantità in valore assoluto è finita: $\mathbb{E}[|X|^n] < +\infty$. Se una v.a. ammette momenti di ordine alto, significa che ha "code leggere" (la probabilità di ottenere valori estremi è molto piccola).

6 Disuguaglianze Notevoli: Markov e Chebyshev

Queste disuguaglianze ci permettono di stimare la probabilità di eventi rari conoscendo solo pochi indici (come la media e la varianza).

Proprietà / Teorema: Disuguaglianza di Markov

Sia X una v.a. non negativa ($X \geq 0$) e sia $a > 0$. Allora:

$$P(X \geq a) \leq \frac{1}{a} \mathbb{E}[X] \quad (6)$$

Corollario: Se X ammette momento n -esimo, si può generalizzare come $P(|X| \geq a) \leq \frac{1}{a^n} \mathbb{E}[|X|^n]$. Questa versione deriva direttamente dall'osservare che l'evento $\{|X| \geq a\}$ è equivalente a $\{|X|^n \geq a^n\}$.

7 Varianza e Deviazione Standard


Mentre il valore atteso indica il "centro", la varianza misura la **dispersione** della distribuzione attorno al centro. Si tratta dell'equivalente probabilistico della varianza empirica della statistica descrittiva.

Definizione: Varianza e Deviazione Standard

Sia X una v.a. che ammette momento secondo (ovvero $\mathbb{E}[X^2] < \infty$). La **Varianza** di X è definita come il valore atteso degli scarti al quadrato rispetto alla media:

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] \quad (7)$$

La **Deviazione Standard** (o scarto quadratico medio) è semplicemente la radice quadrata della varianza: $\sigma(X) = \sqrt{\text{Var}(X)}$.



7.1 Formula Pratica per il Calcolo e Proprietà

Sviluppando il quadrato nella definizione, otteniamo la **formula di calcolo**:

$$\text{Var}(X) = \mathbb{E}[X^2 - 2X\mathbb{E}[X] + \mathbb{E}[X]^2] = \mathbb{E}[X^2] - 2\mathbb{E}[X]\mathbb{E}[X] + \mathbb{E}[X]^2 = \mathbb{E}[X^2] - \mathbb{E}[X]^2 \quad (8)$$

Proprietà / Teorema: Proprietà della Varianza

Siano $a, b \in \mathbb{R}$.

1. **Proprietà di Scaling e Invarianza per Traslazione:** $\text{Var}(aX + b) = a^2 \cdot \text{Var}(X)$.
2. **Varianza di una Costante:** In particolare, se calcoliamo la varianza di un numero fisso otteniamo zero: $\text{Var}(b) = 0$.
3. **Condizione per Varianza Nulla:** $\text{Var}(X) = 0 \iff X$ è una variabile costante.

Esempio: Varianza di un Dado

Sappiamo che $\mathbb{E}[X] = \frac{7}{2}$ e $\mathbb{E}[X^2] = \frac{91}{6}$.

$$Var(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \frac{91}{6} - \left(\frac{7}{2}\right)^2 = \frac{91}{6} - \frac{49}{4} = \frac{182 - 147}{12} = \frac{35}{12}$$

7.2 Disuguaglianza di Chebyshev

Basandosi sulla varianza, questa disuguaglianza lega la dispersione dei dati alla probabilità che la variabile si allontani dalla sua media di una certa distanza d .

Proprietà / Teorema: Disuguaglianza di Chebyshev

Sia X una v.a. con momento secondo finito e $d > 0$. Allora:

$$P(|X - \mathbb{E}[X]| \geq d) \leq \frac{1}{d^2} \cdot Var(X) \quad (9)$$

Significato: La probabilità che la variabile X si discosti dal suo valore atteso per più di d è limitata superiormente dalla varianza divisa per d^2 . Se d è piccolo la frazione risulta grande, fornendo un limite debole; altrimenti se d è grande il limite garantisce che l'evento sia molto raro. Questa disuguaglianza deriva direttamente dall'applicazione di Markov alla variabile aleatoria $(X - \mathbb{E}[X])^2$.

8 Variabili Aleatorie Notevoli Discrete

Le variabili discrete "famose" descrivono modelli ricorrenti nella realtà (successi/insuccessi, conteggi).

8.1 Variabile di Bernoulli: $X \sim Be(p)$

Descrive un esperimento con due soli esiti: "Successo" (1) con probabilità p , o "Insuccesso" (0) con probabilità $q = 1 - p$.

- **Valore Atteso:** $\mathbb{E}[X] = 1 \cdot p + 0 \cdot (1 - p) = p$.
- **Varianza:** $\mathbb{E}[X^2] = 1^2 \cdot p + 0^2 \cdot (1 - p) = p \implies Var(X) = p - p^2 = p(1 - p)$.

8.2 Variabile Binomiale: $X \sim B(n, p)$

Rappresenta il numero di successi in n prove indipendenti di Bernoulli.

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k \in \{0, 1, \dots, n\} \quad (10)$$

Per la linearità del valore atteso (essendo la somma di n Bernoulli indipendenti):

- $\mathbb{E}[X] = n \cdot p$.
- $Var(X) = n \cdot p(1 - p)$.

8.3 Variabile di Poisson: $X \sim \mathcal{P}(\lambda)$

Modella il numero di eventi che avvengono in un intervallo di tempo o spazio fisso (es. arrivi in un centralino, difetti in un tessuto).

Nota: Significato del parametro

λ rappresenta il **tasso medio** (o intensità): è il numero medio di successi nell'intervallo considerato. Deve essere strettamente positivo ($\lambda > 0$).

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k \in \{0, 1, 2, \dots\} \quad (11)$$

[Calcolo di Valore Atteso e Varianza] **Valore Atteso:**

$$\mathbb{E}[X] = \sum_{k=0}^{+\infty} k \cdot e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=1}^{+\infty} \frac{\lambda \cdot \lambda^{k-1}}{(k-1)!} = \lambda e^{-\lambda} \sum_{j=0}^{+\infty} \frac{\lambda^j}{j!} = \lambda e^{-\lambda} e^{\lambda} = \lambda$$

Varianza: Calcoliamo prima il momento fattoriale $\mathbb{E}[X(X-1)]$:

$$\mathbb{E}[X(X-1)] = \sum_{k=2}^{+\infty} k(k-1) e^{-\lambda} \frac{\lambda^k}{k!} = \lambda^2 e^{-\lambda} \sum_{j=0}^{+\infty} \frac{\lambda^j}{j!} = \lambda^2$$

Quindi $\mathbb{E}[X^2] = \mathbb{E}[X(X-1)] + \mathbb{E}[X] = \lambda^2 + \lambda$.

$Var(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$.

9 Variabili Aleatorie Notevoli Continue


9.1 Variabile Uniforme Continua: $X \sim U([a, b])$

Rappresenta una scelta "completamente a caso" tra due estremi a e b .

Nota: Significato delle variabili

a e b sono i **supporti** (minimo e massimo). La densità è costante tra di essi, il che significa che ogni sotto-intervallo della stessa ampiezza ha la medesima probabilità.

Densità: $f(x) = \frac{1}{b-a}$ per $x \in [a, b]$, zero altrove.



[Valore Atteso e Varianza] $\mathbb{E}[X] = \int_a^b \frac{x}{b-a} dx = \frac{1}{b-a} \left[\frac{x^2}{2} \right]_a^b = \frac{b^2-a^2}{2(b-a)} = \frac{a+b}{2}$ (Punto medio).

$Var(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \int_a^b \frac{x^2}{b-a} dx - \left(\frac{a+b}{2} \right)^2 = \dots = \frac{(b-a)^2}{12}$.

9.2 Variabile Esponenziale: $X \sim \text{Exp}(\lambda)$

Utilizzata per modellare il tempo di attesa continuo tra eventi (es. durata di un componente elettronico, tempo fino al prossimo arrivo).

Nota: Significato del parametro

$\lambda > 0$ rappresenta il **tasso di guasto** o di arrivo. Un λ elevato indica che l'evento avverrà mediamente in poco tempo.

Densità: $f(x) = \lambda e^{-\lambda x}$ per $x > 0$, altrimenti 0.

[Calcolo di Valore Atteso e Varianza] Calcoliamo $\mathbb{E}[X]$ tramite **integrazione per parti** (fattore finito x , fattore differenziale $\lambda e^{-\lambda x}$):

$$\begin{aligned}\mathbb{E}[X] &= \int_0^{+\infty} x \lambda e^{-\lambda x} dx = [x(-e^{-\lambda x})]_0^{+\infty} - \int_0^{+\infty} 1 \cdot (-e^{-\lambda x}) dx \\ &= 0 + \int_0^{+\infty} e^{-\lambda x} dx = \left[-\frac{1}{\lambda} e^{-\lambda x}\right]_0^{+\infty} = \frac{1}{\lambda}\end{aligned}$$

Per la varianza, serve il momento secondo $\mathbb{E}[X^2]$, integrando sempre per parti:

$$\begin{aligned}\mathbb{E}[X^2] &= \int_0^{+\infty} x^2 \lambda e^{-\lambda x} dx = [x^2(-e^{-\lambda x})]_0^{+\infty} + \int_0^{+\infty} 2x e^{-\lambda x} dx \\ &= 0 + \frac{2}{\lambda} \int_0^{+\infty} x \lambda e^{-\lambda x} dx = \frac{2}{\lambda} \mathbb{E}[X] = \frac{2}{\lambda} \cdot \frac{1}{\lambda} = \frac{2}{\lambda^2}\end{aligned}$$

Quindi: $\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$.

9.3 Variabile Normale (Gaussiana)

9.3.1 Caso Standard: $Z \sim N(0, 1)$

Densità: $\varphi(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$.


- **Valore Atteso:** $\mathbb{E}[Z] = 0$ (per simmetria della densità, la funzione integranda $z\varphi(z)$ è dispari).
- **Varianza:** $\mathbb{E}[Z^2] = \int_{-\infty}^{+\infty} z(z\varphi(z))dz$. Per parti: $[z(-\varphi(z))]_{-\infty}^{+\infty} + \int_{-\infty}^{+\infty} \varphi(z)dz = 0 + 1 = 1$.

9.3.2 Caso Generale: $X \sim N(m, \sigma^2)$

Si ottiene come trasformazione lineare: $X = \sigma Z + m$.

Nota: Significato delle variabili

- m (media): Determina il **centro** della campana e la posizione del picco (asse di simmetria).
- σ^2 (varianza): Determina la **dispersione**. Se σ^2 è grande, la curva si appiattisce; se è piccola, la curva diventa alta e stretta.



[Momenti Normale Generale] Sfruttando le proprietà di linearità della media e della varianza:

- $\mathbb{E}[X] = \mathbb{E}[\sigma Z + m] = \sigma \mathbb{E}[Z] + m = \sigma(0) + m = \mathbf{m}$.
- $Var(X) = Var(\sigma Z + m) = \sigma^2 Var(Z) = \sigma^2(1) = \sigma^2$.

10 Ulteriori Variabili Discrete Notevoli

10.1 Variabile Geometrica: $T \sim Geom(p)$

Modella il numero di prove necessarie per ottenere il **primo successo**.

Nota: Significato delle variabili

p : Probabilità di successo in una singola prova indipendente.

$1 - p$ (spesso indicato con q): Probabilità di insuccesso.

$$P(T = k) = p(1 - p)^{k-1}, \quad k \in \{1, 2, \dots\} \quad (12)$$

- **Valore Atteso:** $\mathbb{E}[T] = \frac{1}{p}$. (Se la probabilità è 1/10, in media servono 10 lanci).
- **Varianza:** $Var(T) = \frac{1-p}{p^2}$.

10.2 Variabile Ipergeometrica: $X \sim H(N, K, n)$

Utilizzata per estrazioni **senza reimmissione** da una popolazione finita.

Nota: Significato delle variabili

- N : Numero totale di elementi nella popolazione.
- K : Numero di elementi "favorevoli" (successi) presenti nella popolazione totale.
- n : Numero di elementi estratti (ampiezza del campione).
- k : Numero di successi trovati nel campione estratto.

$$P(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}} \quad (13)$$

- **Valore Atteso:** $\mathbb{E}[X] = n \cdot \frac{K}{N}$. (Nota la somiglianza con la Binomiale np , dove $p = K/N$).
- **Varianza:** $Var(X) = n \frac{K}{N} \left(1 - \frac{K}{N}\right) \cdot \frac{N-n}{N-1}$.

11 Variabili Aleatorie Multivariate (Leggi Congiunte e Marginali)

Spesso un esperimento aleatorio non è esaurientemente descritto da una singola variabile, ma richiede l'osservazione simultanea di più caratteristiche.


Definizione: Variabile Aleatoria Doppia (o Bivariata)

Dato uno spazio di probabilità $(\Omega, \mathbb{P})$, una **variabile aleatoria doppia** (X, Y) è una funzione che associa ad ogni esito $\omega \in \Omega$ una coppia di numeri reali $(x, y) \in \mathbb{R}^2$:

$$(X, Y) : \Omega \rightarrow \mathbb{R}^2 \quad \text{con} \quad \omega \mapsto (X(\omega), Y(\omega))$$

Nota: Attenzione alla notazione

La v.a. doppia valuta *lo stesso* individuo ω su due caratteristiche diverse. Ad esempio: $(X, Y)(\omega) = (\text{Voto di } \omega, \text{Mesi per il primo impiego di } \omega)$. Non confondere con coppie di individui diversi $(X(\omega_1), Y(\omega_2))$.



11.1 Legge Congiunta e Leggi Marginali

Definizione: Legge Congiunta

La **legge (o distribuzione) congiunta** di (X, Y) è la distribuzione di probabilità della coppia. Esprime la probabilità che le variabili assumano congiuntamente valori in un certo insieme $A \subseteq \mathbb{R}^2$:

$$\mathbb{P}^{(X,Y)}(A) = \mathbb{P}(\{(X, Y) \in A\}) = \mathbb{P}(\{\omega \in \Omega \mid (X(\omega), Y(\omega)) \in A\})$$

Nel caso in cui l'insieme A sia un prodotto cartesiano $A = A_1 \times A_2$, si ha:

$$\mathbb{P}((X, Y) \in A_1 \times A_2) = \mathbb{P}(X \in A_1, Y \in A_2) = \mathbb{P}(\{X \in A_1\} \cap \{Y \in A_2\})$$

La legge congiunta contiene informazioni essenziali non solo sui singoli fenomeni, ma soprattutto sulla **relazione statistica e il legame di dipendenza** tra X e Y .

Definizione: Leggi Marginali

Le distribuzioni di probabilità delle singole variabili, prese isolatamente, sono dette **leggi marginali**.

$$\mathbb{P}_X(B) = \mathbb{P}(X \in B) \quad \text{e} \quad \mathbb{P}_Y(C) = \mathbb{P}(Y \in C)$$

11.1.1 Il Caso Discreto

Se X e Y assumono un numero finito (o numerabile) di valori, (X, Y) è una v.a. discreta. Definiamo la **funzione di massa congiunta**:

$$p^{(X,Y)}(x_i, y_j) = \mathbb{P}(X = x_i, Y = y_j)$$

Dalla congiunta si possono sempre ricavare le **funzioni di massa marginali** saturando (sommando) rispetto all'altra variabile:

$$p^X(x_i) = \mathbb{P}(X = x_i) = \sum_j \mathbb{P}(X = x_i, Y = y_j) \quad p^Y(y_j) = \mathbb{P}(Y = y_j) = \sum_i \mathbb{P}(X = x_i, Y = y_j)$$

Proprietà / Teorema: Relazione tra Congiunta e Marginali

1. **La funzione congiunta determina univocamente le marginali** (tramite le somme sulle righe o sulle colonne).
2. **Le funzioni marginali NON determinano univocamente la congiunta** (ci sono infinite congiunte che possono avere le stesse marginali).

Esempio: Le marginali non determinano la congiunta

Sia $\alpha \in (0, 1)$ un parametro. Consideriamo la seguente tabella di densità congiunta per due V.A. binarie $X, Y \in \{0, 1\}$:

$X \setminus Y$	0	1	$\mathbb{P}(X = x_i)$ (Tot Marginale)
0	$\frac{\alpha}{2}$	$\frac{1-\alpha}{2}$	$\frac{1}{2}$
1	$\frac{1-\alpha}{2}$	$\frac{\alpha}{2}$	$\frac{1}{2}$
$\mathbb{P}(Y = y_j)$	$\frac{1}{2}$	$\frac{1}{2}$	1

Come si nota, indipendentemente dal valore di α , le distribuzioni marginali di X e Y sono sempre uniformi ($\mathbb{P}(X = 0) = \frac{1}{2}$, ecc.). Tuttavia, al variare di α , la legge congiunta cambia drasticamente, dimostrando che *le marginali non contengono informazioni sulla dipendenza tra le variabili*.

Nota: Il Caso Continuo

Se X e Y sono continue, ammettono una **funzione di densità congiunta** $f(x, y) : \mathbb{R}^2 \rightarrow \mathbb{R}$ tale che:

$$\mathbb{P}((X, Y) \in A) = \iint_A f(x, y) dx dy$$

12 Indipendenza di Variabili Aleatorie

L'indipendenza traduce l'idea che l'informazione sul valore assunto da una variabile non altera le probabilità relative ai valori assunti dall'altra.

Definizione: Variabili Aleatorie Indipendenti

Le variabili $X_1, X_2, \dots, X_n$ si dicono **indipendenti** se per ogni scelta di insiemi $A_1, A_2, \dots, A_n \subseteq \mathbb{R}$, gli eventi $\{X_i \in A_i\}$ sono indipendenti:

$$\mathbb{P}(X_1 \in A_1, X_2 \in A_2, \dots, X_n \in A_n) = \mathbb{P}(X_1 \in A_1) \cdot \mathbb{P}(X_2 \in A_2) \cdots \mathbb{P}(X_n \in A_n)$$

Criterio per V.A. Discrete: X e Y sono indipendenti $\iff \forall (x_i, y_j)$ vale:

$$\mathbb{P}(X = x_i, Y = y_j) = \mathbb{P}(X = x_i) \cdot \mathbb{P}(Y = y_j)$$

Proprietà / Teorema: Stabilità dell'Indipendenza per Composizione

Se $X_1, \dots, X_n, Y_1, \dots, Y_m$ sono V.A. indipendenti e $h : \mathbb{R}^n \rightarrow \mathbb{R}$, $k : \mathbb{R}^m \rightarrow \mathbb{R}$ sono funzioni, allora le nuove variabili:

$$h(X_1, \dots, X_n) \text{ e } k(Y_1, \dots, Y_m) \text{ sono indipendenti.}$$

Funzioni di gruppi disgiunti di variabili indipendenti sono a loro volta indipendenti.
Ad esempio, se si lanciano 6 dadi $(X_1 \dots X_6)$, la somma $X_2 + X_3$ e il massimo $\max\{X_4, X_6\}$ sono V.A. indipendenti.

12.1 Proprietà di Riproducibilità

Se X e Y sono **indipendenti**, la loro somma appartiene alla stessa famiglia di distribuzioni (con parametri sommati) per queste specifiche leggi:

- **Binomiale:** $X \sim \mathcal{B}(n, p), Y \sim \mathcal{B}(m, p) \implies X + Y \sim \mathcal{B}(n + m, p)$
- **Poisson:** $X \sim \mathcal{P}(\lambda), Y \sim \mathcal{P}(\mu) \implies X + Y \sim \mathcal{P}(\lambda + \mu)$
- **Normale:** $X \sim \mathcal{N}(m_1, \sigma_1^2), Y \sim \mathcal{N}(m_2, \sigma_2^2) \implies X + Y \sim \mathcal{N}(m_1 + m_2, \sigma_1^2 + \sigma_2^2)$

Nota: L'importanza dell'indipendenza

L'ipotesi di indipendenza è **cruciale** per la riproducibilità. Se consideriamo $X \sim \mathcal{B}(1, p)$ e definiamo $Y = X$, le due variabili non sono indipendenti. Se consideriamo la somma $X + Y = 2X$, questa **non** è una binomiale $\mathcal{B}(2, p)$. (Infatti, $2X$ può assumere solo i valori 0 e 2, mentre una $\mathcal{B}(2, p)$ assume anche il valore 1 con probabilità non nulla).

13 Valore Atteso, Covarianza e Correlazione

13.1 Valore Atteso di Funzioni di V.A. Doppie

Data una funzione $g : \mathbb{R}^2 \rightarrow \mathbb{R}$, se X, Y sono discrete, si ha:

$$\mathbb{E}[g(X, Y)] = \sum_i \sum_j g(x_i, y_j) \cdot \mathbb{P}(X = x_i, Y = y_j)$$

Proprietà / Teorema: Valore Atteso del Prodotto di V.A. Indipendenti

Siano X, Y V.A. **indipendenti** (con valore atteso finito). Allora:

$$\mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$$

Più in generale: $\mathbb{E}[g(X)h(Y)] = \mathbb{E}[g(X)] \cdot \mathbb{E}[h(Y)]$.

13.2 Covarianza e Correlazione

Definizione: Covarianza

Date due V.A. X, Y con momento secondo finito, la covarianza misura la tendenza delle variabili a variare in modo concorde:

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

Sviluppando il prodotto, si ottiene la formula di calcolo operativa:

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

Proprietà / Teorema: Proprietà della Covarianza

1. **Simmetria:** $\text{Cov}(X, Y) = \text{Cov}(Y, X)$.
2. **Legame con la Varianza:** $\text{Cov}(X, X) = \text{Var}(X)$.
3. **Bilinearità:** $\text{Cov}(aX + bY + c, Z) = a\text{Cov}(X, Z) + b\text{Cov}(Y, Z)$.

Per ovviare alla dipendenza della covarianza dalle unità di misura, si introduce un indice standardizzato.

Definizione: Coefficiente di Correlazione Lineare

Se $\text{Var}(X) \neq 0$ e $\text{Var}(Y) \neq 0$, il coefficiente di correlazione ρ è:

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} \quad \text{con } -1 \leq \rho \leq 1$$

Proprietà / Teorema: Indipendenza e Scorrelazione

Se $\rho(X, Y) = 0$ (ovvero $\text{Cov}(X, Y) = 0$), le variabili si dicono **scorrelate**.

Indipendenza $\implies$ Scorrelazione

(Dimostrazione: Se X, Y indipendenti, $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$, quindi $\text{Cov}(X, Y) = 0$).

Il viceversa NON è vero: due variabili possono essere scorrelate ma fortemente dipendenti (se la dipendenza non è lineare).

Esempio: Variabili scorrelate ma dipendenti

Sia X con distribuzione uniforme discreta su $\{-1, 0, 1\}$. Quindi $\mathbb{E}[X] = 0$.

Sia $Y = X^2$. Chiaramente Y dipende in modo esatto da X . Tuttavia:

$$\text{Cov}(X, Y) = \mathbb{E}[X \cdot X^2] - \mathbb{E}[X]\mathbb{E}[X^2] = \mathbb{E}[X^3] - 0 \cdot \mathbb{E}[X^2] = \mathbb{E}[X] = 0$$


Le variabili sono **scorrelate** ($\rho = 0$), ma **fortemente dipendenti**.

Proprietà / Teorema: Significato Matematico della Correlazione (ρ)

ρ misura unicamente la dipendenza **lineare**. Cercando l'approssimazione lineare ottima di Y tramite X (minimizzando l'errore quadratico medio), si ha:

$$\min_{a, b \in \mathbb{R}} \mathbb{E}[(Y - (a + bX))^2] = \text{Var}(Y)(1 - \rho(X, Y)^2)$$

Più $|\rho|$ è vicino a 1, più l'errore di approssimazione tende a zero (altissima dipendenza lineare). Più ρ è vicino a 0, peggiore sarà l'approssimazione con una retta.



13.3 Varianza della Somma

Siano $X_1, \dots, X_n$ V.A. con momento secondo finito.

Proprietà / Teorema:

$$\text{Var} \left(\sum_{i=1}^n X_i \right) = \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{i < j} \text{Cov}(X_i, X_j)$$

Se le V.A. sono a due a due **scorrelate** (e a maggior ragione se sono **indipendenti**), i termini di covarianza si annullano, portando a:

$$\text{Var} \left(\sum_{i=1}^n X_i \right) = \sum_{i=1}^n \text{Var}(X_i)$$

Esempio: Passeggiata Aleatoria (Random Walk)

Consideriamo il moto di un ubriaco, con $X_i \in \{+1, -1\}$ con probabilità $\frac{1}{2}$ (indipendenti). La posizione al passo n è data da $W_n = \sum_{i=1}^n X_i$.

- $\mathbb{E}[W_n] = \sum_{i=1}^n \mathbb{E}[X_i] = 0$ (mediamente è nell'origine).
- Poiché le X_i sono indipendenti: $\text{Var}(W_n) = \sum_{i=1}^n \text{Var}(X_i) = \sum_{i=1}^n (\mathbb{E}[X_i^2] - \mathbb{E}[X_i]^2) = \sum_{i=1}^n 1 = n$.

L'ubriaco mediamente percorre una "distanza quadratica" pari a n , ovvero una distanza assoluta dell'ordine di $\sqrt{n}$. La varianza della somma cattura le compensazioni tra i passi avanti e indietro.

14 Introduzione all'Inferenza e Teoremi Limite in Probabilità

I teoremi limite studiano il comportamento di V.A. "medie" quando il numero di prove ripetute tende all'infinito, creando un ponte logico verso la *Statistica Inferenziale* (che punta ad ottenere informazioni su una popolazione da un campione).

Definizione: Successione i.i.d.

Una successione di V.A. $X_1, X_2, \dots, X_n, \dots$ si dice **i.i.d.** (indipendenti e identicamente distribuite) se:

1. Sono mutuamente indipendenti.
2. Hanno tutte la stessa distribuzione di probabilità ($\mathbb{P}_{X_i}$ è la stessa $\forall i$).

Questa definizione modella matematicamente le estrazioni campionarie (con rimpiazzo) o le prove ripetute sotto le medesime condizioni.

Sia data una successione i.i.d. Definiamo le seguenti statistiche campionarie:

- **Media Campionaria:** $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$
- **Varianza Campionaria:** $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$

Poiché dipendono dal campione stocastico ω , $\bar{X}_n$ e S_n^2 sono a loro volta variabili aleatorie.

Proprietà / Teorema: Legge dei Grandi Numeri (LGN) - Formulazione debole

Sia $X_1, X_2, \dots$ una successione di V.A. i.i.d. con momento secondo finito. Siano $\mu = \mathbb{E}[X_i]$ e $\sigma^2 = \text{Var}(X_i)$.

Allora la media campionaria $\bar{X}_n$ converge in probabilità al valore atteso μ per $n \rightarrow \infty$. Ovvero:

$$\forall \epsilon > 0, \quad \lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) = 0$$

Traduzione intuitiva: Per n grande, la media campionaria collassa sul valore atteso teorico con probabilità tendente al 100%.

Inoltre, per la varianza campionaria vale lo stesso risultato: S_n^2 converge in probabilità a σ^2 .

Nota: Applicazione Cruciale: Frequenza che tende alla Probabilità

Si consideri lo schema di Bernoulli a n prove. Definiamo X_i l'indicatore del successo all' i -esima prova: $X_i \sim \mathcal{B}(p)$. Il numero totale di successi è $\sum_{i=1}^n X_i$. La media campionaria in questo caso è:

$$\bar{X}_n = \frac{\text{\#successi}}{\text{\#prove}} = \text{Frequenza Relativa dell'evento}$$

Dato che $\mathbb{E}[X_i] = p$, per la LGN si ha che $\bar{X}_n \xrightarrow{\text{prob}} p$. Questo giustifica rigorosamente l'approccio frequentista alla probabilità: **su un numero infinito di esperimenti, la frequenza relativa converge alla probabilità teorica.**

15 Il Teorema del Limite Centrale (TCL)

Mentre la Legge dei Grandi Numeri (LGN) ci garantisce che la media campionaria $\bar{X}_n$ converge al valore atteso μ [cite: 1, 2], il Teorema del Limite Centrale ci fornisce informazioni fondamentali su *come* avviene questa convergenza e su quale sia la distribuzione dell'errore statistico per n grande [cite: 1].

15.1 L'intuizione: lo "Zoom" sulla Media Campionaria

Sappiamo che per una successione i.i.d. con $\mathbb{E}[X_i] = \mu$ e $\text{Var}(X_i) = \sigma^2$, si ha:

$$\mathbb{E}[\bar{X}_n] = \mu \quad \text{e} \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} \quad [\text{cite: 1, 2}]$$

Per semplicità, supponiamo $\mu = 0$. Per la LGN, $\bar{X}_n \rightarrow 0$. Man mano che n cresce, la distribuzione di $\bar{X}_n$ diventa un "picco" sempre più stretto attorno allo zero, poiché la sua varianza tende a zero [cite: 1]. Se vogliamo studiare la forma di questa distribuzione senza che collasi, dobbiamo applicare uno "zoom" moltiplicando $\bar{X}_n$ per un fattore a_n [cite: 1].

Cerchiamo a_n tale che la varianza non svanisca:

$$\text{Var}(a_n \bar{X}_n) = a_n^2 \text{Var}(\bar{X}_n) = a_n^2 \frac{\sigma^2}{n} \text{[cite: 1]}$$

Se scegliamo $a_n = \sqrt{n}$, otteniamo $\text{Var}(\sqrt{n} \bar{X}_n) = \sigma^2 > 0$ [cite: 1]. Il limite della distribuzione scalata $\sqrt{n} \bar{X}_n$ assumerà una forma ben definita [cite: 1].

15.2 Convergenza in Legge e Formulazione del Teorema

Definizione: Convergenza in Legge (o in Distribuzione)

Sia $\{Y_n\}$ una successione di variabili aleatorie e Y una V.A. di limite [cite: 2]. Supponiamo che F_n e F siano le rispettive funzioni di ripartizione e che F sia continua [cite: 2]. Diciamo che Y_n **converge in legge** a Y , e scriviamo $Y_n \xrightarrow{(d)} Y$, se:

$$\lim_{n \rightarrow \infty} F_n(t) = F(t) \quad \forall t \in \mathbb{R} \text{ [cite: 2]}$$

Proprietà / Teorema: Teorema del Limite Centrale - TCL

Sia $X_1, X_2, \dots$ una successione di variabili aleatorie **i.i.d.** con momento secondo finito [cite: 1, 2]. Siano:

- $\mu = \mathbb{E}[X_i]$ il valore atteso [cite: 1, 2]
- $\sigma^2 = \text{Var}(X_i) > 0$ la varianza (escludendo il caso di X_i costanti) [cite: 1, 2]
- $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ la media campionaria [cite: 1, 2]


Allora la variabile standardizzata converge in distribuzione a una Normale Standard $\mathcal{N}(0, 1)$ per $n \rightarrow \infty$:

$$Z_n = \sqrt{n} \frac{\bar{X}_n - \mu}{\sigma} \xrightarrow{(d)} Z \sim \mathcal{N}(0, 1) \text{ [cite: 1, 2]}$$

Ciò significa che per ogni intervallo $[a, b]$ (con $-\infty \leq a < b \leq +\infty$):

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(a \leq \sqrt{n} \frac{\bar{X}_n - \mu}{\sigma} \leq b \right) = \mathbb{P}(a \leq Z \leq b) = \Phi(b) - \Phi(a) \text{ [cite: 1, 2]}$$

dove Φ è la funzione di ripartizione della Normale Standard [cite: 1, 2].



Nota: L'Universalità del TCL e la Regola Empirica

Il TCL è un risultato di **universalità**: *la legge di partenza delle X_i può essere qualunque* (purché ammetta varianza finita), ma la loro somma standardizzata si comporterà sempre approssimativamente come una gaussiana per n grande[cite: 1].

Quanto deve essere grande n nella pratica?

Una regola empirica comunemente accettata (sebbene dipenda dalla simmetria della distribuzione originale) è che l'approssimazione sia affidabile per $n \geq 30$, ed eccellente per $n \geq 50$ [cite: 1].

Proprietà / Teorema: Corollario con Varianza Campionaria

Sia $X_1, X_2, \dots$ una successione i.i.d. con **momento quarto finito**[cite: 1]. Se si sostituisce la varianza teorica σ con la **varianza campionaria** S_n , il risultato limite rimane valido[cite: 1]:

$$\sqrt{n} \frac{\bar{X}_n - \mu}{S_n} \xrightarrow{(d)} Z \sim \mathcal{N}(0, 1)[\text{cite: 1}]$$

15.3 Caso Particolare: Approssimazione Normale della Binomiale

Consideriamo un esperimento dicotomico (successo/insuccesso) ripetuto n volte[cite: 2]. Sia $X_i \sim \mathcal{B}(1, p)$ una variabile di Bernoulli, dove $X_i = 1$ in caso di successo (con probabilità p) e $X_i = 0$ altrimenti[cite: 1, 2]. Le X_i sono i.i.d. e la loro somma $Y_n = \sum_{i=1}^n X_i$ rappresenta il numero totale (frequenza assoluta) di successi su n prove[cite: 1, 2]. Sappiamo che $Y_n \sim \mathcal{B}(n, p)$ [cite: 1, 2].

Essendo una somma di V.A. indipendenti, possiamo applicare il TCL. Sappiamo che:

$$\mathbb{E}[Y_n] = np \quad \text{e} \quad \text{Var}(Y_n) = np(1 - p)[\text{cite: 1, 2}]$$

Standardizzando Y_n otteniamo[cite: 2]:

$$\frac{Y_n - \mathbb{E}[Y_n]}{\sqrt{\text{Var}(Y_n)}} = \frac{Y_n - np}{\sqrt{np(1 - p)}}[\text{cite: 1, 2}]$$

Per il TCL, per n sufficientemente grande, questa quantità è ben approssimata da una $\mathcal{N}(0, 1)$ [cite: 1, 2].

Regola Empirica per la Binomiale: L'approssimazione normale è considerata valida se $np(1 - p) \geq 10$ [cite: 1, 2].

Esempio: 1000 lanci di moneta

Una moneta equilibrata ($p = 0.5$) viene lanciata $n = 1000$ volte[cite: 1, 2]. Definiamo Y il numero di teste ottenute. $Y \sim \mathcal{B}(1000, 0.5)$ [cite: 1, 2].

Verifichiamo la regola empirica: $np(1-p) = 1000 \cdot 0.5 \cdot 0.5 = 250 \geq 10$ (ampiamente soddisfatta)[cite: 1, 2].

Quesito A: Probabilità di ottenere almeno 480 teste?

Vogliamo calcolare $\mathbb{P}(Y \geq 480)$ [cite: 1, 2]. Utilizzando il TCL:

$$\mathbb{P}(Y \geq 480) = \mathbb{P}\left(\frac{Y - np}{\sqrt{np(1-p)}} \geq \frac{480 - 500}{\sqrt{250}}\right) \approx \mathbb{P}\left(Z \geq \frac{-20}{\sqrt{250}}\right) \approx \mathbb{P}(Z \geq -1.26)[\text{cite: 1, 2}]$$

Utilizzando le proprietà della funzione Φ per la normale standard:

$$\mathbb{P}(Z \geq -1.26) = 1 - \Phi(-1.26) = 1 - (1 - \Phi(1.26)) = \Phi(1.26) \approx 0.896[\text{cite: 1, 2}]$$

La probabilità è circa l'89.6%[cite: 1, 2].

Quesito B: Qual è il numero k di teste tale che la probabilità di ottenere almeno k teste sia circa il 95%?

Cerchiamo k tale che $\mathbb{P}(Y \geq k) = 0.95$ [cite: 1, 2]. Poiché la probabilità richiesta (95%) è maggiore di quella del caso precedente (89.6%), sappiamo in anticipo che il valore di k dovrà essere inferiore a 480[cite: 2]. Applicando l'approssimazione:

$$0.95 = \mathbb{P}(Y \geq k) \approx \mathbb{P}\left(Z \geq \frac{k - 500}{\sqrt{250}}\right) = 1 - \Phi\left(\frac{k - 500}{\sqrt{250}}\right) [\text{cite: 1, 2}]$$

Da cui ricaviamo:

$$\Phi\left(\frac{k - 500}{\sqrt{250}}\right) = 1 - 0.95 = 0.05[\text{cite: 1, 2}]$$

Dalle tavole della normale, sappiamo che il quantile $q_{0.05} = -q_{0.95} \approx -1.64$ [cite: 1, 2]. Pertanto:

$$\frac{k - 500}{\sqrt{250}} = -1.64 \implies k = 500 - 1.64\sqrt{250} \approx 500 - 1.64(15.81) \approx 473.91[\text{cite: 1, 2}]$$

Essendo k un numero intero di lanci, per garantire che la probabilità superi il 95%, arrotondiamo per difetto ottenendo $k = 473$ (o al più 474 a seconda del rigore richiesto nella stima)[cite: 1, 2].

16 Introduzione alla Statistica Inferenziale

Mentre nella teoria della probabilità studiamo campioni generati da una popolazione completamente nota (metodo deduttivo), lo scopo della **statistica inferenziale** è l'opposto: ottenere informazioni sulla distribuzione di una popolazione (reale o ideale) studiando i dati rilevati su un campione[cite: 4, 71, 72]. Si procede quindi in modo **induttivo**[cite: 5].

16.1 Il Modello Statistico e il Campione

Consideriamo una popolazione non nota[cite: 5]. Il carattere che vogliamo studiare è rappresentato da una variabile aleatoria X con distribuzione $\mathbb{P}_X$ sconosciuta, in parte o totalmente[cite: 8]. Questa distribuzione rappresenta il risultato di un esperimento aleatorio, come l'estrazione e misurazione di un carattere[cite: 83, 84].

Per studiare $\mathbb{P}_X$, la statistica parametrica suppone che la distribuzione appartenga a una famiglia nota, dipendente da uno o più parametri θ (o β)[cite: 20, 23, 86, 88]. Ad esempio, potremmo ipotizzare che l'altezza segua una normale $X \sim \mathcal{N}(m, \sigma^2)$, dove la forma a campana è assunta, ma i parametri m e σ^2 sono ignoti[cite: 12, 92, 94]. Chiamiamo Θ l'insieme dei valori ammissibili per il parametro[cite: 21, 115].

Nota: Statistica Parametrica vs Bayesiana

Nella teoria frequentista classica (che stiamo studiando), la distribuzione $\mathbb{P}_X$ e i suoi parametri θ sono valori numerici **fissi**, sebbene incogniti[cite: 98, 99, 101, 102]. All'opposto, nella statistica Bayesiana, i parametri stessi sono considerati variabili aleatorie[cite: 104].

Per determinare il parametro, effettuiamo estrazioni dalla popolazione. Un **Campione Statistico** di taglia n è definito da una n -upla $(X_1, X_2, \dots, X_n)$ di variabili aleatorie che godono della proprietà **i.i.d.** (indipendenti e identicamente distribuite)[cite: 9, 10, 85]. L'ipotesi i.i.d. garantisce due cose chiave[cite: 6]:

1. **Indipendenza:** Ogni nuova estrazione è indipendente dalle precedenti[cite: 6].
2. **Identica Distribuzione:** L'estrazione di ogni individuo è fatta in modo identico, seguendo la stessa legge $\mathbb{P}_X$ della popolazione originale[cite: 6, 11, 85].

[Il dualismo del Campione: X_i vs x_i] Perché a volte usiamo le lettere maiuscole e a volte le minuscole? Questa distinzione è vitale!

- **Le Variabili (X_i):** Sono oggetti matematici (funzioni) che rappresentano il campione "*prima dei risultati delle misurazioni*"[cite: 107]. Essendo variabili aleatorie, possiedono valori attesi e varianze.
- **Le Realizzazioni (x_i):** Sono i **valori numerici** concreti assunti dopo aver effettuato la misurazione (es. $x_i = X_i(\omega)$)[cite: 108]. Sono numeri fissi ("esiti"), non più funzioni[cite: 109].

17 Statistiche Campionarie e Stimatori

Una **statistica campionaria** è una qualsiasi funzione $g(X_1, \dots, X_n)$ del campione [cite: 24, 118]. Quando utilizziamo una statistica campionaria con l'obiettivo specifico di approssimare il valore del parametro ignoto θ , essa prende il nome di **Stimatore** [cite: 25, 119].

I due stimatori "usuali" più importanti sono [cite: 124, 125, 126]:

- **Media Campionaria:** $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$, utilizzata per stimare il valore atteso $\mathbb{E}[X]$ [cite: 26, 121, 124].
- **Varianza Campionaria:** $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$, utilizzata per stimare la varianza $Var(X)$ [cite: 125, 126].

Poiché uno stimatore è funzione del campione aleatorio, **lo stimatore è esso stesso una variabile aleatoria** [cite: 127]: il suo risultato numerico (la *stima*) cambierà al variare degli esiti del campione pescato [cite: 128].

17.1 Come valutare l'efficacia di uno stimatore?

Per decidere se uno stimatore è "buono", la statistica richiede che rispetti alcune proprietà fondamentali [cite: 129, 130].

17.1.1 1. Correttezza (Non Distorsione)

Uno stimatore $g(X_1, \dots, X_n)$ del parametro θ si dice **corretto** (o non distorto) se il suo Valore Atteso coincide esattamente con il parametro da stimare: $\mathbb{E}^\theta[g(X_1, \dots, X_n)] = \theta$ per ogni $\theta \in \Theta$ [cite: 30, 131, 133, 134]. Questo significa che, mediando su tutte le possibili realizzazioni infinite del campione, lo stimatore centra perfettamente il bersaglio [cite: 135].

Dimostrazione per la Media Campionaria [cite: 35, 137]: Sappiamo che $\mathbb{E}[X_i] = \mu$ (identicamente distribuite). Per linearità del valore atteso:

$$\mathbb{E}[\bar{X}_n] = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{1}{n}(n \cdot \mu) = \mu$$

Dunque $\bar{X}_n$ è corretto per μ [cite: 33, 35, 136].

Nota: Perché la Varianza Campionaria divide per $n - 1$?

Anche S_n^2 diviso per $(n-1)$ è uno stimatore corretto per la varianza σ^2 [cite: 33, 138]. Se dividessimo semplicemente per n , calcoleremmo $\mathbb{E}\left[\frac{1}{n} \sum (X_i - \bar{X}_n)^2\right] = \frac{n-1}{n} \sigma^2$, ottenendo uno stimatore **distorto** che sottostima la vera varianza [cite: 140, 141]. Dividere per $n - 1$ funge da fattore di correzione.

17.1.2 2. Consistenza

Mentre la correttezza riguarda la "mira", la consistenza riguarda cosa succede raccogliendo infiniti dati. Una successione di stimatori $g_n(X_1, \dots, X_n)$ è **consistente** per θ se, per $n \rightarrow \infty$, converge in probabilità al parametro vero [cite: 38, 142, 143]:

$$\lim_{n \rightarrow \infty} \mathbb{P}(|g_n(X_1, \dots, X_n) - \theta| \geq \epsilon) = 0 \quad \forall \epsilon > 0$$

Significato: per una grande taglia del campione, lo stimatore sarà arbitrariamente vicino a θ con probabilità tendente a 1[cite: 144, 145, 147].

Dimostrazione [cite: 42, 43]: La media campionaria $\bar{X}_n$ è consistente grazie alla **Legge dei Grandi Numeri (LGN)** (assumendo varianza finita)[cite: 41, 149, 150, 152]. Analogo ragionamento (corollario della LGN) rende consistente anche S_n^2 [cite: 41, 153].

17.1.3 3. Efficienza (Rischio Quadratico)

Tra più stimatori corretti per lo stesso parametro, quale scegliamo? Quello che "balla" di meno. Dati due stimatori g e h , g è **più efficiente** se possiede un *Rischio Quadratico* minore: $\mathbb{E}[(g - \theta)^2] \leq \mathbb{E}[(h - \theta)^2]$ [cite: 44, 45, 155, 156].

Se gli stimatori sono corretti, il rischio quadratico coincide esattamente con la loro **Varianza**[cite: 157, 158]. Ad esempio, calcolando la varianza della media campionaria:

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum X_i\right) = \frac{1}{n^2} \sum \text{Var}(X_i) = \frac{n \cdot \text{Var}(X)}{n^2} = \frac{\text{Var}(X)}{n}$$

Questo dimostra che all'aumentare di n , la varianza diventa sempre più piccola (il risultato si disperde meno)[cite: 46, 47, 160].

17.2 Esempio: Stima della probabilità di un evento (Frequenza Relativa)

Se consideriamo un evento A (il "successo") con probabilità incognita p , possiamo modelarlo con variabili di Bernoulli $X_i \sim B(p)$, dove $X_i = 1$ se A si verifica e 0 altrimenti[cite: 161, 162, 163, 164, 166]. La stima di p è data dalla media campionaria $\bar{X}_n$, che in questo caso rappresenta la **frequenza relativa** di A nel campione[cite: 167]. Poiché $p = \mathbb{E}[X_i]$, la frequenza relativa è sia corretta che consistente per stimare una percentuale[cite: 168]. Es: Su 1000 lanci escono 423 teste; la stima della probabilità di testa è proprio $\hat{p} = \frac{423}{1000}$.

18 Il Metodo della Massima Verosimiglianza

Una domanda centrale della statistica è: "Dato un campione $(x_1, \dots, x_n)$, come scegliamo un buon stimatore per il parametro θ ?". Uno dei metodi più potenti e utilizzati è il **Metodo della Massima Verosimiglianza** (Maximum Likelihood Estimation - MLE).

18.1 La Funzione di Verosimiglianza

L'idea alla base è ribaltare la prospettiva della funzione di densità. Invece di considerare θ fisso e variare x , consideriamo i dati x_i come fissi e variamo θ . Sia $(X_1, \dots, X_n)$ un campione i.i.d. di X con parametro $\theta \in \Theta$. Definiamo la **Funzione di Verosimiglianza** $L_\theta(x_1, \dots, x_n)$ come:

- **Caso Discreto:** È la probabilità congiunta di ottenere esattamente quei dati:

$$L_\theta(x_1, \dots, x_n) = \mathbb{P}^\theta(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n p_\theta(x_i)$$

- **Caso Continuo:** È il prodotto delle densità nei punti osservati:

$$L_{\theta}(x_1, \dots, x_n) = \prod_{i=1}^n f_{\theta}(x_i)$$

Nota: Il Significato Intuitivo

La funzione di verosimiglianza ci dice quanto sono "plausibili" i dati osservati sotto diverse ipotesi di θ . Ad esempio, se lanciando una moneta 5 volte otteniamo $(1, 1, 0, 1, 0)$, il valore $L_{0.5} \approx 0.031$ è maggiore di $L_{0.2} \approx 0.005$. Questo significa che è molto più plausibile che la moneta sia equa ($\theta = 0.5$) piuttosto che sbilanciata ($\theta = 0.2$).

18.2 Definizione di Stimatore MLE

Lo **Stimatore di Massima Verosimiglianza** $\hat{\theta}$ è quel valore del parametro che massimizza la funzione L_{θ} . Formalmente:

$$L_{\hat{\theta}(x_1, \dots, x_n)} = \max_{\theta \in \Theta} L_{\theta}(x_1, \dots, x_n)$$

Procedura Pratica: Poiché la funzione logaritmo è strettamente crescente, massimizzare L_{θ} equivale a massimizzare la **Log-verosimiglianza** $\ell(\theta) = \log L_{\theta}$. Questo è estremamente utile perché trasforma i prodotti in somme, facilitando il calcolo delle derivate:

$$\frac{d}{d\theta} \log L_{\theta} = 0 \implies \hat{\theta}$$

18.3 Esempi Notevoli di MLE

18.3.1 1. Distribuzione di Poisson ($X \sim \text{Poisson}(\lambda)$)

Dalla funzione di massa $p_{\lambda}(k) = \frac{\lambda^k}{k!} e^{-\lambda}$, otteniamo:

$$L(\lambda) = \prod \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \frac{\lambda^{\sum x_i}}{\prod x_i!} e^{-n\lambda}$$

Applicando il logaritmo e derivando rispetto a λ , si ottiene lo stimatore:

$$\hat{\lambda}_{MLE} = \bar{X}_n$$

La media campionaria è l'unico MLE per la Poisson, ed è corretto e consistente.

18.3.2 2. Distribuzione Esponenziale ($X \sim \text{Exp}(\theta)$)

Con densità $f_{\theta}(x) = \theta e^{-\theta x}$, la log-verosimiglianza è $\log L_{\theta} = n \log \theta - \theta \sum x_i$. Derivando e ponendo uguale a zero: $\frac{n}{\theta} - \sum x_i = 0$.

$$\hat{\theta}_{MLE} = \frac{1}{\bar{X}_n}$$

18.3.3 3. Distribuzione Uniforme su $[0, \theta]$

In questo caso la densità è $f_\theta(x) = \frac{1}{\theta} \mathbb{I}_{[0, \theta]}(x)$. La verosimiglianza è $\frac{1}{\theta^n}$ se **tutti** gli x_i sono $\leq \theta$, altrimenti è 0. Per massimizzare $\frac{1}{\theta^n}$ dobbiamo scegliere il più piccolo θ possibile, ma con il vincolo che θ deve essere maggiore o uguale di tutti i dati osservati.

$$\hat{\theta}_{MLE} = \max(X_1, \dots, X_n)$$

[Il caso del Minimo] Consideriamo una densità $f_\theta(x) = \frac{\theta}{x^2} \mathbb{I}_{(\theta, +\infty)}(x)$. Qual è l'MLE?

Seguendo la logica dell'uniforme, la verosimiglianza è $L_\theta = \theta^n \prod \frac{1}{x_i^2}$ purché $\theta \leq x_i$ per ogni i . Per massimizzare θ^n , dobbiamo scegliere il valore di θ più grande possibile che rispetti il vincolo $\theta \leq \min(x_i)$.

$$\hat{\theta}_{MLE} = \min(X_1, \dots, X_n)$$

Attenzione: Questo stimatore è consistente (per $n \rightarrow \infty$ si avvicina a θ), ma **non** è **corretto** per $n > 1$. Infatti, calcolando il valore atteso tramite la distribuzione del minimo, si trova $\mathbb{E}[\hat{\theta}] = \frac{n}{n-1} \theta \neq \theta$.

18.3.4 4. Distribuzione Normale $\mathcal{N}(m, \sigma^2)$ con m noto

Se la media m è nota, l'MLE per la varianza $\theta = \sigma^2$ si trova massimizzando:

$$L_\theta \propto \frac{1}{\theta^{n/2}} \exp\left(-\frac{1}{2\theta} \sum (x_i - m)^2\right)$$

Il risultato è:

$$\hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2$$

Questo stimatore risulta essere sia corretto che consistente.

Approfondimento Teorico-Pratico: Esercizi MLE e Grafici

Per comprendere veramente il Metodo della Massima Verosimiglianza, applichiamo passo dopo passo a tre scenari classici, integrando le visualizzazioni grafiche del comportamento delle funzioni.

Esercizio 1: MLE per la Poisson

Sia $X \sim \text{Poisson}(\lambda)$ con $\lambda > 0$ incognito. Abbiamo un campione $(X_1, \dots, X_n)$ e vogliamo trovare lo stimatore MLE per λ . La densità discreta è $p_\lambda(k) = \frac{\lambda^k}{k!} e^{-\lambda}$.

La funzione di verosimiglianza è il prodotto delle densità:

$$L(\lambda, x_1, \dots, x_n) = \prod_{i=1}^n \left(\frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = \left(\prod_{i=1}^n \frac{1}{x_i!} \right) \lambda^{\sum_{i=1}^n x_i} e^{-n\lambda}$$

Passiamo alla log-verosimiglianza (su $\lambda \in (0, +\infty)$):

$$\log L(\lambda) = \log \left(\prod_{i=1}^n \frac{1}{x_i!} \right) + \left(\sum_{i=1}^n x_i \right) \log \lambda - n\lambda$$

Deriviamo rispetto a λ e poniamo uguale a zero per trovare il massimo:

$$\frac{d}{d\lambda} \log L = \frac{\sum_{i=1}^n x_i}{\lambda} - n \geq 0 \iff \lambda \leq \frac{\sum_{i=1}^n x_i}{n} = \bar{x}_n$$

Quindi la log-verosimiglianza cresce fino a $\bar{x}_n$ e poi decresce. L'unico MLE è $\hat{\lambda} = \bar{X}_n$. Sappiamo dalla teoria che $\bar{X}_n$ è sia corretto che consistente per $\mathbb{E}[X_i] = \lambda$.

Esercizio 2: Il caso critico della densità decrescente

Questo è un esercizio fondamentale perché lo stimatore **non** è la media campionaria. Sia X con densità $f_\theta(x) = \frac{\theta}{x^2} \mathbb{I}_{(\theta, +\infty)}(x)$, con $\theta > 0$ incognito.

a) Trovare lo stimatore MLE

Dato che $f_\theta(x) = 0$ per $x \leq \theta$, possiamo supporre che tutti i dati osservati siano $x_i > 0$.

$$L_\theta(x_1, \dots, x_n) = \prod_{i=1}^n \frac{\theta}{x_i^2} \mathbb{I}_{x_i \geq \theta} = \frac{\theta^n}{\prod_{i=1}^n x_i^2} \mathbb{I}_{\min x_i \geq \theta}$$

La funzione L_θ cresce con θ^n , ma *precipita a zero* non appena θ supera il valore del dato più piccolo osservato ($\min x_i$). Per massimizzare L_θ , dobbiamo spingere θ il più a destra possibile senza oltrepassare $\min x_i$. L'unico MLE è quindi $\hat{\theta} = \min_i X_i$.

Funzione di Verosimiglianza per $f(x) = \theta/x^2$




Figura 1: Il massimo si trova sul "bordo" del dominio valido.

b) Consistenza dello stimatore

Per $n \rightarrow \infty$, il minimo campionario $\min X_i$ è coerente? Calcoliamo la probabilità che si discosti dal valore vero θ di un errore ϵ :

$$\mathbb{P}(|\hat{\theta}_n - \theta| > \epsilon) = \mathbb{P}(\min X_i > \theta + \epsilon)$$

Poiché il minimo è maggiore di una soglia solo se *tutti* i campioni lo sono (e sono indipendenti):

$$= \prod_{i=1}^n \mathbb{P}(X_i > \theta + \epsilon) = [\mathbb{P}(X_1 > \theta + \epsilon)]^n$$

Questa probabilità base è un numero strettamente minore di 1 (poiché è l'area della coda della distribuzione). Elevando una frazione < 1 alla potenza n per $n \rightarrow \infty$, il limite fa **zero**. Lo stimatore è **consistente**.




Figura 2: L'area rossa rappresenta $\mathbb{P}(X_1 > \theta + \epsilon)$. Essendo < 1 , elevata alla n tende a 0.

c) Correttezza dello stimatore

La Funzione di Ripartizione del minimo è $1 - (1 - F_X(x))^n$. Integrando la nostra densità, troviamo $F_X(x) = 1 - \frac{\theta}{x}$ per $x \geq \theta$. Quindi:

$$F_{\min X_i}(x) = 1 - \left(\frac{\theta}{x}\right)^n$$

La densità del minimo si ottiene derivando: $f_{\min X_i}(x) = n\theta^n x^{-n-1} \mathbb{1}_{(\theta, +\infty)}(x)$. Calcoliamo il valore atteso:

$$\mathbb{E}[\min X_i] = \int_{\theta}^{\infty} x \cdot n\theta^n x^{-n-1} dx = \frac{n}{n-1} \theta \neq \theta$$

Poiché il risultato ha un fattore di distorsione $\frac{n}{n-1}$, lo stimatore **non è corretto** (anche se, per n enorme, la frazione tende a 1, confermando la consistenza).

Esercizio 3: MLE per la Varianza della Normale

Sia $X \sim \mathcal{N}(m, \sigma^2)$ con la media m nota. Cerchiamo l'MLE per $\theta = \sigma^2 \in (0, +\infty)$. La funzione di verosimiglianza è:

$$L_{\theta}(x_1, \dots, x_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\theta}} \exp\left(-\frac{(x_i - m)^2}{2\theta}\right) = \frac{1}{(2\pi)^{n/2}} \frac{1}{\theta^{n/2}} \exp\left(-\frac{1}{2\theta} \sum_{i=1}^n (x_i - m)^2\right)$$

Passiamo alla log-verosimiglianza:

$$\log L_{\theta} = \log \frac{1}{(2\pi)^{n/2}} - \frac{n}{2} \log \theta - \frac{1}{2\theta} \sum_{i=1}^n (x_i - m)^2$$

Deriviamo rispetto a θ :

$$\frac{d}{d\theta} \log L_{\theta} = -\frac{n}{2\theta} + \frac{1}{2\theta^2} \sum_{i=1}^n (x_i - m)^2 \geq 0 \iff \theta \leq \frac{1}{n} \sum_{i=1}^n (x_i - m)^2$$

Il punto di massimo (MLE) è quindi $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n (X_i - m)^2$. Poiché $\hat{\theta}$ è esattamente la media campionaria della variabile aleatoria $(X_i - m)^2$, esso è uno stimatore **corretto e consistente** per $\mathbb{E}[(X_1 - m)^2] = \text{Var}(X) = \sigma^2$.

19 Intervalli di Fiducia

19.1 Scopo e Definizione

Il secondo scopo fondamentale della statistica inferenziale, dopo la stima puntuale, è fornire una stima intervallare. Sulla base dei dati estratti da un campione, vogliamo determinare una regione (un intervallo) entro la quale il parametro vero incognito θ si trovi con un'alta probabilità, definita a priori. Tale probabilità prende il nome di **fiducia**[cite: 5, 6, 8].

Definizione: Intervallo di Fiducia

Sia $(X_1, \dots, X_n)$ un campione i.i.d. dipendente da un parametro ignoto $\theta \in \Theta$. Dato un valore $\alpha \in (0, 1)$ piccolo (es. $\alpha = 0.05$), un **Intervallo di Fiducia (I.F.)** per θ di livello $1 - \alpha$ è un intervallo aleatorio del tipo:

$$I = [a(X_1, \dots, X_n), b(X_1, \dots, X_n)]$$

dove gli estremi sono due statistiche campionarie, tale che:

$$\mathbb{P}^\theta(\theta \in I) \geq 1 - \alpha \quad \forall \theta \in \Theta$$

[cite: 9-12]

[L'aleatorietà risiede nell'intervallo] È cruciale interpretare correttamente la notazione $\mathbb{P}(\theta \in I) \geq 1 - \alpha$. Il parametro θ **non è una variabile aleatoria**: esso è un numero fisso, seppur incognito[cite: 17]. Ciò che cambia al ripetersi dell'esperimento sono gli estremi dell'intervallo I , poiché dipendono dal campione estratto[cite: 16]. Pertanto, il livello di fiducia $1 - \alpha$ va interpretato in ottica frequentista: se estraessimo infiniti campioni e calcolassimo i rispettivi intervalli, almeno una proporzione pari a $(1 - \alpha)$ di essi "intrappolerebbe" il valore vero θ [cite: 18, 19].

Un intervallo di fiducia ideale possiede due caratteristiche in contrasto tra loro[cite: 30]:

1. Un livello di fiducia $1 - \alpha$ molto elevato (es. 95% o 99%).
2. Un'ampiezza dell'intervallo piccola (alta precisione).

Purtroppo, a parità di dati, per aumentare la certezza (livello) è necessario allargare l'intervallo[cite: 30]. L'unico modo per aumentare la precisione senza sacrificare la fiducia è aumentare la numerosità del campione n .

19.2 Caso 1: Media di popolazione Gaussiana con Varianza Nota

Supponiamo che la popolazione segua una distribuzione Normale $X \sim \mathcal{N}(m, \sigma^2)$, dove la varianza σ^2 è un parametro **noto**, mentre la media m è incognita[cite: 37].

Poiché $\bar{X}_n$ è lo stimatore naturale per la media, cerchiamo un intervallo simmetrico centrato su di esso:

$$I = [\bar{X}_n - d, \bar{X}_n + d]$$

dove d rappresenta la semiampiezza (o precisione della stima)[cite: 40, 41].

Derivazione matematica

Sappiamo dalla teoria (proprietà riproduttiva della Normale) che la distribuzione della media campionaria è $\bar{X}_n \sim \mathcal{N}(m, \frac{\sigma^2}{n})$ [cite: 44, 45]. Standardizzando, otteniamo una variabile pivotale (ovvero con distribuzione nota e indipendente dal parametro ignoto):


$$Z = \frac{\bar{X}_n - m}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

Vogliamo che $\mathbb{P}(m \in [\bar{X}_n \pm d]) = 1 - \alpha$. Questo equivale a richiedere che l'errore standardizzato cada nell'area centrale della campana:

$$\mathbb{P}\left(|Z| \leq \frac{\sqrt{n}}{\sigma}d\right) = 1 - \alpha$$

[cite: 42, 47, 49]

Per lasciare un'area pari ad α divisa equamente sulle due code (cioè $\alpha/2$ a sinistra e $\alpha/2$ a destra), il limite deve corrispondere al quantile $q_{1-\alpha/2}$ della Normale Standard [cite: 55].



Uguagliando l'argomento della probabilità al quantile:

$$\frac{\sqrt{n}}{\sigma}d = q_{1-\alpha/2} \implies d = \frac{\sigma}{\sqrt{n}}q_{1-\alpha/2}$$

[cite: 55]

Proprietà / Teorema: Intervallo di Fiducia per m

Sia $(X_1, \dots, X_n)$ un campione casuale estratto da $\mathcal{N}(m, \sigma^2)$ con $\sigma^2 > 0$ nota. L'Intervallo di Fiducia per la media m di livello $1 - \alpha$ è dato da:

$$I = \left[\bar{X}_n - \frac{\sigma}{\sqrt{n}}q_{1-\alpha/2}, \bar{X}_n + \frac{\sigma}{\sqrt{n}}q_{1-\alpha/2} \right]$$

[cite: 57, 58]

Osservando la formula della semiampiezza d , notiamo tre dipendenze fondamentali [cite: 81]:

- **Cresce** al crescere del livello di fiducia desiderato $1 - \alpha$ (poiché aumenta il quantile q) [cite: 82].

- **Cresce** al crescere della variabilità intrinseca del fenomeno σ^2 [cite: 84, 85].
- **Decresce** (con proporzionalità inversa alla radice) al crescere della numerosità campionaria n [cite: 86].

Esempio Pratico: Il peso dei Salmoni

Un biologo vuole stimare il peso medio m di una certa specie di salmoni. Si assume che il peso segua una distribuzione $\mathcal{N}(m, \sigma^2)$ con deviazione standard nota $\sigma = 0.4$ kg. Da un campione di $n = 10$ esemplari, si calcola un peso medio campionario $\bar{x}_{10} = 3.58$ kg[cite: 66, 67].

Quesito A: Calcolare l'I.F. al livello del 95%. [cite: 68] Poiché $1 - \alpha = 0.95$, si ha $\alpha = 0.05$ e $\alpha/2 = 0.025$. Il quantile da cercare nelle tavole della Normale Standard è $q_{0.975} = 1.96$ [cite: 71, 72, 73]. Sostituendo i valori:

$$I = \left[3.58 \pm \frac{0.4}{\sqrt{10}} \cdot 1.96 \right] = [3.58 \pm 0.248] = [3.332, 3.828]$$

[cite: 74, 75]

Quesito B (Dimensionamento): Quanti salmoni bisogna campionare affinché il margine di errore d non superi 0.1 kg, mantenendo il 95% di fiducia? [cite: 76-78] Dobbiamo risolvere la disuguaglianza rispetto a n :

$$d = \frac{\sigma}{\sqrt{n}} q_{1-\alpha/2} \leq 0.1 \implies \sqrt{n} \geq \frac{\sigma}{0.1} q_{1-\alpha/2}$$

Elevando al quadrato:

$$n \geq \left(\frac{0.4}{0.1} \cdot 1.96 \right)^2 = 61.46$$

[cite: 79] Poiché n deve essere un intero, il biologo dovrà pesare almeno $n = 62$ salmoni[cite: 80].

19.3 Caso 2: Media di popolazione Gaussiana con Varianza Non Nota

Nella pratica statistica, è rarissimo conoscere la vera varianza σ^2 della popolazione se non se ne conosce la media. Se abbiamo un campione i.i.d. $X_1, \dots, X_n \sim \mathcal{N}(m, \sigma^2)$ dove **entrambi** i parametri sono ignoti, non possiamo più utilizzare la variabile standardizzata $Z = \frac{\bar{X}_n - m}{\sigma/\sqrt{n}}$, perché σ ci è sconosciuta[cite: 92, 94, 95].

La soluzione "naturale" è sostituire il parametro ignoto σ^2 con il suo miglior stimatore campionario: la **varianza campionaria**[cite: 96, 99].

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \implies S_n = \sqrt{S_n^2}$$

[cite: 96, 98]

Inserendo S_n al posto di σ , otteniamo una nuova statistica:

$$T = \sqrt{n} \frac{\bar{X}_n - m}{S_n}$$

[cite: 100] Poiché S_n è una variabile aleatoria (cambia da campione a campione) e non una costante come σ , questa nuova statistica T introduce ulteriore incertezza. Pertanto, **non** si distribuisce più come una Normale Standard, ma segue una distribuzione più "larga" sulle code, chiamata **t di Student**[cite: 101, 102].


La Distribuzione t di Student

La distribuzione t_k di Student è parametrizzata da un valore intero k chiamato **gradi di libertà**. Nel nostro caso, per un campione di taglia n , i gradi di libertà sono $k = n - 1$ [cite: 103, 104].

[Caratteristiche della t-Student] La densità $f_k(x) = c_k \left(1 + \frac{x^2}{k}\right)^{-\frac{k+1}{2}}$ presenta le seguenti peculiarità[cite: 106]:

1. È simmetrica, pari e a forma di campana, proprio come la Normale[cite: 107].
2. Ha le **code più pesanti** rispetto alla Normale $\mathcal{N}(0, 1)$. Questo significa che i valori estremi sono più probabili[cite: 115]. Di conseguenza, i suoi quantili (indicati con τ) sono *maggiori* dei rispettivi quantili della Normale: $\tau_{1-\alpha/2, k} > q_{1-\alpha/2}$ per α vicino a 1 [cite: 116-118].
3. **Convergenza asintotica:** All'aumentare dei gradi di libertà $k \rightarrow \infty$, l'incertezza su S_n svanisce e la distribuzione t_k converge alla Normale Standard $\mathcal{N}(0, 1)$ (nel senso della convergenza delle densità)[cite: 120, 122].

[Regola Pratica per l'Esame] Il professore indica che per $k \geq 50$, l'approssimazione è talmente buona che è consentito utilizzare i quantili della Normale q al posto dei quantili τ della t-Student per semplificare i calcoli[cite: 124].



Costruzione dell'Intervallo

Sostituendo il quantile q della Normale con il quantile τ della t-Student e σ con S_n , otteniamo la formula definitiva per il caso realistico[cite: 125, 126]:

Proprietà / Teorema: Intervallo di Fiducia per m

Sia $(X_1, \dots, X_n)$ un campione casuale estratto da $\mathcal{N}(m, \sigma^2)$ con varianza ignota[cite: 127]. L'Intervallo di Fiducia per la media m di livello $1 - \alpha$ è:

$$I = \left[\bar{X}_n - \frac{S_n}{\sqrt{n}} \tau_{1-\alpha/2, n-1}, \bar{X}_n + \frac{S_n}{\sqrt{n}} \tau_{1-\alpha/2, n-1} \right]$$

[cite: 129]

Esempio Pratico: Il peso dei Salmoni (Varianza ignota)

Riprendiamo l'esempio dei salmoni ($n = 10$ esemplari misurati). Questa volta, il biologo **non conosce** la varianza della popolazione, ma la calcola direttamente dai 10 salmoni estratti, trovando una deviazione standard campionaria $s_{10} = 0.4$ kg e una media $\bar{x}_{10} = 3.58$ kg [cite: 130-132].

Vogliamo calcolare l'I.F. di livello 95% [cite: 133].

1. I gradi di libertà sono $k = n - 1 = 10 - 1 = 9$.
2. Il livello di fiducia richiede un'area centrale del 95%, quindi $\alpha/2 = 0.025$.
3. Sulle tavole della t-Student, cerchiamo il quantile $\tau_{0.975, 9}$. Troviamo il valore 2.26 [cite: 134].

Calcoliamo l'intervallo [cite: 134, 135]:

$$I = \left[3.58 \pm \frac{0.4}{\sqrt{10}} \cdot 2.26 \right] = [3.58 \pm 0.286] = [3.294, 3.866]$$

19.4 Caso 3: Grandi Campioni (Teorema del Limite Centrale)

Quando la dimensione del campione è sufficientemente elevata ($n \geq 50$), non è più necessario richiedere che la popolazione sia distribuita normalmente [cite: 142, 143]. Grazie al **Teorema del Limite Centrale (TCL)**, la statistica pivotale converge alla Normale Standard indipendentemente dalla legge di X [cite: 145-147].

Proprietà / Teorema: I.F. per Grandi Campioni

Per n sufficientemente grande, un intervallo di fiducia approssimato di livello $1 - \alpha$ per la media m è dato da:

- Se σ^2 è nota: $I \approx [\bar{X}_n \pm \frac{\sigma}{\sqrt{n}} q_{1-\alpha/2}]$ [cite: 152, 153].
- Se σ^2 è incognita: $I \approx [\bar{X}_n \pm \frac{S_n}{\sqrt{n}} q_{1-\alpha/2}]$ [cite: 156, 158].

In questo caso, si utilizza il quantile q della Normale anche se la varianza è stimata, poiché per grandi n l'approssimazione è giustificata [cite: 158].

[Qualità dell'approssimazione] L'approssimazione fornita dal TCL è tanto più affidabile quanto più il livello di fiducia $1 - \alpha$ è lontano da 1. Per valori vicini a 1, l'approssimazione funziona peggio [cite: 159, 160].

19.5 Caso 4: Intervalli di Fiducia per una Proporzione

Un caso di fondamentale importanza riguarda la stima della probabilità $p = \mathbb{P}(A)$ di un evento A . In questo contesto, le variabili X_i seguono una legge di Bernoulli, dove $X = 1$ se si verifica l'evento A , $X = 0$ altrimenti [cite: 166-168]. Sappiamo che:

- Il valore atteso è $\mathbb{E}[X] = p$ [cite: 173].
- La varianza è $Var(X) = p(1 - p)$ [cite: 176].
- Lo stimatore di p è la frequenza relativa campionaria $\bar{X}_n$ [cite: 170].

Proprietà / Teorema: I.F. per la Proporzione - Grandi Campioni

Sotto la condizione di applicabilità del TCL (solitamente verificata se $n\bar{X}_n(1 - \bar{X}_n) \geq 10$) [cite: 175], l'I.F. di livello approssimato $1 - \alpha$ per p è [cite: 181]:

$$I \approx \left[\bar{X}_n - \sqrt{\frac{\bar{X}_n(1 - \bar{X}_n)}{n}} q_{1-\alpha/2}, \bar{X}_n + \sqrt{\frac{\bar{X}_n(1 - \bar{X}_n)}{n}} q_{1-\alpha/2} \right]$$

[Indipendenza dalla Popolazione] Le stime non dipendono dalla taglia della popolazione [cite: 225].

Dimensionamento del campione per i sondaggi

Per garantire che la semiampiezza d (il margine di errore) sia inferiore a una soglia prestabilita ϵ (es. $d \leq 0.01$) [cite: 200, 201]:

$$d = \sqrt{\frac{\bar{X}_n(1 - \bar{X}_n)}{n}} q_{1-\alpha/2} \leq \epsilon$$

Poiché $\bar{X}_n$ non è noto a priori [cite: 202], si procede in due modi [cite: 203, 216]:

1. **1^a Soluzione (Conservativa):** Si sfrutta il fatto che il massimo di $x(1 - x)$ per $x \in [0, 1]$ è $1/4$ [cite: 208, 209]. Imponendo il caso peggiore, si ottiene:

$$\frac{1}{2\sqrt{n}} q_{1-\alpha/2} \leq \epsilon \implies n \geq \left(\frac{q_{1-\alpha/2}}{2\epsilon} \right)^2$$

[cite: 210-213] A posteriori, si verificherà che $n\bar{X}_n(1 - \bar{X}_n) \geq 10$ [cite: 214, 215].

2. **2^a Soluzione (Con info pregresse):** Se disponiamo di una stima preliminare che confina X_n in un range (es. $[0.37, 0.63]$), stimiamo il massimo di $x(1 - x)$ in quel range e imponiamo la disuguaglianza [cite: 216].

Esempio: Sondaggio d'opinione

In un sondaggio su 1000 intervistati, 400 dichiarano di voler votare per il partito A ($\bar{x}_n = 0.4$) [cite: 185, 186, 193]. Calcoliamo l'I.F. al 95%. Essendo $n\bar{x}_n(1 - \bar{x}_n) = 1000 \cdot 0.4 \cdot 0.6 = 240 \geq 10$ [cite: 197], usiamo il TCL:

$$I = \left[0.4 \pm \sqrt{\frac{0.4 \cdot 0.6}{1000}} \cdot 1.96 \right] = [0.4 \pm 0.03] = [37\%, 43\%]$$

[cite: 198, 199, 204, 205] Se il margine di errore desiderato fosse stato dell'1% ($d \leq 0.01$), avremmo avuto bisogno di un campione conservativo di [cite: 212, 213]:

$$n \geq \left(\frac{1.96}{2 \cdot 0.01} \right)^2 = 9604 \text{ persone}$$

19.6 Esercizi Riassuntivi e Applicazioni

Esercizio 7.1: Misura del pH (Varianza Nota)

Sia X la misura del pH di una soluzione, con $X \sim \mathcal{N}(m, 0.1^2)$. Effettuiamo $n = 50$ misurazioni ottenendo una media $\bar{x}_{50} = 8.19$ [cite: 231-233].

1. **Calcolo dell'I.F. al 95%** [cite: 234]: Essendo la varianza nota, usiamo il quantile della Normale $q_{0.975} = 1.96$ [cite: 235, 236].

$$I = \left[8.19 \pm \frac{0.1}{\sqrt{50}} \cdot 1.96 \right] = [8.19 \pm 0.0277]$$

[cite: 236-238]

2. **Dimensionamento** [cite: 239]: Per avere un margine di errore $d \leq 0.01$, calcoliamo [cite: 243, 244]:

$$n = \left(\frac{\sigma}{d} q_{1-\alpha/2} \right)^2 = \left(\frac{0.1}{0.01} \cdot 1.96 \right)^2 = 384.16 \implies n = 385$$

[cite: 245]

Esercizio 7.2: Errori di un Server (Proporzione)

Un server commette 50 errori su 1000 richieste ($\bar{x}_{1000} = 0.05$) [cite: 247, 248, 252].

1. **Calcolo dell'I.F. al 95%** [cite: 249]: Prima verifichiamo la condizione del TCL: $n\bar{x}_n(1 - \bar{x}_n) = 1000 \cdot 0.05 \cdot 0.95 = 47.5 \geq 10$ [cite: 254, 256].

$$I = \left[0.05 \pm \sqrt{\frac{0.05 \cdot 0.95}{1000}} \cdot 1.96 \right] = [0.05 \pm 0.0135]$$


[cite: 257]

2. **Dimensionamento per errore $d \leq 0.003$** [cite: 258, 259]:

- **I Modo (Conservativo):** Massimizzando $x(1-x)$ a $1/4$, si ottiene $\frac{1}{2\sqrt{n}} 1.96 \leq 0.003 \implies n \geq 106711$ [cite: 260-263].
- **II Modo (Con Info Preliminari):** Sappiamo che $x \in [0.05 \pm 0.0135] = [0.0365, 0.0635]$. Il valore che massimizza $x(1-x)$ in questo range è l'estremo superiore, ovvero $x = 0.0635$. Calcoliamo $\max = 0.0635 \cdot (1 - 0.0635) = 0.0595$ [cite: 266-270]. Imponendo $\frac{\sqrt{0.0595}}{\sqrt{n}} 1.96 \leq 0.003$, otteniamo $n \geq 25397$. Un notevole risparmio campionario [cite: 268, 271]!

Esercizio 7.8: Sondaggio Elettorale A vs B

Un sondaggio assegna il 53% al candidato A e il 47% al candidato B, con un margine di errore del 0.04 al livello del 95% [cite: 280-284]. Possiamo affermare con fiducia che A sarà eletto[cite: 285]? **Risposta:** Falso[cite: 286]. L'intervallo di fiducia per A è $[0.53 - 0.04, 0.53 + 0.04] = [0.49, 0.57]$ [cite: 287-290]. Poiché l'intervallo contiene valori < 0.50 , esiste la probabilità che A perda. Lo si evince chiaramente dal grafico delle sovrapposizioni:



Esercizio 7.5: Temperature Medie a Milano (t-Student)

Si considerano le temperature medie di $n = 6$ anni. Si rileva una media campionaria $\bar{x}_6 = 20.83$ e una deviazione standard campionaria $s_6 = 1.35$ [cite: 298-300]. La varianza della popolazione non è nota[cite: 302, 306].

1. **Calcolo dell'I.F. al 95%**[cite: 303, 304]: Usiamo la t-Student con $k = 6 - 1 = 5$ gradi di libertà. Il quantile è $\tau_{0.975,5} = 2.5706$ [cite: 308].

$$I = \left[20.83 \pm \frac{1.35}{\sqrt{6}} \cdot 2.5706 \right] = [20.83 \pm 1.42]$$

[cite: 309-314]

2. **Dimensionamento complesso (con t-Student)**: Trovare n affinché la semiampiezza sia ≤ 1 [cite: 315]. Imponiamo $\frac{s_n}{\sqrt{n}} \tau_{1-\alpha/2, n-1} \leq 1$ [cite: 316]. Questo calcolo è circolare poiché τ dipende da n . Stimiamo $\tau_{1-\alpha/2, n-1}$ con $\tau_{1-\alpha/2, 5}$ poiché la funzione è decrescente in n [cite: 320, 321]. Risolviamo:

$$\frac{1.35}{\sqrt{n}} \cdot 2.5706 \leq 1 \implies \sqrt{n} \geq 1.35 \cdot 2.5706 = 3.47 \implies n \geq 12.04$$

Dunque $n \geq 13$ [cite: 322].